AI 시대의 경쟁력과 지식 융합

- 2026년 한국공학대학교 교양교과 교재-

2026년 1월 20일

교양교육센터

송경모

<제목 차례>

1. AI 현상 개요 I ····· 1

가. 비즈니스 ····· 1

나. 사회 ····· 17

다. 학문과 예술 ····· 24

2. AI 현상 개요 II ····· 34

가. 공급 형태의 분류 ····· 34

나. 오남용과 위험성 개관 ····· 47

3. AI의 역사I: 태동부터 딥러닝까지 ····· 59

가. 태동 ····· 59

나. 전문가 시스템의 보급 ····· 64

다. 공장 자동화와 로봇 ····· 67

라. 기계학습 machine learning ····· 69

마. 딥러닝 혁명 ····· 81

4. AI의 역사 II: LLM의 등장 ····· 94

가. Transformer ····· 94

나. GPT 와 BERT ····· 107

다. chatGPT 이후 ····· 110

5. AI의 역사 III: LLM 이후 ····· 115

가. 영상과 음성 AI ····· 115

나. 효과적인 프롬프트의 원리 ····· 125

다. 학습 데이터의 성격 ····· 128

6. AI 생태계의 현재와 미래 I ····· 134

가. 문서 요약과 번역의 원리 ····· 134

나. 추론과 기억의 원리 ····· 139
다. Agentic AI의 확대 ····· 149
7. AI 생태계의 현재와 미래 II ····· 157
가. 바이브 코딩(Vibe Coding) ····· 157
나. 하드웨어와 전력 문제 ····· 174
다. 인공지능의 미래에 대한 전문가 견해 ····· 178
8. AI와 사회경제의 변화 ····· 181
가. 분업 구조의 변화 ····· 181
나. 노동의 대체가 이루어지는 방향 ····· 182
다. 자본·노동 이분법의 붕괴 ····· 183
라. 학벌 중심 사회의 쇠퇴 가능성 ····· 184
마. 조직의 소규모, 개인화 ····· 185
바. 성문법과 제도에서 모델과 코드로 ····· 187
사. 전반적 IT 운영비용의 하락 ····· 188
아. AI 전환(AX)의 효과와 한계 ····· 191
자. AI 창업 ····· 193
9. AI 시대의 법과 제도 ····· 208
가. 지식재산권 제도 ····· 208
나. 사생활과 개인정보 보호 ····· 211
다. 고위험 영역의 AI 규제 ····· 213
라. 자율 시스템 시대의 법적 책임 구조 ····· 217
마. 규제 대상이 아니라 규범 내장 AI 시스템으로 ····· 219
바. AI 시대에 법의 존재 이유 ····· 220
사. 전체주의와 민주주의 ····· 221
10. AI 시대의 Liberal Arts 지식 ····· 225

가. 개요 ····· 225
나. 리버럴 아트의 의미 ····· 227
다. 지식 노동의 성격 변화 ····· 229
라. 사람 지식 대 기계 지식 ····· 231
마. 사람 지식의 생동성 ····· 233
11. AI와 철학적 성찰 ····· 236
가. 지능의 개념 ····· 236
나. 기능주의 심리학의 한계 ····· 238
다. 중국어 방 논증과 기계의 이해력 ····· 240
라. 마음은 어디에 있는가 ····· 242
마. 의식과 주관적 경험: AI는 '느낌'을 가질 수 있는가 ····· 244
바. AI의 창의성과 인간의 창의성 ····· 246
사. 인간의 능력 증강과 자기 성찰 ····· 248
아. 지능과 지식의 과도한 민주화의 함정 ····· 251

<표 차례>

표 1 AI를 이용한 연구 논문 작성의 생산성 향상 사례 ····· 26
표 2 AI를 이용한 논문 작성 작업 흐름 예시. ····· 27
표 3 연구 논문 작성용 다양한 AI 서비스 ····· 28
표 4 수량 분석 연구 특화된 AI 도구들 ····· 29
표 5 chatGPT 대규모 모델 개발 소요자원 추정 ····· 41
표 6 구글 대규모 모델 개발 소요자원 추정 ····· 42
표 7 소규모 언어 모델(SLM)의 대표적인 예시 ····· 43
표 8 멀티 에이전트 서비스 예시 ····· 45
표 9 XOR 문제 ····· 62
표 10 나쁜 프롬프트와 좋은 프롬프트 예시 ····· 128

표 11 일반 요약과 추론 기반 요약의 비교 ····· 135
표 12 일반 트랜스포머 모델과 추론 모델의 특성 비교 ····· 140
표 13 주요 빅테크 기업의 데이터 센터 현황 ····· 176
표 14 2000년대 이후 IT 운영 비용 구조 변화 ····· 189

<그림 차례>

그림 1 AI 수학문제 풀이용 예제 ····· 25
그림 2 모델 붕괴: 숫자 이미지의 예 ····· 53
그림 3 Symbolic AI의 사물 분류 개념 ····· 60
그림 4 로젠블랫의 단층 Perceptron 구조 ····· 61
그림 5 회귀분석의 입력값 배열 --> 출력값 개념 ····· 70
그림 6 로지스틱 회귀분석의 입력값 배열 --> 출력 개념 ····· 71
그림 7 지도학습을 위한 사전 데이터 라벨링 ····· 73
그림 8 SVM 의 데이터 분류 개념 ····· 74
그림 9 KNN의 데이터 분류 개념 ····· 74
그림 10 의사결정나무의 분류 개념 ····· 75
그림 11 인공신경망 모델의 분류 개념 ····· 76
그림 12 과적합 모델의 개념 ····· 79
그림 13 머신 러닝 방법론별 장단점 ····· 80
그림 14 CNN이 인식하는 대상 이미지 ····· 82
그림 15 CNN은 그림이 아니라 숫자의 행렬을 읽는다 ····· 82
그림 16 Convolutional kernel 적용하여 다음 layer에 전달 ····· 83
그림 17 Convolution 커널의 종류 예시 ····· 84
그림 18 Convolution 필터 적용 후 생성된 흐릿한 이미지 단계 ····· 84
그림 19 CNN의 구조도 ····· 85
그림 20 바둑돌의 배치 형상을 입력값으로 표현하는 방식 ····· 87

그림 21 AlphaGO MTCS 의 개념 ····· 89
그림 22 Demis Hassabis ····· 91
그림 23 AlphaFold의 단백질 3D구조 예측 흐름도 ····· 93
그림 24 단어를 공간 상의 한 좌표로 표현하는 방법 ····· 99
그림 25 텍스트 "검은 고양이가 소파에 앉아있다"로부터 이미지 생성 주요 단계 예시 ·· 120
그림 26 바이브 코딩의 코페르니쿠스적 전환 ····· 158
그림 27 Sam Altman과 Ilya Sutskever, 2023. ····· 179
그림 28 Fei Fei Li 와 Geoffrey Hinton 2023 ····· 180
그림 29 2000년대 이후 IT 운영 비용의 하락 추세 ····· 190
그림 30 중국어 방 논증과 LLM ····· 241

1. AI 현상 개요 I

AI는 비단 최근의 일이 아니다. 대중들은 2022년 11월 OpenAI가 chatGPT를 공개한 이후 AI의 위력을 비로소 체험하기 시작했지만, AI는 이미 20세기 내내 산업 곳곳에, 그리고 사람의 삶과 사회 곳곳에서 자리를 잡아오고 있었다. 지난 100여년간 비단 AI라는 이름으로 불리지는 않았어도, 공장 및 사무 자동화, 자동제어, 로보틱스, OCR, 기계학습(Machine Learning), 빅데이터(Big Data) 등 여러 이름 아래 이미 다양한 AI 기술들이 적용되어 왔다.

최근의 대형 언어 모델(LLM: Large Language Model), 특히 그 중에서도 chatGPT의 등장은 그 기나긴 개발의 여정에서, 전례 없는 기술적 도약을 일으킨 혁명적 사건이었다.

과거의 인공지능은 전문가 시스템(Expert System)이거나 분류형(discriminative) AI 중심으로 응용되어 왔지만, chatGPT 이래 생성형(generative) AI의 성능이 획기적으로 향상됨으로써 사회 곳곳에 인공지능의 폭발전 확산이 촉발될 수 있었다. 아래에 소개하는 여러 사례들은 그렇게 오랜 세월에 걸친 개발의 성과들이었다.

아래 제시하는 AI 응용 현황은 지금 시중에서 활용되는 AI 서비스 중 지극히 일부의 것이지만, 이들 현황만 살펴보아도 우리의 모든 삶에 AI가 얼마나 깊숙이 침투해 있는지 확인할 수 있다.

가. 비즈니스

1) 자율주행

자율주행은 이미 1920년대에 미국에서 무선 통제 기능이 시도되었을 정도로 역사가 깊다. 하지만, 당시에는 AI 개념이 없었다. 더구나 디지털 컴퓨터 개념 자체가 등장하기 전이었다. 20세기에 지속적으로 무선 정보통신 기술에 의거한 자율주행 개념이 발전을 거듭해왔지만, 부분적인 성능 구현에만 머물렀다.

21세기에 들어서는, 2004년에 DARPA 그랜드 챌린지 (DARPA Grand Challenges)는 100만 달러의 상금을 걸고 첫 번째 무인 자동차 사막 횡단 대회를 개최했다. 참가 차량 중 완주에 성공한 차량은 없었지만, 이 대회를 통해 자율주행 분야에 대한 관심이 크게 높아졌다. 2005년 두 번째 챌린지에서는 스탠퍼드 대학교 팀의 폭스바겐 투아렉(Volkswagen Touareg) 차량 '스탠리(Stanley)'를 포함해 5대의 차량이 132마일(약 212km)의 사막 코스를 완주하는 데 성공했다.

2009년, 구글(Google)이 자체 자율주행차 프로젝트(현 Waymo)를 시작하며 민간 분야의 대규모 투자가 이루어졌다. 2010년대 중반부터 BMW, 포드, 메르세데스-벤

츠 등 여러 자동차 제조사들이 자율주행차 테스트에 착수했다. 테슬라(Tesla)는 2015년에 '오토파일럿(Autopilot)'이라는 첨단 운전자 보조 시스템(ADAS)을 도입하여, 자율주행 기능을 일반 소비자들에게 선보였다. 이는 레벨 2 수준의 반자율 주행 기술이었지만 큰 관심을 불러일으켰다.

이제는 단순히 주행기능만이 아니라, 자동차 자체가 하나의 전자 제품으로서 운전자에게 AI를 이용한 정보 관리와 오락 기능을 제공하고 있다. Mercedes MBUX는 운전자의 특성을 부분석하여 음성 비서, 예측 정비 시스템, 차량 보험 및 정비 예약 자동화. 그리고 운전 스타일에 맞춰 음악을 자동으로 생성해주는 기능까지 갖추고 있다.

2) 유통

■전자상거래

1994년, 당시 닷컴 열풍 속에서 창업한 아마존 Amazon.com 은 설립 이래 인공지능의 도입에 다른 어떤 기업보다도 선구적이었다.

[1990년대 후반: 개인화된 추천 시스템 도입]

아마존은 1990년대 후반부터 고객의 과거 구매 행동과 검색 패턴을 분석하여 선호도를 예측하는 머신러닝(machine learning) 기반의 협업 필터링 추천 엔진을 도입했다. 이 기술은 고객에게 맞춤형 상품을 제안함으로써 쇼핑의 편의성을 개선했을 뿐만 아니라 실제 매출 증대에도 큰 역할을 수행했다.

[2000년대 ~ 2010년대: 운영 전반 및 클라우드 서비스 확장]

2006년에는 내부 IT 인프라 관리의 문제를 해결하기 위해 아마존 웹 서비스(AWS)를 출시했다. AWS는 개발자들이 AI 기술에 쉽게 접근할 수 있는 환경을 제공하며 AI 기술의 대중화에 기여했다. 물류 분야에서는 AI 알고리즘을 재고 관리와 배송 경로 최적화에 활용하여 운영 효율성을 극대화했다. 특히 2010년대에는 물류센터에 수십만 대의 로봇을 배치하여 재고 정리와 포장 작업을 자동화했다. 또한 2014년에는 음성 인식 AI 비서인 '알렉사'와 '에코'를 출시하며 딥러닝과 자연어 처리 기술을 스마트 홈 분야에 성공적으로 안착시켰다.

[2020년대 ~ 2025년: 생성형 AI 및 첨단 기술 도입]

최근 아마존은 생성형 AI를 활용하여 고객과 판매자 경험을 혁신하고 있다. 2023년에는 상품평 요약 서비스를 시작했으며, 2024년에는 대화형 쇼핑 어시스턴트인 '루퍼스'를 선보였다. 판매자를 위해서는 최소한의 정보로 상세 페이지를 작성해 주는 AI 도구를 지원한다. 의료 분야에서는 'AWS HealthScribe'를 통해 진료 대화를 기록으로 변환하는 서비스를 제공 중이다. 아울러 자율 주행 드론 배송 시스템인 '프라임 에어'에 딥러닝을 적용하고, '포장 결정 엔진' 모델을 통해 포장재 폐기물을 줄이는 등 지속 가능성 측면에서도 AI 기술을 적극적으로 활용하고 있다.

■IKEA

IKEA는 초기에 증강현실(AR) 앱 IKEA Place를 활용하여, 스마트폰 카메라를 통해 실제 공간에 가구를 가상으로 배치할 수 있도록 했다. 실제 크기로 3D 모델링된 가구를 98%의 정확도로 표현하여, 소파나 책장 같은 제품이 내 거실이나 침실에 실제로 놓였을 때의 모습을 확인할 수 있다.

이 기능은 AI를 응용한 IKEA Kreativ로 더 발전되어 기존 가구를 AI가 자동으로 제거하고 새로운 IKEA 제품으로 교체해 볼 수 있는 기능을 갖추게 됐다. 공간 전체를 3D 스캔하여 다양한 인테리어 옵션을 시뮬레이션할 수 있으며, 여러 디자인 조합을 저장하고 비교할 수 있다. 또한 고객의 취향, 공간 크기, 예산 등을 분석하여 맞춤형 가구 조합을 제안한다. 머신러닝 알고리즘이 과거 구매 패턴과 인기 트렌드를 학습하여 개인화된 인테리어 솔루션을 제공한다.

3) 홈 자동화

■ 가정 생활 Home Computing

삼성의 Bespoke AI 기능이 탑재된 세탁기는 인공지능 센싱 기술을 통해 세탁의 전 과정을 자동화하고 효율성을 향상시키고 있다.

내부 센서가 세탁물의 무게, 재질, 오염도를 실시간으로 감지한다. 이를 바탕으로 물의 양, 세제 투입량, 세탁 및 헹굼 시간을 최적화하여 옷감 손상을 줄이고 세척력을 높임으로써 AI 맞춤 세탁을 가능하게 한다.

AI 에코버블 기능은 세제를 미세한 거품으로 만들어 찬물에서도 빠르게 침투시킨다. 일반 세탁 대비 에너지 사용량을 절감하면서도 찌든 때를 효과적으로 제거한다.

AI 버블워시 & 진동 저감(VRT+) 기능은 진동 센서와 AI 알고리즘이 탈수 시 불균형을 감지하고 회전 속도를 조절하여 소음을 최소화한다.

심지어 화장실 변기도 AI를 도입하고 있다. 듀크 대학교 연구팀과 Throne 같은 기업은 변기 내부에 카메라와 AI 알고리즘을 탑재해서, AI가 배설물의 모양과 색상을 분석하고 혈액 유무를 감지하여 장염, 대장암, 과민성 대장 증후군(IBS) 등의 초기 진단을 돕는다.

TOTO와 옐로시스(Yellosis) 등 변기 회사들은 소변 내 포도당, 단백뇨, 나트륨 농도를 측정하는 센서를 도입했고, AI가 이 데이터를 분석해서 당뇨병이나 신장 질환 여부를 모니터링하며, 개인별 맞춤형 식단이나 건강 관리 조언을 앱으로 전송하도록 하고 있다.

4) 기존 SW의 성능 향상

Microsoft의 오피스 제품인 Word, Excel, PowerPoint 등에서 Copilot 기능이 내장되어 텍스트 작성, 데이터 분석 지원 등, 기존에 수작업으로 번거롭게 행하하던 것들을 프롬프트 명령으로 실행할 수 있도록 했다.

예들 들어서, 과거에는 5개의 서로 다른 Excel 보고서, 이메일, PDF 자료에서 정보를 찾아 하나의 제안서를 만들려면 각 문서를 일일이 열어보고 복사-붙여넣기를 반복해야 했지만, Copilot은 프롬프트로 "지난 분기 매출 보고서, 고객 피드백 문서, 경쟁사 분석 자료를 참고해서 신제품 제안서 초안을 작성해줘"라고 지시하면 여러 문서의 내용을 자동으로 참조하여 통합 문서를 생성한다.

한국의 대표 오피스 SW인 훈글 hwp는 한글 2024년 이후 AI 기반 문서 작성 보조 기능을 탑재했으며, '한컴어시스턴트'라는 이름의 생성형 AI 도구를 제공하고 있다. 문서 요약, 초안 자동 생성, 문맥 기반 이어 쓰기, 문장 교정, 이미지 생성 및 삽입 기능, AI 요약 기능, 음성 입력 기능, 동시 편집 기능 등이다. 그러나, hwp는 자체 모델 개발에 아직 한계가 있고 외부 모델을 사용하고 있는 상황이며, 방대한 학습 데이터에 기반을 둔 자체 모델을 지니고 있는 MS Word의 Copilot이나 Google Docs의 Gemini와 비교했을 때 기능 범위와 성숙도 면에서 아직은 상당한 격차가 있다고 평가된다.

특히 바이너리 포맷의 기존 hwp 문서는 여타 AI 모델에서 학습 및 추론용 텍스트와 데이터를 추출하기 어려워 AI에 직접 응용하기에는 많은 제약이 있다. 새로 도입된 hwpx는 xml 형식에 바탕을 두고 있으나 그 효과는 시간을 두고 좀 더 지켜보아야 한다고 보인다.

그 외에도 기존에 국내외에서 시장을 주도하던 수많은 영역의 SW들이 대부분 AI 기능을 탑재하여 편의성을 극대화하고 있다. 역시 Microsoft의 Excel을 예로 들자면, 과거에는 VLOOKUP, INDEX-MATCH, IF 중첩 함수 등을 조합한 복잡한 수식을 작성하려면 함수 문법을 정확히 알아야 했고, 오류를 찾아 수정하는 데 상당한 시간이 걸렸다. 지금은 Copilot에게 "A열의 제품명과 B열의 월별 판매량을 기준으로, C열에는 전월 대비 증감률을 계산하되 첫 달은 '신규'로 표시해줘"라고 자연어로 요청하면 자동으로 적절한 수식을 생성하고 전체 열에 적용해준다.

COVID19 사태 이후 전세계적으로 사용량이 폭증한 화상회의 플랫폼 Zoom은, 2023년 이후 AI 기능을 본격적으로 채택하기 시작했다. Zoom AI Companion(이전 Zoom IQ)은, 전체 회의 내용을 요약하고 논의된 'Next Step(후속 작업)'을 리스트로 자동 추출하는 것은 물론이고, 늦게 참석한 사람을 위해 "지금까지 무슨 이야기가 나왔어?"와 같은 질문에 실시간 답변을 제공한다. 최근에는 지라(Jira), 아사나

(Asana), 서비스나우(ServiceNow) 등 16개 이상의 외부 비즈니스 앱과 연동되어 줌 환경 내에서 대화 중에 직접 티켓 처리나 프로젝트 관리를 실행할 수 있도록 하고 있다. 대한항공은 클라우드 기반의 줌폰(Zoom Phone)과 AI 기능을 도입하여 전 세계 250개 지점의 복잡한 통신 시스템을 중앙 집중식으로 관리하고 운영 효율성을 대폭 높이기도 했다.

유서 깊은 건축 또는 기계 설계 전문 SW인 AutoCAD에서, 과거에는 건축 평면도에서 책상 옆에 의자를 배치할 때, 각 의자마다 정확한 위치, 회전 각도, 간격을 수동으로 조정해야 했다. 100개의 책상이 있다면 100번의 개별 배치 작업이 필요했다.

그러나, 최근에 도입된 AI 기능을 이용하면, 블록을 삽입할 때 이전에 배치한 블록과 유사한 방식으로 배치할 수 있는데, 예를 들어 책상 근처에 의자 블록을 배치했다면, 다른 의자를 삽입할 때 AutoCAD가 다른 책상에 가까이 가면 자동으로 같은 위치에 배치해준다. 블록을 이동하면 책상이 하이라이트되고, 이전 블록의 위치, 회전, 스케일에 맞춰 자동으로 조정된다.

IBM은 IBM QRadar SIEM (Security Information and Event Management), ATOM (Autonomous Threat Operations Machine), PTI Agent (Proactive Threat Intelligence Agent), IBM Guardium AI Security, IBM Trusteer, IBM Verify 등 자사의 보안 패키지에 AI기능을 이미 오래전부터 계속 포함시켜왔으며, 그들은 다음과 같은 공통된 원리로 작동하는데, 이들은 주로 과거 머신러닝의 분류형 AI와 전문가 시스템 AI에 기반을 둔 것이다.

- 데이터 수집 및 통합: 네트워크 트래픽, 로그 파일, 사용자 행동, 엔드포인트 데이터 등 다양한 소스에서 데이터를 수집한다.
- 머신러닝 기반 패턴 분석: 정상적인 행동 패턴을 학습하고, 이를 기준으로 이상 징후를 탐지한다.
- 상관관계 분석: 서로 다른 소스의 이벤트들을 연결하여 복합적인 공격 패턴을 식별한다.
- 위험 점수 부여: AI가 각 경고의 심각도를 자동으로 평가하여 우선순위를 지정한다.
- 자동화된 대응: 특정 위협에 대해 사전 정의된 대응 절차를 자동으로 실행한다.
- 지속적 학습: 새로운 위협 데이터를 지속적으로 학습하여 탐지 정확도를 향상시킨다.

2024년 이후 패키지에는 생성형 AI 기능이 추가되어, 자연어로 질의하고 보고서

를 생성하는 기능을 강화하기 시작했다.

5) 교육

듀오링고(Duolingo)는 AI 기능에 기반을 둔 다음과 같은 혁신으로 외국어 교육과 학습의 패러다임을 바꾸고 있다.

- 게이미피케이션으로 학습을 재미있게 만들었다
- 완전 무료 모델로, 빈곤층이나 소외층의 교육 접근성을 민주화했다
- GPT-4 생성형 AI로 개인 튜터 경험을 대규모로 제공한다
- AI 콘텐츠 생성으로 개발 속도를 10배 이상 가속화했다
- 마이크로러닝으로 바쁜 현대인도 학습 가능하게 했다
- 개인화된 적응형 학습으로 각자의 수준에 맞는 교육을 제공한다
- 온라인 공인 시험으로 자격증 취득의 장벽을 낮췄다

이러한 혁신들은 "언어 학습은 비싸고, 어렵고, 시간이 많이 걸린다"는 기존 통념을 완전히 뒤집고 있다.

구글 리서치 팀이 2025년 발표한 “Towards an AI-Augmented Textbook” 연구는 정적인 PDF 교과서를 생성형 AI를 통해 역동적이고 개인화된 학습 도구로 변환하는 시스템인 ‘당신의 방식으로 배워라(Learn Your Way)’에 관한 것이다. 이 연구는 기존의 ‘일률적인(One-size-fits-all)’ 교과서 중심 교육에서 벗어나, 학습자 개개인의 특성에 맞춰 지식이 재구성되는 새로운 교육 패러다임을 제시한다. 주요 내용과 혁신적인 영향은 다음과 같다.

이 시스템은 원본 교과서의 신뢰성을 유지하면서도 AI 레이어를 추가하여 콘텐츠를 다각화했는데, 가장 두드러진 향상은 바로 텍스트의 개인화 (Text Personalization)다. 즉 학생의 독해 수준(예: Flesch-Kincaid 지수)에 맞춰 텍스트 난이도를 실시간으로 조정하고, 관심사 기반으로 콘텐츠를 재구성한다. 예를 들어 학생이 스포츠를 좋아하면 뉴턴의 법칙을 농구공의 움직임으로 설명하고, 미술을 좋아하면 붓의 압력으로 설명하는 등 개인의 흥미에 맞춘 예시를 생성한다. 또한 문서 중간중간 AI가 퀴즈를 생성하여 삽입하며, 학생의 답변에 따라 부족한 부분을 보완할 수 있는 추가 설명을 제공한다.

이 연구는 단순히 기술적 진보를 넘어 교육의 근본적인 방식을 변화시키고 있다.

학습자로 하여금 수동적 독서에서 능동적 참여로 전환할 수 있도록 한다.

읽기 능력이 부족하거나 배경지식이 다른 학생들도 자신만의 난이도와 예시로 학습할 수 있어 교육의 평등권을 강화한다.

교사의 역할도 크게 달라지는데, 교사는 기존에 개별 학생을 위한 맞춤형 자료를

만드는 데 방대한 시간이 소모되므로 불가능했던 것을 AI가 대체함으로써 가능하게 됐다. 이로 인해 교사는 지식 전달자보다는 학생과의 정서적 교감 및 심화 멘토링에 더 집중할 수 있다.

구글의 이번 연구는 교과서가 더 이상 고정된 책자가 아니라, 학습자와 상호작용하며 함께 성장하는 지능형 동반자가 될 수 있음을 시사한다.

시카고의 고등학생 60명을 무작위로 나눠 RCT(무작위대조시험)한 결과 이 시스템을 사용한 그룹은 기존 교과서를 사용한 그룹보다 즉각적인 성취도와 3일 뒤 기억 유지력에서 모두 압도적으로 우수했다. 모든 학생이 "자신감이 높아졌다"고 응답했다[1].

☞ 참고 사이트: https://learnyourway.withgoogle.com/
☞ 참고 설명 영상: https://www.youtube.com/watch?v=DqjsRpe2rxI&start=5

반면 한국에서 2025년부터 도입 예정이었던 'AI 디지털 교과서'는 많은 논쟁을 불러 일으켜서 현재 진행이 정체되어 있다. AI 디지털 교과서 도입에 따른 주요 쟁점 및 운영 현황

AI 디지털 교과서 도입 발표 이후, 교육 현장과 사회 전반에서는 다양한 정책적·사회적 논쟁이 발생했다. 주요 쟁점은 다음과 같다.

1. 법적 및 제도적 불확실성

정부는 AI 디지털 교과서를 공식 교과서로 도입하고자 했으나, 법적 근거와 지위 규정이 명확하지 않아 입법적 논쟁이 지속되었다. 이로 인해 정책 추진 과정에서 법적 지위를 둘러싼 혼선이 빚어졌다.

2. 데이터 보안 및 교육의 질적 우려

학습 이력 데이터 활용에 따른 개인정보 보호 문제와 불분명한 데이터 처리 정책이 비판의 대상이 되었다. 또한, 교과서 내용의 정확성과 신뢰성 부족, 과도한 화면 노출로 인한 학습자 집중력 저하 등 교육 효과에 대한 의구심도 제기되었다.

3. 현장의 준비 부족과 격차 심화

---

1) https://arxiv.org/abs/2509.13348
[Submitted on 13 Sep 2025 (v1), last revised 30 Sep 2025 (this version, v4)]
"Towards an AI-Augmented Textbook", LearnLM Team, Google: Alicia Martín, Amir Globerson, Amy Wang, Anirudh Shekhawat, Anna Iurchenko, Anisha Choudhury, Avinatan Hassidim, Ayça Çakmakli, Ayelet Shasha Evron, Charlie Yang, Courtney Heldreth, Diana Akrong, Gal Elidan, Hairong Mu, Ian Li, Ido Cohen, Katherine Chou, Komal Singh, Lev Borovoi, Lidan Hackmon, Lior Belinsky, Michael Fink, Niv Efron, Preeti Singh, Rena Levitt, Shashank Agarwal, Shay Sharon, Tracey Lee-Joe, Xiaohong Hao, Yael Gold-Zamir, Yael Haramaty, Yishay Mor, Yoav Bar Sinai, Yossi Matias

교사들을 위한 연수와 준비가 미흡하여 현장의 부담이 가중되었으며, 디지털 기기 접근성 차이에 따른 교육 불평등 심화 우려도 나타났다.

4. 2025년 운영 실태 및 향후 전망

2025년 실제 도입 과정에서는 기술적 결함과 교사·학부모의 반발로 인해 큰 차질을 빚었다. 결국 도입 4개월 만에 공식 지위가 박탈되어 학교 자율 선택제로 전환되었으며, 감사원으로부터 준비 부족과 절차상 문제에 대한 지적을 받았다. 자칫 해당 계획을 중단하거나 축소할 가능성까지 거론되는 상황이다.

☞찬성 입장:

①개인별 학습성과 극대화 관점 https://youtu.be/mLHTyEwmyAY?si=E_q29DHp6sEE3GWm

②사회적 관점: https://www.youtube.com/watch?v=B42vKq1oGUM

☞반대 입장:

①사회적 관점, https://youtu.be/vryB4AjI7Kk?si=ej_yk8Q3Wes7ECyL

②뇌과학과 생리학적 관점: https://youtu.be/LJJXrjgPOR8?si=oBI8GTAITltC43k0

☞[과제] 찬반 양론을 검토한 후 디지털 AI 교과서의 도입에 대한 학생의 의견을 정리해보라.

6) 출판

■원고 선별 업무

트릴로지(Trilogy)의 매뉴스크립트 AI(Manuscript AI)는 출판사에 매일 같이 쌓이는 산더미 같은 투고 원고를 분류 평가하는 기능을 한다. 과거에는 대부분 충분한 검토 이전에 시간과 인력의 한계로 충분한 검토가 어려웠다. Manuscript AI에 원고를 업로드하면 다음과 같은 내용을 담은 분석 리포트를 생성한다. (1)장르별 베스트셀러와 판매 데이터를 기반으로 해당 원고의 잠재적 판매 가능성을 수치화하고, (2)아마존과 굿리즈 등 주요 독서 플랫폼의 데이터를 참고해 예상 독자 평점을 추정한다. 여기에 (3)원고 내용이 제출된 장르 정의에 얼마나 부합하는지를 살피는 장르 적합도, (4)문장 구조·대화 비중·감정의 흐름·전개 속도 등 서사와 문체를 분석하는 스타일 적합도가 더해진다. 이 4가지 요소는 다시 하나의 종합 점수로 환산되어, 편집자가 '지금 읽어야 할 원고'와 '나중에 볼 원고'를 구분하는 참고 지표로 활용된다[2].

■ 편집 업무

전통적으로 출판 편집 업무는 책의 품질을 결정짓는 핵심적인 과업이다. 이 과업이야말로 탁월한 편집자와 그렇지 않은 편집자 사이의 전문성 차이가 많이 드러나는 영역이기도 하다. 최근 출판 업계는 AutoCrit, Claude 등 AI 편집 도구의 확산으로 효율성 증대를 기대하면서도, 한편으로는 편집자의 역할 변화에 대해 경계와 기대를 동시에 드러내고 있다. 하지만 많은 전문가와 교육기관은 아직 AI를 보조적 수단으로 정의하며 인간 편집자의 본질적 가치를 강조하고 있기도 하다. 문체와 맥락, 감정적 뉘앙스 및 저자와의 소통은 기계가 대체하기 어려운 영역이기 때문이다. 특히 프리랜서 편집자들 사이에서는 AI를 활용해 작업 속도를 높이려는 '하이브리드 방식'과, 오히려 '비(非) AI'를 브랜드화하여 인간만의 섬세함을 내세우는 전략이 공존하고 있다.

결국 출판 편집의 미래는 AI와 인간의 명확한 역할 분담에 달려 있다. AI가 기초 교정과 반복 작업을 수행한다면, 인간은 서사의 깊이와 저자의 의도를 읽어내는 고유의 영역을 지킨다. 앞으로의 편집자는 기술적 숙련도와 인간적 감수성을 동시에 갖춘 새로운 유형의 전문직으로 진화할 전망이다.

■번역가의 전문성에 대한 위협

최근 출판계에서 발생한 두 사례는 AI 번역이 번역가의 생존권과 언어적 전문성에 미치는 상반된 영향을 드러낸다.

하퍼콜린스 프랑스(Harper Collins France) 산하의 할리퀸(Harlequin)사가 자사 도서 번역에 기계번역 소프트웨어를 도입하기로 한 결정에 대해, 프랑스 문학번역가협회(ATLF)와 'In Flesh and Bone: For Human Translation'이라는 단체가 공동으로 문제를 제기했다. 출판사가 비용 절감만을 앞세워 수십 년간 헌신해 온 번역가들을 하루아침에 실업 위기로 내몰았고, 번역가의 숙련된 노동을 저평가하고 있으며, 인간만이 구사할 수 있는 미묘한 문체와 생동감을 배제함으로써 문학적 품질의 하향 평준화를 초래한다는 것이 비판의 주된 내용이었다.

한편 일본 만화는 전 세계적으로 불법 복제가 큰 문제였는데, 일본 문하청은 그 근본 원인이 해외 독자들의 수요에 비해 공식적인 만화 번역과 공급 속도가 이를 따라가지 못했다고 보았다. 그래서 문화청은 AI를 활용한 번역 지원 프로그램을 마

---

2) 류영호 페이스북 포스팅, <iframe src="https://www.facebook.com/plugins/post.php?href=https%3A%2F%2Fwww.facebook.com%2Fryuyoungho75%2Fposts%2Fpfbid02TjiLbEbLx4huRSxezhf3DSqUcKo2v3WyRoDixrHaieYN6ALYguH9ffwtvTSt95dZl&show_text=true&width=500" width="500" height="250" style="border:none;overflow:hidden" scrolling="no" frameborder="0" allowfullscreen="true" allow="autoplay; clipboard-write; encrypted-media; picture-in-picture; web-share"></iframe>

련햇 번역가들에게 전문 번역 기법과 AI 활용 방법을 교육하는 동시에, 만화 번역에 특화된 AI 도구 개발을 지원했다. 도쿄대학에서 출발한 스타트업 만트라(Mantra)는 슈에이샤와 쇼가쿠칸의 지원을 받아 등장한 대표 사례다. Mantra의 번역 도구는 등장인물의 말투와 이야기의 배경 설정까지 고려해 작품 전체를 자동으로 번역하는데, 18개 언어를 지원하고 기존 방식에 비해 번역 시간을 절반 수준으로 단축한다. 현재 이 시스템은 매달 약 20만 페이지 분량의 번역을 처리하고 있다. 그리고 이렇게 처리된 자동 번역은 다시 전문 번역가의 손으로 다듬어지게 된다.

이 두 사례는 AI 번역 결과물에 대해 정확성, 어조, 문체, 유창성을 점검하기 위한 '인간의 개입'이 필수적이라는 점에서, AI와 전문가의 협업 시스템이 어떻게 정착되어야 할지에 대해서 많은 시사점을 제공하고 있다[3].

■ 전자책의 언어 기반 확대

글로벌 전자책 시장을 주도하는 아마존닷컴은 2025년 11월, 킨들 트랜스레이트(Kindle Translate)라는 AI 서비스를 베타 버전으로 출시했다. 이 서비스는 아마존닷컴에서 5% 미만의 도서만이 두 개 이상의 언어로 제공되는 상황을 개선하기 위해 개발되었다.

현재 영어와 스페인어 간 양방향 번역, 독일어에서 영어로의 번역을 지원하고 있지만, 향후 더 많은 언어가 추가될 예정이다

저자는 72시간 내에 완전히 포맷된 번역본을 출판할 수 있으며 모든 번역은 출판 전 자동으로 정확도 평가를 받는다. 저자는 번역을 미리 검토하거나 자동 출판을 선택할 수 있다. 또한 AI 번역임을 명시적으로 표시하여 독자가 인지할 수 있도록 한다.

서비스는 무료로 제공되며 저자에게 별도의 비용이 청구되지 않는다. 번역본은 아마존의 전자책 출판관리 시스템인 KDP(Kindle Direct Publishing) 셀렉트에 등록할 수 있다.

저자들은 손쉽게 외국어 번역본을 냄으로써 전 세계 새로운 독자들에게 문을 열고 작품을 확산시킬 기회를 얻게 된다. 독자 역시 다양한 언어로 제공되는 도서 목록이 확대되어, 기존에 접근하기 어려웠던 언어권 국가의 도서들에 대해 더 많은 선택권을 확보하게 된다

반면에 부정적인 효과도 예상된다. 예를 들어 소설과 문학 작품에서 인간 번역가가 뉘앙스를 더 잘 포착하며, AI의 기계 번역은 중요한 오역을 낳을 수 있다. 특히 시, 아동 도서 등 문화적 뉘앙스가 중요한 작품의 경우 사람의 손질이 필수적이다.

3) https://publishingperspectives.com/2026/01/the-future-of-translation-ai-and-the-greater-good/

이런 영역에 대해서 아마존이 어떤 식으로 사람의 감수를 거칠 수 있을지는 좀 더 지켜보아야 한다.

또한 노동 시장에도 영향을 미쳐, 전문 번역가들의 일자리를 감소시킬 가능성이 높다.

■ 저자와 도서의 양적 범위 폭발

한편 AI를 활용한 글쓰기는, 단순히 인터넷 포스팅이나 과제물 제출 같은 비영리 사적 행위 단계를 넘어, 저자 및 콘텐츠의 폭발을 일으켜 출판 산업 자체의 패러다임을 바꾸고 있다.

과거에는 AI가 초안 작성이나 문법 교정에 머물렀다면, 이제는 기획부터 집필, 편집, 마케팅에 이르는 출판의 전 과정을 주도하거나 인간과 긴밀히 협력하는 '공동 저자'의 단계로 진화했다.

출판계에서는 'Generative Workflow'가 점점 자리잡고 있다. 작가들은 AI 에이전트로 활용해 방대한 데이터를 순식간에 요약하고, 다채로운 서사 구조, 주제 및 목차 구성안, 집필 가이드를 제안받는다.

- 실용서 및 전문 서적: 정보의 최신성이 중요한 비즈니스 도서나 기술 가이드북 분야에서는 AI가 실시간 데이터를 바탕으로 원고를 생성하여 집필 기간을 획기적으로 단축한다.
- 장르 문학: 웹소설이나 로맨스 등 공식이 뚜렷한 장르에서는 AI가 설정한 캐릭터와 플롯을 바탕으로 하루에 수만 자의 원고를 생산하는 사례가 빈번하다.
- 백리스트(Backlist) 부활: 출판사들은 AI를 이용해 절판된 구간 도서를 오디오북으로 변환하거나 다국어로 번역하여 전 세계 시장에 즉각 재출시하는 경제적 혁신을 이뤄내고 있다.

급격한 확산에 따른 부작용도 만만치 않다. 가장 큰 문제는 '데이터의 질 저하'와 '저작권 분쟁'이다.

- 콘텐츠의 하향 평준화: 저품질의 AI 생성 도서가 시장에 범람하면서 독자들의 피로도가 높아지고, 탁월한 작가의 콘텐츠가 묻혀버리는 현상이 나타나고 있다.
- 권리의 모호성: AI 학습에 사용된 기존 저작물에 대한 보상 체계가 여전히 미비하며, AI가 쓴 글의 저작권 인정 여부를 둘러싼 법적 갈등이 계속 일어나고 있다.

2025년 일부 출판사가 AI를 이용해 일주일에 평균 150권의 책을 만들어 연간 수천 권에 달하는 전자책을 발행했다. 문제는 이를 국회도서관과 국립중앙도서관에 납품하면서 불거졌다. 국회도서관 심사 과정에서 파손된 도서를 검토하던 중, 내용

이 부실하고 형식이 정형화된 점을 수상히 여겨 AI 탐지기를 돌린 결과 AI 생성물임이 확인되었다.

도서관법 및 국회도서관법에 규정된 '납본 제도'는 국내에서 발행된 모든 도서를 국가 기관에 제출하도록 강제하는 대신, 국가가 해당 도서에 대한 보상금을 지급하도록 되어 있다. 보상금을 노리고 대량 납본을 한 것이다,

이런 행동이 허용되면, 국가 도서관의 납본 보상 예산이 순식간에 바닥날 수도 있을 뿐 아니라, 도서관 서고가 저품질 AI 생성물로 채워지는 하향 평준화 현상이 가속화된다. 이 사건을 계기로 AI 생성 저작물에 대한 납본 거부 근거를 마련하거나, 보상금 지급 대상을 선별하는 등 관련 법령과 시스템을 시급히 재점검해야 한다는 논의가 일어나기 시작했다.

7) 로봇

스타십(Starship)은 현재 세계에서 가장 앞서나가는 배달로봇 제조 기업이다. 2014년 스카이프 공동 창업자인 아흐티 하인라(Ahti Heinla)와 야누스 프리스(Janus Friis)가 에스토니아 탈린에서 설립했다. 8월에 첫 번째 프로토타입 로봇을 제작했다. 2015년에 글로벌 테스트 및 첫 배달으 성공했고, 2016년 7월, 런던(Just Eat), 뒤셀도르프(Metro) 등 유럽 도시에서 음식 및 소형 화물 배달 시범 운행을 시작했고 이어서 같은 해 11월, 미국 캘리포니아 레드우드 시티에서 첫 공식 로봇 배달(쿠키 배달)에 성공했다.

2017년 1,720만 달러 규모의 시드 투자를 유치하며 본격적인 사업 확장에 나서, 2018년 4월, 영국 밀턴케인즈에서 식료품 체인(Co-op, Tesco)과 협력하여 세계 최초의 본격적인 상용 로봇 배달 서비스를 시작했다. 2019년 이후 조지 메이슨 대학교를 시작으로 미국 내 여러 대학 캠퍼스로 서비스를 확대했다. 학생들에게 편리함을 제공하며 캠퍼스 내 주요 배달 수단으로 자리 잡았다. 2024년 말 기준 전 세계 2,000대 이상의 로봇을 운영하며 누적 배달 700만 건을 기록했다.

☞참고영상: Starship First Delivery 이 영상은 스타쉽 로봇이 캘리포니아 레드우드 시티에서 성공적으로 수행한 첫 번째 공식 배달 장면을 담고 있다.
https://youtu.be/DW16O6UWtSc

우리나라에서는 배달의민족 배달 로봇 '딜리'가 서울 일부 지역에 한하여 시범 운영을 이미 시작했다.

"우아한형제들은 . . .(중략) . . .2019년 건국대학교에서 국내 최초로 실외 배달로봇 서비

스를 시범 운영했으며, 2020년에는 광교 앨리웨이 주상복합 단지에서 도어 투 도어(door to door) 로봇배달 서비스를 제공한 바 있다. 지난 2023년에는 '테헤란로 로봇거리 조성사업'의 일환으로 삼성동 코엑스에서 배달로봇으로 음식배달을 진행하면서 자율주행 로봇배달을 위한 기술과 데이터를 쌓았다.

이번에 배민이 자체기술로 선보이는 로봇배달 서비스는 강남 지역 내 B마트 도심형 유통센터(Pick Packing Center, PPC)를 중심으로 장보기, 쇼핑 서비스를 제공한다. PPC 기준 최대 1.5km 반경 내 300여 개의 건물 입구까지 30분 내외로 배달하며, 5월 이후 1,000여곳 이상으로 범위를 확장할 계획이다."[4)]

건설 분야에서 AI 건설 로봇은 주로 물류, 안전 관리, 시공 지원 등의 고위험·반복 작업을 자동화하는 데 활용되고 있다. 이러한 로봇들은 주로 고위험 작업 대체, 인력 부족 해소, 시공 품질 및 안전성 향상, 공정 효율화를 목표로 도입되고 있다.

현대차그룹이 인수한 보스턴 다이나믹스의 '스팟'과 같은 4족 보행 로봇은 2022년 이후 현대건설, GS건설 등에서 다양한 센서와 AI 기반 소프트웨어를 탑재하여 험지 이동이 가능하며, 현장 순찰, 위험 구역 점검, 실시간 데이터 수집 등을 수행해오고 있다. 또한 현대건설은 국내 건설 현장에 다관절 로봇을 시범 적용하여, 도장공 등 숙련공의 업무 패턴을 프로그래밍화한 시공 작업을 자동 수행하고, 3D 프린팅 출력 장비를 장착하여 건설용 구조물을 제작하는 기술을 연구하고 있다.

☞참고 영상: 현대건설 https://youtu.be/ewTdVLuwiOo

그밖에도 AI 로봇은 무수히 많은 분야에서 이미 적용되고 있다.

- Ocado: 수천 개의 로봇이 협업해 물류 처리 (AI가 항공 관제사처럼 조율)
- Ameca: 표정 및 동작 구현 가능한 휴머노이드 로봇
- Tesla Optimus: 반복적·위험한 작업을 위한 휴머노이드
- DeepMind: 로봇이 축구를 통해 시행착오 학습 (코딩 없이 학습함)

8) 내부 프로세스 효율화

한솔제지는 영업 활동 데이터를 자동으로 수집·분석하여 담당자에게 요약 보고서를 제공함으로써 고객 맞춤형 제안을 가능하게 한다. 또한, AI는 단순 정리를 넘어 판매 추세와 구매 주기 등 영업 패턴을 분석하여 전략적 의사결정을 지원한다. 예를 들어 계절별 수요 변화를 감지해 재고 확보를 권장하거나 특정 시기의 대량 구매에 대비한 사전 영업 계획 수립을 돕는다. 이를 통해 영업 담당자는 반복적인 데이터 정리 업무에서 벗어나 창의적인 업무에 집중할 수 있으며, 실시간 시장 동향

4) 2025-02-25, https://www.woowahan.com/report/detail/845 우아한 형제들 홈페이지

을 반영해 전략을 조정할 수 있다[5].

그밖에도 전세계의 수많은 기업들이 내부 프로세스 효율화를 위해 적극적으로 AI를 도입하고 있다. 몇 가지만 들자면 다음과 같은 것들이 있다.

- Octopus Energy: ChatGPT로 44% 고객 문의 처리, 250명 업무 대체.
- Walmart의 Ask Sam: 매장 직원 지원, 비상 알림 기능 포함.
- Verizon의 직원용 챗봇: 고객 문의 95% 해결.
- Grammarly, ProWritingAid 등으로 문장 교정 및 스타일 개선.
- Voicea EVA, Google Duplex: 회의 요약 및 일정 예약 자동화.

주목할 만한 것은 바이브 코딩을 통해 사내 디지털 전환 업무를 효율화하는 과업이다. 일반적으로 기업들은 자신의 사업을 영위하기 위한 기업용 ERP 내지 다양한 SW를 사용한다. 세일스포스는 기업이 자신의 필요에 맞는 SW를 사내 개발자들이 '자연어'로 개발할 수 있도록 지원하는 솔루션 Agentforce Vibes(에이전트포스 바이브)를 제공한다. 예를 들어서 이렇게 컴퓨터 SW를 프로그래밍 언어를 직접 코딩하는 대신 '자연어'로 지시하면서 개발하는 것을 바이브 코딩(Vibe Coding)이라고 한다. 이 솔루션으로, 자연어 설명을 소스 코드로 변환하여 소프트웨어 개발 및 자동화 작업을 지원하는 역할을 한다.

자연어 입력은 단계화, 범주화 되어 진행된다. 막연히 "주문 고객 정보를 획득해서 추천 상품을 선별해서 이메일로 보내고 이메일로 주문 시 주문 처리하는 프로그램을 만들어줘."라고 해서는 안 된다. 개발자는 서비스가 안내하는 입력 창에 다음과 같은 식으로 순서대로, 체계적으로 자연어로 지시한다. 바이브 코딩이 효율적으로 이루어지면, 개발자는 프로그래밍 로직과 처리 방법들에 대한 최소한의 기초 지식이 있어야 한다.

☞바이브 코딩 프롬프트 예시:

1. 고객 구매 정보 획득 및 데이터 통합

이 단계에서는 외부 데이터나 Salesforce 내부의 여러 객체에 흩어진 정보를 통합하고, 필요한 필드를 자동으로 생성하도록 지시한다.

프롬프트 예시:

"계정(Account) 객체와 주문(Order) 객체를 분석해서 '고객 평생 가치(LTV)'와 '최근 구매일'을 계산하는 새로운 필드를 만들어줘. 그리고 Shopify API와 연동해서 외부 결제 데이터를 Salesforce의 'External_Purchase_History__c' 커스텀 객체로 실시간 동기화하는 통합 스케줄러를 Apex로 작성해줘. 데이터가 들어올 때 중복 체크 로직도 포함해."

---

5) 기자명안재석 jsahn@hitech.co.kr
출처 : 하이테크정보(http://www.hitech.co.kr)

2. 개인화된 추천 상품 목록 생성 (식별 데이터 활용)

고객의 지역, 성별, 연령 정보를 기반으로 AI가 판단 로직을 만들도록 지시한다.

프롬프트 예시:

"Contact 객체의 'MailingCity', 'Gender__c', 'Age__c' 필드를 읽어서 해당 고객에게 가장 적합한 상품 3개를 추천하는 AI 추천 엔진 액션을 생성해줘.

20대 여성 서울 거주자에게는 '신규 뷰티 아이템' 우선 순위 부여.

40대 남성 경기 거주자에게는 '홈 가드닝 세트' 우선 순위 부여. 추천 결과는 'Recommended_Products__c' 필드에 JSON 형태로 저장하고, 추천 근거(Reasoning)도 함께 텍스트로 남겨줘."

3. 정기적인 개인화 이메일 발송 자동화

추천된 상품 정보를 담아 정기적으로 발송되는 캠페인 워크플로우를 생성한다.

프롬프트 예시:

"매주 월요일 오전 9시에 실행되는 '레코드 트리거 플로우(Record-Triggered Flow)'를 만들어줘. 대상은 최근 3개월간 구매 이력이 있고 'Recommended_Products__c' 필드가 업데이트된 고객이야. 추천 상품 목록을 HTML 표 형태로 이메일 템플릿에 삽입하고, 고객의 성함을 포함해 '안녕하세요 [Name]님, 이번 주 고객님을 위한 특별 제안입니다'라는 제목으로 이메일을 자동 발송하도록 설정해줘."

4. 이메일 답장 및 구매 주문 처리 자동화

이메일을 통해 들어오는 구매 의사를 분석하고 실제 주문(Order) 레코드를 생성하는 복합 기능을 요구한다.

프롬프트 예시:

"고객이 발송된 이메일에 대해 '이거 주문할게요' 또는 '장바구니에 담아줘'라고 답장을 보내면 이를 감지하는 인바운드 이메일 핸들러를 구성해줘.

AI는 이메일 본문에서 상품명과 수량을 추출해야 해.

추출된 정보로 새로운 'Order'와 'OrderItem' 레코드를 생성하고, 상태를 'Draft'로 설정해.

주문 생성이 완료되면 고객에게 '주문서가 접수되었습니다. 결제를 진행하시겠습니까?'라는 확인 답장을 다시 보내는 기능까지 포함해줘."

5. 기타 필요에 따라 여러 기능들을 추가해 줄 것을 자연어로 요청할 수 있다.

데이터 정제 (Data Cleansing):

"구매 정보 획득 시, 주소 정보가 부정확하면 Google Maps API를 호출해 표준 주소로 자동 교정해줘."

이탈 예측 (Churn Prediction):

"최근 6개월간 활동이 없는 고객에게는 추천 상품과 함께 15% 할인 쿠폰 코드를 자동으로 생성해서 메일에 포함해줘."

Slack(기업용 메신저 및 협업 툴) 알림:

"VIP 고객(회당 100만 원 이상 구매)이 이메일로 주문 요청을 하면 담당 영업 사원에게 Slack으로 즉시 알림을 보내줘."

9) 사무

AI는 사무 생산성 향상을 위한 툴과 결합되어 지식노동자에게 많은 도움을 주고 있다. 수많은 AI 앱들이 있지만, 노션과 감마를 예로 들어보자.

○노션

노션 Notion은 사무용 문서 관리 툴이다. 에버노트처럼 단순히 메모를 작성하고 관리하는 것이 아니라, 사용자의 입력 텍스트마다 데이터베이스 구조로 관리되어 유연한 템플릿을 생성할 있는 기능이 각광을 받았다. 이반 자오(Ivan Zhao)와 사이먼 라스트(Simon Last)가 공동 설립한 미국 샌프란시스코 소재의 기업 '노션 랩스(Notion Labs)'에서 개발했다.

주 사용자 층은 초기에는 스타트업과 IT 업계 종사자들을 중심으로 확산되었으나, 현재는 학생, 프리랜서, 대기업에 이르기까지 폭넓은 사용자층을 보유하고 있다. 특히 한국, 일본 등 아시아 지역의 사용 비중이 매우 높다.

'Notion AI'라는 이름으로 문서 요약, 초안 작성, 번역, 작업 목록 추출 등의 기능을 제공한다. 최근에는 데이터베이스 내의 방대한 정보를 분석하여 답변을 찾아주는 질문 답변(Q&A) 기능까지 도입하며 생산성을 높이고 있다.

☞ 시청: 노션 창업자 인터뷰: AI 시대에는 기술력이 아니라 안목의 역할이 더 중요 https://youtu.be/iTypFtxogNQ?si=yLYCHHSsAI0GbOqs

○감마

감마 Gamma는 프리젠테이션 작성 및 관리 툴로서, 기존 마이크로소프트의 파워포인트 사용에서 느끼는 온갖 불편을 해소하는 것을 개발 목표로 했다. 2020년 샌프란시스코에서 Grant Lee와 Jon Noronha가 공동 창업한 스타트업 Gamma Tech, Inc.에 의해 개발됐다.

사용자가 입력한 간단한 아이디어나 한 줄의 프롬프트를 바탕으로 전체 슬라이드 구조와 내용을 스스로 생성한다. 기존의 파워포인트가 빈 슬라이드에서 시작해 수동으로 요소를 배치해야 했다면, 감마는 AI가 목차 구성, 본문 작성, 관련 이미지 삽입까지 일괄적으로 수행한다. 사용자는 생성된 초안을 바탕으로 세부적인 내용만 수정하면 되기에 작업 시간을 획기적으로 단축한다. 각종 제안서, 보고서, 강의교안, 시각화에 특화된 문서를 만들고자 하는 모든 사용자층이 형성되어 있다.

노션이 문서 관리와 데이터베이스 구축에 강점이 있다면, 감마는 정보를 '시각적으로 전달'하는 데 특화되어 있다. 노션에 작성된 방대한 텍스트 내용을 복사하여

감마에 입력하면 즉시 시각적인 발표 자료로 변환되므로, 두 도구를 병행하여 사용하는 하이브리드 워크플로우가 대중화되는 추세이다.

10) 의사결정

사업 경영자는 항상 모든 것이 불확실한 상황에서도 의사결정을 내려야 한다. 벤처캐피탈리스트는 새로 검토하고 있는 스타트업에 투자를 해야 할지 말아야 할지 결정해야 한다. VC의 투자의사결정은 그동안 오랜 경험을 쌓은 사람 VC의 전문적인 영역으로 간주되어 왔다. 그러나, 최근 AI가 사람 전문가 VC보다 더 우수한 결정을 내린다는 연구 결과가 발표되기도 했다. 영국 옥스포드대학과 Vela research가 공동으로 연구한 내용에 따르면, 링크드인으로 부터 9000명 창업자 프로파일을 모아서 5억달러 이상 IPO나 펀드레이징 성공한 경우를 대상으로, 일정 기간이 지난 뒤 실제로 '성공', '실패' 데이터를 확보하여 이를 토대로 AI 예측 모델을 만들었다. 실제 성공률은 대략 9%, 즉 100개 기업당 9개 기업 정도만이 성공한 것으로 나왔다. 전문가 사람이 '성공', '실패' 예측을 한 결과보다, 모델의 예측 결과가 더 정확도가 높게 나왔다. 현재 DeepSeek 등 LLM을 대표하는 9개 모델에서 모두 사람보다 더 정확히 예측하는 것을 나왔다. 사용한 독립변수는 소속산업industry, 학위education degree, 전공분야 education field of study, 담당직무job role, 교육경력education record의 소수개에 불과했고, 실험적인 연구로서, 앞으로 보완이 많이 필요한 연구이지만, 이를 계기로 앞으로 AI를 이용한 경영 의사결정 분야에서 많은 연구가 이루어질 것으로 예상된다[6].

나. 사회

1) 사회 인프라

■ 기상 예측

○ 공공 기관

모든 사회에서 AI의 혜택을 현실에서 가장 많인 보는 영역 중 하나가 바로 기상예보다. 단기 예보의 경우 과거와는 비할 수 없을 정도의 정확도를 가지고 예측을 함으로써 많은 사람들이 일정 수립에 도움을 주고 있다. 최근 개선된 AI 모델이 적

6) https://arxiv.org/abs/2509.14448
"VCBench: Benchmarking LLMs in Venture Capital", 17 Sep 2025 제출
Rick Chen, Joseph Ternasky, Afriyie Samuel Kwesi, Ben Griffin, Aaron Ontoyin Yin, Zakari Salifu, Kelvin Amoaba, Xianling Mu, Fuat Alican, Yigit Ihlamur

용되기 전, 과거 기계학습 수준의 AI에서도 매우 개선된 성과를 보여주었지만, 하드웨어 성능 향상과 모델이 진보에 따라 그 정확도가 더욱 향상됐다.

유럽중기예보센터(ECMWF)는 2025년 초부터 AI 기반 예보 시스템인 AIFS(Artificial Intelligence Forecasting System)를 정식 운영하기 시작했다. 세계 최초로 AI 전용 시스템을 기존 물리 기반 모델과 병행 운영하며 기상 예보 분야의 혁신을 선도한다. 또한, 오픈소스 프레임워크인 '아네모이(Anemoi)'를 개발하여 글로벌 협력을 강화하고 있다. 이러한 기술력을 바탕으로 열대성 사이클론의 경로 예측을 기존보다 12시간 앞당기는 성과를 달성했다.

미국 NOAA (국립해양대기청)은 미국 NOAA는 2025년 말에 하이브리드 AI-물리 기반 앙상블 시스템인 HGEFS를 세계 최초로 실용화했다. 현재 'Project EAGLE'을 통해 AI 기상예측 통합을 가속화하고 있다. AI 기반의 AIGFS는 기존 GFS 대비 계산 자원의 0.3%만 사용하면서도 40분 만에 16일 치 예보를 완료하는 효율성을 보여준다. 특히 하이브리드 모델인 HGEFS는 AI 전용 및 물리 전용 시스템을 모두 능가하는 성능을 보인다.

한국 기상청은 2025년 2월부터 AI 모델을 초단기 예보 현장에 실제 활용하고 있다. 2024년 10월부터는 KIM-전구앙상블모델 기반의 AI-앙상블 운영체계를 실시간으로 운영한다. 격자간격 8km의 고해상도 전지구 수치예보모델인 KIM을 통해 세계에서 9번째로 자체 수치예보모델을 보유한 국가가 되었다. 아울러 세계기상기구(WMO)와 공동으로 '기상·기후 AI 글로벌 테크 포럼'을 개최하며 국제 협력을 주도한다.

○민간 기업

공공조직 이외에 민간 기업에서도 앞다투어 기상예보 모델을 내놓고 있다.

Google DeepMind는 2025년 11월 WeatherNext 2를 출시하여 단일 TPU에서 1분 이내에 수백 개의 기상 시나리오를 예측한다. 이는 이전 모델 대비 99.9%의 변수 및 예측 시간대에서 성능이 향상된 결과이다. GenCast 모델은 앙상블 예측에서 ECMWF의 기존 시스템을 능가하는 허리케인 추적 정확도를 보이며, GraphCast는 10일 예보를 1분 이내에 완료하고 90% 이상의 변수에서 기존 HRES를 능가한다.

Huawei의 Pangu-Weather 모델은 43년간의 방대한 데이터를 학습하여 단 몇 초 만에 고해상도 전지구 예보를 생성한다. 이를 통해 전통적인 수치 예보 모델(NWP) 대비 10,000배의 속도 향상을 달성했다.

Microsoft는 ClimaX 모델을 개발하여 4주 이내의 기후 예측을 수행하는 것을 목표로 삼는다. Vision Transformers(ViT) 기반 아키텍처를 채택하여 다양한 시공간 데이터를 효과적으로 처리하며, 최근에는 Aurora 모델을 통해 장기 기후 예측 분

야에도 성공적으로 진출했다.

NVIDIA는 FourCastNet 및 FourCastNetv2를 개발하여 대학 연구 그룹에서도 활용 가능한 효율적인 AI 기상 예측 환경을 제공한다. 또한, Meteomatics와의 협력을 통해 90미터 반경의 초정밀 AI 기반 기상 예보를 수 분 내에 제공하는 기술력을 선보였다.

☞ 과제: 새로운 방법론으로 기상 예보 서비스를 개발하는 스타트업들로 무엇이 있는가?

○ 데이터

훈련 데이터는 유럽기상청(ECMWF)이 제공하는 ERA5 재분석 데이터가 현재 AI 기상 모델 훈련의 사실상 표준으로 자리 잡고 있다. ERA5는 1979년부터 현재까지의 전 지구적 기상 상태를 시간당 단위로 제공하며, 약 31km의 공간 해상도를 갖는다. 이 데이터는 위성 관측 자료와 전 세계 기상 관측소에서 수집된 실측 데이터를 물리 기반 수치 모델과 결합해 생성되며, 장기간에 걸쳐 시공간적으로 일관된 기상 데이터셋을 제공한다. 많은 기업들이 ERA5를 공통 학습 데이터로 활용하고 있다.

ERA5의 중요한 특징 중 하나는 대기의 수직 구조를 정밀하게 반영한 다층 대기 데이터 구성이다. 지표면 인근의 2m, 10m, 100m 고도 데이터뿐 아니라, 900hPa, 850hPa 등 다양한 기압면에서의 대기 변수가 포함된다. 이를 통해 모델은 지상과 상층 대기의 상호작용을 동시에 학습할 수 있다.

그 외에 실시간 입력 데이터가 활용되기도 하는데, 그 원천은 크게 위성 관측 데이터, 지상 관측소 데이터, 레이더 및 해양 부이로 구분할 수 있다.

[위성 데이터] Atmo는 대부분의 주요 기상 위성으로부터 실시간 데이터를 수집하며, Tomorrow.io는 자체적으로 운용하는 위성을 통해 관측 자료를 확보한다. 또한 NOAA의 GOES-19와 같은 정지궤도 위성 데이터가 활용되며, AGRI(Advanced Geosynchronous Radiation Imager)에서 수집된 관측치는 자료 동화 과정에 사용되어 예측의 초기 조건을 정밀하게 보정한다.

[지상 관측소] 위성 관측을 보완하기 위해 전 세계 지상 기상 관측소에서 측정된 데이터도 함께 사용된다. 이들 관측소는 온도, 습도, 기압, 풍속 등 기본적인 기상 변수를 지속적으로 제공한다. WeatherXM은 5,000개 이상의 지역 기상 관측소 네트워크를 운영하며, Aardvark Weather는 위성, 지상 관측소, 각종 센서에서 직접 수집된 관측 데이터를 AI 모델의 입력으로 활용한다.

[레이더 및 해양 부이] 강수와 폭풍 구조를 정밀하게 파악하기 위해 레이더 데이

터도 실시간으로 활용된다. Atmo는 전 세계 레이더 데이터를 수집해 강수 패턴과 폭풍의 내부 구조를 분석한다. 더불어 해양 부이로부터 수집되는 데이터는 해수면 온도, 파고, 해류와 같은 해양 상태 정보를 제공하며, 이는 해양-대기 상호작용을 고려한 예측에 중요한 역할을 한다.

○ 모델의 특성

현대의 AI 기상 모델은 단일 변수가 아닌 수백 개의 기상 변수를 동시에 처리한다. 여기에는 온도, 습도, 풍속, 풍향, 기압, 강수량, 지위고도 등이 포함된다. WeatherNext 2는 전체 변수와 예측 시간대의 99.9%를 다루도록 설계되었으며, ClimaX는 다양한 기상 변수를 서로 다른 시공간 해상도에서 통합적으로 처리하는 구조를 갖는다.

마지막으로, 많은 AI 기상 모델은 전통적 수치예보모델(NWP)의 출력을 배경장(background field)으로 활용한다. 이러한 데이터에는 에너지 보존, 질량 보존 등 기본적인 물리 법칙이 이미 반영되어 있으며, AI 모델은 이를 학습함으로써 물리적으로 일관된 예측을 생성할 수 있다. 이는 순수 데이터 기반 접근의 한계를 보완하고, 예측의 안정성과 신뢰도를 높이는 핵심 요소로 작용한다.

■ 교통 관리

기후 예측과 마찬가지로, 많은 국가에서 공공기관과 민간기업이 AI 교통 관리 시스템을 개발하고 있다.

○ 한국도로공사 등

한국도로공사는 2023년부터 디지털본부를 중심으로 AI 기반 차세대 지능형 교통시스템(C-ITS) 구축에 본격적으로 나서며 고속도로 운영의 지능화를 가속화하고 있다. 특히 2023년부터는 AI 기반 적재불량 단속시스템을 도입해 고정형 CCTV로 고속도로 진입 차량을 촬영하고, 인공지능이 적재물 상태를 자동 분석함으로써 사고 예방의 실효성을 높였다. 그 결과 낙하물 사고는 2020년 1~3월 3,530건에서 2024년 같은 기간 2,465건으로 줄어 약 30.2% 감소하는 성과를 거두었다.

아울러 IoT 센서를 활용한 스마트 제설 관리시스템을 통해 제설 작업 소요 시간을 평균 30분 단축했으며, 드론과 라이다(LiDAR) 센서를 결합한 시설물 자동 점검 시스템을 도입해 유지관리 비용을 약 30% 절감하는 등 운영 효율성도 크게 개선했다. 현재는 5분 단위로 고속도로 위험 구간을 분석하는 딥러닝 기반 모델을 개발 중이며, 교통량, 기상 정보, 공사 정보, 돌발 상황 등 고속도로 운용 전반에서 발생하는 방대한 데이터를 통합적으로 수집·분석해 사고 발생 가능성과 정체 구간을 사

전에 예측하는 지능형 교통 관리 체계 구축을 추진하고 있다.

그 외에 많은 민간기업들이 자신만의 특화된 영역에서 교통 정보 분석 시스템을 개발해서 출시하고 있다.

○ 데이터와 모델

투입 데이터는 실시간 교통 데이터(특정 지점을 통과하는 차량의 수와 차량 속도, 특정 도로 구간이 차량으로 점유된 비율, 승용차, 버스, 트럭 등 차종 분류, 단위 거리당 차량 수 등)가 우선 측정된다. 그 데이터들은 교통 CCTV는 물론이고 도로 표면에 매설된 유도 루프 검출기(Inductive Loop Detectors), 적외선 센서(Infrared Sensors), 레이더, GPS 추적기, 스마트 카메라 등 다양한 원천에서 수집한다. 또한 도로 공사, 통행 제한, 통행료 정보 등 지자체 데이터와 속도 제한, 회전 제한 등 교통 규칙 정보 등 교통 법규 데이터: 를 포함한다.

이 데이터들은 시간대, 요일, 계절, 그리고 스포츠 경기, 콘서트, 축제 등 특별 이벤트의 존재 여부 등으로 가공 분석된다. 또한 사용자 생성 데이터, 그리고 내비게이션 앱을 통해 사용자가 실시간으로 보고하는 교통 정보 까지 데이터에 포함된다.

교통 데이터 뿐만 아니라 교통에 중요한 영향을 미치는 기상 데이터, 즉 강수량, 기온, 가시거리, 노면 상태와 도로의 품질(포장 여부, 자갈, 흙, 진흙 등 도로 상태)까지 모델 변수에 포함된다.

모델은 주로 딥러닝 계열을 사용하나, 필요에 따라 AI의 여러 방법론을 선택적으로 조합해서 사용한다. 딥러닝 모델로는 시계열 교통 데이터를 분석하여 미래 교통 흐름을 예측하는 장단기 메모리(LSTM, Long Short-Term Memory) 분석, 교통 카메라 영상을 분석하여 차량, 보행자, 교통 위반을 감지하고 차량 번호판 인식, 차량 유형 분류에 사용되는 합성곱 신경망(CNN, Convolutional Neural Networks), 복잡한 교통 데이터의 비지도 학습(unsupervised learning)에 사용되는 적층 오토인코더(SAE, Stacked Autoencoder), Google DeepMind가 도입한 아키텍처로 도로 네트워크를 그래프로 모델링한 그래프 신경망(GNN, Graph Neural Networks) 등이 주로 활용되고 있다.

2) 사회적 약자 보호

AI의 성능 향상 덕분에 장애인, 고령자 등 사회적 약자를 도울 수 있는 획기적인 서비스들이 등장하는 것이 가능해졌다.

○ 시잉AI

Microsoft가 개발한 Seeing AI는 2016년 Build 컨퍼런스에서 처음 시연되었고, 2017년 7월 12일 iOS용 앱이 정식 출시되었다. 2023년 12월 3일 세계 장애인의 날에 Android 버전도 출시되어 30억 명 이상의 Android 사용자들이 접근할 수 있게 되었다. Microsoft Garage 인턴십 프로그램에서 대학생들과 개발자들이 협력하여 개발했으며, 어린 시절부터 시각장애를 가진 Microsoft 소프트웨어 개발자 Saqib Shaikh가 주요 후원자로 참여했다.

주요 활용 현황 및 도움 효과

Seeing AI는 현재 70개국에서 18개 언어(체코어, 덴마크어, 네덜란드어, 영어, 핀란드어, 프랑스어, 독일어, 그리스어, 헝가리어, 이탈리아어, 일본어, 한국어, 노르웨이어, 폴란드어, 포르투갈어, 러시아어, 스페인어, 스웨덴어, 터키어)로 서비스되고 있다. 2017년 출시 이후 첫 해 말까지 300만 건 이상의 작업을 지원했으며, 미국 맹인재단으로부터 권위 있는 헬렌 켈러 성취상을 수상했다. 앱은 무료로 제공되며 수많은 시각장애인들이 일상 생활을 불편 없이 영위하는 데에 큰 도움을 받고 있다.

○ 스토리사인

StorySign는 중국의 Huawei가 FCB Inferno 광고 에이전시, 유럽연합 청각장애인협회(European Union of the Deaf), 영국 청각장애인협회(British Deaf Association) 등 11개 국제 청각장애인 자선단체, 아카데미상 수상 애니메이션 스튜디오 Aardman, 세계 최대 출판사 Penguin Random House와 협력하여 개발했다. 2018년 12월에 유럽 10개국에서 처음 출시되었고, 이후 중국, 호주 등으로 확대되었다. 2019년 The Drum Social Purpose Awards에서 Grand Prix를 수상했다.

StorySign은 현재 15개 수화 언어(미국 수화, 영국 수화, 호주 수화, 프랑스 수화, 독일 수화, 이탈리아 수화, 스페인 수화, 포르투갈 수화, 네덜란드 수화, 아일랜드 수화, 벨기에 플랑드르 수화, 벨기에 프랑스 수화, 스위스 프랑스 수화, 스위스 독일 수화, 브라질 수화)를 지원한다. 전 세계 청각장애 아동 상당수가 청각이 정상인 부모에게서 태어나 부모가 수화를 할 줄 모르는 상황에서, 이 앱은 부모와 아이가 함께 수화와 독서를 배울 수 있도록 돕는다. 사용자가 아동 도서를 선택하고 스마트폰을 책 위에 대면, 'Star'라는 애니메이션 캐릭터가 실시간으로 텍스트를 수화로 번역하고 각 단어를 수화 순서대로 강조 표시하여 단어와 수화 사이의 연결을 만들어준다.

○패러트런

Parrotron은 Google의 Speech 팀과 Google Brain 팀이 공동으로 개발한 Parrotron은 2019년 4월 8일 논문이 arXiv에 게시되었고, 2019년 7월 17일 공식 블로그를 통해 발표되었다. 이는 2019년 5월 Google I/O 컨퍼런스에서 발표된 Project Euphonia의 연장선상에 있는 연구 프로젝트다.

Parrotron은 비정형적 말하기 패턴을 가진 사람들의 음성을 텍스트 생성 단계를 건너뛰고 직접 유창한 합성 음성으로 변환하는 시스템이다. 약 3만 시간의 익명화된 발화 쌍으로 구성된 코퍼스로 훈련되었으며, 입술 움직임 같은 시각적 단서가 아닌 음성 신호만을 고려한다. Google 연구 과학자이자 수학자인 Dimitri Kanevsky는 어린 시절부터 청각 장애를 가지고 있으며 러시아어 음성 표현을 사용하여 영어를 배웠기 때문에 일반적인 영어 화자와 상당히 다른 발음을 가지고 있다. 그가 녹음한 15시간의 음성으로 모델을 적응시킨 결과, Google의 자동 음성 인식(ASR) 시스템의 단어 오류율이 89%에서 32%로 크게 감소했다. 또한 근육 약화를 일으키는 근이영양증을 가진 Google 직원 Aubrie Lee는 1.5시간의 음성을 제공했으며, ALS(루게릭병) 환자의 음성에 대한 테스트도 진행되었다.

○ 엘리큐

ElliQ는 미국 내 65세 이상 혼자 사는 1,730만 명(노인 인구의 약 30%)의 사회적 고립 문제를 해결하기 위해 설계되었다. ElliQ는 이스라엘 텔아비브 소재 Intuition Robotics가 개발한 AI 기반 동반자 로봇이다. 2017년 런던 디자인 박물관에서 처음 출시되었으며, 삼성 NEXT가 초기 단계부터 투자한 포트폴리오 기업이다. 창립자이자 CEO인 Dor Skuler가 주도했으며, 유명 디자인 스튜디오 Fuseproject와 고령화 및 로봇공학 전문가들이 2016년부터 협력하여 개발했다. 제품 디자인은 애니메이션 스튜디오 Aardman이 참여했다. COVID-19 직전에 출시되어 팬데믹 기간 동안 고립된 노인들에게 큰 도움을 주었다.

뉴욕주 고령자청(NYSOFA)은 2024년 한 해 동안 800명 이상의 뉴욕 주민에게 ElliQ를 파일럿 프로그램으로 제공했으며, 외로움이 95% 감소하고 웰빙이 크게 개선되었다고 보고했다. 현재 플로리다, 뉴욕, 뉴저지 등 여러 주 정부가 필요한 노인들에게 무료로 제공하고 있다.

ElliQ는 단순히 명령을 기다리는 Amazon Alexa나 Google Home과 달리, 능동적으로 대화를 시작하고 활동을 제안하며 사용자가 말한 내용을 기억한다. 음성, 신체 언어, 텍스트, 이미지, 조명, 소리를 조합하여 자연스럽게 상호작용한다. 대화를 통해 기억을 추출하고 중요도와 관련성에 따라 분류하여 미래 대화에 맥락을 주입한다. 감정 상태와 가용성을 지속적으로 평가하여 능동적 의사결정에 활용한다. 또한 사용자에게 음성으로 뉴스, 날씨, 퀴즈를 제공하고, 음악을 들려주며, 게임을 함

께 하고, 정기적으로 먼저 연락하는, 마치 사람 동반자와 같은 역할을 하기도 한다.

다. 학문과 예술

1) 논리적 추론

최근 AI의 가장 놀라운 성과는 논리 추론에서 놀라운 성과를 보이고 있다는 것이다. 수학문제 풀이가 그 대표적인 예다. AI의 수학 문제 해결 능력은 단순 계산을 넘어 고난도 논증과 증명의 영역에서 인간의 최고 수준(엘리트 단계)에 근접해 있다.

고등학교 내지 대학 초급 수준의 수학 문제 풀이, 심지어 대입 수능 문제까지 거의 완벽하게 풀어낼 수 있는 수준에 도달해 있다. 특히 2024년 '은메달' 수준에 머물렀던 AI의 성능은 2025년을 거치며 국제수학올림피아드(IMO) 금메달 수준으로 도약했다. 현재 AI 수학 능력의 핵심 단계를 요약해 드린다.

2025년 7월, Google DeepMind의 Gemini Deep Think와 OpenAI의 o1(및 후속 모델) 계열은 IMO 문제 6개 중 5개를 완벽히 풀어냈다. 과거에는 사람이 문제를 컴퓨터 언어(Lean 등)로 번역해 줘야 했으나, 이제는 자연어와 수학기호로 표현된 수학 문제를 직접 이해하고 논리적인 풀이 과정을 생성한다.

답을 즉각 내놓지 않고, 내부적으로 수만 번의 시행착오를 거치는 추론(Reasoning) 모델 방식을 사용한다. 스스로 풀이 과정을 점검하고, 오류가 발견되면 논리를 수정하는 '자기 반성(Self-reflection)' 기능이 고도화되었다.

현재 AI는 단순 경시대회 문제를 넘어 전문적인 수학 연구자에게도 AI는 도움을 주고 있다.

- 정리 증명(Theorem Proving): 수천 개의 정리를 동시에 증명하거나, 인간이 수개월 걸릴 논증 과정을 몇 분 만에 완수한다.
- 전문 분야의 확장: 대수기하학, 수론 등 전문적인 분야에서도 논리적 결함이 없는 정교한 증명 초안을 작성한다.

그러나, 대학교 수준 이상의 난제나, 완전 자동 정리·증명은 아직 체계적 안정도가 높다고 보긴 어렵다, 일부 획기적인 해법을 찾아내는 경우도 관찰되고 있으나 수학적 엄밀성에서 오류를 범하는 경우도 자주 등장하고 있는 것이 현실이다.

☞ 고교 수준의 수학 문제가 포함된 다음 문제를 첨부해서 풀이를 지시하는 프롬프트를 입력하고 결과를 확인하라. (1번, 4번 문제에 대해서 AI가 추론을 적용하는

절차는 본교재 5장에서 상세히 설명하고 있다.)

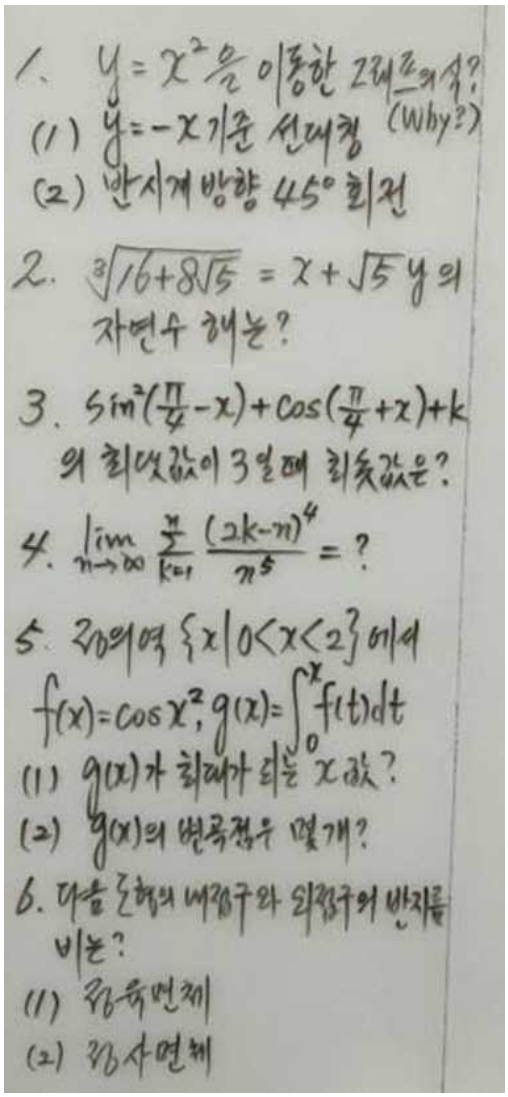

그림 1 AI 수학문제 풀이용 예제

문제 출처: 신정수

2) 학술 연구

학술 연구 결과를 논문으로 작성해서 출판하는 작업은 전문적, 논리적 심층 지식 탐구의 꽃이라고도 할 수 있다. 그만큼 그 절차가 엄밀하고 동원되는 수단들도 다양하다. 과거에는 연구자가 단독으로, 또는 공동연구자와 협업과 보조 연구자의 도움을 받아 오랜 시간 공을 들여야 일정 수준 이상의 품질을 갖춘 연구 논문을 작성할 수 있었다.

최근 AI의 도움으로 이 지난한 작업의 상당 부분이 비교적 수월하게 해결되어 연

구 생산성 제고에 기여하고 있다.

AI를 이용한 학술 연구논문 작성 이후, AI를 이용하지 않았을 때 대비하여 생산성이 향상된 실증 증거는 많이 제시되고 있다. 그 대표적인 내용은 <표 1>과 같다.

표 1 AI를 이용한 연구 논문 작성의 생산성 향상 사례

구분	실증 증거 및 수치	관련 문헌 근거 및 연구 사례
작업 시간 단축	초고 작성 및 편집 시간 약 37~50% 감소	Noy & Zhang (2023, Science): MIT 연구진의 실험 결과, chatGPT 활용 시 문서 작성 속도가 37% 향상됨을 입증했다.
언어 장벽 극복	비영어권 연구자의 영문 교정 비용 및 시간 대폭 절감	Casal & Kessler (2023): AI가 비네이티브 연구자의 학술적 문체 구현을 도와 투고 승인율을 높이는 데 기여함을 확인했다.
문헌 검토 효율	관련 문헌 탐색 범위 3~5배 확장 및 요약 시간 절감	Elicit/ResearchRabbit 사례: 수동 검색 대비 키워드 연결 및 시맨틱 검색을 통해 관련 논문 식별 효율이 급증했다.
코딩 및 데이터 분석	통계 분석 코드 작성 시간 최대 2배 이상 단축	GitHub Copilot/Gemini 활용: 연구용 데이터 정제 및 시각화 코드 생성 시 디버깅 시간이 획기적으로 줄어들었다.
아이디어 질 향상	브레인스토밍 단계의 아이디어 생성량 약 40% 증가	Girotra et al. (2023): 생성형 AI가 인간 단독보다 더 독창적이고 풍부한 연구 아이디어를 제안할 수 있음을 실험으로 증명했다.

출처: Gemini 조사, 2026-01-02 현재.

AI가 학술 연구에 도입된 이후, 드러난 큰 변화 중 하나는, 비영어권 국가 연구자들의 논문 생산성 향상이다. Science지에 게재된 "Scientific production in the era of large language models" 연구에 따르면, LLM 도입 이후 arXiv에서는 약 33%, bioRxiv와 SSRN 등에서는 50% 이상의 논문 생산성 향상이 관찰되었다. 특히 비영어권 국가 연구자들의 논문 게재가 약진했는데, 이는 AI가 언어 장벽을 해소함으로써 비영어권의 연구자들의 영문 논문 출판 기회가 훨씬 넓어졌기 때문인 것으로 판단된다[7].

한편 부작용을 드러내는 증거도 있다. 한 실증 분석에 따르면[8], 자연과학 전반의 논문 4,130만 편을 분석한 결과 AI를 활용한 과학자들은 논문 생산(3.02배), 인용(4.84배), 그리고 연구 리더(PI급) 전환 시점(1.37년 단축) 등에서 상당한 진전을 보였다. 반면, AI 도입 이후 연구 주제의 전체 범위는 4.63% 축소되고, 연구자들의 논문 간 후속 참여(engagement)가 22% 감소하는 경향이 관찰됐다. AI 기반 연구

7) https://www.science.org/doi/abs/10.1126/science.adw3000
8) https://www.nature.com/articles/s41586-025-09922-y

가 데이터가 풍부한 영역으로 집단적으로 쏠리면서, 새로운 영역을 탐험하기보다는 기존 영역을 자동화/최적화하는 방향으로 편향되는 부작용이 나타나고 있다. 연구 사례나 데이터 자체가 부족하여 AI 적용에 한계가 있는 특수한 주제들은 여전히 연구자 자신의 능력에 더욱 의존해야만 하고, 그들은 연구 업적의 양으로 연구 성과를 평가하는 프레임 아래에서 그런 연구는 외면 받을 가능성이 높다.

연구 및 논문 작성 작업은 단일 과업이 아니라, 하나의 작업 흐름(work flow)으로 이루어지는데, 작업 흐름의 각 단계마다 적절한 AI 도구를 동원하여 완수된다. 다양한 AI 도구를 이용하여 학술 논문 한 편을 완성하기 위한 작업 흐름을 대표적으로 예로 들면 <표 2>에 제시된 바와 같다.

표 2 AI를 이용한 논문 작성 작업 흐름 예시.

단계	세부 내용
과제 이해 및 계획 단계	✓ **주제선정 및 범위 탐색**: 주제 아이디어를 생성하고, 주제 범위를 설정함 → chatGPT와 Gemini를 활용하여 다양한 관점에서 주제를 탐색함
	✓ **연구질문 도출**: 연구주제에 대해 해결해야 할 질문 리스트를 도출함 → chatGPT와 Gemini 각각에게 연구주제를 주고 질문을 5개씩 뽑도록 함
	✓ **연구 계획 수립**: 연구 수행을 위한 단계별 계획을 수립함 → chatGPT와 Gemini에게 연구주제, 연구질문을 제시하고 구조화된 템플릿으로 연구계획서를 작성하게 함
과제 수행 단계	✓ **자료 조사**: 국내외 선행연구들을 수집하여 요약 정리함 → chatGPT나 논문 요약 AI를 활용하여 논문들을 자동 요약하고 해당 논문에 대해서 논의함
	✓ **데이터 분석 및 처리**: 엑셀, R, python을 활용하여 데이터 분석 및 의미를 해석함 → chatGPT에게 데이터를 주고 시각화 및 통계분석을 하도록 함
	✓ **논문 초안 작성**: 연구주제, 연구질문, 분석결과를 토대로 논문 초안을 작성함 → chatGPT, Gemini, Claude에게 지금까지 작성된 결과를 주고 논문 초안 작성을 위한 목차와 세부내용을 제시하도록 함
논문 작성 및 검토 단계	✓ **최종 논문 수정·보완**: 최종 논문에 대한 문법적 오류 수정, 문체 개선, 중복 / 불필요한 내용을 제거함 → chatGPT, Gemini, Claude에게 동일한 수정요청을 하여 공통적인 것은 반영하고 각기 다른 수정·보완 내용에 대한 검토를 실시함 ✓ **최종 검토**: 최종 논문을 chatGPT 등에 업로드하고 반론, 청중 입장에서 할 수 있는 질문 리스트를 작성하도록 함
참고문헌 정리 및 발표 준비	✓ **참고문헌 정리**: 최종 논문에서 원하는 참고문헌 스타일을 확인하고 작성함 → chatGPT 또는 참고문헌 정리 AI를 활용하여 APA 또는 MLA 스타일의 인용 및 참고문헌 목록을 자동 생성하도록 함 ✓ **프레젠테이션 준비**: 최종 논문을 Gamma를 활용해 초안을 만들도록 함

출처: 김규환, “책임 있는 AI 활용과 연구 혁신 - 연구 윤리 및 효율성 극대화”, 2025.12.09., 강연자료.

chatGPT, Gemini, Claude, Perplexity 등 범용 AI 서비스 외에, 각 단계 작업마다 특화된 다양한 AI 서비스가 보조적으로 활용되고 있다. 그 내용은 <표 3>과 같다.

표 3 연구 논문 작성용 다양한 AI 서비스

과업	특화 서비스명	기능
문헌 탐색 및 시각화	ResearchRabbit	관심 논문을 추가하면 유사 논문들을 네트워크 지도로 시각화하여 탐색을 돕는다.
문헌 검색 및 요약	Elicit	질문을 던지면 논문을 검색하여 핵심 내용을 요약하고 데이터를 표 형식으로 정리해 준다.
의미 기반 논문 검색	Semantic Scholar	논문의 영향력과 인용 관계를 분석하여 정확한 학술 정보를 제공한다.
문맥 기반 검색 및 인용 분석	Consensus, Scite	과학적 근거에 기반한 답변을 제공하거나, 인용 논문의 지지/반박 여부를 분석한다.
영문 교정 및 편집	Grammarly, Quillbot	문법 오류 수정 및 문장의 맥락을 유지하며 세련된 표현으로 재작성(Paraphrasing)을 돕는다.
서지 관리 및 인용 생성	Zotero, EndNote	수집한 자료를 관리하고 각 학술지 형식에 맞는 참고문헌 목록을 자동 생성한다.

출처: 위의 김규환(2025) 강연자료에서 정리.

특히 수량 분석, 통계 분석이 필요한 연구 분야(자연과학, 공학, 의학, 심리학, 사회과학 등)에서 역시 그에 특화된 AI 툴들이 다양하게 개발되어 있다. 과거에 널리 사용됐던 SAS, SPSS, R, Matlab 등은 그 과업에서 지금도 막강한 성능을 발휘하지만, 연구자가 직접 데이터 전처리와 구문 코딩을 직접 해야 했었다. 이런 번거로운 작업을 AI를 이용하여 편의성 측면에서 크게 개선한 다양한 AI 도구들이 있는데, <표 4>와 같다.

표 4 수량 분석 연구 특화된 AI 도구들

세부 과업 범주	AI 도구	기능
데이터 전처리 및 정제	Powerdrill, Flowtrail AI, OpenRefine, Trifacta	이상치(Outlier) 및 중복 자동 탐지, 결측치 보정 등을 통해 분석 전 데이터의 신뢰성을 확보함.
통계 분석 및 추론	Julius AI, Ajelix	자연어로 통계 분석을 요청하면 회귀분석, t-test 등을 수행하고 Python/R 코드로 검증한다.
데이터 시각화	Vizly, Polymer	업로드된 데이터에 적합한 차트 유형을 AI가 추천하고, 출판 가능한 수준의 고해상도 그래프를 생성한다.
설문 분석	Displayr, Standard Insights	마켓 리서치 및 설문에 특화되어, 설문 조사 데이터의 논리를 체크하고, 주관식 답변(Open-ended)을 정량적 수치로 자동 코딩하며, 교차 분석(Crosstabs)과 통계적 유의성 검정을 자동화한다.
예측 모델링 및 ML	RapidMiner, Qlik	코딩 없이 드래그 앤 드롭 방식으로 머신러닝 모델을 구축하고 시계열 예측을 수행한다.
스프레드시트 자동화	Ajelix, Formula Bot	Excel 및 Google Sheets 내에서 복잡한 수식을 생성하고 데이터 요약 보고서를 즉시 작성한다.

논문심사에도 학자들은 AI를 활용한다. Frontiers 출판사가 111개국 약 1,600명의 연구자를 대상으로 실시한 설문조사에 따르면, 응답자의 50% 이상이 논문심사 과정에서 인공지능(AI)을 활용한 경험이 있는 것으로 나타났다. 보다 구체적으로 살펴보면, 동료 심사에 AI를 사용한다고 답한 연구자 중 59%는 심사 보고서 작성에 AI를 활용한다고 응답했습니다. 또한 29%는 원고 요약, 미비한 부분의 파악, 참고문헌 확인을 위해 AI를 사용한다고 밝혔으며, 28%는 표절이나 이미지 중복과 같은 연구 부정행위의 가능성을 감지하는 데 AI를 활용한다고 답했습니다.

상당수의 학술지는 심사 대상 논문 파일을 인공지능 도구에 업로드하는 행위를 금지하는 편집정책을 유지하고 있다. 이러한 정책은 주로 저작권 침해나 민감한 데이터 유출 가능성을 우려하기 때문이다. 그러나, 이러한 정책이 실제 현장에서는 상징적 의미에 그치고 있으며 실효성이 없다[9].

※논문 심사 전문 AI에이전트

더 나아가서 논문 심사 기능을 전문적으로 갖춘 에이전트 AI 서비스까지 등장했

9) https://youtu.be/n4RjJKxsamQ?si=gmJ0MmltFswBfbpZ

다. 스탠포드의 한 학생은 논문이 계속 게재 거절당하고 피드백을 받는 기간도 수개월이 넘도록 걸리기도 하는 경험을 했다. 그는 이 비효율적인 논문 심사 루프가 말이 안 된다고 느껴 연구자들이 즉시 피드백을 받을 수 있는 논문 리뷰 에이전트 AI 페이퍼리뷰(https://paperreview.ai/)를 만들었다.

최신 대형 언어 모델(LLM)을 기반으로 문법 오류 수정은 물론, 연구 방법론의 타당성과 초록의 명확성 등을 심층 분석한다. 실제 학술지 심사 위원의 관점을 반영한 피드백을 제공하는 것이 특징이다.

대학원생과 연구자들 사이에서 논문의 통과 가능성을 높이는 사전 검토 도구로 활발히 이용된다. 특히 영어가 모국어가 아닌 연구자들에게 유용한 학술 영어 교정 수단이 된다.

3) 세부 연구 적용 사례: 신약개발

다양한 R&D 영역 중에서 신약 개발은 특히 AI가 크게 기여하고 있다. 신약 개발은 전통적으로 10-15년이 걸리고 투자액만 수십억 달러가 소요되는 지난한 과정인데, AI는 이 과정의 여러 단계에서 획기적인 효율화와 시간 단축을 가져왔다.

○ 후보 물질 발견 단계

이 중에서도 발견 단계가 실질적인 도움을 많이 받고 있다. 발견 단계에서 하는 일은 특정 질병에 반응하는 후보 물질 후보군을 탐색하는 일이다. AI는 수십억 개의 화합물 중에서 타겟 단백질에 결합할 가능성이 높은 분자를 예측하고, 새로운 분자 구조를 생성할 수 있다. 전통적 방법으로 수년 걸리던 과정을 몇 주로 단축시킬 수 있었다. 예를 들어ㅓ AlphaFold 같은 단백질 구조 예측 모델은 3D 단백질 구조를 정확히 예측하여 약물 설계의 정확도를 향상시킬 수 있다.

그런데 이렇게 탐색된 새로운 분자 구조는 자연에 이미 존재하는 물질이 아니라, 이론적으로 설계된 화학 구조에 불과하다. 이 분자들이 실제로 만들어질 수 있는지, 그리고 설령 만들어질 수 있다 하더라도 화학구조의 안정성이 부족해서 실효성이 떨어진다든지, 합성 경로가 너무 복잡하다든지, 합성 비용이 너무 커서 경제성이 없다든지 하는 것들은 별개의 문제다.

그래서 최신 신약 개발 용 AI 모델들은 합성 가능성(synthesizability)과 합성 난이도를 설계 단계부터 고려해서 작동한다. MIT의 ASKCOS, Insilico Medicine의 Chemistry42 같은 AI 모델이 그런 식으로 설계되어 있다. 합성이 불가능하거나 합성이 어려운 분자 구조는 이 모델에서 사전에 걸러낸다.

이렇게 선별된 합성 가능한 물질 중에서, 실험실에서 실제로 합성이 가능한지 테스트를 해보고 그 과정에서 성공한 물질들만 생물학적 임상 단계에 적용이 들어간

다.

경험적으로 AI가 제안한 흥미로운 분자 중 실제로 합성 가능한 것은 30-70% 정도에 불과하며, 합성이 가능하다 해도 합성 절차의 복잡성이나 합성 비용 때문에 대량 생산이 어려운 경우도 많다.

한편 이런 화학 구조 탐색에 보조적인 방법으로, 기존에 발표된 수백만건의 과학 논문을 대상으로 자연어 질의를 통해 질병-유전자-단백질 관계를 추출해 낼 수 있다. 이를통해 신 후보물질 탐색의 방향성을 보다 좁힐 수 있다.

○ 전 임상 시험 최적화

동물 실험에 들어가기 전에 약물의 독성, ADME(흡수·분포·대사·배설) 특성, 부작용을 예측하여 실패 가능성이 높은 후보를 조기에 걸러내야 하는데, 이때 AI 모델을 이용해서 독성을 예측(간독성, 심장독성 등)한다. AI를 활용하기 전에는 수많은 동물 실험이 필요했고, 임상 시험 단계에서 실패하는 경우가 많아 비용과 시간이 낭비되었다.(임상 실패율 약 90%).

○ 임상시험 설계 및 환자 선별

AI 기능을 이용하여, 전자건강기록(EHR)상 환자 데이터로부터 자연어 질의를 통해 적합한 환자를 빠르게 찾고, 시험 설계를 최적화하며, 실시간으로 시험 결과를 모니터링할 수 있다.

또한 환자의 유전체 데이터에서 예상되는 약물 반응을 미리 예측한다. AI가 도입되기 전에는 적합한 환자를 찾는 데 오랜 시간이 걸렸고, 부적절한 시험 설계로 인한 실패가 잦았다.

○약물 재창출 (Drug Repurposing)

기존에 승인된 약물을 새로운 질병 치료에 활용할 수 있는지 식별하는 데에도 AI는 크게 기여하고 있다. COVID-19 팬데믹 때 이 방법이 크게 주목받았다.

과거에는 기존 약물의 새로운 용도를 발견하는 것은 대부분 우연에 의존했다. 즉, 환자가 사용 중 우연히 부작용으로 새로운 효능을 발견하는 것이다. 예를 들어 간질약이 우연히 탈모치료제 효과가 있음을 발견하는 것과 같은 사례가 있다, AI가 구축한 약물-질병-유전자-단백질 관계망과 약물 반응 패턴을 이용해서 숨겨진 새로운 효능을 발견할 가능성이 크게 높아진다.

Insilico Medicine 모델이 설계한 특발성 폐섬유증 치료제가 30개월 만에 임상 2상 진입 (전통적으로 5-6년 소요)한 것이나, DeepMind의 AlphaFold가 2억 개 이

상의 단백질 구조 예측에 성공함으로써 구조생물학 연구 가속화한 것, 그리고 Exscientia 모델이 설계한 약물이 12개월 만에 임상시험 진입에 성공한 사례 등이 존재한다.

4) 예술

■ 음악 창작

2026년 현재, 인공지능 음악 창작은 실험적 단계를 넘어 음악 산업의 핵심 인프라로 완전히 자리 잡았다.

Suno가 WavTool 인수 후 선보인 'Suno Studio'와 같은 제너레이티브 DAW(Generative DAW)는 작곡부터 믹싱까지의 전 과정을 하나의 플랫폼으로 통합하며 기존의 분업 구조를 해체했다. Udio와 Stable Audio 역시 시각적 워크스테이션과 기업형 BGM 시장을 공략하며, 이제 AI는 가이드 수준을 넘어 즉각적으로 상업적 활용이 가능한 고품질의 음악을 쏟아내고 있다.

이들 AI 서비스는 텍스트를 음악으로 변환하는 생성형 AI 모델들은 작곡, 편곡, 가창을 포함한 완곡을 단 몇 초 만에 생성하며, 그 품질 또한 차트 상위권 곡들과 경쟁할 수 있을 만큼 비약적으로 발전했다. 이제 AI는 단순한 멜로디 생성을 넘어 악기별 트랙 분리(Stem separation), 실시간 마스터링, 나아가 특정 가수의 음색을 복제하는 보컬 클로닝 기술까지 완벽히 구현한다. 실제로 주요 스트리밍 플랫폼에는 매일 수만 곡의 순수 AI 생성곡이 업로드되고 있으며, 2026년 초에는 AI 아티스트가 빌보드 등 주요 차트에 진입하는 사례가 빈번해지며 기술적 완성도를 증명했다.

음악 산업 측면에서 AI는 제작 공정의 민주화를 불러왔다. 고가의 장비나 전문 교육 없이도 누구나 수준 높은 음악을 생산할 수 있게 되어 창작의 진입 장벽이 낮아졌고, 배경음악(BGM)이나 게임·광고 음악 시장은 이미 AI가 주도하는 저비용·고효율 구조로 재편되었다. 그러나 이러한 변화는 기존 음악인들에게 생존의 위협이자 기회라는 양면성을 띤다. 전문 작곡가와 연주자들은 AI와의 협업을 통해 창의성을 확장하는 '센타우르형 생산자'로 거듭나고 있지만, 동시에 라이브러리 음악이나 단순 루프를 제작하던 창작자들은 AI에 의한 대체와 수익 감소라는 현실적인 위기에 직면했다.

특히 음악인의 삶에 미치는 영향은 수익 구조와 저작권 문제에서 두드러진다. 2024년 발표된 연구 결과에 따르면, AI의 확산으로 인해 2028년까지 음악 창작자의 수익이 약 24% 감소할 것이라는 비관적 전망이 현실화되고 있다. AI 학습에 자신의 저작물이 무단으로 사용되는 것에 대한 법적 분쟁이 지속되고 있다.

☞ 영상: 인공지능 음악창작의 산업 부작용 Spotify 사태 https://youtu.be/lITe3a72xv0?si=Rt0QRcK_G7cB_Q_H

■ 미술 창작

AI 미술 창작은 기술적 정교함을 넘어 현대 미술계의 구조적 변동을 일으키는 핵심 동력으로 자리 잡았다.

미드저니(Midjourney)와 스테이블 디퓨전(Stable Diffusion) 같은 생성형 AI 모델들은 이제 단순한 이미지 생성을 넘어, 예술가의 의도와 감정적 어조까지 해석하는 수준으로 진화했다. 특히 3D 렌더링, 텍스트 기반의 고해상도 질감 구현, 그리고 멀티모달 기술을 통한 영상 및 음향과의 통합 제작이 가능해지면서, AI는 물리적 한계를 넘어서는 새로운 시각적 경험을 제공하고 있다.

미술 시장은 이러한 변화에 기민하게 반응하고 있다. 2026년 상반기 기준, 주요 순수 미술 경매의 약 35%가 AI 활용 작품을 포함하고 있으며, 전체 현대 미술 시장에서 AI 아트가 차지하는 비중은 5%를 넘어섰다. AI는 개인의 취향을 분석해 맞춤형 작품을 제안하는 큐레이션 서비스부터, 가상 현실(VR)과 결합한 몰입형 전시까지 시장의 외연을 확장하고 있다. 하지만 이러한 양적 팽창 이면에는 '평균의 붕괴'라는 냉혹한 현실이 존재한다. 고도의 전략적 기획력을 갖춘 상위 창작자들은 AI를 협업 도구로 삼아 생산성을 높이지만, 상업 일러스트나 단순 그래픽을 제작하던 중하위권 작가들은 AI의 저비용·고효율 공세에 밀려 시장에서 퇴출당하는 양극화 현상이 심화되고 있다.

예술가들의 삶 또한 '창작자'에서 'AI 통제자 및 비평가'로 그 역할이 재정의되고 있다. 작가들은 이제 AI 학습 데이터에 자신의 화풍이 무단 복제되는 저작권 분쟁의 최전선에 서 있으며, 2028년까지 시각 예술 분야의 수익이 약 20% 이상 감소할 것이라는 우려 속에 생존 전략을 고심하고 있다.

2. AI 현상 개요 II

가. 공급 형태의 분류

1) 서비스의 다양성과 차이

AI 서비스는 2022년 말 chatGPT의 첫 등장한 것을 계기로 2023년 이후 폭발적으로 증가해서 현재 그 수를 헤아릴 수 없을 정도로 많다. 이 모든 서비스는 저마다 강점을 지닌 특화 영역을 지니고 있다. 범용 서비스인 chatGPT, Gemini, Claude, Perplexity 조차도 이미지 생성 능력이냐 문서 작성이냐 등 강점이 있는 과업에서 차이를 드러낸다. 예를 들어 또한 동일한 프롬프트로, 서로 다른 서비스마다 수준이나 방향에서 차이가 있는 상이한 결과를 보주어, 어떤 한 서비스만을 고수하는 일의 위험성을 암시한다. 심지어 동일한 서비스 조차도 시점을 달리해서 동일한 프롬프트를 넣어도 결과는 다르게 나오기도 한다.

☞ 임의의 동일한 이미지 생성 프롬프트" !!! "로 다음 세 서비스에 대하여 실행해서 서로 다른 결과를 확인하라.

-제미나이-나노 바나나

-chatGPT-Dall E,

-포토샵-FireFly.

이런 상황에서 올바른 AI 모델 선택은 매우 어려워지고 있다. 각 모델은 특정 직업에 적합한 선택이 될 수 있는 명확한 강도를 가지고 있다. 예를 들어서 Gemini 3는 추론과 과학적 작업에 강점을 지니며, Google Workspace 전반에 걸친 업무를 효과적으로 지원하는 데 적합하다. ChatGPT-5.1은 일상적으로 사용하기에 가장 균형 잡힌 모델로, 글쓰기와 분석, 음성 처리, 코딩, 기획 등 다양한 작업 전반에서 안정적인 성능을 제공한다. 클로드 4.5는 깊이 있는 사고와 긴 문서 처리, 그리고 높은 수준의 기술적 정확성이 요구되는 상황에 특히 이상적이다.

Perplexity는 검증된 답변과 명확한 출처 제시를 중심으로 설계되어 연구나 시장 스캔과 같은 정보 탐색 작업에 필수적인 도구로 활용된다. DeepSeek-V4는 비용 대비 성능이 뛰어나며, 엔지니어링 팀이나 맞춤형 AI 환경을 구축하려는 경우에 적합하다. 그록 4는 라이브 데이터와 실시간 트렌드, 소셜 인사이트를 파악하는 데 유용한 모델이다.

코파일럿은 Microsoft 도구를 일상적으로 사용하는 팀 환경에서 자연스럽게 작동하도록 설계되었으며, Meta AI는 간단하고 빠른 응답을 강점으로 삼아 소셜 플랫폼

전반에서 즉각적인 작업을 처리하는 데 적합하다.

보다 자세한 내용을 조사하고 싶으면 이렇게 질문해볼 수도 있다.

☞ "현재 나와 있는 주요 LLM 서비스 별 최적 용도, 강점, 단점을 비교해서 표로 만들어줘"

누구든 어느 서비스가 어디에 장단점이 있는지 아는 것 자체는 중요하지 않다. 내가 수행해야 할 특수한 과업들이 어떤 서비스에서 상대적으로 잘 수행되는지를 판별할 수만 있다면 문제가 없다.

시행착오를 통해 선별하는 것이 가장 바람직하겠지만, 차선책으로 AI서비스에 내가 현재 수행하고자 하는 과업을 수행하기에 가장 적합한 서비스의 조합을 추천해 줄 것을 의뢰해보는 것도 효과적이다.

☞ "간략한 스토리 라인을 주면 그에 따라 10컷짜리 웹툰을 만들려고 한다. 현재 이 과업을 잘 수행하는 AI 서비스를 추천해줘."

☞ 아래 논리 문제를 여러 AI 서비스에 질의해보고 결과를 비교해보라.

문제: 다음 박스 1)~ 7)을 통해 알 수 있는 P에 대한 설명으로 맞는 것은?

1) P는 운동선수가 아니면 무용수이다.
2) 모든 무용수는 겉옷으로 흰색 재킷을 입는다.
3) P는 초록색 재킷을 입었다.
4) 만일 P가 운동선수라면 그는 미국인이거나 독일인이다.
5) 어느 독일인도 한국 생활 경험이 없다면 김치를 못 먹는다.
6) P는 김치를 먹을 줄 안다.
7) 한국 생활 경험이 있는 운동선수들은 모두 흰색 재킷을 입는다.

정답 후보:

① 독일인 무용수이다.
② 미국인 운동선수이다.
③ 무용수이면서 운동선수이다.
④ 한국 생활 경험이 없는 독일인이다.
⑤ 한국 생활 경험이 있는 미국인이다.

--> 이 문제의 정답은 무엇인가?

(출처: 신정수)

☞과제: 다음 논문을 다운로드 받아서, 2025년 8월 시점 기준 다양한 LLM 모델

사이에 성능 차이가 기능별로 어떻게 차이가 나는지 상세한 내용을 살펴보시오. 필요하면 NotebookLM 등으로 요약 및 번역을 권합니다.

Shiwen Ni, Guhong Chen, Shuaimin Li, Xuanang Chen, Siyi Li, Bingli Wang, Qiyao Wang, Xingjian Wang, Yifan Zhang, Liyang Fan, Chengming Li, Ruifeng Xu, Le Sun, Min Yang, "A Survey on Large Language Model Benchmarks", submitted at 21 Aug 2025 https://arxiv.org/abs/2508.15361 , HTML - https://arxiv.org/html/2508.15361v1

2) 폐쇄형 대 개방형

폐쇄형 AI는 AI 모델의 소스를 철저하게 비공개하는 것이다. 2022년 12월 첫 공개되어 생성형 인공지능 혁명을 촉발했던 chatGPT는 폐쇄형 서비스였다. 회사 이름이 '개방'을 뜻하는 OpenAI였던 것과는 사뭇 다른 방향이었다. 비영리 공익 목적으로 사용하겠다는 비전으로 출범한 OpenAI였지만, 샘 앨트먼은 철저하게 시장 원리에 따라 chatGPT를 하나의 상품으로서, 폐쇄형 서비스로 출범시켰다. 그래서 종종 그 회사는 OpenAI가 아니라 CloseAI라는 비판이 일기도 했다. 여하튼 chatGPT를 비롯하여 Claude, Gemini 등도 마찬가지로 폐쇄형 서비스로 태동했다.

반면에 개방형 AI는 그 소스를 공개해서 누구나 수정 보완해서 활용할 수 있도록 허용한다. 즉 소위 '오픈 소스(Open Source)'의 철학을 견지하는 서비스다. 페이스북 메타의 Llama, Stable Diffusion, 중국의 DeepSeek 등이 개방형 AI의 대표 주자들이다.

오픈소스와 폐쇄형 소스 AI 솔루션 사이에서 어떤 것을 선택할 것인지는 현대 기업과 개발자들에게 중요한 과제이다. 쿠크.

○개방형 AI

오픈소스 모델, 즉 개방형 AI 모델은 누구나 기존 기술을 바탕으로 새로운 기능을 개발할 수 있어 혁신과 협업을 촉진한다는 강점이 있다. 특히 기업의 특화된 요구에 맞춰 모델을 직접 커스터마이징하거나 미세 조정(Fine-tuning)할 수 있는 유연성을 제공한다.

보안 측면에서도 코드가 공개되어 있어 외부 감사를 통해 결함을 조기에 발견하고 해결할 수 있으며, 이는 투명성과 설명 가능성을 중시하는 윤리적 AI 지지자들에게 선호되는 이유가 된다.

비용 면에서는 겉으로 보기에 무료인 것처럼 보이지만, 실제로는 서버 설정, 운영, 최적화 과정에서 상당한 시간과 인적 자본이 투입될 수 있다는 점을 유의해야

한다.

또한 모형의 프로그래밍 구조를 이해하는 숙련된 AI개발자라 하더라도 기술적 진입 장벽이 높아 초기 설정이 어렵고, 공식적인 기술 지원이 없어 문제 발생 시 제3자 업체와 별도 계약을 맺어야 하는 번거로움이 단점으로 꼽힌다.

○폐쇄형 AI

반면, 폐쇄형 소스 모델(ChatGPT, Claude, Gemini 등)은 구독(subscription)형 또는 종량제 상용 제품으로서 뛰어난 접근성과 사용 편의성을 갖추고 있다. 전문적인 기술 지원과 정기적인 업데이트가 보장되며, 데이터 유출 방지와 체계적인 인증 시스템을 갖추고 있어 보안 관리 측면에서 유리한 면이 있다. 하지만 지속적인 구독료나 사용료로 인해 비용 부담이 크고, 소스 코드가 공개되지 않아 사용자 맞춤형 변경이 제한적이라는 한계가 있다. 또한 내부 동작 원리를 알 수 없는 '블랙박스' 문제로 인해 AI의 답변 도출 과정을 완벽히 설명하기 어렵다는 점도 문제로 지적된다.

결국 어떤 솔루션을 선택하느냐는 예산 규모, 자사의 기술적 전문성, 보안 및 규제 준수 요건, 그리고 기존 시스템과의 통합성을 종합적으로 고려하여 판단해야 할 문제이다. 내부 기술 역량이 충분하고 독자적인 맞춤형 개발이나 빠른 혁신이 핵심인 경우에는 오픈소스가 더 유리하다. 그러나 기술 인력이 부족하여 빠른 실행과 손쉬운 유지보수가 우선되거나, 금융이나 의료 분야처럼 엄격한 보안 규제와 책임 소재가 명확한 서비스가 필요한 경우에는 폐쇄형 소스를 선택하는 것이 바람직하다.

○ 개방형, 폐쇄형 간 전략 변경

최근에는 기존에 폐쇄형으로 운영되던 서비스가 일부 오픈소스 모형을 공개하기도 해서 주목을 끌고 있다. OpenAI는 2025년에 오픈 가중치 모델인 gpt-oss-20B와 120B를 전격 공개했다[10]. 이 모델은 H100 GPU 한 장만으로도 충분히 구동이 가능하여 개인이나 소규모 연구소에도 활용이 가능하고, 코드를 수정하여 맞춤형 과업에 적용할 있다는 특징이 있다. 그러나, 대규모 모델의 일부 기능, 예컨대 RAG(Retrieval-Augmented Generation)가 적용된 구조는 아니기 때문에 환각 현상을 방지하는 데 효과가 떨어진다는 단점도 있다. 그럼에도 불구하고,고성능 GPU를 장착한 서버급 개인 컴퓨터만 있으면, 데이터 보안 우려 없이 자신만의 AI 모델을 개발할 수 있는 흘륭한 수단이 도고 있다. 또한 오픈 소스의 아파치 2.0 라이선

10) https://openai.com/index/introducing-gpt-oss

스가 적용되므로, 파인튜닝 후 자신의 API를 개발하여 유료 서비스 모델로 활용할 수 있고, 원본 코드를 수정·재배포하는 것까지 모두 허용된다[11].

그밖에 구글 딥마인드는 같은 해에 최소 2GB RAM 스마트폰에서도 실행 가능한 초경량 모델 Gemma 3n을 오픈소스로 공개했다. 이 모델은 텍스트·오디오·이미지·비디오를 모두 처리하는 멀티모달 AI임에도 불구하고, 140개 언어 번역까지 지원하는 놀라운 성능을 갖추고 있다. 또한 중국의 알리바바가 멀티 에이전트 AI 애플리케이션 개발 프레임워크인 AgentScope를 역시 아파치 라이선스 오픈소스로 GitHub 공개 저장소에 공개했다.

반면에 페이스북은 기존의 개방형 전략을 재검토하고 폐쇄형 전략으로 전환할 것이라는 계획을 검토하고 있다. 메타는 2026년 중 아보카도(Avocado)라는 코드명의 차세대 모델을 개발 중인데, 이 모델은 Llama 시리즈와 달리 소스 코드나 가중치(Weights)를 공개하지 않는 폐쇄형 방식으로 출시될 가능성이 높다고 보고 있다. 이는 기존에 오픈소스로 공개한 Llama 모델이 중국의 DeepSeek 등 경쟁사들에 의해 기술적으로 활용되면서 내부적으로 보안 및 경쟁력 유출에 대한 우려가 커졌기 때문인 것으로 흔히 추정하고 있다.

※ 오픈 웨이트(weight) 모델

오픈웨이트 모델은 AI 학습의 최종 결과물인 '모델 가중치(parameter, 보통 수십억 ~ 수천억개에 이르는 구성원을 가지는 행렬의 복합체, 다차원 데이터 배열로서 텐서 tensor)'만을 공개하는 방식을 뜻한다. 이를 통해 구조적 검증과 재사용은 가능하지만, 학습 데이터 세트나 학습 코드, 데이터 필터링 기준 등 학습 과정 전반은 공개되지 않는 것이 일반적이다. 가중치만을 공개했을 뿐 소스가 공개되지 않는다는 의미에서 완전한 개방형이라고 볼 수는 없다. 앞에서 언급했던 메타(Meta)의 Llama 시리즈와 오픈AI(OpenAI)의 GPT-OSS 모델도 가중치만을 공개해서 부분 개방형 모델이라고 볼 수 있다.

3) 온프레미스 대 클라우드

많은 경우에 개인은 스스로 모델을 개발하고 데이터를 학습시켜서 자신의 과업에 활용할 필요가 없다. 다양한 무료 또는 유료 AI 서비스를 구독하면 대부분 충분하기 때문이다. 물론, 대학교나 가정 등에서 연구 목적으로 AI 개발을 하는 개인들도 있지만 그것은 예외라고 할 수 있다.

반면에, 기업의 경우 chatGPT나 Gemini 같은 범용 글로벌 AI 서비스를 구독해

11) https://huggingface.co/openai/gpt-oss-120b

서 사용하는 것으로 충분하다면 해당 사항이 없겠지만, 그 수준을 넘어서 자신의 사업 특성에 맞는 자체 모델을 개발해서 활용해야 할 경우가 있다. 이때 AI 하드웨어의 소유권과 통제 범위에 따라 구분되는 것이 자체 하드웨어(on-premise)와 클라우드 시스템이다. 이 둘 중 어떤 방식을 선택할지는 조직의 목적과 환경에 따라 달라진다.

○ 온프레미스 AI

온프레미스 방식은 기업이 물리적 서버(충분한 용량의 CPU, GPU, 저장장치)와 데이터를 자신의 사적 통제 하에 두는 것이다. 가장 큰 장점은 데이터와 인프라를 전적으로 자체 통제할 수 있다는 점으로, 특히 데이터 규제가 엄격한 산업에서는 큰 이점을 가진다. 반면 초기 하드웨어와 소프트웨어에 대한 투자 비용이 크고, 시스템의 구축·유지·보안·모니터링을 모두 조직 내부에서 수행해야 한다는 부담이 따른다. 또한 향후 확장성을 미리 예측해 투자를 결정해야 하며, 이를 운영할 전문 인력을 확보해야 한다는 점도 단점으로 작용한다.

※온프레미스 AI는 데이터 보안이 중시되는 사업에서 주로 채택한다.

○금융 및 국방: 개인정보나 국가 기밀 등 외부 유출이 절대 안 되는 민감 데이터를 다룰 때 사용한다. (예: 은행의 이상거래탐지시스템(FDS), 군사 시뮬레이션)

○제조 및 스마트 팩토리: 공장 내에서 실시간으로 불량품을 검사하거나 로봇을 제어해야 할 때, 네트워크 지연을 없애기 위해 현장에 서버를 둔다.

○의료: 환자의 민감한 의료 기록을 병원 내부망에서만 처리하여 보안 규정을 준수해야 하는 경우에 적합하다.

○클라우드 AI

클라우드 시스템은 Amazon, Google, IBM과 같은 글로벌 사업자의 하드웨어를 임대해서 사용하는 방식이다. 이 방식의 장점은 초기 진입 비용이 낮으며 빠른 구축이 가능하다는 데에 있다. 유연성과 확장성이 뛰어나 중소기업도 대규모 인프라 투자 없이 AI를 활용할 수 있다는 점에서 매력적이다. 그러나 특정 벤더에 대한 종속 위험이 존재해 가격 인상이나 서비스 중단과 같은 문제가 발생할 수 있으며, 이를 완화하기 위해서는 멀티 클라우드 전략이 필요하다. 또한 민감한 데이터를 외부에 저장해야 한다는 점에서 보안 우려가 제기될 수 있고, 사용량이 늘어날수록 비용이 급격히 증가할 가능성도 있다. 다만 벤더가 제공하는 비용 절감 방안을 활용하거나 장기 계약을 통해 가격 협상을 진행함으로써 이러한 부담을 일부 완화할 수 있다.

※클라우드 AI는 비용의 경제성, 속도, 또는 확장성을 중시하는 기업에서 주로 채택한게 된다.

○AI 스타트업 및 연구소: 고가의 GPU를 직접 사기 어려운 초기 단계에서 저렴하게 모델을 학습시키고 테스트할 때 활용한다.

○이커머스 추천 엔진: 블랙프라이데이처럼 트래픽이 폭증할 때 유연하게 서버 자원을 늘려야 하는 추천 서비스에 최적이다.

○생성형 AI API 서비스: ChatGPT나 Gemini 같은 대형 언어 모델(LLM)을 활용한 앱 개발 시, 이미 구축된 클라우드 인프라를 API 형태로 빌려 쓴다.

○ 하이브리드 hybrid AI

이 두 방식의 장점을 절충한 하이브리드 방식도 대안이 될 수 있다. 민감한 데이터는 온프레미스에 두고, 일반적인 응용과 서비스는 클라우드를 활용함으로써 비용·유연성·통제력 간의 균형을 도모할 수 있다. 다만 운영 환경이 복잡해지므로 내부 전문가가 필요하고, 지연(latency) 문제나 추가적인 보안 위험에 대해서도 별도의 평가와 관리가 요구된다.

4) LLM 대 SLM

chatGPT 등 이른바 대형 언어 모델(LLM)은, 모델의 파라메터(parameter) 수가 수천억개에 달하므로 대규모라고 한다. 그만큼 학습 및 훈련 시에 방대한 양의 GPU의 병렬 연산이 필요하다. chatGPT의 제반 모델 개발에 소요된 자원의 크기는 비공개이지만, 여러 자료를 종합하여 chatGPT가 정리해 준 정보는 <표>와 같다.

표 5 chatGPT 대규모 모델 개발 소요자원 추정

모델 계열	최초 공개 시점	파라미터 수(추정)	사용 GPU/가속기(주요)	GPU 수량(추정)	비고
GPT-3	2020	175B	NVIDIA V100 32GB	~1,000–3,000	OpenAI 논문에 파라미터 수 명시. 학습 인프라는 다수 인터뷰·보도 기반 추정
GPT-3.5 (ChatGPT 초기)	2022	~175B (미세조정)	V100 / A100 40GB	수천 대 규모	GPT-3 기반에 RLHF·SFT 대규모 적용
GPT-4	2023	비공개 (혼합전문가 MoE 추정)	A100 40–80GB	수만 대 규모(추정)	다수 소스에서 "MoE, 수만 GPU" 언급. 단일 파라미터 수 미공개
GPT-4 Turbo	2023	비공개	A100 / H100	수만 대 규모	효율 개선·지연 감소 중심
GPT-4o	2024	비공개	H100 중심	비공개	멀티모달 최적화, 실시간성 강화
ChatGPT-5.x (5 / 5.1 등)	2024–2025	비공개	H100 / H200	대규모 클러스터	차세대 스택, 학습·추론 통합 최적화

출처: chatGPT 질의에 대한 응답 2026-01-03.

구글의 여러 모델을 개발하는 데 소요된 자원 규모는 표와 같다. chatGPT와 다른 점은 NVIDIA의 GPU가 아니라, 구글이 자체 개발한 TPU(Tensor Processing Unit)를 사용한다는 점이다.

표 6 구글 대규모 모델 개발 소요자원 추정

모델 계열	최초 공개 시점	파라미터 수(추정)	사용 가속기(주요)	가속기 수량(추정)	비고
BERT	2018. 10.	3억 4,000만 (Large)	TPU v2 / v3	16 ~ 64개	초기 NLP 혁명을 이끈 모델로, 현재 기준으로는 매우 적은 자원으로 학습 가능
LaMDA	2021. 05.	1,370억	TPU v3	1,024개	대화형 AI의 시초 격으로, 대규모 소셜 데이터 학습에 최적화됨
PaLM	2022. 04.	5,400억	TPU v4	6,144개	두 개의 TPU v4 Pod을 병렬로 연결하는 효율적인 분산 학습 기법 도입
PaLM 2	2023. 05.	3,400억 (L)	TPU v4	수천 개 이상	이전 모델보다 파라미터는 줄였으나 데이터 품질과 학습 효율을 극대화함
Gemini 1.0 Ultra	2023. 12.	1.6조 ~ 1.8조	TPU v4 / v5p	수만 개 단위	구글 역사상 최대 규모의 인프라 투입. 대규모 멀티모달 학습 수행
Gemini 1.5 Pro	2024. 02.	2,000억 ~ 4,000억	TPU v5p	수만 개 단위	MoE(전문가 혼합) 구조를 채택하여 효율성과 성능(긴 문맥 처리)을 동시에 잡음

출처: Gemini 질의에 대한 응답 2026-01-03.

<표 6>에서 보듯이 대규모 모델은 기본적으로 파라메터의 수가 수천억개에 이른다. 그만큼 모델 개발에 방대한 규모의 GPU, 또는 TPU 연산장치가 필요하다. 반면에 소규모 언어 모델 SLM은 파라메터의 수가 수억 내지 수십억 개에 그치는 모델이다. SLM은 소수개, 심지어 1개의 GPU 또는 TPU로도 개발 및 구동할 수 있는 수준이다.

현재 나와 있는 SLM의 대표적인 것은 마이크로소프트의 Phi, 구글의 Gemma 3, 메타(페이스북)의 LLama 3.2를 들 수 있다(<표 7> 참조)

표 7 소규모 언어 모델(SLM)의 대표적인 예시

모델명	개발사	파라미터 수	하드웨어 소요 규모	주요 특징
Microsoft Phi-3-mini	Microsoft Research & Azure AI	3.8B	• GPU 메모리: 약 8-16GB• 파인튜닝 시: 최소 31.8GB RAM, GPU 40GB• 양자화 시: 2-4GB	• 합성 "교과서" 데이터로 학습• 추론 및 코딩에 강함• 엣지 디바이스 최적화• MIT 오픈소스 라이선스
Microsoft Phi-4	Microsoft Research & Azure AI	14B	• GPU 메모리: 약 28-56GB• 양자화 시: 7-14GB	• Gemini Pro 1.5 수준의 수학 능력• LLaMA, Mistral 능가• 저지연 추론 최적화• 2025년 1월 출시
Microsoft Phi-4-mini	Microsoft Research & Azure AI	3.8B	• GPU 메모리: 약 8-16GB• 양자화 시: 2-4GB	• Phi-3-mini의 후속 모델• 향상된 성능• 2025년 2월 출시
Microsoft Phi-4-multimodal	Microsoft Research & Azure AI	5.6B	• GPU 메모리: 약 12-24GB• 128K 컨텍스트 지원	• 텍스트, 이미지, 오디오 입력 처리• 멀티모달 기능• 2025년 2월 출시
Google Gemma 3 270M	Google DeepMind	270M (2억 7천만)	• GPU 메모리: 약 0.5-1GB (INT4)• 1-2GB (FP16)	• 가장 작은 Gemma 모델• 작업별 파인튜닝용• 극도로 에너지 효율적• 텍스트 전용
Google Gemma 3 1B	Google DeepMind	1B	• GPU 메모리: 약 2-4GB• 양자화 시: 1-2GB	• Pixel 9 Pro에서 배터리 0.75% 사용• 모바일 최적화• 텍스트 전용
Google Gemma 3 4B	Google DeepMind	4B	• GPU 메모리: 약 8-16GB• 양자화 시: 4-8GB	• 멀티모달 지원 (이미지+텍스트)• 128K 컨텍스트• 140개 이상 언어 지원
Google Gemma 3 12B	Google DeepMind	12B	• GPU 메모리: 약 24-48GB• 양자화 시: 12-24GB	• 멀티모달 기능• 함수 호출 지원• 중급 성능/효율 균형
Google Gemma 3 27B	Google DeepMind	27B	• GPU 메모리: 약 54-108GB• 양자화 시: 27-54GB	• 최대 성능의 Gemma 모델• 복잡한 추론 작업• Gemini 기술 기반
Meta Llama 3.2 1B	Meta AI Research	1B	• GPU 메모리: 약 2-4GB• 양자화 시: 1-2GB• 모바일 SoC 실행 가능	• 지금까지 가장 작은 Llama• 모바일/엣지 최적화• Qualcomm, Mediatek 협력• 128K 컨텍스트
Meta Llama 3.2 3B	Meta AI Research	3B	• GPU 메모리: 약 6-12GB• 양자화 시: 3-6GB• 모바일 SoC 실행 가능	• Gemma 2 2.6B, Phi 3.5-mini 능가• 다국어 대화 최적화 (8개 언어)• 에이전틱 검색/요약 특화• TensorRT-LLM 가속

출처: Claude 질의에 대한 응답, 2026-01-02.

대형 언어 모델(LLM)은 다양한 과제에서 인간에 근접한 성능을 보이고 일반적인 대화를 수행할 수 있는 능력으로 종종 높은 평가를 받아왔다. 그러나 최근 에이전틱(Agentic) AI 시스템이 부상하면서 언어 모델이 소수의 특화된 작업을 큰 변동

없이 반복적으로 수행하는 새로운 응용 영역이 대거 탄생하고 있다.

이런 추세에서 소규모 언어 모델(SLM)이 에이전틱 시스템에서의 활용도가 매우 높을 뿐아니라 필연적으로 더 경제적일 것으로 보인다. 현재 SLM이 보여주는 역량 수준, 에이전트형 시스템의 일반적인 아키텍처, 그리고 언어 모델 배포의 경제성은 충분히 확인된 바 있다. 또한 범용적인 대화 능력이 필수적인 상황에서는 여러 서로 다른 모델을 호출하는 이종(heterogeneous) 에이전트형 시스템이 자연스러운 선택이 될 것이다[12].

5) 단일 대 멀티 에이전트

단일 에이전트(Single Agent)는 하나의 인공지능 개체가 모든 판단과 행동을 독자적으로 수행하는 반면, 멀티 에이전트 시스템(MAS: Multi Agent System)은 여러 개의 특화된 에이전트가 협력하거나 경쟁하며 복잡한 목표를 달성한다.

초기 생성형 AI는 단일 에이전트 형태로 과업을 처리했지만, 최근에는 멀티 에이전트 방식으로 과업 처리 성격이 변해가고 있다. 이 대비는 마치 개인 대 기업조직의 관계와 같다. 기업 조직은 상이한 지식 영역(마케팅, 영업, 연구개발, 생산, 재무, 교육훈련, 기획, 행정 등)을 담당한 여러 개인들이 하나의 기구 아래 계약 관계로 연합한 것이다. 피터 드러커는 기업 조직의 기능이 '한 명의 천재'가 아니라 '다수의 평범한 사람들이 모여서 비범한 성과를 내도록 하는 것'이라는 말을 한 적이 있다.

이런 일이 AI 세계에서도 일어나고 있는 것이다. 즉 , 단일 에이전트는 만능 전문가 한 명이 모든 일을 처리하는 1인 기업과 같다. 반면에 멀티 에이전트는 기획자, 개발자, 분석가 등 각 분야 전문가들이 모인 팀 프로젝트와 같다.

▪ 단일 에이전트가 적합한 경우: 이메일 요약, 번역, 단순 챗봇, 고정된 API 호출 기반 작업 등 선형적인 워크플로우를 가질 때이다.

▪ 멀티 에이전트가 적합한 경우: 질적으로 상이한 성격의 여러 과업이 순차로, 또는 병행해서 이루어져야 할 경우가 적합하다. 다음과 같은 예를 들 수 있다.

○ 공급망 관리 및 물류 최적화 (Supply Chain Management)

---

12) Peter Belcak, Greg Heinrich, Shizhe Diao, Yonggan Fu, Xin Dong, Saurav Muralidharan, Yingyan Celine Lin, Pavlo Molchanov, "Small Language Models are the Future of Agentic AI" submitted on 2 Jun 2025, https://arxiv.org/abs/2506.02153

- 재고 관리 에이전트: 창고별 재고 수준을 모니터링하고 부족분을 파악한다.
- 배송 최적화 에이전트: 교통 상황과 날씨를 고려하여 최적의 운송 경로를 계산한다.
- 수요 예측 에이전트: 과거 판매 데이터와 시장 동향을 분석해 미래 수요를 예측한다.

○ 소프트웨어 개발 자동화 (AI 소프트웨어 엔지니어링 팀)
- 요구사항 분석가: 사용자의 모호한 요청을 기술 사양서로 구체화한다.
- 코드 작성기: 사양서를 바탕으로 실제 소스 코드를 구현한다.
- 리뷰어/테스터: 작성된 코드의 버그를 찾고 최적화 방안을 제시한다.

개인 또는 기업이 멀티 에이전트 시스템을 구축하기 위한 도구로는 Microsoft AutoGen,
CrewAI, LangGraph (LangChain), OpenAI Swarm 등이 사용되고 있다.
특정 직무군(소프트웨어 개발 등)이나 특정 목적(기업용 워크플로우 협업 관리 등)을 위한 멀티 에이전트도 다양한 형태로 출시되어 있다.(<표> 참조)

표 8 멀티 에이전트 서비스 예시

서비스 명	주요 특징 및 역할 분담	주요 대상
ChatDev	CEO, CTO, 프로그래머, 테스터 에이전트가 가상의 소프트웨어 회사를 구성하여 앱을 개발한다.	소프트웨어 개발 자동화
Cognition (Devin)	세계 최초의 AI 소프트웨어 엔지니어로, 내부적으로 여러 추론 및 실행 에이전트가 협력하여 코딩 과제를 완수한다.	전문 개발 및 디버깅
Microsoft Copilot Studio	기업 내 다양한 데이터 소스를 연결하고, 각 부서별 에이전트를 만들어 협업 체계를 구축할 수 있게 돕는다.	기업용 업무 워크플로우
MultiOn	웹 브라우징 에이전트들이 협력하여 항공권 예약, 쇼핑, 정보 검색 등 실생활 작업을 대신 수행한다.	웹 기반 작업 자동화

Gemini 2.5 Deep Think는 기존의 단일 AI 모델로는 달성할 수 없던 성과를 멀

티 에이전트 식 구조를 모델에 도입함으로써 이루어냈다. 단일한 사고 경로를 따르지 않고, 여러 가상의 에이전트가 동시에 협력하는 듯한 '병렬 추론'을 수행한다.

- 전문가 혼합(MoE: Mixture of Experts) 구조: MoE는 하나의 레이어 또는 연산(예: 선형 레이어, MLP 또는 attention projection)의 계산을 여러 개의 “전문가(expert)” 하위 네트워크로 분할하는 신경망의 아키텍처 패턴이다. 이러한 하위 네트워크는 각각 독립적으로 자체 연산을 수행하며, 그 결과를 결합하여 MoE 레이어의 최종 출력을 생성한다. 하나의 문제에 대해 여러 해결 가설을 동시에 생성한다. 이는 내부적으로 전문화된 에이전트들이 각자의 관점에서 해법을 제시하는 것과 유사한 효과를 낸다.

- 추론 시간(Thinking Time)의 활용: 기존 AI가 입력 즉시 답을 내던 것과 달리, Deep Think는 여러 번의 사고와 검증 과정을 통해 다양한 가설을 실험하고, 가장 설득력 있는 해법을 채택한다. 복잡한 문제일수록 최대 30분까지 '생각'하는 시간을 갖는다. 이 과정에서 각 사고 분기(Branch)들이 서로의 논리를 검토하고 결합하여 최적의 답을 도출한다.

6) AI 앱 서비스 거래 시장

chatGPT, Gemini, Claude 등 범용 AI의 API(애플리케이션 프로그래밍 인터페이스) 또는 SDK(소프트웨어 개발 키트)가 공개되면서 많은 개발자들이 이들을 활용한 AI 앱 개발에 뛰어들고 있다. 그렇게 개발된 다양한 수많은 앱들은, 마치 애플의 앱스토어나 구글의 플레이스토어와 성격이 비슷한 AI 앱 거래소(exchange market) 내지 온라인 쇼핑몰에서 구매할 수 있다. 사용자는 이를 통해서 자신의 비즈니스에 필요한 에이전트를 즉시 고용(구독)할 수 있다. 대표적인 것들로는 다음과 같은 것들이 있다.

- GPT Store: OpenAI의 공식 스토어로, 전 세계 사용자가 만든 수십만 개의 맞춤형 GPT를 이용할 수 있다. chatgpt.com/gpts
- Agent.ai : 영업, 마케팅, 고객 지원 등 실무형 AI 에이전트를 고용하거나 판매할 수 있는 전문 마켓플레이스이다. agent.ai
- AWS Marketplace: 기업용 환경에 특화된 보안이 검증된 대규모 AI 솔루션과 에이전트를 거래한다. aws.amazon.com/marketplace
- AI Agent Store: 다양한 분야의 AI 에이전트들을 카테고리별로 모아놓은 종합 디렉토리 및 마켓플레이스이다. aiagentstore.ai
- Lyzr AI Marketplace: 기업의 워크플로우 자동화에 최적화된 에이전트들을 전문적으로 취급한다. lyzr.ai/marketplace

한 편, 특화된 사용자 층이나 특수 기능에 중점을 둔 AI 앱을 구독할 수 있는 플랫폼은 다음과 같다.

- 개발/자동화 LangChain Hub: 에이전트 설계도(Prompt, Chain)를 공유하는 개발자 중심의 허브이다.smith.langchain.com/hub
- 영업/비즈니스 Artisan AI: 'Ava'와 같은 디지털 영업 사원 에이전트를 고용할 수 있는 플랫폼이다.artisan.co
- 비즈니스 통합 AgentExchange: Salesforce 생태계 내에서 작동하는 비즈니스용 에이전트들을 거래한다.salesforce.com/agentexchange
- 노코드 구축Lindy.ai: 코딩 없이 나만의 AI 비서(Lindies)를 만들고 활용하는 플랫폼이다.lindy.ai

한편, 팰로(Fello, https://www.fello.io/products)도 AI 앱 서비스 모델 거래소라고 볼 수 있으나, 비즈니스를 사고 파는, 즉 M&A를 목적으로 하는 특수한 쇼핑몰이라고 볼 수 있다.

소규모 앱, SaaS, 웹 서비스, 온라인 비즈니스 등 다양한 디지털 제품을 판매 리스트로 등록하고, 구매자가 그 서비스(프로덕트)를 인수하거나 거래할 수 있도록 한다. 최근에 이르러 AI 기능을 갖춘 서비스의 비중이 크게 늘어나고 있는 중이다.

나. 오남용과 위험성 개관

1) 환각(hallucination)

환각은 말 그대로 존재하지 않는 사실을 마치 있는 것처럼 보여주는 현상이다. 생성형 AI의 결과물이 구조적으로 피할 수 없는 태생적 결함이다. 가장 문제가 되는 경우다 올바른 사실(fact)과 근거를 바탕으로 논리적인 정보를 생성해야 할 때이다. 이때, AI는 가끔씩 완전히 그릇된 정보를 포함하거나 논리적으로 허황된 답변을 제시하는 경우가 있다. AI가 생성한 다음 문장은 얼핏 보면 그럴듯 하지만, 분명히 오류라는 것을 누구가 알 수있다.

"마이클 잭슨은 비록 BTS를 직접 만난 적은 없었지만 그 음악 세계를 깊이 인정하고 존중하면서 많은 요소를 자신의 작품에 차용하기도 했다."

특히 일반인은 유추할 수 없는, 전문 분야의 내용에서 이런 미묘한 오류를 포함한 답변이 나올 가능성은 항존한다. 그 오류는 오직 그 내용과 관련된 전문 지식을 갖

춘 사람람만이 발견해낼 수 있으며, 그렇지 않은 비전문가들은 자칫 검증 없이 이를 그대로 받아들일 위험이다.

물론 사실 기반이 아니라 창의적인 영상 콘텐츠를 자유롭게 생성하는 경우에는 이런 허황됨 자체가 치명적인 결격이 되지는 않는다고 볼 수 있지만, 이 환각 문제는 생성형 AI가 앞으로 해결해야 할 근본 문제로 간주되고 있다. 특히 허위 사실임에도 불구하고 외견상으로 매우 매끄러운 문장으로 그정보가 제공되면, 사용자들은 그 사실을 참인 것으로 대부분 착각하게 된다는 데에 문제의심각성이 있다.

☞ 환각의 부작용:

예를 들어 학술 연구 분야에서, 생성형 AI는 실제로 존재하지 않는 학술 논문과 저널을 제시하고 이들이 실제 학술 논문에서 인용되는 사례가 확산되는 사태가 발생하고 있다. 이러한 가짜 논문이 거기에서 끝나는 것이 아니라, 다른 연구에서 다시 인용되는 과정이 반복된다는 점이다. 사실 이런 허위 인용을 걸러내야 하는 새로운 과제에 직면하고 있다[13]. 특히 첨단 과학 연구 과정에서 오류를 범할 수 있어, 그 분야의 도메인 지식(Domain Knowledege)를 지닌 전문가가 반드시 검토를 해야 할필요성이 더욱 커지고 있다.

의료에서는 AI가 존재하지 않는 진단 근거·논문을 제시해 오진과 치료 지연을 유발할 수 있고, 법률에서는 허위 판례·조항을 생성해 잘못된 법적 판단을 초래한다. 금융에서는 가짜 지표·수치를 만들어 투자 손실을 키울 수 있다.

○환각이 발생할 수밖에 없는 구조적 원인

환각(hallucination)은 대규모 언어모델이 사실을 조회·검증하는 시스템이 아니라, 확률적으로 연결 가능성이 높은 다음 토큰(next token)을 생성하여 연결하는 구조를 갖기 때문에 발생할 수밖에 없다[14].

모델은 입력과 학습 데이터 분포를 바탕으로 언어적 일관성을 최우선으로 최적화되며, 실제 세계의 진위 여부나 최신성, 맥락 외부의 사실을 직접 확인하지 못한다.

또한 학습 데이터의 불완전성·편향·공백이 존재하고, 질문이 모호하거나 과도한

---

13) https://www.rollingstone.com/culture/culture-features/ai-chatbot-journal-research-fake-citations-1235485484/

14) 최근 오픈AI는 언어 모델이 환각을 일으키는 근본 원인을 규명한 논문 Adam Tauman Kalai, Ofir Nachum, Santosh S. Vempala, Edwin Zhang, “Why Language Models Hallucinate” September 4, 2025를 발표했다. https://cdn.openai.com/pdf/d04913be-3f6f-4d2b-b283-ff432ef4aaa5/why-language-models-hallucinate.pdf

이 논문은 AI 모델의 환각 현상이 단순한 기술적 결함이 아니라 현행 딥러닝 개발 패러다임에서 비롯된 필연적 결과임을 입증했다.

추론을 요구할수록 모델은 공백을 “추정”으로 메우게 된다. 여기에 보상학습(RLHF)이 유창성과 만족도를 강화하면서 불확실성을 명시적으로 거부하기보다 답을 생성하도록 유도하는 점도 환각을 구조적으로 증폭시킨다.

○ 환각을 최소화하기 위해 시도되는 다양한 방법

환각을 완전히 제거할 수는 없지만 최소한 다음과 같은 여러 방법으로 통해 최소화에 보다 근접할 수 있다.

- **사람 전문가의 검토**: 이는 가장 본원적이면서도 최우선적인 방법이다. AI 응답에 대한 인간의 지속적인 검토와 피드백을 시스템에 통합하는 것이 중요하다. 생성된 내용을 해당 분야의 전문가가 사실 여부나 논리적 오류를 검증하고, 이를 학습 데이터로 활용하여 모델을 개선한다. 또한 중요한 결정이나 전문적인 내용에는 반드시 사람의 최종 검토 단계를 거치도록 워크플로우를 설계해야 한다. 이러한 인간-AI 협업 체계는 환각 현상을 조기에 발견하고 수정할 수 있게 하며, 시간이 지날수록 시스템의 신뢰성을 향상시킨다.
- **벤치마크 시스템을 보완하는 방법**: 예를 들어 ‘명시적 신뢰도 목표(Explicit Confidence Targets)’를 도입하는 것을 들 수 있다. 가령 프롬프트에 “정답 확신이 90% 이상일 때만 답하세요. 오답 시 9점 감점됩니다”와 같은 규칙을 명시하여, 모델이 무조건 추측하기보다 자신의 확신 수준이 기준을 충족할 때만 답변하도록 유도하는 방식이다.
- **검색 증강 생성(RAG: Retrieval-Augmented Generation) 활용**: 검색 증강 생성은 AI가 응답을 생성하기 전에 신뢰할 수 있는 외부 데이터베이스나 문서에서 관련 정보를 먼저 검색하여 참조하는 방식이다. 이 방법은 AI가 학습 데이터에만 의존하지 않고 실시간으로 검증된 정보를 활용할 수 있게 한다. 특히 최신 정보나 특정 도메인의 전문 지식이 필요한 경우에 효과적이며, 응답의 근거를 명확히 제시할 수 있어 환각 현상을 크게 줄일 수 있다. 기업 내부 문서나 전문 데이터베이스와 연동하면 더욱 정확한 답변이 가능하다.
- **프롬프트 엔지니어링 최적화**: 명확하고 구체적인 지시사항을 포함한 프롬프트를 작성하면 AI의 환각을 줄일 수 있다. 응답 형식을 지정하고, 불확실한 경우 모른다고 답하도록 명시하며, 단계별 추론을 요청하는 것이 효과적이다. 또한 역할을 부여하거나 예시를 제공하면 AI가 맥락을 더 잘 이해하여 정확도가 높아진다. 특히 "확실하지 않으면 추측하지 말고 모른다고 답하라"는 지시를 포함하면 AI가 근거 없는 정보를 생성하는 것을 방지할 수 있다.

※ 팔란티어 온톨로지와 환각 현상 감소 가능성

팔란티어(Palantir)는 2003년 피터 틸, 알렉스 카프, 조 론스데일, 스티븐 코헨, 네이선 게팅스가 설립한 빅데이터 분석 전문 소프트웨어 회사다. BritannicaMedium 페이팔의 사기 탐지 기술에서 영감을 받아 9/11 테러 이후 금융 거래 추적을 통한 테러 방지라는 사회적 사명에서 출발했다. Medium CIA 산하 벤처캐피탈 In-Q-Tel의 초기 투자를 받아 정보기관과 국방 분야를 위한 Gotham 플랫폼을 구축했다.

일반적으로 온톨로지(Ontology)는 철학에서는 '존재론(Knowledge on Beings)'을 의미하나, 컴퓨터 공학에서는 '사물, 정보, 지식의 분류론'을 의미한다. 위계 구조의 생물분류 체계나 동의어-반의어-용법 등이 충분히 기술된 사전(dictionary)은 매우 단순한 형태의 온톨로지 표현이라고 할 수 있다. 디지털 시대에 온톨로지는 상호 연결되어 있는 다양한 개념들을 체계적으로 표현하는 구조, 공식적으로는 "어떤 관심 분야를 개념화하기 위해 명시적으로 정형화한 명세서(an explicit and formal specification of a conceptualization of a domain of interest)'[15]로 정의될 수 있다.

팔란티어는 자신만의 고유한 개념 분류 체계를 가지고 모든 데이터를 거기에 대응시킨다. 플랜트나 장비 같은 물리적 자산부터 주문이나 금융 거래 같은 개념까지 실세계 대응물과 연결하며, 객체 타입, 속성, 링크 같은 시맨틱(semantic) 요소와 액션, 함수 같은 동적 요소를 포함한다.

팔란티어 온톨로지는 단순히 토큰의 확률적 생성 기제를 수행하는 LLM을 조직의 신뢰할 수 있는 데이터, 로직, 액션에 연결함으로써 환각의 가능성과 영향을 줄인다고 알려져 있다.

첫째, 온톨로지가 신뢰할 수 있는 데이터 소스로 작용하여 LLM을 조직의 특정 맥락에 그라운딩한다. AIP Logic에서 LLM에게 온톨로지 객체를 쿼리할 수 있는 도구를 제공하면, 사용자 프롬프트에 온톨로지 메타데이터를 추가하여 LLM이 검색 쿼리를 생성하고 온톨로지에 대해 실행할 수 있도록 안내한다.

둘째, 온톨로지 내 커스텀 함수를 통해 LLM이 수행하기 적합하지 않은 특정 논리적 작업을 위임할 수 있다. 예를 들어 거리 계산 같은 작업에서 LLM이 잘못된 답을 환각하는 대신 커스텀 함수에 의존하게 함으로써 전체 Logic 함수의 환각 가능성을 더욱 줄인다.

셋째, 의사결정 계보 전체가 자동으로 포착되고 인간 개발자와 생성형 AI 모두 안전하게 접근할 수 있어, AI 주도 학습을 대규모로 구동할 수 있는 포괄적인 기반을 제공한다. 이를 통해 AI가 제안한 결정에 대해 적절한 감독과 통제를 보장하면서도

15) Tomas R. Gruber, 1993, A Translation Approach to Portable Ontology Specifications, Knowledge Systems Laboratory Technical Report KSL 92-71, Stanford University, Knowledge Systems Laboratory.

생성형 AI를 활용할 수 있다.

2) chatBot 지식의 피상성

AI에 대해 질의를 통해 얻은 지식은 가장 평균적이면서도 보편적인 정보를 조합해서 제시될 가능성이 높다. 자신만의 목적에 맞는 수준 높은 지식, 또는 깊은 지식은, 비록 프롬프팅을 정밀하게 제시함으로써 어느 정도는 획득 가능할지 몰라도, 인터넷 상에 공개되지 않은 특수 정보 또는 고급 정보는 원천적으로 접근이 불가능하고 암묵지(tacit knowledge) 수준으로 형성된 지식에 대해서는 아직도 표현이 어렵다. 세상의 모든 지식 가운데 인터넷 상에 공개된 지식은 지극히 일부분에 불과하다.

또한 AI는 이미 패턴이 확립된 지식 영역에서는 사람보다 탁월한 해결 능력을 보유하지만, 불확실한 상황에서 의사결정을 조율하는 능력은 사람보다 미흡하다. 최근 LLM들은 충분한 정보가 주어질 때 단순 진단 과제에서 85% 이상의 정확도를 보이며 개별 의사들의 진단 정확도를 일반적으로 능가한다. Medium GPT-4는 USMLE 스타일 문제에서 67.6% 정확도로 이전 최고 성능을 17% 이상 초과했으며, NBME 임상 과목 시험에서 100% 정확도를 달성한 사례도 있다. QuoraApoorv03 그러나 표준 의료 면허 시험이 동적 맥락에서 임상의들이 의사결정을 업데이트하는 방식을 평가하지 못한다는 한계가 있으며, 불확실성 하에서 판단을 조율하는 능력을 측정하는 스크립트 일치 검사에서 LLM들의 성능이 현저히 낮았다. Palantir 최고 성능의 o3 모델도 67.8%에 그쳤고, 모델들은 의대생 수준과 유사하거나 이를 초과했지만 전공의나 전문의 수준에는 도달하지 못했다. Palantir 응급실 임상 노트를 사용한 실제 임상 권고 과제에서 GPT-4와 GPT-3.5는 전공의에 비해 각각 평균 8%, 24% 낮은 정확도를 보이며 과도하게 신중한 경향을 나타냈다. Palantir 결론적으로 명제는 정확하며, LLM이 지식 기반 시험에서는 탁월하지만 맥락적 불확실성 속에서 판단을 조율하는 임상 추론 능력은 여전히 초보 임상의 수준에 머물러 있다[16].

---

16) Chicago Style 참고문헌

1. LLM 진단 정확도 연구는 Nature Communications. "Quantifying the Reasoning Abilities of LLMs on Clinical Cases." Nature Communications 16 (2025). https://doi.org/10.1038/s41467-025-64769-1. GPT-4의 USMLE 성능은 Singhal, Karan, Shekoofeh Azizi, Tao Tu, S. Sara Mahdavi, Jason Wei, Hyung Won Chung, Nathan Scales, et al. "Large Language Models Encode Clinical Knowledge." Nature 620, no. 7972 (2023): 172-80. https://doi.org/10.1038/s41586-023-06291-2. ,
   Nori, Harsha, Nicholas King, Scott Mayer McKinney, Dean Carignan, and Eric Horvitz. "Capabilities of GPT-4 on Medical Challenge Problems." arXiv preprint arXiv:2303.13375 (2023). https://www.microsoft.com/en-us/research/uploads/prod/2023/03/GPT-4_medical_benchmarks.pdf. 스크립트 일치 검사 성능은 "Assessment of Large Language Models in Clinical Reasoning: A Novel Benchmarking Study." NEJM AI 2, no. 2 (2025). https://doi.org/10.1056/AIdbp2500120. 응급실 임상 권고 연구는 Williams, Cyrus Y. K., Brian Y. Miao, Aaron E. Kornblith, and Atul J. Butte. "Evaluating the Use of Large Language Models to Provide Clinical Recommendations in the Emergency Department." Nature Communications 15 (2024): 8468.

3) 모델 붕괴

모델 붕괴(Model Collapse)란 AI가 생성한 데이터를 훈련용으로 재투입할 경우에 발생하는 현상이다. AI 모델 개발 초기에는 학습용으로 투입되는 데이터가 모두 사람이 작성한 문서 또는 영상이었다. 그리고 이 데이터는 대부분 인터넷 상 공개된 기사, 문학작품, 블로그 등에서 취해왔다. 그런데, 오늘날 유튜브는 물론이고 상당수의 웹사이트와 블로그 문서가 사람이 직접 생산한 것이 아니라, AI가 생성한 것들로 채워지고 있다. 인터넷 상에서 AI가 학습용 데이터를 수집할 때 그 안에 얼마나 많은 AI 생성물이 포함되어 있을 것인가?

AI 모델이 AI가 생성한 출력물을 반복적으로 훈련에 재투입할 때 시간이 지남에 따라 모델이 실제 데이터 분포를 망각하게 되는 현상이 발생한다. 초기 단계에서는 분포의 꼬리 부분, 즉 소수 데이터에 대한 정보를 잃기 시작하고, 후기 단계에서는 모델의 분산이 극도로 줄어들어 델타 함수처럼 하나의 점으로 수렴한다. 확률이 높은 사건은 과대평가되고 드문 사건은 과소평가되며, 세대가 거듭될수록 오류가 복합적으로 누적되어 데이터 분포가 실제와 점점 더 멀어진다[17]..

■ 문서(텍스트) 생성의 진부화, 평범화

언어 모델에서 재귀적으로 생성된 텍스트로 훈련하면 어휘, 구문, 의미적 다양성이 지속적으로 감소하며, 창의성이 요구되는 작업에서 특히 두드러진다. 중세 건축에 관한 텍스트가 수 세대 후에는 토끼에 관한 무의미한 텍스트로 퇴화하는 사례가 관찰되기도 했다.

■ 이미지 생성의 퇴화

손글씨 숫자를 생성하는 모델에서 세대가 거듭될수록 이미지가 점진적으로 흐려져 결국 각 숫자가 균일한 얼룩처럼 보이게 된다(<그림> 참조). 확산 모델(diffusionn model)에서 반복적 재훈련 시 이미지 품질이 저하되고, 새, 꽃과 같은 특정 카테고리 이미지는 2세대 안에 사용 불가능한 결과를 생성하는 사례가 관찰됐다.

---

https://doi.org/10.1038/s41467-024-52415-1.5. 진단 확률 추정 연구는 Rodman, Adam, Tamar A. Buckley, Arjun K. Manrai, and Daniel J. Morgan. "Artificial Intelligence vs Clinician Performance in Estimating Probabilities of Diagnoses Before and After Testing." JAMA Network Open 6, no. 12 (2023): e2347075. https://doi.org/10.1001/jamanetworkopen.2023.47075.

17) Shumailov, Ilia, Zakhar Shumaylov, Yiren Zhao, Nicolas Papernot, Ross Anderson, and Yarin Gal. "AI Models Collapse When Trained on Recursively Generated Data." Nature 631, no. 8022 (2024): 755-59. https://doi.org/10.1038/s41586-024-07566-y.

▪ 음악/오디오 생성의 진부화

음악 생성 모델도 합성 오디오 데이터로 재훈련 시 음색, 리듬, 화성의 다양성이 감소하고 특정 패턴으로 수렴하는 현상이 나타날 수 있다. 드문 음악 장르나 독특한 악기 조합은 세대가 지나면서 손실되며, 종국에 가서는 획일적이고 창의성이 결여된 출력물이 생성될 가능성이 높아진다.

☞ 예시: 숫자 이미지 투입-산출의 퇴화 과정

실제 숫자 이미지 (Original Data): 사람이 직접 작성한 MNIST[18] 데이터셋이다. 숫자의 굵기, 각도, 모양이 매우 다양하며 정보의 밀도가 높다. 모델은 이 깨끗한 데이터를 첫 학습에 사용한다.

- 1세대 출력 결과물: 실제 데이터를 학습한 직후의 모델이 생성한 이미지이다. 숫자의 형태가 명확하며 원본의 다양성을 잘 보존하고 있다.
- 세대 반복 학습의 결과: 이전 세대가 생성한 데이터를 다시 학습 재료로 사용하면서, 모델은 데이터의 가장 일반적인 특징(평균값)에만 집중하게 된다. 이 과정에서 드문 형태나 세밀한 특징들이 사라진다.
- 최종 퇴화 단계: 반복 학습이 거듭될수록 숫자의 개별 특성은 완전히 사라진다. 결국 모든 숫자가 비슷하게 뭉개진 형태의 '균일한 얼룩(Uniform Smudge)'으로 변하여 어떤 숫자인지 판별이 불가능한 상태가 된다.

이러한 현상은 인공지능이 인간의 창작물이 아닌, AI 자신의 결과물에만 의존할 때 발생하는 문제점을 명확히 보여준다.

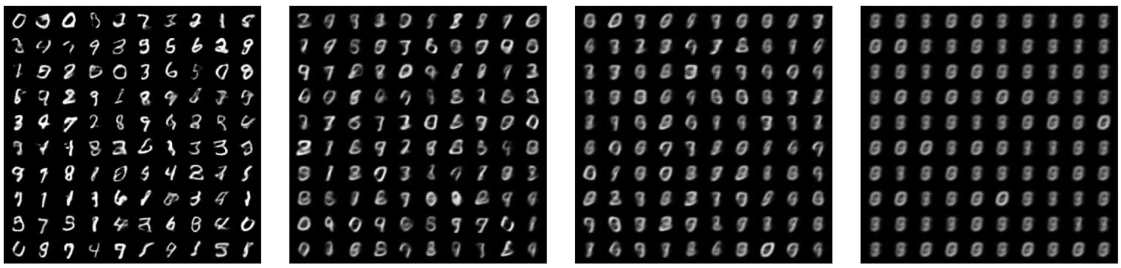

Original model *Generation 5* *Generation 10* *Generation 20*

그림 2 모델 붕괴: 숫자 이미지의 예

4) 여러 윤리적 문제들

■ 범죄나 악행에 이용

18) MNIST는 'Modified National Institute of Standards and Technology'의 약자로, 손으로 쓴 숫자(0~9) 이미지로 구성된 대규모 데이터베이스다.

AI 기술은 악의적 목적으로 전용될 수 있는 이중용도 특성을 지닌다. 딥페이크 기술은 실존 인물의 얼굴과 음성을 합성하여 허위 영상을 제작할 수 있으며, 이는 사기, 명예훼손, 정치적 조작에 악용된다.

생성형 AI는 피싱 메일 작성, 악성코드 개발, 가짜 뉴스 대량 생산 등에 활용될 수 있다. 실제로 2019년 영국에서는 AI 음성 합성 기술을 이용해 CEO의 목소리를 모방하여 22만 유로를 사취한 사건이 발생했다.

AI는 악성 해커뿐 아니라 초보자조차도 이를 이용하여 디지털 공격 수단을 습득하거나 코드를 생성할 수 있어서, 디지털 범죄에 대한 진입 장벽을 낮추는 역할을 했다. 복잡한 시스템 침투 AI 자동화, 랜섬웨어 및 멀웨어 공격, AI를 이용한 정교한 피싱 이메일 생성, CEO 음성 위조를 통한 금융 사기 수단을 손쉽게 제공하기 때문이다.

2023년에는 한국에서 유명인의 얼굴을 합성한 딥페이크 성착취물이 텔레그램을 통해 유포되어 사회적 충격을 주었다. 이러한 기술 오남용은 개인의 명예와 재산을 침해하고 사회적 신뢰를 훼손하며, 기술 발전 속도에 법적·윤리적 규제가 따라가지 못하는 문제를 드러낸다.

■ 표절과 지식재산 침해

AI 언어모델은 방대한 데이터로 학습하여 텍스트를 생성하는데, 이 과정에서 원저작자의 의도나 동의 없이 저작물의 표현이나 아이디어가 재현될 수 있다. 특히 AI가 생성한 콘텐츠가 기존 저작물과 유사할 경우 저작권 침해 논란이 발생한다.

사용자는 AI 생성물이 독창적이라고 믿고 사용했다가 의도치 않게 표절자가 될 위험에 처한다. 2023년 미국 작가들은 OpenAI와 메타를 상대로 자신들의 저작물이 무단으로 AI 학습에 사용되었다며 집단 소송을 제기했다.

학계에서도 학생들이 AI로 작성한 과제가 기존 논문과 유사하여 표절로 판정되는 사례가 증가하고 있다. 심지어 AI가 작성한 '가짜' 논문으로 학술지 심사를 통과할 수 있다. ChatGPT 같은 생성형 AI 도구를 사용하여 표준 표절 검사를 통과하는 거의 내용이 동일한 '중복' 논문을 생성할 수 있다[19].

이는 AI 학습 데이터의 출처와 저작권, 생성물의 독창성 기준, 사용자의 책임 범위 등에 대한 명확한 법적·윤리적 기준 마련이 시급함을 보여준다.

■노동 대체와 경제적 불평등 심화

AI 자동화는 생산성을 향상시키지만 동시에 광범위한 일자리 대체를 초래하여 경

19) Nature News (23 Sep. 2025)
https://www.nature.com/articles/d41586-025-03046-z

제적 불평등을 확대할 수 있다는 우려가 널리 확산되어 있다. 단순 반복 업무뿐 아니라 창작, 분석, 상담 등 고숙련 직종까지 AI가 대체 가능해지면서 중산층 일자리가 위협받는다. 특히 재교육 기회나 자본 접근성이 낮은 계층은 경제적 취약성이 증가하며, AI 기술을 소유한 소수 기업과 개인에게 부가 집중되는 양극화가 심화된다. 2023년 맥킨지 보고서는 2030년까지 전 세계적으로 최대 8억 개 일자리가 자동화로 대체될 수 있다고 전망했다. 한국에서도 금융권과 제조업에서 AI 도입으로 인한 인력 감축이 진행 중이다. 이는 사회안전망 강화, 기본소득 논의, 평생교육 체계 구축 등 포괄적인 사회정책 대응이 필요함을 시사한다.

이 문제는 노동과 경영의 본질에 대한 더욱 자세한 성찰이 필요한 문제이므로, 본 교재 후반 <AI와 사회 변화>에서 보다 깊이 다룬다.

■알고리즘 편향과 차별 재생산

AI 시스템은 학습 데이터에 내재된 사회적 편견을 학습하고 증폭시켜 특정 집단에 대한 차별을 자동화할 수 있다. 인종, 성별, 나이, 지역 등에 따른 편향이 채용, 대출 심사, 범죄 예측, 의료 진단 등 중요한 의사결정에 반영되면 구조적 불평등이 고착화된다. 알고리즘의 불투명성으로 인해 차별 피해자가 이를 인지하거나 이의를 제기하기 어렵다는 점도 문제다. 2018년 아마존은 AI 채용 시스템이 여성 지원자를 체계적으로 불리하게 평가한다는 사실이 밝혀져 프로그램을 폐기했다. 미국의 범죄 위험 예측 알고리즘 COMPAS는 흑인 피고인에게 더 높은 재범 위험 점수를 부여하여 인종 차별 논란을 야기했다. 이는 AI 개발 과정에서 다양성 확보, 편향 감사, 투명성 제고, 윤리적 검토가 필수적임을 입증한다.

■Social Media와 연관된 부작용

소셜미디어에 공유된 개인 데이터는 사용자 동의 없이 AI 학습에 활용되어 프라이버시 침해와 데이터 주권 문제를 야기한다. 사용자들은 게시물, 사진, 행동 패턴이 상업적 AI 모델 훈련에 사용될 것을 예상하지 못한 채 콘텐츠를 공유하며, 이는 정보적 자기결정권을 침해한다. 2021년 메타는 10억 명 이상의 인스타그램 사진을 무단으로 AI 학습에 사용했다는 논란에 휩싸였다.

반대로 AI가 생성한 허위정보, 조작된 이미지, 편향된 콘텐츠가 소셜미디어를 통해 급속히 확산되면 여론 왜곡, 사회 분열, 민주주의 훼손이 발생할 수 있다. 2024년 미국 대선 기간 중 AI로 생성된 가짜 정치인 발언 영상이 X(구 트위터)에서 수백만 회 조회되며 유권자를 혼란시켰다. 이렇게 편향된 콘텐츠의 범람을 야기하는 것을 '필터 버블(filter bubble)'이라 부르며, 가짜 뉴스가 확산되기 쉬운 환경을 만든다. 이는 플랫폼의 데이터 사용 투명성 확보, AI 생성물 표시 의무화, 허위정보

탐지 시스템 강화 등 종합적 대응이 필요함을 보여준다.

한편 최근 유튜브나 페이스북 등 게시물 중 AI가 생성한 텍스트나 이미지의 비중이 날이 갈수록 늘어나고 있다. 이는 어쩌면 평균화(平均化)의 범람이 일상화되고 있는 것이다. 이는 윤리적인 문제는 아니지만, 사람 고유의 지력과 성찰 능력이 탁월성을 지향하기보다 평균적인 수준으로 회귀하게 만드는 미묘한 부작용이 있다.

5) 생명, 재산, 기밀정보

의료, 무기, 금융 등 재산이나 생명을 보호하는 사업에서 AI가 환각 또는 오류 정보를 생성하는 경우, 또는 기업의 기밀 정보가 클라우드나 조직 외부 AI를 활용하면서 유출될 경우, 심각한 문제를 야기할 수 있다.

■ 의료

AI 의료 시스템은 진단 정확도를 높이지만, 오류 발생 시 환자의 생명을 직접적으로 위협한다. 학습 데이터의 편향, 알고리즘 오작동, 의료진의 과도한 AI 의존은 오진, 부적절한 치료, 약물 오투여로 이어질 수 있다. 특히 AI가 희귀 질환이나 비전형적 증상을 제대로 인식하지 못하거나, 특정 인종·성별 데이터가 부족한 경우 체계적 오류가 발생한다. 의료진이 AI 판단을 맹신하여 임상적 직관을 무시하면 위험이 증폭된다.

2018년 미국 듀크대학교 병원의 AI 패혈증 예측 시스템은 실제 환자 적용 시 개발 단계보다 훨씬 낮은 정확도를 보였다. 2021년 영국에서는 AI 피부암 진단 시스템이 유색인종 환자의 암을 제대로 감지하지 못하는 편향이 드러났다. 한국에서도 일부 AI 영상 판독 시스템이 미세한 병변을 놓쳐 진단 지연 사례가 보고되었다. 이는 AI 의료기기의 엄격한 검증, 지속적 모니터링, 최종 판단에서 의료 전문가의 개입 필요성을 강조한다.

■ 국방

군사 AI 시스템의 오작동은 잘못된 표적 식별, 민간인 피해, 나아가 국제 분쟁 확대로 이어질 수 있다. 자율무기체계는 적군과 민간인을 구별하거나 전투 상황을 판단하는 과정에서 오류를 범할 수 있으며, 해킹이나 적대적 공격에 취약하다. AI 조기경보 시스템의 오판은 잘못된 군사적 대응을 촉발하여 불필요한 교전이나 외교적 위기를 초래한다. 특히 핵무기 관련 의사결정에 AI가 관여할 경우 인류 전체의 생존이 위협받을 수 있다.

2020년 리비아 내전에서 터키제 자율 드론 카르구-2가 인간 조종 없이 표적을 추적하고 공격한 것으로 알려져 국제사회의 우려를 샀다. 2023년 이스라엘군이 가자

지구에서 AI 표적 선정 시스템 '라벤더'를 사용했으나 다수의 민간인 오인 공격이 발생했다는 보도가 있었다. 냉전 시기 1983년 소련의 조기경보 시스템이 미국의 미사일 공격을 잘못 감지했으나 인간 판단으로 핵전쟁이 회피된 사례는 AI 군사 시스템에 대한 인간 통제의 중요성을 보여준다.

■ 금융

AI 금융 시스템의 오류는 시장 붕괴, 대규모 자산 손실, 금융 시스템 불안정을 초래한다. 알고리즘 거래는 밀리초 단위로 대량 매매를 실행하므로 오작동 시 급격한 가격 변동과 유동성 위기가 발생한다. AI 신용평가 오류는 부당한 대출 거부나 과도한 대출로 개인과 기업의 재정을 위협하며, AI 사기 탐지 시스템의 오판은 정상 거래를 차단하거나 실제 사기를 놓칠 수 있다. 여러 금융기관이 유사한 AI 모델을 사용하면 동조화된 거래 행태로 시스템적 위험이 증폭된다.

2010년 미국 증시에서 발생한 '플래시 크래시'는 알고리즘 거래 오류로 다우지수가 9% 급락했다가 수분 내 회복되었으나 1조 달러의 시가총액이 순간적으로 증발했다. 2012년 나이트캐피털은 거래 알고리즘 오류로 45분 만에 4억 4천만 달러 손실을 입고 파산 위기에 처했다. 2022년 한국의 한 암호화폐 거래소에서 AI 시스템 오류로 비정상적인 가격이 표시되어 투자자 혼란과 손실이 발생했다. 이는 AI 금융 시스템의 실시간 감시, 서킷브레이커 같은 안전장치, 스트레스 테스트 강화가 필수적임을 입증한다.

■ 기업 기밀정보

AI 시스템이 기업 기밀정보를 학습하거나 처리하는 과정에서 데이터 유출, 무단 재생성, 경쟁사 노출 위험이 발생한다. 직원들이 AI 챗봇에 민감한 정보를 입력하면 해당 데이터가 모델 학습에 사용되거나 다른 사용자에게 노출될 수 있다. AI 시스템 해킹, 프롬프트 인젝션 공격, 모델 추출 공격을 통해 기밀 정보가 탈취될 수 있으며, 클라우드 기반 AI 서비스는 제3자 접근 위험을 내포한다. AI가 학습한 영업 비밀, 제품 설계, 고객 데이터가 경쟁사에 유출되면 기업의 경쟁력과 시장 지위가 치명타를 입는다.

2023년 삼성전자 직원들이 ChatGPT에 반도체 설비 정보와 회의록을 입력하여 기밀 유출 우려가 제기되었고, 이후 사내 생성형 AI 사용이 제한되었다. 같은 해 아마존도 직원의 AI 툴 오용으로 전략 정보가 노출될 뻔한 사례가 보고되었다. 2024년 한 글로벌 제약사는 AI 협력업체의 보안 허점으로 신약 개발 데이터가 유출되어 수십억 달러 손실을 입었다.

이는 기업 내 AI 사용 정책 수립, 데이터 암호화, 온프레미스 AI 솔루션 도입, 직

원 보안 교육 강화가 시급함을 보여준다.

6) AI 위장(Washing)

AI Washing은 실제로 고도화된 인공지능 기술을 사용하지 않으면서도, 마케팅 효과를 노리고 마치 혁신적인 AI 기능이 포함된 것처럼 광고하는 기만적인 행위를 의미한다. 기업들은 투자 유치나 브랜드 이미지 제고를 위해 단순한 알고리즘이나 수동 자동화 프로세스를 AI로 포장하기도 한다.

이러한 현상은 소비자에게 혼란을 주고 기술에 대한 신뢰도를 떨어뜨리는 부작용을 초래한다. 특히 실제 기술력보다는 과장된 수식어에 의존하기 때문에, 장기적으로는 진정한 AI 혁신을 방해하는 요소가 된다. 최근 금융 및 IT 규제 당국은 이러한 허위 광고를 차단하기 위해 감시와 처벌을 강화하는 추세이다. 따라서 기업은 기술의 실체를 투명하게 공개해야 하며, 소비자는 비판적인 시각으로 제품의 기능을 살펴볼 필요가 있다.

대표적으로 아마존은 'Just Walk Out' 무인 매장 기술을 100% AI 시스템이라 홍보했으나, 실제로는 인도에 있는 1,000여 명의 직원이 영상을 수동으로 검토해 결제를 진행했다는 사실이 밝혀져 논란이 되었다.

미국 증권거래위원회(SEC)는 투자 자문사 델피아와 글로벌 프리딕션에 대해 실제로는 인공지능이 아닌 단순 통계 모델을 사용했음에도 AI 기반 예측 기술을 보유했다고 허위 광고한 혐의로 벌금을 부과했다. 또한, AI 기반 채용 플랫폼을 표방했던 스타트업 준코 역시 기술력을 부풀려 거액의 투자를 유치했다가 기소되는 등 금융권의 규제도 강화되는 추세이다.

국내에서도 2025년 11월, 공정거래위원회가 AI 기능이 없거나 미미한 가전제품을 'AI 제품'으로 광고한 20건의 의심 사례를 적발했다. 예컨대 단순 센서로 작동하는 냉풍기를 AI 기술인 것처럼 포장하거나, 특정 조건에서만 작동하는 기능을 기업 전체의 핵심 기술인 양 과장한 사례들이 포함되었다. 이러한 행위는 소비자의 오인을 유발하고 기술 신뢰도를 저하시키는 결과를 낳는다.

이런 현상은 AI 시대에만 일어난 것이 아니라, 과거 블록체인, 메타버스 등 신기술이 등장할 때마다 일어났다. 앞으로도 이런 현상은 계속 반복될 것이다.

3. AI의 역사I: 태동부터 딥러닝까지

가. 태동

1950년대에 인공지능이라는 개념이 태동하는 데에는 수많은 학자들이 기여했지만, 그 중에서도 Marvin Minsky 와 Frank Rosenblatt 이라는 두 인물이 중심에 서 있었다.

■ Marvin Minsky(미국, 1927-2016): Symbolic AI의 개척자

마빈 민스키는 MIT 인공지능 연구소를 공동 설립한 인지과학자이자 컴퓨터 과학자이다. 인공지능 분야의 기틀을 마련한 공로로 1969년 튜링상을 수상했으며, 인공지능의 아버지 중 한 명으로 평가받는다.

민스키는 1950년대 초반부터 인간의 사고와 기계의 프로세스 사이에 근본적 차이가 없다고 확신했다. 1951년 최초의 신경망 시뮬레이터(SNARC)를 구축했으며, 1956년 다트머스 회의를 통해 'Artificial Intelligence'이라는 용어를 정립하는 데 주도적 역할을 했다.

기존의 컴퓨터(IBM 과학 연산용)가 숫자의 연산에 중점을 두었던 반면에, 그는 컴퓨터를 기호와 개념의 논리적 조작을 중심에 둔 '심볼(Symbolic) AI'를 구현할 수 있는 장치로 보았다. 인간의 언어는 다양한 명사와 동사라는 심볼들로 이루어진다.

Symbolic AI의 핵심 원리는 다음과 같다.

- 명시적 지식 표현: 정보가 구조화된 기호 형식으로 인코딩된다
- 규칙 기반 추론: IF-THEN 규칙을 통해 논리적으로 결론을 도출한다
- 투명성: 의사결정 과정을 단계별로 추적하고 설명할 수 있다
- 하향식 접근: 프로그래머가 명시적으로 규칙을 코딩한다

Symbolic AI 개념을 Computer Vision 의 경우를 예로 들어 설명해보자.

지금에야 Computer Vision 시스템이 대부분 인공신경망 딥러닝(Deep Learning) 기반으로 작동하지만, 1970~80년대의 초기만 하더라도 Computer Vision 시스템은 사물의 특징을 '규칙'과 '논리'로 정의하여 인식하려 했던 Symbolic AI 방식을 주로 사용했다. 예를 들어서 "의자는 다리가 4개 있고 평평한 판이 위에 있다"와 같은 기하학적 규칙을 프로그래밍하여 그 조건에 맞는 사물을 찾는 방식이다. 기술적으로는 이미지로부터 윤곽선을 추출해서 그 윤곽선의 형태가

조건에 부합하는지를 판단하는 방식이다.

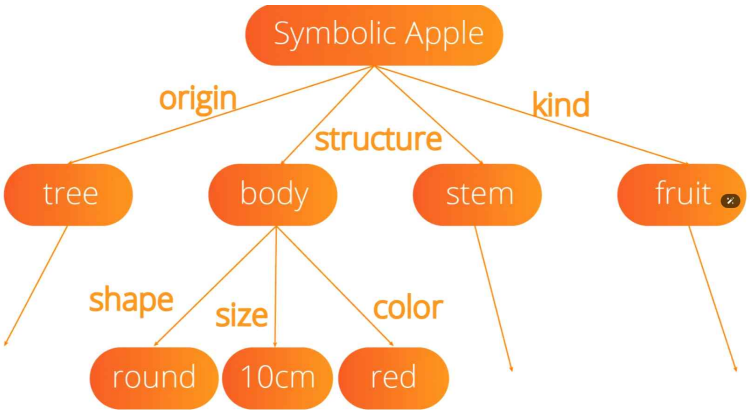

그림 3 Symbolic AI의 사물 분류 개념

출처 : https://medium.com/data-science/symbolic-vs-subsymbolic-ai-paradigms-for-ai-explainability-6e3982c6948a

또한 민스키는 1970년대 중반 "프레임(frames)" 개념을 개발하여 지식 표현에 획기적인 기여를 했다. 프레임은 전형적인 상황을 표현하기 위한 데이터 구조다. 예를 들어 "생일 파티" 프레임은 주최자, 손님, 선물, 케이크 같은 역할과 그들 사이의 전형적인 상호작용 및 기대를 포함한다.

■ Frank Rosenblatt (1928-1971): 인공신경망 기반 인공지능의 효시

프랑크 로젠블랫은 코넬대학교의 심리학자이자 컴퓨터 과학자이다. 1956년 코넬에서 박사학위를 받은 후 IBM 704 대형 컴퓨터에 접근할 수 있게 되면서 1957년 코넬 항공연구소에서 퍼셉트론(Perceptron)을 발명했다. 1958년 상세한 논문을 발표했고, 첫 국제 AI 심포지엄 "사고 과정의 기계화"에서 발표했다. 퍼셉트론은 생물학적 뇌의 학습 구조를 모방한 인공 신경망의 시초로 평가된다.

로젠블랫은 민스키가 채택한 것과 같은 기호 논리 방식 대신에 생물학적 뉴런의 작동 방식에 주목했다. 1957년 당시 대형 컴퓨터인 IBM 704를 이용하여 강화 학습을 통해 성능을 개선하는 인공 패턴 인식 시스템을 실험하며 퍼셉트론 개념을 구체화했다.

퍼셉트론은 감각(S, 입력층), 연합(A, 연결층), 반응(R, 출력층) 유닛으로 구성된 3층 구조를 가진다. 입력값에 가중치를 곱해 합산한 값이 임곗값을 넘으면 신호를 출력하는 방식이다. 학습 과정에서 ***실제 값과 정답 사이의 오차를 줄이기 위해 가중치를 반복적으로 수정하는 방식***을 취했는데, 이는 현대 딥러닝의 기초가 되는 선형 분류기(linear classifier)의 원형이다.

로젠블랫의 신경망은 입력층과 출력층 사이의 연결층이 단층(single-layer)이었다는 면에서 한계가 있었다. 하지만 이는 훗날 다층(multi-layer), 심지어 딥러닝 수준으로 많은 층에서 효과적으로 작동할 수 있는 방법론으로 발전함으로써 현대 생성형 A의 씨앗이 됐다.

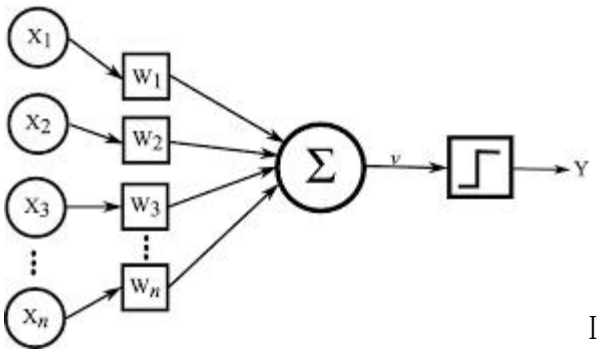

I

그림 4 로젠블랫의 단층 Perceptron 구조

※단층 Perceptron의 작동 과정 예시

과일에 대해 x1(=무게)'와 x2(=표면의 거칠기)라는 두 가지 수치 정보를 입력받아, 이 과일이 사과인지 배인지 분류하는 퍼셉트론을 생각해보자.

- w1과 w2는 각 입력 정보가 판단에 미치는 중요도 값, 일명 가중치(weight)다. 분석가는 이 w1과 w2 값을 임의로 부여한다.(예: w1= 0.3, w2= 0.7 같은 식으로)
- 어떤 과일의 무게가 무겁고(x1 = 0.8) 표면이 아주 거칠다면(x_2 = 0.9) $w_1x_1 + w_2x_2$은 0.87이 된다.
- 합계 점수가 미리 설정한 임곗값(예: 0.5)을 넘으면 1을 출력하고, 넘지 못하면 0을 출력한다. 0.87은 임곗값 0.5보다 크므로 이 퍼셉트론은 1을 출력한다.
- 출력값 1은 '배', 0은 '사과'로 부여해 놓았다.
- 여러 과일의 수치로 작업을 하면서 '배'이냐 '사과'이냐에 대해 ***실제 분류와 퍼셉트론 모델 분류 결과가 차이***가 날 때마다 ***가중치 w1과 w2를 계속 수정***해 간다.
- 결국 ***이 차이가 발생하는 빈도가*** 가장 작게 나오는 ***최적 가중치 w1 과 w2를 찾아내는 것***이 목표다.

(※이 빈도가 0%로 나오는 w1과 w2 값을 찾아낼 수 있다면, 우리는 이 모델을 '예측률 100%' 모델이라고 부른다.)

■ 로젠블랫 대 민스키의 논쟁

민스키와 로젠블랫은 Bronx 과학고등학교 동창으로 우호적인 관계를 유지했으나, AI 방법론에서는 격렬하게 대립했다. 1969년 민스키는 세이무어 페퍼트와 함께 저

서 《퍼셉트론》을 출간하여, 단층 퍼셉트론이 XOR(Exclusive OR) 문제와 같은 비선형 분리 가능 함수를 학습할 수 없음을 수학적으로 증명해서 로젠블랫의 방식에 큰 타격을 입혔다. XOR문제는 신경망 연구의 운명을 바꾼 결정적인 사건이었다.

이 비판은 역설적으로 후대의 페셉트론 연구자들이 다층 퍼셉트론(MLP: Multi-Layer Perceptron)과 오차(Error)의 역전파(Back-Propagation) 알고리즘을 개발하도록 자극하는 촉매제가 되었고, 이는 이후 인공신경망 모델이 딥러닝(Deep Learning)을 거쳐 현대 LLM 생성형 AI로까지 발전하도록 하는 계기가 됐다.

1980년대 이후 신경망 연구가 재조명되면서 로젠블랫의 퍼셉트론은 현대 딥러닝 모델의 기원으로 인정받았다. 한편 민스키 역시 1951년에 SNARC라고 하는 신경망 모델을 개발한 적이 있었는데, 민스키는 그보다는 기호에 대한 논리적 추론 과정을 중시하는 업적이 더욱 높게 평가받았다. 서로 반대편에 서 있었던 민스키와 로젠블랫의 경쟁과 통찰은, 각각 심볼주의(symbolisim)과 연결주의(connectionism)이라는 요약어로 대비되면서, 오늘날 인공지능이 인간의 인지 능력을 복제하는 종합 과학으로 성장하는 데 거대한 밑거름이 되었다.

■ XOR(Exclusive OR) 문제란?

인공지능의 초기 역사에서 XOR(Exclusive OR) 문제는 신경망 연구의 운명을 바꾼 결정적인 사건이었다.

표 9 XOR 문제

입력값		출력값
(0, 0)	→	0
(0, 1)	→	1
(1, 0)	→	1
(1, 1)	→	0

민스키와 페퍼트는 1969년 저서 《퍼셉트론》에서 단층 퍼셉트론 구조로는 이 단순한 XOR 논리조차 해결할 수 없음을 수학적으로 증명했다. 이로 인해 로젠블랫의 단층 퍼셉트론 모델의 위상은 크게 추락했다.

하지만 훗날, 이 문제를 해결하기 위해서는 입력층과 출력층 사이에 하나 이상의 은닉층(Hidden Layer)**을 추가해야 한다는 사실이 밝혀졌다. 1980년대에 이르러 오차 역전파(Backpropagation) 알고리즘이 대중화되면서, 다층 구조에서 가중치를 효율적으로 학습시키는 것이 가능해졌다. 이를 통해 XOR 문제를 포함한 복잡한 비선형 문제를 해결할 수 있게 되었다.

민스키의 비판 이후 인공신경망 연구는 수학적 한계가 명확하다는 낙인이 찍혔고 이로 인해 연구 자금이 끊기고 학계의 관심이 Symbolic AI(논리 및 규칙 기반)로

쏠리며 약 10년간 신경망 연구의 암흑기가 지속됐다.

■ SNARC와 Perceptron

민스키가 신경망 계열 인공지능을 전혀 도외시한 것은 아니었다. 그는 1951년 프린스턴 대학 대학원생 시절 딘 에드먼즈와 함께 SNARC(Stochastic Neural Analog Reinforcement Calculator)를 개발했다. 이는 역사상 최초의 인공 신경망 기계로, 민스키는 학부 시절 1943년 워렌 맥컬록과 월터 피츠의 인공 뉴런 논문에 영감을 받아 이 기계를 만들기로 결심했다. SNARC는 그랜드 피아노만한 크기의 장치였으며, 약 300개의 진공관을 사용했다.

○ 설계 차이

SNARC와 Perceptron은 동일한 인공 신경망 구조이지만 설계에 근본적 차이가 있었다. SNARC는 약 40개의 헵 시냅스(Hebb synapses)로 구성된 무작위 연결 네트워크(randomly connected network)였다. 반면에 Perceptron은 입력, 출력, 연결층으로 층별 구조화된 네트워크였다.

○학습 메커니즘 차이

학습 메커니즘에세도 차이가 있었다. SNAR는 스키너식 강화 학습(Skinnerian reinforcement learning)을 사용했다. 민스키는 개발 과정에서 행동주의 심리학자 B.F. 스키너와 광범위하게 대화를 나누었다.

각 시냅스는 입력 신호가 들어올 때 출력 신호를 내보낼 확률을 저장하는 메모리를 가졌다. 포텐시오미터가 0에서 1 사이의 확률을 나타냈다. 확률 신호가 통과하면 커패시터가 이 기능을 기억하고 전자기 클러치를 작동시켰다.

시스템이 "보상"을 받으면 최근에 사용된 경로가 강화되었다. 학습은 시행착오(trial and error) 과정을 통해 이루어졌으며, 운영자가 기계가 올바른 결과를 내놓을 때 수동으로 피드백을 제공했다. 커패시터는 뉴런이 최근에 신호를 전달했는지 몇 초 동안 기억하는 단기 메모리를 제공했고, 포텐시오미터는 장기 메모리를 관리했다.

반면에 Perceptron은 지도 학습(Supervised Learning) 방식을 사용했다. 레이블(앞의 예에서 보인 ‘배’, ‘사과’ 레이블)이 지정된 예제들이 제공됐고. 예측 출력과 실제 출력을 비교해서 나온 오차를 더 줄이는 방향으로 반복적으로 가중치를 조정하는 방식을 택했다.

○해결 과업의 성격 차이

SNARC와 Perceptron은 해결하고자 하는 문제의 성격이 달랐다.

SNARC는 미로 학습(maze solving) 문제를 해결하도록 설계되었다. 미로에서 달리는 쥐를 시뮬레이션했다. 시뮬레이션은 "조명 배치"로 표시되었으며, 시뮬레이션된 쥐가 목표에 도달할 때마다 회로가 강화되었다. 놀랍게도 쥐들은 실제로 서로 상호작용했다. 한 마리가 좋은 경로를 찾으면 다른 쥐들이 그것을 따라가는 경향이 있었다. 여러 쥐가 동시에 달릴 수 있어 시스템 학습 속도가 증가했다.

Perceptron은 패턴 인식(pattern recognition) 작업을 위해 설계되었다. 퍼셉트론은 이진 분류기(binary classifier)로, 사물을 두 가지 선택지 가운데 어디에 속하는지를 구분하는 용도로 사용됐다.

○ 아날로그 대 디지털 구현의 차이

기술적 구현 방식에서도 차이가 있었다. SNARC는 진공관과 커패시터 등 전자장치로 가동된 반면, Perceptron은 디지털 컴퓨터로 가동되는 장치였다.

SNARC는 최초의 실제 작동하는 인공 신경망 기계로서 역사적 중요성을 지니며, 하드웨어 신경망 구현의 가능성을 최초로 입증했지만, 기술적 한계와 자료 소실로 인해 후속 연구로 이어지지 못했다. 반면에 퍼셉트론은 현대 딥러닝 인공 신경망 기술의 기원이 되었다. 감독 학습과 역전파 알고리즘의 이론적 기초를 제공했다.

1960년대 민스키는 MIT에서 시지각(vision)과 자연어 처리의 복잡한 문제를 해결하려면 SNARC 식의 인공 신경망 모델로는 한계가 있다고 판단해서 더 유연한 해결책으로서 symbolic AI로 방향을 전환했다.

나. 전문가 시스템의 보급

■ 민스키의 Symbolic AI를 구현하는 수단으로서 전문가 시스템

전문가 시스템(Expert system)은 symbolic AI의 이론적 원리를 실용적 시스템으로 구체화한 것이다. 이들은 지식 베이스와 추론 엔진이이라는 두 가지 주요 구성요소를 가진다

- [지식베이스] 지식 베이스는 도메인별 정보와 규칙을 포함하고, 추론 엔진은 이러한 규칙을 새로운 상황에 적용하여 결론이나 권장사항을 도출한다. 아키텍처는 여러 중요한 요소를 포함한다: 특정 도메인에 대한 사실, 규칙, 관계의 구조화된 모음인 지식 베이스, 결론에 도달하기 위해 지식 베이스를 처리하는 추론 메커니즘인 추론 엔진, 사용자가 시스템과 상호작용하는 수단인 사용자 인터페이스, 시

스템의 추론 과정을 설명하는 구성요소인 설명 기능, 지식 베이스를 업데이트하고 유지하는 도구인 지식 획득 서브시스템이다.

- [추론 엔진]: 규칙과 생산 시스템은 지식을 "if-then" 규칙의 형태로 인코딩하며, 특정 조건이 충족될 때 취해야 할 행동을 정의하고, 새로운 지식을 추론하거나 의사결정을 하는 데 사용된다.

앞에서 말한 민스키의 '프레임' 사상은 훗날 전문가 시스템 안에서 의미 네트워크가 작동하도록 하는 이론적 기반이 됐다. 웹 온톨로지(ontology) 언어(OWL)는 이 연결을 더욱 명확하게 만들었다. 민스키와 다른 이들이 개발한 프레임 기반 시스템의 진화인 기술 논리 위에 구축된 OWL은 클래스 계층, 속성 제한, 논리적 관계를 정의하는 정교한 메커니즘을 제공했다.

■ 초기 Expert System의 등장 (1960년대 중반~1970년대)

○ DENDRAL: 최초의 Expert System

1960년대 스탠퍼드 대학에서 에드워드 파이겐바움, 브루스 뷰캐넌, 조슈아 레더버그, 칼 제라시가 개발한 DENDRAL은 화학자들이 미지의 유기 분자를 식별하도록 돕기 위해 설계되었다.

DENDRAL은 질량 분광계의 단편화 패턴을 입력 데이터로 사용하여 분자 구조에 대한 연속적인 추론을 수행했다. 분자 내 구조적 제약을 관찰하고, 화합물의 정체성에 대한 가설을 생성 및 테스트하며, 구조적 제약에 맞지 않는 후보를 배제하는 방식으로 작동했다.

○MYCIN: 의료 진단 Expert System

DENDRAL의 성공을 기반으로 스탠퍼드 대학 연구자들은 1970년대 의료 진단용 전문가 시스템 MYCIN을 개발했으며, 이는 혈액 감염을 진단하고 적절한 항생제 치료를 권장하도록 설계된 획기적인 시스템이었다.

1970년대에 개발된 MYCIN은 박테리아 감염 진단 및 치료 권장을 위한 expert system으로, symbolic AI의 실제 문제에 대한 최초의 성공적인 응용 중 하나였다. MYCIN은 600개 이상의 생산 규칙을 활용하여 환자 증상, 실험실 결과, 병력을 평가하고 정보에 기반한 권장사항을 제공했다.

■ Expert System의 전성기 (1970년대~1980년대)

○상업적 성공 사례

1970년대는 expert system 시대의 시작을 알렸으며, DENDRAL이래 다양한 분야에서 expert system이 개발되어 AI 시스템이 전문 분야에서 인간의 전문성과 필적할 수 있음을 증명했다.

1970년대 첫 주요 상업적 성공은 DEC의 XCON 시스템이었다. XCON은 많은 수의 구성요소 서브어셈블리로부터 제약 조건 하에서 DEC 미니컴퓨터를 구성하는 작업을 수행했다. 구성 작업을 매우 빠르고 정확하게 수행하여 DEC은 연간 수천만 달러를 절약했다.

Expert System Shell의 등장

MYCIN에서 파생된 선구적인 도구/셸은 EMYCIN이었으며, 이는 상업적으로 이용 가능한 수십 개의 expert system 셸의 프로토타입이었다. EMYCIN은 프로그램 소프트웨어가 데이터와 분리된 expert system 셸의 실현 가능성을 입증했다.

Expert System이 확장되면서 개발자들이 절감한 사실은, 탁월한 Expert System 을구축하려면 데이터베이스나 프로그래밍 지식에 앞서서 충분한 도메인 지식(domain knowledge)이 선행되어야 한다는 것이었다. 도메인 지식은 '업역(業域) 지식'이라고도 번역할 수 있다. 즉 어떤 전문적 업무 영역에서 지식이 구사되과 과업이 처리되는 고유한 방식에 대한 지식을 의미한다. 의사, 법률가, 금융가, 개발자 등등 분야별 전문가마다 자신의 고유한 경험을 통해서 축적한 업역 지식을 다 갖추고 있다. 이 업역 지식을 확보해야만, Expert System 개발자는 그 영역에서 고유한 지식 베이스와 If-then 규칙을 설계할 수있다.

■ "AI의 겨울"

1970년대 중반부터 1980년대 초까지의 "AI의 첫 번째 겨울"은 이전 시대의 충족되지 않은 높은 기대로 인해 AI 연구에 대한 자금 지원과 관심이 감소한 시기였다. 이 접근법의 내재적 한계는 1970년대 후반 이른바 "첫 번째 AI 겨울"로 이어졌다.

지식 획득 병목 현상은 인간 전문성을 규칙 기반 시스템으로 인코딩하는 것이 매우 노동 집약적이고 종종 불완전함을 의미했다. 민스키 식 '프레임' 체계 안에 지식을 담기에는 실제 세계 추론에 필요한 지식의 맥락은 너무나 방대했다. .

Expert system은 유지 관리 및 업데이트 비용이 많이 들어 "두 번째 AI 겨울", 즉 전문가들이 기계가 내린 결정을 불신하는 시기로 이어졌다. 의사들은 컴퓨터가 내린 진단을 신뢰하기를 꺼려하여 수용을 얻는 데 어려움을 겪었다.

사실 Symbolic AI와 그 구현 수단인 Expert System의 겨울은, 인공신경망 계열 AI의 겨울만큼이나 혹독했다. 인공신경망 계열 AI가 21세기 들어 화려하게 부활하면서, 기존에 Symbolic AI가 봉착했던 근본적인 한계들을 돌파하기 시작했지만, 인

공신경망 계열 AI는 또 '환각(hallucination) 현상과 같은 그 나름의 구조적 한계를 드러냈다.

현대 인공지능은 연구자들이 symbolic 추론의 정밀성과 신경망의 학습 능력을 점점 더 결합하는 단계로 접어들고 있다.

다. 공장 자동화와 로봇

■ 공장 자동화

1950년대 이후 심볼주의와 연결주의 인공지능이 서로 경쟁하면서 발전하고 있는 와중에, 또 한켠에서는 공장 자동화(facory automation)이라는 흐름이 태동하고 있었다. 공장 자동화는 훗날 AI와 결합하게 되고, 이 과정에서 로보틱스(robotics) 산업이 크게 발흥하게 된다. 오늘날 공장 자동화는 '스마트 팩토리(smart factory)' 또는 '인더스트리4.0' 이라는 이름으로 불린다.

인공지능의 효시가 마빈 민스키와 프랭크 로젠블랫인 것처럼, 공장 자동화의 효시는 포드자동차였다. 1947년 포드자동차는 오토메이션(automation)이라는 명칭을 처음 만들어 사용했다. 기존의 조립라인에 수력, 전기장치, 기압설비를 결합함으로써 사람이 손을 대지 않고도 처리할 수 있는 공정들을 도입했다. 포드의 오토메이션 디파트먼트(Automation Department)는 처음에 5명으로 시작, 1년 뒤에는 50명으로 늘었다. 생산 품목도 처음에 밸브, 피스톤에서 점점 코일, 휠, 차체, 차축으로 확장됐다. 1949년 자동화 공정이 본격적으로 도입된 압연 공장이 버팔로에 건설됐다. 이듬해에는 클리블랜드 엔진 공장에 자동화가 도입됐다. 새로 건설된 공장에서는 이른바 기계손(iron hand)이 처음 도입됐는데, 이를 통해 각종 장비와 부품을 자동으로 이송 배치할 수 있었다.

자동화 덕분에 종전의 조립라인에 비해 직접 노동 시간은 49%, 공장의 총 바닥면적은 17%나 절감됐다. 노동조합은 인력 감축 가능성에 대해 우려를 나타냈지만, 포드는 기계 때문에 사람을 해고하는 일은 하지 않았다. 1954년에는 5만 명을 추가로 고용하기까지 했다.

이후 미국과 유럽 각국의 기업들은 서서히 자동화 설비를 도입하기 시작했다. 자동화 공정은 자동차 업계에서 가장 먼저 확산됐고 곧 이어 화학, 전기, 서비스 등 모든 업종으로 확대됐다 20세기 후반 공장 자동화 확산의 또 다른 주역은 전기회사였던 독일의 지멘스(Siemens AG)가 개발한 SIMATIC(Simens Automatic) 시스템이었다. 특히 1980년대 자동차 제조에 CIM(컴퓨터 통합제조)이 채택되면서 SIMATIC이크게 각광을 받았다. 이어서 토요타를 비롯한 일본의 자동차 회사들이 PLC(Programmable Logic Controller)를 도입하면서 공장 자동화의 선두에 섰다[20].

공장자동화는 비슷한 시기에 태동한, 다음 절에 설명할 산업용 로봇과 결합이 이루어졌다. 오늘날, 이제 글로벌 대기업치고 자동차, 반도체, 식음료, 유통 등 산업을 불문하고 산업용 로봇을 이용한 자동화 공정을 도입하지 않은 곳이 없다. 이제 어떤 지역에, 예컨대 평택이든 디트로이트든, 대규모 공장이 들어선다고 해서 지역의 인력 고용이 활성화될 것이라는 과거와 같은 기대는 접어야 할 시대가 왔다.

■ 로봇

○산업용 로봇

산업용 로봇의 역사는 1954년 조지 데볼이 프로그래밍 가능한 로봇 장치의 특허를 출원하면서 시작되었다. 1961년 데볼과 조셉 엥겔버거가 공동 개발한 유니메이트가 GM 뉴저지 공장에서 다이캐스팅 부품을 다루는 작업에 투입되면서 최초의 상업용 산업 로봇이 탄생했다.

1970년대는 산업용 로봇의 확산기였다. 1974년 신시내티 밀라크론이 컴퓨터 제어 로봇 T3를 선보였고, 일본은 가와사키중공업을 통해 유니메이트 기술을 도입하며 로봇 산업 강국으로 도약했다. 1978년 유니메이션의 PUMA 로봇은 프로그래밍 가능한 범용 조립 로봇의 표준을 제시했다.

1980년대 들어 센서와 비전 시스템이 통합되면서 로봇의 지능화가 시작되었다. 독일 쿠카는 1973년 파마트론을 개발했고, ABB는 용접과 도장 분야에서 혁신을 이뤘다. 2000년대 이후 협동로봇의 등장이 새로운 변곡점이 되었다. 2008년 유니버설 로보틱스가 UR5를 출시하며 안전 펜스 없이 인간과 함께 작업할 수 있는 코봇 시대를 열었고, 최근에는 AI와 머신러닝이 결합되어 자율 학습과 적응형 제조가 가능해지고 있다.

○ 휴머노이드 로봇

사람의 몸을 형상화한 휴머노이드 로봇 개발은 1973년 일본 와세다대학교가 WABOT-1을 선보이며 본격화되었다. 이 로봇은 두 다리로 걷고 물체를 잡을 수 있었으며 일본어로 대화가 가능했다. 1984년 WABOT-2는 악보를 읽고 전자 오르간을 연주하는 수준으로 진화했다.

1990년대 혼다의 연구가 중요한 전환점이 되었다. 1986년부터 비밀리에 진행된 E 시리즈 프로젝트는 1996년 P2 로봇으로 결실을 맺었고, 2000년 아시모(ASIMO)가 공개되며 세계를 놀라게 했다. 아시모는 계단 오르내리기, 사람 인식, 자율 보행이 가능한 수준이었다.

---

20) 여기 공장자동화의 역사에 대한 내용은 송경모, “스마트팩토리 역사가 말하는 일자리의 미래”, 테크엠, 2017.09.20.에서 재인용한 것이다. https://www.techm.kr/news/articleView.html?idxno=4174

2000년대 들어 다양한 연구 기관들이 참여했다. 2004년 소니의 QRIO, 일본 산업기술종합연구소의 HRP 시리즈가 등장했고, 2013년 보스턴 다이나믹스의 아틀라스가 DARPA 로보틱스 챌린지에 참가하며 재난 대응 로봇의 가능성을 보여줬다. 2017년 아틀라스가 백플립에 성공하면서 동적 균형 제어 기술의 획기적 진전을 입증했다.

최근 가장 주목할 만한 변화는 AI 기술의 융합이다. 2021년 테슬라가 옵티머스 프로젝트를 발표했고, 2024년에는 실제 공장 배치가 시작되었다. Figure AI, 1X Technologies 같은 스타트업들이 대규모 투자를 받으며 상용화 경쟁에 뛰어들었고, LLM과 결합된 휴머노이드는 복잡한 지시를 이해하고 수행하는 단계로 진화하고 있다.

2026년 1월 CES 2024에서 현대자동차는, 자회사인 보스턴 다이내믹스의 휴머노이드 로봇 아틀라스(Atlas)를 자동차 전 제조공정에 투입하고 아울러 다양한 시장에서 로봇 생태계를 구축해나갈 구상을 발표하기에 이르렀다.

☞현대자동차 홍보 영상
https://youtu.be/mU1LCazDCg8?si=4q_y47mLeEUqXmUu

라. 기계학습 machine learning

'머신러닝(Machine Learning)'이라는 용어는 1959년 IBM의 컴퓨터 과학자 아서 사무엘(Arthur Samuel)이 처음 사용했다. 사무엘은 체커(checkers) 게임을 하는 프로그램을 개발하면서, 컴퓨터가 명시적으로 프로그래밍되지 않고도 경험을 통해 스스로 성능을 향상시키는 능력을 연구했다. 그는 이러한 학습 과정을 설명하기 위해 "기계가 학습한다"는 의미의 머신러닝이라는 명칭을 만들었다. 이 용어는 컴퓨터가 데이터로부터 패턴을 발견하고 예측 능력을 개선하는 분야를 지칭하게 되었으며, 21세기에 LLM 기법이 등장하기 전까지 인공지능을 구현하는 주요 수단으로 활용됐다.

■ 회귀분석

회귀분석(regression)이라는 통계적 추론 기법은 1886년 영국의 통계학자이자 유전학자인 프랜시스 골턴(Francis Galton, 1822-1911)에 의해 처음 개발되었다. 골턴은 부모와 자녀의 키를 연구하던 중 키가 큰 부모의 자녀들이 부모보다는 평균에 가까운 키를 가지는 경향을 발견했고, 이를 "평균으로의 회귀(regression toward the mean)"라고 명명했다. 즉 '[입력]부모의 키 --> [출력]자녀의 키'라는 연결 관계를 통계학의 개념을 통해 처음 착상했다.

이후 골턴의 제자인 칼 피어슨(Karl Pearson)이 1900년대 초 상관계수와 회귀선 개념을 수학적으로 정교화했다. 1920년대에는 로널드 피셔(Ronald Fisher)가 최소제곱법과 분산분석을 통해 회귀분석을 현대적 통계학의 핵심 도구로 발전시켰다.

$$y = \beta_0 + \beta_1 x_1 + \ldots + \beta_i x_i + e(\text{오차항})$$

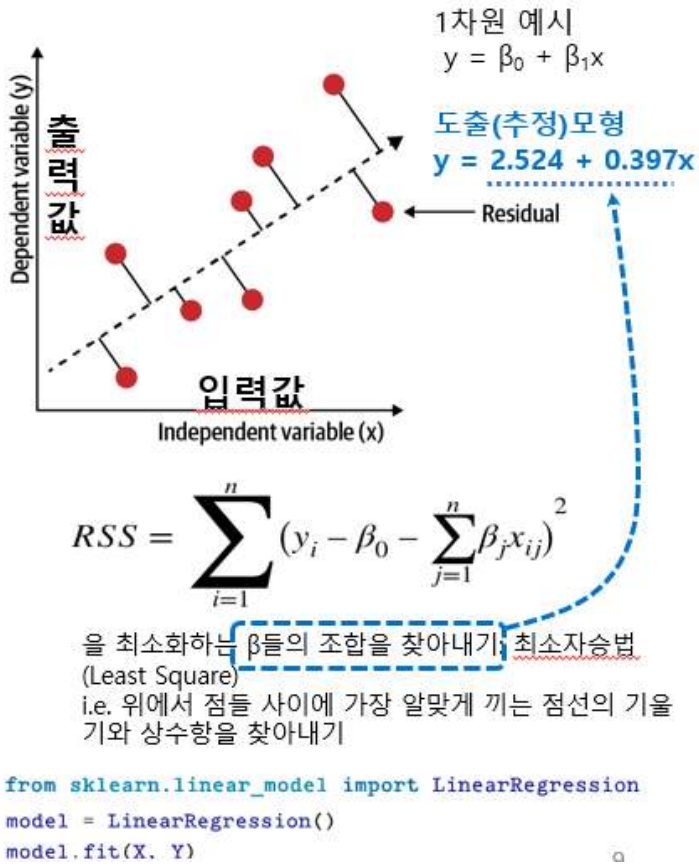

그림 5 회귀분석의 입력값 배열 --> 출력값 개념

초창기 회귀분석이 등장했을 때 거기 어렴풋하게나마 인간의 지능을 모방하는 기능이 있다는 사실은 아무도 눈치채지 못했다. 이후 통상적인 회귀분석으로부터 로지스틱 회귀분석(logistic regression)이라는 변형된 회귀분석 기법이 개발되면서, 회귀분석은 가장 원시적인 인공지능의 한 기법으로 자리잡았다.

로지스틱 회귀분석은 어떤 입력값 숫자들의 배열(vector)을 넣으면 그 출력값으로 일반적인 숫자가 출력되는 것이 아니라, 두 개의 결과, 흔히 '0'가 '1'로 코딩된 두 개의 값 중 하나가 출력되록 설계된 회귀분석이다. 앞에서 로젠블랫의 퍼셉트톤을 설명하는 절에서 '사과', '배' 중 하나를 출력값으로 내놓는 사례를 설명한 것과 원

리는 같다.

<그림>은 홍길동사의 재무비율 5개의 입력값 배열로부터 부도(0), 비부도(1) 중 하나를 출력하는 로지스틱 회귀분석 모델의 사례를 보여주고 있다. 회귀분석에서 β로 표기된 기호들은, 퍼셉트론 인공신경망 모형의 가중치 w와 사실상 같은 기능을 한다. 그것들을 우리는 파라메터(parameter)라고 부른다. LLM 모형으로 발전해도 이 가중치 파라메터의 본질은 그대로 남는다.

$$y = \frac{\exp\,(\beta_0 + \beta_1 x_1 + ... + \beta_i x_1)}{1 + \exp\,(\beta_0 + \beta_1 x_1 + ... + \beta_i x_1)}$$

- 데이터
  - 수천, 수만, 수백만 관찰 데이터
  - 독립변수 x1, x2, x3, . . . 재무비율들
  - 종속변수 y: 부도, 비부도 여부
    - Labelling: 0, 1
- 도출된 모형

최적의 $\beta_0, \beta_1, \beta_2, \beta_3, \beta_4, \beta_5$ 추정치를 찾아낸 결과

Y = -5.1294 + 0.1187*배당률
+ 0.0572*유보액/총자산
+ 0.0483*EBITDA/매출액
- 0.0097*부채총계/매출액
+ 0.0597*유형자산비중

- 예측
  - 홍길동사의 재무비율 5개 값 대입 결과
    - Y= 0.89: 비부도 가능성 구간 1 출력
    - Y =0.32: 부도 가능성 구간 0 출력

그림 6 로지스틱 회귀분석의 입력값 배열 --> 출력 개념

로지스틱 회귀분석이 출력값을 '0' 또는 '1' 가운데 하나만 선택하는 경우 이항 모델(binary model)이라고 한다. 그 방법은 [0, 1] 구간에서 적절한 임계값, 흔히 0.5를 임계값으로 설정해놓고 y값이 0.5보다 크면(<그림> 예시에서 0.89) '1'로, 0.5보다 작으면(<그림> 예시에서 0.32) '0'으로 출력하는 절차를 거쳐 나온 것이다.

로지스틱 회귀분석은 더 발전해서 [0, 1] 구간을 2개 이상으로 분할하여, 2개 이상의 출력값을 내놓는 다항로지스틱 모델(multi-logistic model)도 활용되고 있다.

■ 분류기(classifier)

로지스틱 회귀분석은 물론이고, 이후 설명할 다양한 머신러닝 기법들은 대부분 사

물의 입력값 배열로부터 출력값을 그 사물이 어디에 해당하는지를 분류하는 기능을 제공한다. 예를 들어, 동물의 사진을 넣어주고 이 사진이 '개', '고양이', '기타' 중 어디에 해당하는지를 분류, 즉 판별하는 역할을 한다. OCR(Optical Character Recognition) 모델은, 어떤 알파벳 이미지를 입력하면 그로부터 그 이미지의 특성을 대변하는 입력값 배열을 추출한 뒤, 그로부터 출력값으로 A, B, C, D, ..., Z, a, b, c, d, . . z 중 어디로 분류되는지를 판별한다.

회귀분석, SVM, DecisionTree, 앙상블, 강화학습, 초기 인공신경망(ANN) 모델은 대부분 이렇게 대상물이 어디에 속하는지를 분류하는 기능을 수행했다.

■ 기계학습의 다양한 기법과 지도학습/비지도학습

기계학습은 로지스틱 회귀분석 외에도 다양한 방법을 활용한다. 이 방법들은 사물을 분류하는 방식이 크게 지도학습과 비지도학습의 두 가지로 나뉜다.

- **지도 학습에 의한 분류**: 기계학습 중 지도 학습(Supervised Learning)은 이미 정답 라벨(Label)이 부여된 학습 데이터를 활용하여 모형을 구축하는 방식이다. 독립변수 값을 통해 종속변수인 라벨을 추정하고 판단하는 것이 핵심이다. 예를 들어 OCR 문자인식에서는 문자의 정체가 라벨이 되며, 신용평가에서는 '부도'와 '비부도'라는 두 종류의 라벨을 사용한다. 또한 사진 판독을 통해 개나 고양이를 분류하거나, 과거 데이터를 바탕으로 자산 가격을 예측하는 데에도 활용한다. 구체적인 방법론으로는 로지스틱 회귀분석, 프로빗 분석, SVM(Support-Vector Machine), 그리고 딥러닝을 포함한 인공신경망(ANN) 계열의 기법들이 존재한다.
- **비지도 학습에 의한 분류**: 비지도 학습(Unsupervised Learning)은 라벨 없이 데이터 자체의 특성만을 분석하여 분류하거나 군집화하는 방식이다. 대표적으로 주성분 분석(PCA)과 같은 차원 축소 기법과 k-means와 같은 군집화(Clustering) 기법이 있으며, 이를 통해 특정 기준 없이 고객 집단을 분류하는 사례 등에 활용한다.

그림 7 지도학습을 위한 사전 데이터 라벨링

■비지도학습의 대표적 기법

SVM, KNN, LDA 서포트 벡터 머신(SVM)은 데이터를 상이한 집단으로 구분하는 최적의 초평면(Hyperplane)을 찾는 방법이다. 직선으로 구분이 어려운 경우에는 커널 함수를 통과시켜 데이터를 변환하는 커널 트릭을 사용한다. K-최근접 이웃(KNN)은 거리가 가까운 데이터 점들끼리 모아 집단을 구분하며, 군집 수(k)와 거리 지표를 미리 설정해야 한다. 선형판별분석(LDA)은 데이터를 저차원 공간에 사영시켜 축을 이동 및 회전함으로써 집단을 가장 잘 구분하는 방식을 취한다.

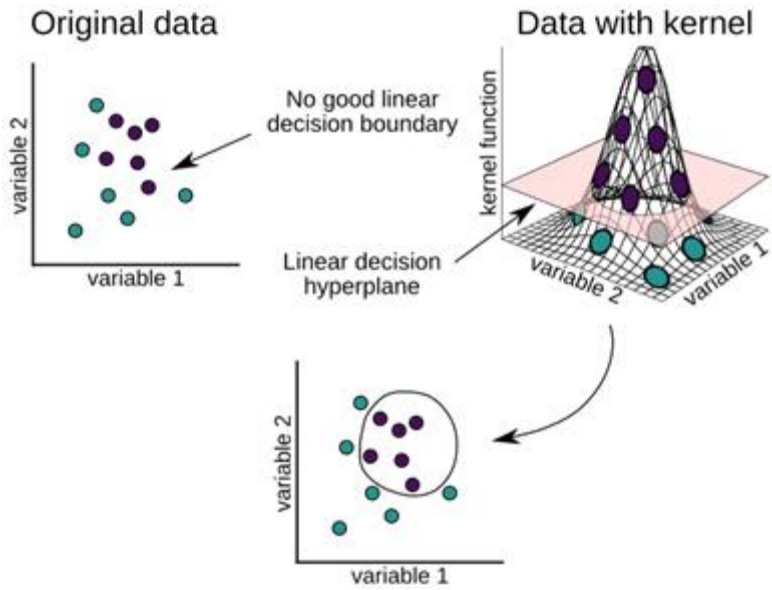

그림 8 SVM 의 데이터 분류 개념

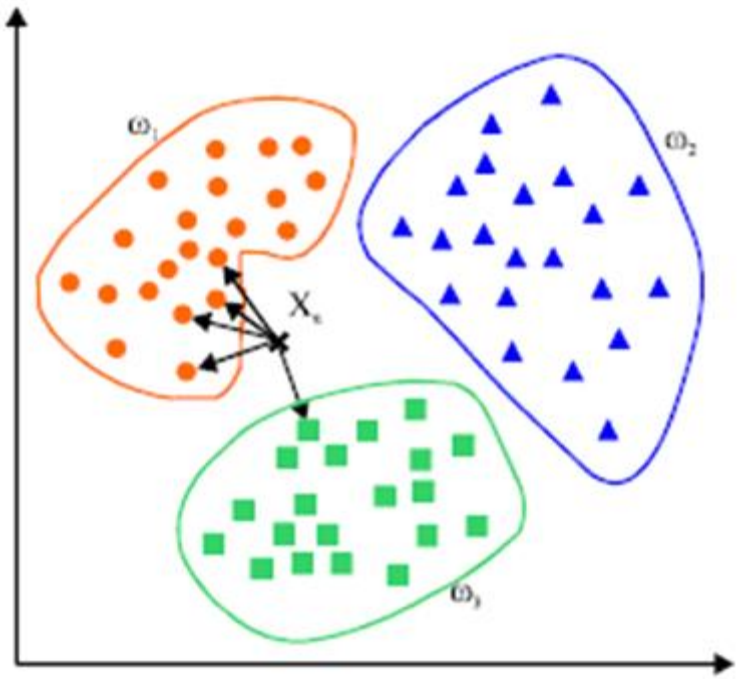

그림 9 KNN의 데이터 분류 개념

의사결정나무(Decision Tree, CART:Classification and Regression Trees)는 조건부(if-then) 논리를 사용하여 반복적인 시행착오 끝에 데이터를 분류하는 방식이다. 단일 모델의 한계를 극복하기 위해 랜덤 포레스트나 그래디언트 부스팅(GBM)과 같은 앙상블 모형을 널리 활용한다. 이때 분류를 어느 수준에서 멈출지 결정하

는 스토핑(Stopping)이나 복잡한 가지를 쳐내는 가지치기(Pruning)와 같은 조정 파라미터를 적절히 선정하는 과정이 필수적이다.

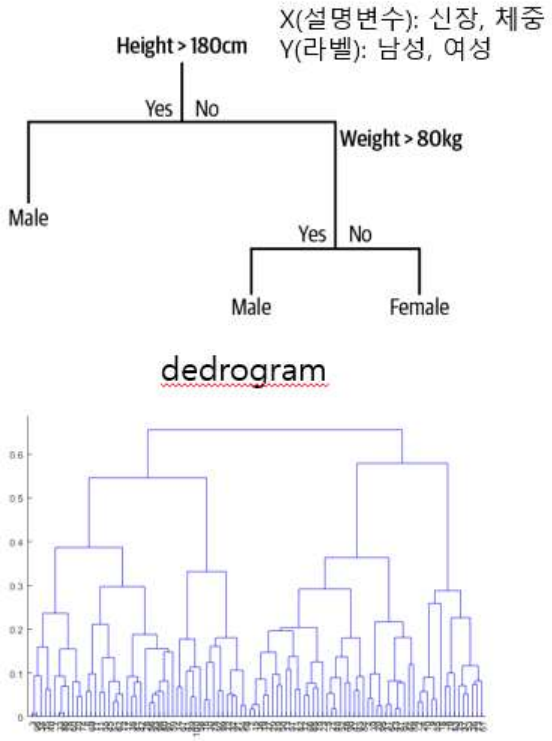

그림 10 의사결정나무의 분류 개념

■인공신경망(ANN)

○ 개요

인공신경망은 입력층과 출력층 사이에 은닉층(Hidden Layer)을 생성하여 각 노드 간의 가중치를 추정한다. 로젠블랫의 퍼셉트론은 은닉층이 단층이었으나, 이후 개선된 인공신경망은 여러 개의 층, 예컨대 3 ~4 개 층을 가진다. 이후 이 은닉층의 수가 수십개 층으로 확대된 모델을 딥러닝(Deep Learning)이라고 부른다.

ANN은 역전파(Back-propagation)나 경사하강법을 통해 오차를 최소화하는 가중치 벡터를 찾아내는 반복 과정을 거친다. 전통적인 회귀분석이 선형 분류에 치중한다면, ANN은 은닉층의 개수와 크기를 조절하여 매우 복잡한 비선형 관계를 학습할 수 있는 '블랙박스'적 특성을 지닌다.

여기서 '블랙박스'라는 의미는 파라메터 간의 연결관계가 너무 복잡하여 무엇이 무엇에 영향을 미쳐서 어떤 출력값이 나오는지 직관적으로 파악하기가 불가능하다는 뜻이다. 반면에 회귀분석의 경우에는 입력값 각각이 어느 정도 크기의 영향을 미쳐서 출력값이 나오는지 모델 수식을 보면 직관적으로 파악이 된다.

인공신경망의 구현과 시계열 예측 Python의 Keras 패키지 같은 것을 활용하면 TensorFlow와 같은 다양한 엔진을 통해 인공신경망을 효율적으로 구동할 수 있으며, 은닉층의 구조와 활성화 함수를 자유롭게 지정할 수 있다. 특히 순환신경망(RNN)은 주가나 채권 가격 같은 시계열 데이터를 예측하는 데 탁월한 성능을 보인다. RNN은 이전 시점의 정보가 현재 시점의 학습에 영향을 주는 구조를 가지고 있어 데이터의 시간적 흐름을 모형에 효과적으로 반영한다. ANN은 Python이외의 다양한 언어로 개발이 가능하지만, 지금 상당수의 ANN 개발자들은 여러 잇점 때문에 Python을 주 개발 언어로 사용하는 경향이 있다.

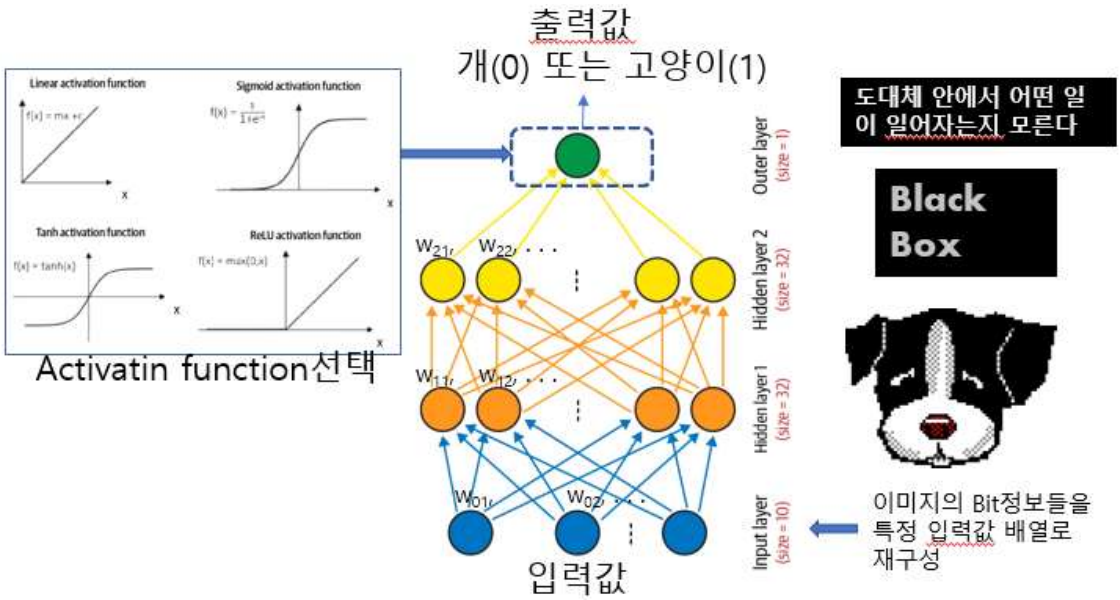

그림 11 인공신경망 모델의 분류 개념

○ANN에서 역전파(back-propagation) 기법의 기여

초기의 ANN은 은닉층의 개수가 조금만 늘어도 연산 시간이 기하급수적으로 늘어났고 그 정확도도 떨어지기 일쑤였다. 그러다나 역전파 기법이 도입되면서 그 성능이 획기적으로 개선되어, 머신러닝 ANN은 역전파기법을 보편적으로 활용하게 되었다.

역전파 알고리즘은 1960년대부터 개념이 논의되었으나, 1986년 제프리 힌튼(Geoffrey Hinton), 데이비드 루멜하트, 로널드 윌리엄스의 논문을 통해 대중화되었다. 이는 단층 퍼셉트론의 한계를 극복하고 다층 신경망을 학습시키기 위해 고안된 핵심 방법론이다.

역전파는 신경망의 예측값과 실제 정답 사이의 오차(Error)를 뒤에서부터 앞으로

(출력층 → 입력층) 전파하며 각 가중치를 갱신하는 원리이다. 이때 미분의 연쇄 법칙(Chain Rule)을 사용하여 각 가중치가 오차에 미치는 영향력을 계산한다.

간단한 수치 예시

- 입력값 x = 1.0, 초기 가중치 w = 0.5, 목표값 y = 1.0인 아주 단순한 모델을 가정한다.
- 순전파: 예측값 $\hat{y} = 1.0 \times 0.5 = 0.5$이다.
- 오차 계산: 오차 $Error = y - \hat{y} = 1.0 - 0.5 = 0.5$ 발생한다.
- 역전파: 오차를 줄이기 위해 가중치 w를 이전의 0.5로부터 다른 값으로 수정한다.
- 경사하강법에 따라 가중치를 $w_{new} = w_{old} + (\text{학습률} \times \text{오차} \times x)$ 로 갱신한다.
- 개발자가 학습률을 0.1로 지정했다면, 새로운 가중치는 0.5 + (0.1 × 0.5 × 1.0) = 0.55 가 된다.
- 이 과정을 반복하여 예측값 $\hat{y}$ 가 목표값 y에 가장 수렴하도록 가중치를 최적화한다.

역전파는 다층 신경망(MLP)의 학습을 효율적으로 가능하게 함으로써 인공신경망의 암흑기를 끝냈다. 이는 현대 딥러닝의 근간이 되었으며, 복잡한 비선형 문제를 해결할 수 있는 강력한 모델 구축의 토대를 마련했다.

■머신러닝 모델의 예측 성공률과 과적합(Overfitting) 문제

학습 과정에서는 모델이 훈련 데이터에만 지나치게 최적화되어 실제 데이터 예측력이 떨어지는 과적합 문제를 경계해야 한다. 이를 방지하기 위해 데이터를 여러 조합으로 나누어 반복 검증하는 교차 검증(Cross Validation)을 시행하여 모형의 강건성을 확보한다.

훈련 데이터에서 도출된 결과가 실제 테스트 데이터에서도 유효한지 판단하기 위해 모형의 성능을 정량적으로 측정해야 한다.

- 예측 성공률(prediction success rate): 성공률은 전체 데이터 수 중 예측치와 실제치가 일치하는 수의 비중을 의미하며, 99%와 같이 높을수록 우수하지만 실질적인 모형으로 인정받기 위해서는 최소 70~80% 이상의 수준을 유지해야 한다.
- 정분류율(accuracy) : 실제 라벨이 특정 항목(예: 남자)일 때 모형이 이를 동일하게 예측한 비율인 정분류율은 높을수록 모형의 정밀도를 나타내는 지표가 된다.
- 오분류율(error rate): 반면 실제 라벨과 다른 결과를 도출한 비율인 오분류율은

낮을수록 좋으며, 이는 모형의 안정성을 평가하는 중요한 잣대이다.

예를 들어 남자 500명, 여자 500명으로 구성된 10,000명의 입력값 데이터로부터 그가 '남자'인지 '여자'인지 분류하는 모델을 만들고 있다.

- 모델을 두 개로 적절히 분할해서 7,000명은 "훈련용(training) 데이터", 3,000명은 "검증용(validating) 데이터"로 삼았다.
- 7,000명의 훈련용 데이터로 모델을 훈련(train) 시켜보았다. 즉 모델의 노드에 대해 최적의 가중치 조합 w1, .., wn을 찾았다.
- 이 모델로 나머지 3,000명의 데이터를 대상으로 그가 '남자'인지 '여자'인지 올바로 예측을 하는지 평가해보았다. 그 결과는 다음과 같았다.

실제 남자 1,500명 중

- 남자로 정확히 예측: 1,350명
- 여자로 잘못 예측: 150명

실제 여자 1,500명 중

- 여자로 정확히 예측: 1,380명
- 남자로 잘못 예측: 120명

이 모델의 성능 지표는 다음과 같이 계산한다.

- 정분류(True Classification): 1,350 + 1,380 = 2,730명
- 오분류(Misclassification): 150 + 120 = 270명
- 예측 성공률(Accuracy) = 정분류 / 전체 = 2,730 / 3,000 = 91.0%
- 정분류율 = 2,730 / 3,000 = 0.91 (91%)
- 오분류율(Error Rate) = 270 / 3,000 = 0.09 (9%)

이 모델은 검증용 데이터에서 91%의 정확도를 보이며, 100명 중 약 9명을 잘못 분류하는 성능을 나타낸 것이다. 남자를 여자로 오분류한 경우가 150건, 여자를 남자로 오분류한 경우가 120건으로 비교적 균형잡힌 오류 분포를 보인다.

예측 성공률이 91%라면 매우 우수한 수준이라고 보는가? 누구도 여기에 대해 일반적으로 '예', 또는 '아니오'라고 대답하기 어렵다. 대상이 되는 분류 문제에 따라 그 답은 달라진다. 고전적인 머신러닝 모델에서는 패턴이 너무나 복잡한 분류 대상에 대해서 예측 성공률이 80%만 나와도 매우 우수한 모델이라고 평가하기도 했다.

예를 들어서 기업의 부도 가능성 예측 모델, 이른바 신용평가(credit rating) 모델

을 들 수 있다. 또는 영화 마이너리티 리포츠럼, 어떤 사람이 범죄를 저지를 가능성에 대핸 평가 모델가도 그럴 것이다.

가장 이상적인 성공률은 100%여야 하지만, 영향 변수가 너무나 많은 많은 복잡한 문제에 대해 그걸 기대할 수는 없다.

그러나 비교적 단순한 분류 문제인 OCR의 문자 인식 성공률이 98%라고 해도 그것은 매우 불량한 예측 성과가 될 것이다. 이때 문서 곳곳에서 a를 o 로 인식한다던가 숫자 1을 영문 소문자 l (엘)로 인식한다던가 하면, 이용자는 문서의 틀린 글자를 교정하느라 더 많은 시간을 보내야 할 것이다. 과거의 OCR 소프트웨어는 99%의 예측율을 보였지만 오늘날 OCR 기능은 발전된 ANN기법 덕분에 영문의 경우 99.9999% 수준으로 인식률이 완성되어 있다. 심지어 필기 텍스트도 매우 인식 성공률이 높다.

영화 '마이너리티 리포트'에서 범죄 가능성이 없는 선량한 사람이 가해자로 분류되는 위험 사례처럼, 잘못된 예측은 현실 세계에서 심각하고 해로운 결과를 낳을 수 있다. 따라서 정분류율을 높이고 오분류율을 낮추기 위한 지난한 시행착오를 거쳐야 하며, 모형 도출 과정에서 필연적인 타협(trade-off)을 통해 최적의 결론에 도달해야 한다. 이는 마치 의사가 진단 기기를 설계할 때, 건강한 사람을 환자로 오진하지 않으면서도 실제 환자를 단 한 명도 놓치지 않기 위해 끊임없이 정밀도를 조정하고 타협점을 찾는 과정과 유사하다.

※과적합(overfitting)이란 무엇인가?

앞의 예에서 만일 700명의 훈련 데이터 값을 다시 모델에 집어넣어서 분류를 해보았더니 분류 성공률 99%라는 매우 탁월한 분류 기능을 보였다고 가정하자.

그림 12 과적합 모델의 개념

그런데, 이 모델을 검증용 데이터를 이용하여 분류해보았더니 분류 성공률이 80%로 나왔다고 가정하자.

즉, 훈련용 데이터로는 거의 완벽하게 분류에 성공한 모델이, 검증용 데이터에서는 형편없이 낮은 성공률을 보이는 이런 현상을 과적합(overfitting)이라고 한다.

모델 개발자는, 훈련용과 검증용 데이터 사이에 성공률, 정분류율, 오분류율에 큰 격차가 발생하지 않도록 해야 한다. 대개 모델 구축이 1회 실행으로 완성되는 경우는 드물며, 이 다수의 성공지표 사이에 적절한 균형이 달성되도록 여러 시행착오를 거쳐야 한다. 개발자는 대개 다음과 같은 여러 방법을 동원해서 다양한 시도를 하면서 모델을 완성해간다.

- 데이터셋 재추출 또는 훈련용 데이터와 검증용 데이터의 적절한 재분할
- 모델에 포함시키는 변수와 그렇지 않은 변수 조합의 다양한 재시도
- 사용하는 모델 방법론 자체를 변경하여 재시도(<그림 13> 참조)

	Linear regression	Logistic regression	SVM	CART	Gradient boosting	Random forest	Artificial neural network	KNN	LDA
Simplicity	✔	✔	✔	✔	✕	✕	✕	✔	✔
Training Time	✔	✔	✕	✔	✕	✕	✕	✔	✔
Handle non-linearity	✕	✕	✔	✔	✔	✔	✔	✔	✔
Robust to overfitting	✕	✕	✔	✕	✕	✔	✕	✔	✕
Large datasets	✕	✕	✕	✔	✔	✔	✔	✕	✔
Many features	✕	✕	✔	✔	✔	✔	✔	✕	✔
Model interpretation	✔	✔	✕	✔	✔	✔	✕	✔	✔
Feature scaling needed	✕	✕	✔	✕	✕	✕	✕	✕	✕

그림 13 머신 러닝 방법론별 장단점

■ 머신러닝 강화학습

강화 학습(Reinforcement Learning)은 에이전트의 행동 결과에 따른 보상(reward)의 정도에 따라 알고리즘을 수정하며 학습하는 방식이다. 즉 앞에서 설명한 모델은 가중치 체계가 고정(fixed)되어 있고 주어진 데이터로부터 두 대상 A, B 중 하나를 선택(분류)하는 기능을 제공한 반면, 강화학습은 여러 차례 데이터를 반복적으로 재투입해가면서 어떤 대상을 택하는 것이 더 유리한지 스스로 계산해서 그 대상을 선택하도록 계속 조정해해주는 기능을 지닌다.

예를 들어서, 특정 종목의 주식을 '매도' 또는 '매수'할 것인지를 선택하기 위해서는 시간이 흐르면서 지속적으로 재투입되는 시장 데이터가 선택 앨고리즘을 스스로 수정한다.

보다 높은 기대값을 제공하는 선택지 조합을 반복적으로 탐색하여 최적의 정책(Policy)에 도달한다. 주요 구성 요소로는 에이전트, 행동(Action), 상태(State), 보상(Reward)이 있으며, 벨만 방정식(Bellman equation)과 마르코프 결정 과정(MDP)을 통해 이론적으로 구현된다.

■ LLM 등장 이전 자연어 머신러닝 처리(NLP)와 텍스트 분석

자연어 처리는 사람의 말과 글을 데이터화하여 분석하고 추론하는 기술로, 전처리, 특징 표현, 추론의 단계를 거친다. LLM이 등장하면서 자연어 처리는 일대 도약을 맞게 되지만, 그 이전에는 단어를 컴퓨터가 이해할 수 있는 벡터로 표현하기 위해 One-Hot Encoding이나 TF-IDF, Word2vec 등의 기법을 사용했다. 2010년대까지만 해도 이 기법들이 많이 각광을 받았으나, 대부분은 오늘날 LLM의 막강한 성능 앞에서 대부분 빛을 잃은 낡은 기술이 되어버렸다.

LLM이 등장하기 전에도, 인공지능은 텍스트 분류를 통해 영화 감상평의 호평과 악평을 나누거나 스팸 메일을 분류하는 역할을 수행했었다.

마. 딥러닝 혁명

1) CNN의 혁신

Geoffrey Hinton 교수 팀과 AlexNet의 역사적 승리 2012년 토론토 대학의 Geoffrey Hinton 교수와 그의 제자들은 'AlexNet'을 통해 ImageNet 대규모 시각 인식 경진대회(ILSVRC)에서 압도적인 성적으로 우승했다. 당시 기존 컴퓨터 비전 기술들의 오차율이 25%대에 머물렀던 반면, AlexNet은 15.3%라는 파격적인 수치를 기록하며 전 세계를 놀라게 했다. 이는 GPU를 활용한 병렬 연산과 layer의 수를 크게 확대한 deep 구조가 이미지 인식에서 실질적인 성능이 있음을 증명한 역사적 사건이었으며, 이를 기점으로 인공지능 연구의 중심은 전통적인 머신러닝에서 딥러닝으로 급격히 이동했다.

○ CNN의 작동 원리와 계층적 구조

CNN은 생물학적 시각 피질 구조에서 영감을 받아 설계되었으며, 이미지 데이터의 공간적 위계 구조를 효율적으로 학습한다.

▪ 1단계:

합성곱 층(Convolutional Layer)에서는 작은 필터가 이미지를 훑으며 ***지역적 특징을 추출***하여 '특징 지도(Feature Map)'를 생성한다. 초기 층은 선이나 색상 같은 단순한 특징을 인식하고, 층이 깊어질수록 사물의 형체와 같은 복잡한 패턴을 학습

한다. 예를 들어서, 초기 층에서는 점, 선, 면 같은 단순한 형태를 찾고, 층이 깊어질수록 눈, 코, 입 또는 사물의 형체와 같은 복잡한 패턴을 학습한다.

CNN에 입력되는 이미지는 픽셀 값으로 이루어진 행렬(matrix)이다. 1단계인 합성곱 층에서 CNN은 사물, 선, 형태를 전혀 인식하지 못한다. 단지 “숫자로 된 격자”만을 읽는다.

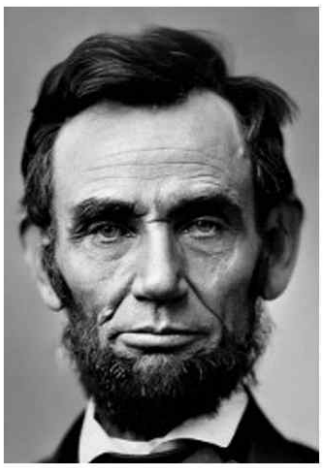

링컨 대통령의 얼굴 이미지

CNN에게는 처음에
아무 것도 보이지 않는다

그림 14 CNN이 인식하는 대상 이미지

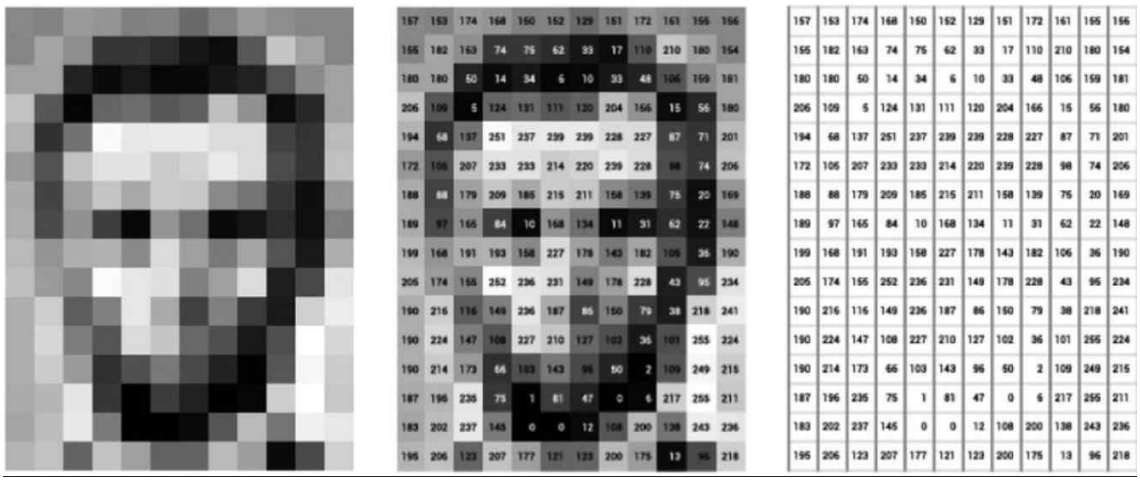

157	153	174	168	150	152	129	151	172	161	155	156
155	182	163	74	75	62	33	17	110	210	180	154
180	180	50	14	34	6	10	33	48	106	159	181
206	109	5	124	131	111	120	204	166	15	56	180
194	68	137	251	237	239	239	228	227	87	71	201
172	105	207	233	233	214	220	239	228	98	74	206
188	88	179	209	185	215	211	158	139	75	20	169
189	97	165	84	10	168	134	11	31	62	22	148
199	168	191	193	158	227	178	143	182	106	36	190
205	174	155	252	236	231	149	178	228	43	95	234
190	216	116	149	236	187	86	150	79	38	218	241
190	224	147	108	227	210	127	102	36	101	255	224
190	214	173	66	103	143	96	50	2	109	249	215
187	196	235	75	1	81	47	0	6	217	255	211
183	202	237	145	0	0	12	108	200	138	243	236
195	206	123	207	177	121	123	200	175	13	96	218

157	153	174	168	150	152	129	151	172	161	155	156
155	182	163	74	75	62	33	17	110	210	180	154
180	180	50	14	34	6	10	33	48	106	159	181
206	109	5	124	131	111	120	204	166	15	56	180
194	68	137	251	237	239	239	228	227	87	71	201
172	105	207	233	233	214	220	239	228	98	74	206
188	88	179	209	185	215	211	158	139	75	20	169
189	97	165	84	10	168	134	11	31	62	22	148
199	168	191	193	158	227	178	143	182	106	36	190
205	174	155	252	236	231	149	178	228	43	95	234
190	216	116	149	236	187	86	150	79	38	218	241
190	224	147	108	227	210	127	102	36	101	255	224
190	214	173	66	103	143	96	50	2	109	249	215
187	196	235	75	1	81	47	0	6	217	255	211
183	202	237	145	0	0	12	108	200	138	243	236
195	206	123	207	177	121	123	200	175	13	96	218

그림 15 CNN은 그림이 아니라 숫자의 행렬을 읽는다

출처: https://www.researchgate.net/figure/mage-of-Abraham-Lincoln-as-a-matrix-of-pixel-values_fig1_330902210

CNN은 별도로 설계된 convolutional kernal(일명 필터 filter) 행렬을 이 숫자

행렬에 적용해서 새로운 행렬을 만들어서 다음 layer에 전달한다.

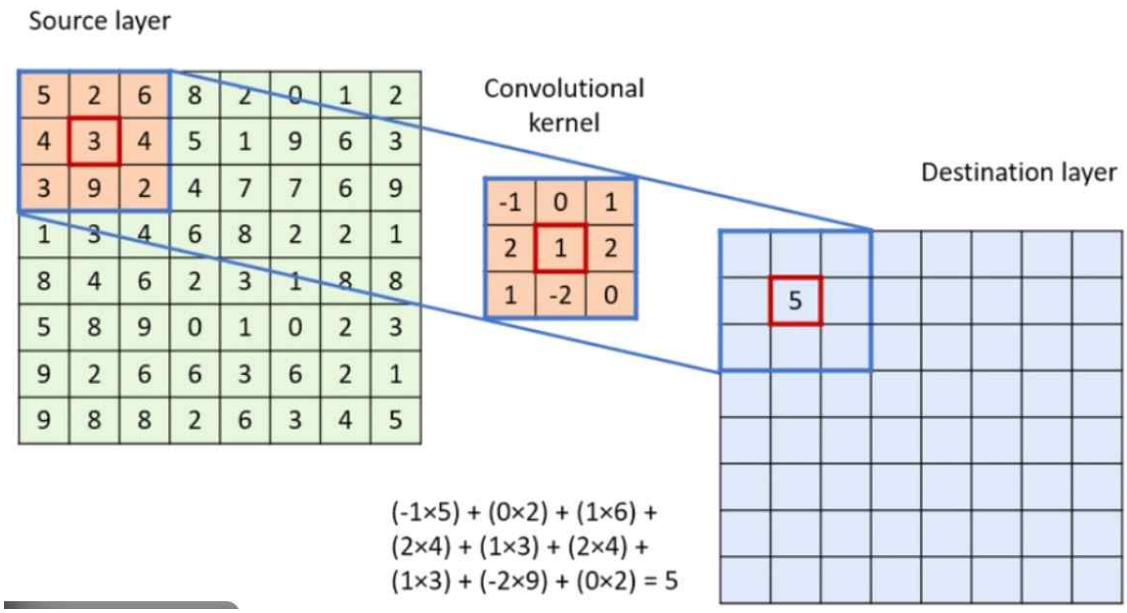

그림 16 Convolutional kernel 적용하여 다음 layer에 전달

출처 : https://medium.com/%40abhishekjainindore24/all-about-convolutions-kernels-features-in-cnn-c656616390a1

커널(필터)는 여러 종류가 있으며, 대상 이미지 행렬에 여러 종류의 커널을 적용한 뒤 그 결과를 변형된 새로운 이미지로 생성해낸다. 예를 들어서 '윤곽선 필터' $\begin{bmatrix} -1 & -1 & -1 \\ 0 & 0 & 0 \\ 1 & 1 & 1 \end{bmatrix}$를 적용하면 이 필터는 밝기 변화가 큰 부분(경계, edge)에 강하게 반응하고, 필터 적용 결과는 비록 결과(feature map)는 원본보다 흐릿하지만 비교적 윤곽선(선, 경계)이 강조되는 새로운 형태로 생성된다. 이렇게 CNN의 1층 Convolution은 보통 수평선, 수직선, 대각선, 간단한 코너 같은 저수준(low-level) 특징을 학습한다. 필터의 종류마다 어떤 필터는 세로선, 어떤 필터는 곡선, 어떤 필터는 질감(texture)을 두드러지게 하는 효과를 지니고 있다.

Original	Gaussian Blur	Sharpen	Edge Detection
$\begin{bmatrix} 0 & 0 & 0 \\ 0 & 1 & 0 \\ 0 & 0 & 0 \end{bmatrix}$	$\frac{1}{16}\begin{bmatrix} 1 & 2 & 1 \\ 2 & 4 & 2 \\ 1 & 2 & 1 \end{bmatrix}$	$\begin{bmatrix} 0 & -1 & 0 \\ -1 & 5 & -1 \\ 0 & -1 & 0 \end{bmatrix}$	$\begin{bmatrix} -1 & -1 & -1 \\ -1 & 8 & -1 \\ -1 & -1 & -1 \end{bmatrix}$

그림 17 Convolution 커널의 종류 예시

출처: 앞과 동일

이렇게 여러 종류의 필터를 통과시키면, 예를 들어 4종의 필터를 적용하면 서로 특징이 다른 4장의 feature map 이미지 행렬이 도출된다. 이 4장의 이미지는 적절한 계산 절차를 거쳐 하나의 이미지 행렬로 생성된다. 이 과정에서 활성화 함수(activation function, 주로 ReLU[21] 활용)를 통해 비선형성을 도입하고, 풀링 층(Pooling Layer)에서 데이터를 압축하여 연산 효율성과 공간 불변성을 확보한다. CNN은 여러 층을 거치면서 역전파 방식으로 필터 행렬의 값을 계속 갱신해가면서 이 과정을 반복한다. 그 과정에서 처음의 흐릿한 이미지로부터 점점 선명한 이미지에 도달한다.

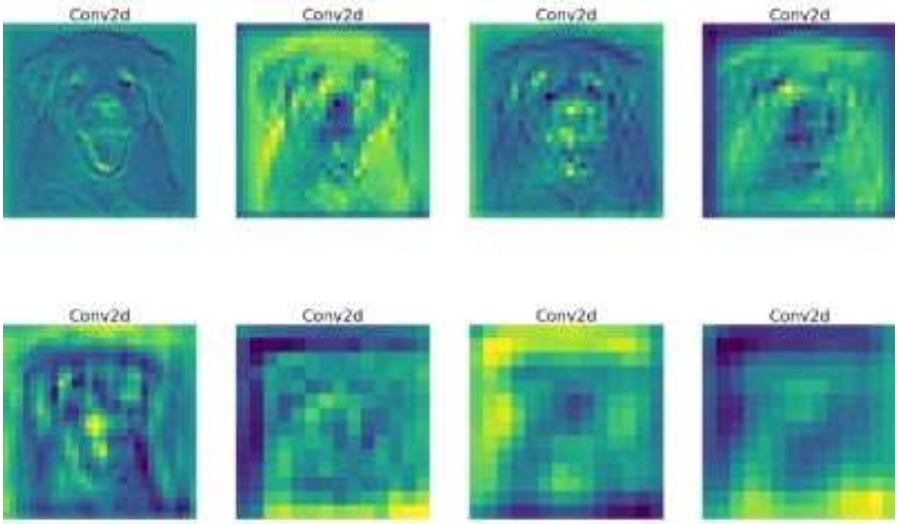

그림 18 Convolution 필터 적용 후 생성된 흐릿한 이미지 단계

21) ReLU(Rectified Linear Unit)는 딥러닝 신경망에서 가장 널리 쓰이는 활성화 함수로서, 입력이 0보다 크면 그대로 출력하고, 0보다 작으면 0으로 만드는 함수다. $f(x) = \max(0, x)$

출 처 : https://ravivaishnav20.medium.com/visualizing-feature-maps-using-pytorch-12a48cd1e573

이렇게 필터를 적용하면서 생성되는 이미지 행렬의 수치를 별도의 조작을 거쳐 인공신경망의 최종 입력값 행렬로 전환한다. 이 입력값으로부터 이미지를 가장 잘 분류하는 출력값을 얻을 수 있도록 node의 방대한 연결 계층을 구성하는 가중치 w 이 조합을 찾아낸다.

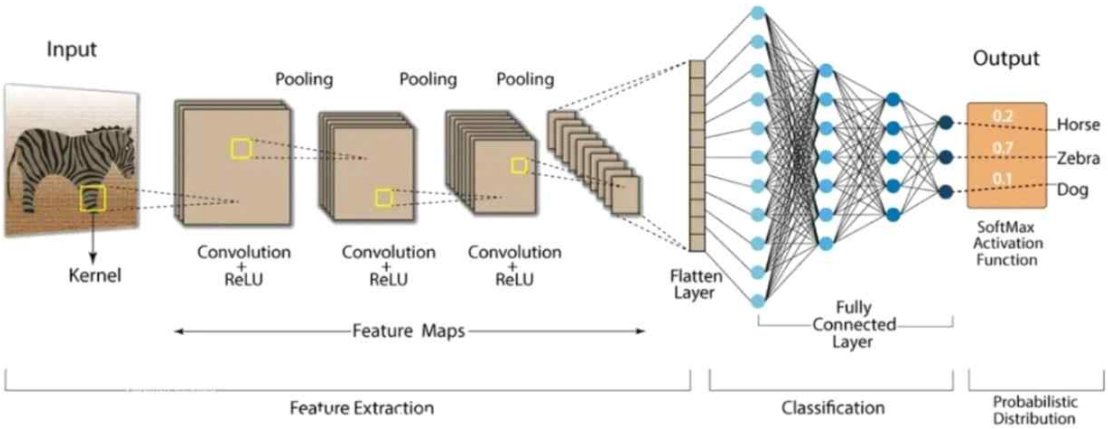

그림 19 CNN의 구조도

출 처 : https://medium.com/%40sumbatilinda/deep-learning-part-3-convolution-neural-networks-cnns-acd07bfeb6a1

마지막으로 하여 최종 분류를 수행한다.

○ Deep Learning 확산과 산업 생태계에 미친 영향

AlexNet의 성공은 딥러닝이 이론을 넘어 실제 산업 문제를 해결하는 데 탁월함을 입증했다. 이후 VGG, ResNet 등 더욱 깊고 정교한 모델들이 등장하며 자율주행, 의료 영상 분석, 얼굴 인식 등 산업 전반이 딥러닝 중심으로 재편되었다. 또한 ImageNet의 성공은 "충분한 데이터와 컴퓨팅 파워만 있다면 복잡한 문제도 해결 가능하다"는 패러다임을 확립했으며, 이는 GPU 활용의 표준화와 오픈소스 프레임워크의 발전을 촉발하여 오늘날 AI 생태계의 기틀을 마련했다.

○ 이미지에서 텍스트로 확장

CNN은 처음 이미지 분류를 목적으로 개발된 방법론이었으나, 이후 텍스트 처리에서의 효과성이 있다는 사실이 구명됐다. 문장 내 단어의 의미는 주변 단어들과의 관계, 즉 문맥에 의해 결정되므로 필터가 특정 범위의 단어 조합(n-gram)을 훑으며 주요한 의미 패턴을 추출할 수 있기 때문이다.

이후 순차적 텍스트 데이터의 생성을 다루는, CNN과 접근법이 상이한 Transformer 구조가 2017에 구글에 의해 등장하면서 텍스트 생성의 주된 방법으로 사용되고 있다. Google이 발표한 이 혁명적인 모델은 기존의 RNN이나 CNN 없이 오직 어텐션(Attention) 구조만으로 언어를 분석할 수 있다는 사실을 보여주었다. 하지만, CNN이 처음 증명했던 deep learning 표현 학습 능력은 수작업 특징 공학 없이도 탁월한 성능을 내는 통찰을 제공하며 NLP 혁명과 대형 언어 모델(LLM) 시대를 여는 초석이 되었다.

2) 알파고의 충격

2016년 3월 데미스 허사비스Demis Hasabis 가 창업한 구글 딥마인드Google Deepmind의 AlphaGo는 세계 최정상급 프로기사 이세돌 9단과의 5번기 대국에서 4승 1패로 승리했다. 이는 인공지능이 복잡한 직관과 창의성이 요구되는 바둑에서 인간 최고수를 처음으로 이긴 역사적 사건이었다.

○AlphaGo의 작동 원리[22)]

AlphaGo는 딥러닝과 강화학습을 결합한 혁신적 시스템이다. 바둑판의 19×19 격자 구조는 이미지와 유사한 2차원 공간 데이터로, CNN이 국면을 분석하는 데 최적이었다.

- **바둑판의 이미지화**: AlphaGo는 바둑판을 다층 이미지로 표현한다. 각 채널은 흑돌 위치, 백돌 위치, 빈 점, 최근 착수 이력, 불법 착수 위치 등의 정보를 담는다. 이렇게 약 48개 채널의 19×19 크기 입력 데이터가 CNN으로 전달된다.

22) https://medium.com/applied-data-science/alphago-zero-explained-in-one-diagram-365f5abf67e0 전체 과정 이미지 참조

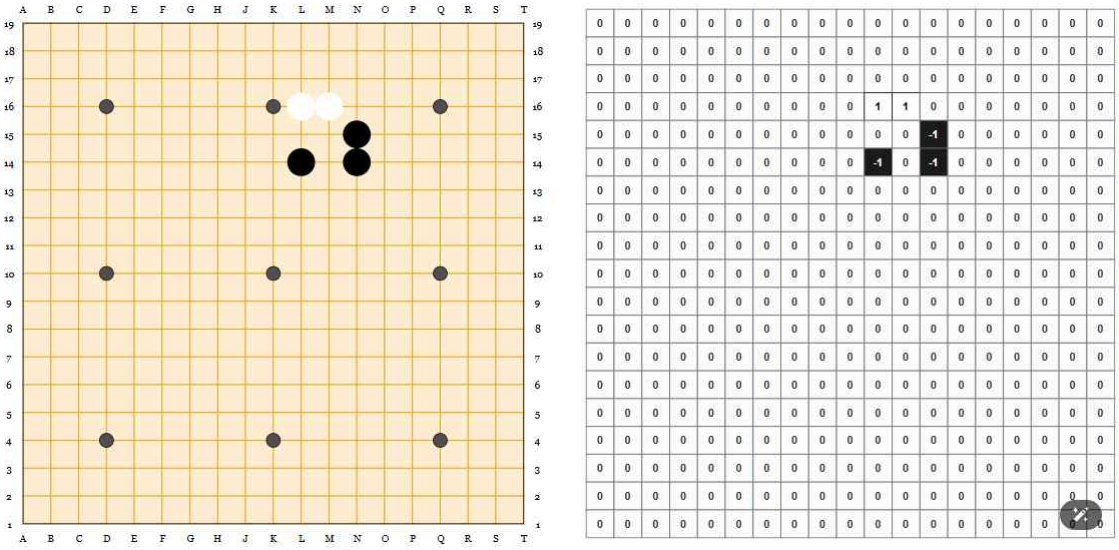

그림 20 바둑돌의 배치 형상을 입력값으로 표현하는 방식

- **정책 신경망(Policy Network)**: 13개 합성곱 층으로 구성된 CNN이 현재 국면을 분석해 다음 착수 위치의 확률 분포를 출력한다. 초기 합성곱 층은 인접한 돌들의 단순 연결 패턴을 감지한다. 중간 층은 축, 끊음, 호구 같은 전술적 형태를 인식한다. 깊은 층은 세력권, 두터움, 요충지 같은 전략적 개념을 추상화한다. CNN의 필터들은 바둑의 국부적 패턴이 위치와 무관하게 반복된다는 특성을 활용해, 동일한 형태를 바둑판 어디서든 인식할 수 있다. 이 신경망은 프로기사 기보 약 3천만 국면으로 지도학습되어 57%의 정확도로 인간 고수의 착수를 예측한다.
- **가치 신경망(Value Network)**: 정책 신경망과 유사한 CNN 구조지만 출력이 다르다. 현재 국면이 얼마나 유리한지를 -1(흑 완패)에서 +1(흑 완승) 사이의 단일 값으로 평가한다. 이 신경망은 자가 대국(self-play)으로 생성된 3천만 개의 서로 다른 국면에서 학습되었다. 각 국면마다 최종 승패 결과를 레이블로 사용해, 특정 배치가 승리로 이어질 가능성을 학습한다.
- **몬테카를로 트리 탐색(MCTS)의 통합**: AlphaGo는 위의 두 신경망을 MCTS와 결합해 최선의 수를 찾는다. 탐색 과정은 다음과 같다. 먼저 정책 신경망이 유망한 착수 후보들을 제안한다. 각 후보에 대해 가상으로 착수한 후, 가치 신경망으로 그 국면의 승률을 즉시 평가한다. 동시에 빠른 정책 신경망(shallow CNN)으로 수천 번의 무작위 시뮬레이션을 수행해 통계적 승률도 계산한다. 두 평가를 결합해 가장 유망한 가지를 우선적으로 탐색한다. 이 과정을 1회의 착수당 수만 번 반복하며, 점점 정확한 승률 추정치로 수렴한다. 최종적으로 가장 방문 횟수가 많은 수를 선택한다.
- **CNN의 결정적 역할**: 바둑의 핵심은 국부적 전투와 전역적 전략의 균형이다.

CNN은 지역적 패턴 인식에 탁월하므로, 특정 영역의 삶과 죽음, 연결 상태를 정확히 판단한다. 동시에 깊은 층을 쌓으면서 넓은 수용 영역(receptive field)을 확보해, 멀리 떨어진 돌들 간의 상호작용과 전체 세력 균형도 파악한다. 13개 층을 통과하며 정보가 점진적으로 추상화되는 과정은, 인간 기사가 국면을 직관적으로 이해하는 방식과 유사하다.

- **강화학습을 통한 자기 개선**: 인간 기보로 초기 학습 후, AlphaGo는 자신의 복사본과 수백만 번 대국하며 정책 신경망을 개선했다. 승리로 이어진 착수 패턴은 강화되고 패배로 이어진 패턴은 약화되는 방식으로, 인간이 발견하지 못한 새로운 전략을 스스로 개발했다. 이세돌과의 2국 37수 "어깨 짚기"는 정석에 없던 수로, 당시 해설자들조차 실수로 오인했지만 결국 승리의 핵심이 되었다.

※몬테카를로(Monte Carlo) 트리 탐색(Tree Search)

몬테 카를로 기법은 컴퓨터로 가상의 수치를 무수히 반복시켜서 어떤 문제의 최적 선택 또는 최적 해(解)을 찾아내는 방법이다. 무수히 많은 횟수(수천, 수만회 이상)로 난수(random number)를 발생시켜서 그 중에서 해결하고자 하는 조건에 가장 부합하는 것들을 선별하여 그를 바탕으로 문제의 해답을 찾아내는 방법이다.

AlphaGo의 경우에는, 바둑판 상에 어떤 돌의 조합이 주어져 있을 때 경기자가 다음 차례에 취할 수 있는 여러 갈래의 가능한 수(手) 중 어떤 가지(tree)를 택해야 가장 이길 확률이 높아지는가를, 난수 생성을 통해 찾아낸다.

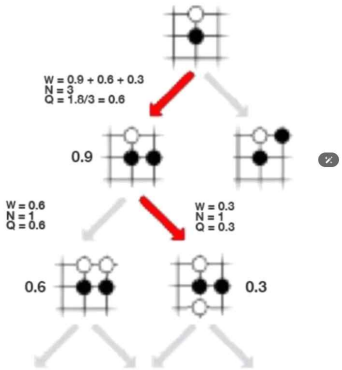

그림 21 AlphaGO MTCS 의 개념
출처 : https://jonathan-hui.medium.com/monte-carlo-tree-search-mcts-in-alphago-zero-8a403588276a

일반적으로 수학 방정식 체계를 논리적으로 풀어서 답을 구할 수 없는 상황에서, 몬테카를로 기법을 통해서 답에 가장 가까운 근사치를 찾아내는 방법이 과학자나 공학자들 사이에서 자주 활용되고 있다. 간단한 예를 들어서 방정식 $f(x) = x^5 - 3x^4 + 2x^3 - 5x^2 + x - 7 = 0$ 의 해 x를 찾아내는 일은, 대수(algebra)의 방법으로는 불가능하다. 그래서 이 해를 찾기 위해 수천, 수만회에 걸쳐 그럴 듯한 x 값들을 임의의 난수로 생성해서 이 방정식에 대입해보면 이 조건에 가장 근접하는 값을 찾을 수 있다. 실제로 Monte Carlo 기법을 적용해보면, 그 해 x는 2.1~2.3 사이에 있다는 점이 드러나고 그 구간 안의 값으로 다시 정밀하게 반복 탐색해보면 약 $x \approx 2.186$ 이라는 사실을 알 수 있다.

AlphaGo는 CNN의 공간 패턴 인식 능력, 깊은 신경망의 계층적 추상화, 강화학습의 전략 최적화, 그리고 MCTS의 체계적 탐색을 결합해 바둑이라는 난제를 돌파했다. 경우의 수가 10^170에 달하는 문제를 무차별 탐색이 아닌 학습된 직관으로 해결함으로써, 인공지능이 인간 고유의 영역으로 여겨졌던 창의성과 직관의 영역에 도달할 수 있음을 증명했다.

이 사건으로 인공지능의 위력이, 전문가 세계를 벗어나 전세계의 대중에게 깊이 각인되는 효과가 었었다. 그러나, 이것만 가지고는 아직 AI가 실생활에 확산되는 계기를 마련하지는 못했다. 바둑이라는 주제 자체가 특수한 활동 영역에 국한된 것이

었기 때문이다.

※ Demis Hassabis(1976~)

"데미스 허사비스는 1976년 영국 런던에서 태어나 어린 시절부터 체스 신동으로 유명했다. 그는 13세에 체스 마스터의 경지에 이르렀으며, 17세에는 이미 게임 개발자로 활약했다. 케임브리지 대학교에서 컴퓨터과학을 전공한 뒤, 게임 산업에서 경험을 쌓고, 인지신경과학 분야에서 박사학위를 취득하며 학문과 실무를 두루 경험했다.

2010년, 그는 AI 연구 기업 딥마인드를 공동 창업했고, 2014년에 구글에 인수된 후 AI 연구의 세계적 리더로 자리매김했다. 특히 2016년 알파고가 이세돌 9단을 꺾으며 전 세계에 이름을 알렸고, 2020년 단백질 구조 예측 시스템 AlphaFold를 통해 과학계의 난제를 해결했다. 이를 통해 그는 2024년 노벨 화학상을 수상하며 AI 기술의 과학적 가치를 입증했다."[23)]

3) AlphaFold

데미스 허사비스의 노벨상 수상의 근거가 된 업적에 대해 좀 더 자세히 살펴보자.

단백질 접힘 문제(Protein Folding Problem)는 1970년대부터 연구자들이 해결하려 했던 악명 높은 난제였다. 단백질은 20종류의 아미노산이 긴 사슬처럼 연결된 구조다. 이 사슬이 복잡하게 접혀서 3차원 구조를 만드는데, 이 3차원 구조가 단백질의 기능을 결정한다. 문제는 아미노산 서열만 보고 최종 3차원 구조를 예측하는 것이 극도로 어렵다는 점이었다.

100개 아미노산으로 이루어진 단백질도 이론적으로 취할 수 있는 구조가 10^300개 이상이다. 우주의 원자 개수(10^80개)보다 훨씬 많다. 기존에 실험적 방법, 예컨대 X-ray 결정학이나 냉동 전자현미경으로 구조를 밝히는 데 수개월에서 수년이 걸렸다. 또한 많은 단백질은 결정화가 불가능하거나 실험 조건에서 불안정하며, 단백질 하나를 밝히는 데조차 막대한 비용이 소요된다. 물리학 법칙에 기반한 시뮬레이션은 작은 단백질에도 슈퍼컴퓨터로 수년이 걸렸고, 정확도도 낮았다.

2020년 데미스 허사비스와 존 점퍼는 AlphaFold2라는 AI 모델을 발표했다. 이 모델은 CASP(Critical Assessment of Structure Prediction) 대회에서 실험적으로 밝혀진 구조와 원자 수준으로 일치하는 예측을 내놓아 과학계를 놀라게 했다.

거기 적용된 방법론은 다음과 같다.

- **Attention 기반 트랜스포머 아키텍처**

23) https://edumorning.com/articles/524

- 아미노산 서열의 먼 거리에 있는 잔기들 간의 관계를 포착한다
- 어떤 아미노산끼리 공간적으로 가까이 있을지 예측한다

○ **진화적 정보 활용 (MSA - Multiple Sequence Alignment)**

- 유사한 단백질들의 서열을 비교 분석한다
- 진화 과정에서 보존된 패턴이 구조적으로 중요하다는 가정을 활용한다
- 수백만 개의 알려진 단백질 서열 데이터베이스를 학습한다

○ **구조 모듈 (Structure Module)**

-3차원 좌표를 직접 예측하는 신경망이다
- 반복적으로 구조를 개선한다 (iterative refinement)
- 물리적 제약조건을 암묵적으로 학습한다

○ **데이터 학습 과정**

- 실험적으로 밝혀진 약 17만 개의 단백질 구조(Protein Data Bank)로 학습했다
- 예측 구조와 실제 구조 간의 오차를 최소화하도록 훈련했다.

그림 22 Demis Hassabis
출처 : https://en.wikipedia.org/wiki/Demis_Hassabis

AlphaFold2는 단순히 물리 법칙을 시뮬레이션하는 대신, "진화가 이미 해결한 문제의 패턴"을 학습했다는 데에 특장점이 있었다. 자연은 수십억 년에 걸쳐 안정적으

로 접히는 단백질만 선택했고, AI는 이 진화적 지혜를 데이터에서 추출한 것이다.

AlphaFold2는 연구자들이 확인한 거의 모든 2억 개의 단백질 구조를 예측할 수 있었고, 190개국에서 200만 명 이상이 이를 사용했는데, 단백질 하나의 구조를 예측하는 시간을 기존에 수개월 또는 수년 걸리던 것을 수 분 내지 수 시간 내에 예측했다. 아울러 예측 결과는 원자 수준의 정확도(GDT 점수 90점 이상)까지 달성했다. 또한 모든 연구자가 무료로 사용 가능하도록 했다는 면에서 그 효용을 더욱 크게 확산시킬 수 있었다.

의학계 및 생리학계는 이 성과에 힘입어 다음과 같은 발전이 가능했다.

1. 신약 개발 가속화

연구자들은 이제 항생제 내성을 더 잘 이해하고 플라스틱을 분해하는 효소의 이미지를 만들 수 있다. 질병 관련 단백질의 구조를 즉시 파악하여 약물 타겟 발견이 빨라졌다. 약물과 타겟 단백질의 결합 방식을 정확히 예측할 수 있다. 구조 실험이 불가능했던 단백질들을 발견하게 딤으로써 희귀질환 연구가 활성화되었다

2. 질병 메커니즘 이해

암, 알츠하이머, 파킨슨병 등과 관련된 단백질 구조를 밝혀 병의 원인을 이해하게 되었다. 돌연변이가 단백질 구조에 미치는 영향을 예측하여 유전 질환 연구가 진전되었다

3. 백신 및 치료제 개발

COVID-19 스파이크 단백질 구조 예측으로 백신 개발에 기여했다. 항체 설계가 가능해져 면역치료제 개발이 가속화되었다

4. 기초 생물학 혁신

광합성, DNA 복구, 세포 분열 등 기본 생명 과정의 분자 메커니즘을 이해하게 되었다

알려지지 않았던 단백질 가족의 기능을 추론할 수 있다

생명의 진화 과정을 분자 수준에서 추적할 수 있다

5. 연구 민주화

값비싼 실험 장비 없이도 전 세계 어디서나 단백질 연구가 가능해졌다. 개발도상국 연구자들도 첨단 구조생물학 연구에 참여할 수 있게 됐다.

6. 합성생물학 및 효소 공학

AlphaFold는 실제 효소와 우리 세포의 단백질이 어떻게 생겼는지 보여줌으로써 생물학 과학을 혁신했고, 이는 AI 방법이 수십만 가지의 다양한 단백질을 만들 수 있게 하여 단백질 설계 능력을 촉진했다. 새로운 기능을 가진 효소 설계, 산업용 생체촉매 개발, 환경 정화용 효소 개발 등 관련 인접 연구에까지 그 위력을발휘했다.

핵심은 "선형 염기 서열 → AI 변환 → 복잡한 3D 구조(<그림> 참조)"를 통해 50년 난제를 AlphaFold가 해결했다는 점이다. 과거에는 이 변환 과정을 실험적으로만 밝힐 수 있었고 수년이 걸렸지만, 이제는 몇 분 안에 정확히 예측할 수 있다.

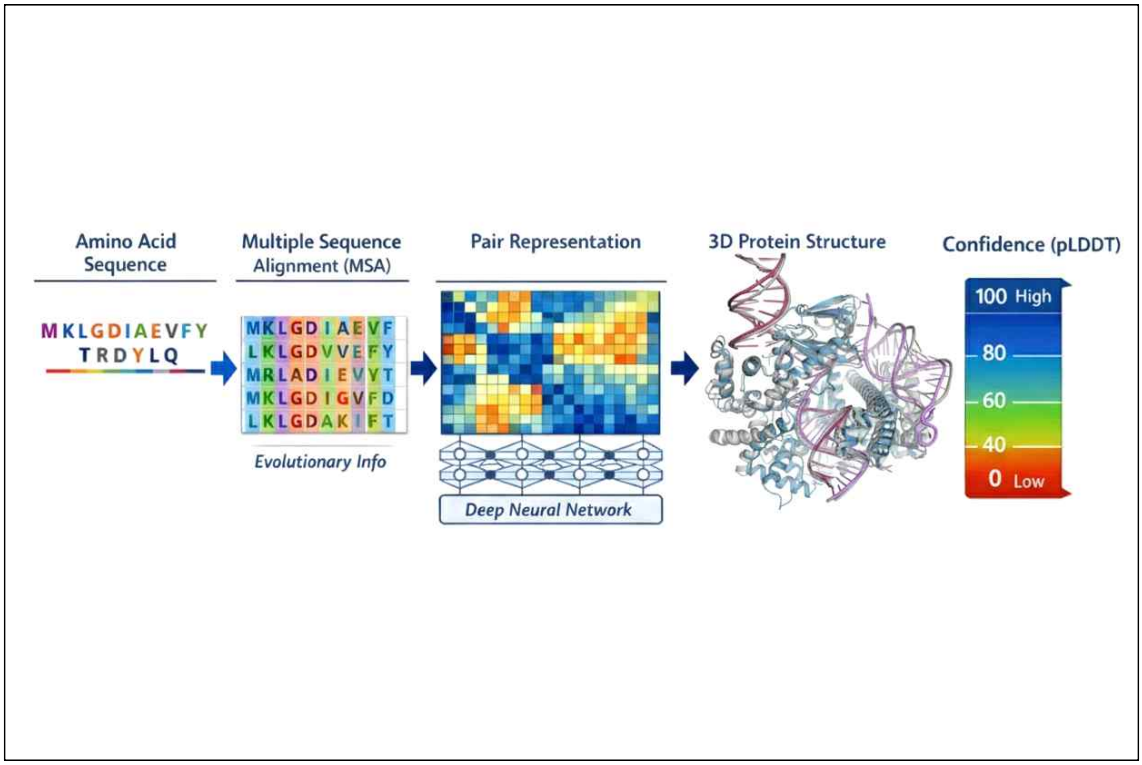

그림 23 AlphaFold의 단백질 3D구조 예측 흐름도

출처: ChatGPT & Gemini Image 조합 2026년 1월 3일 오후 06_12_41

4. AI의 역사 II: LLM의 등장

가. Transformer

1) 등장

트랜스포머(Transformer) 아키텍처는 2017년 구글 브레인 팀이 발표한 논문 "Attention is All You Need"를 통해 세상에 처음 공개되었다. 이 모델이 등장하기 전, 자연어 처리(NLP) 분야를 지배하던 기술은 RNN(순환 신경망)과 LSTM(장기 단기 메모리)이었다.당시 RNN 계열 모델들은 문장의 단어를 하나씩 순차적으로 처리해야 한다는 구조적 한계가 있었다.

이는 두 가지 심각한 문제를 야기했다. 첫째는 병렬 연산의 불가능이다. 이전 단어의 처리가 끝나야 다음 단어를 처리할 수 있었기에 대규모 데이터를 학습시키는데 엄청난 시간이 소요되었다.

둘째는 장기 의존성(Long-term Dependency) 문제이다. 문장이 길어질수록 앞부분에 등장한 정보가 소실되어 문맥을 정확히 파악하지 못하는 현상이 발생했다. 트랜스포머는 이러한 순차적 처리 방식에서 완전히 벗어나기 위해 탄생했다.

2) 원리

트랜스포머의 명칭에서 알 수 있듯이, 이 모델의 핵심은 Self-Attention(자기 주의 집중) 메커니즘이다. 기존 모델들이 단어를 순서대로 훑었다면, 트랜스포머는 문장 내의 모든 단어를 동시에 입력받고 각 단어 간의 관계를 수치화한다.

입력된 문장에서 특정 단어가 다른 모든 단어와 어떤 연관성이 있는지 계산한다. 예를 들어 "동물은 길을 건너지 않았다. 그것은 너무 피곤했기 때문이다."라는 문장에서 '그것'이 '길'이 아닌 '동물'을 가리킨다는 것을 수학적인 가중치로 결정한다. 이를 위해 데이터는 $Query$(질문), Key(비교 대상), $Value$(값)라는 세 가지 벡터로 변환되어 연산된다.

Multi-Head Attention은 한 번에 하나의 관계만 보는 것이 아니라, 여러 개의 어텐션 메커니즘을 동시에 가동하는 것이다. 이는 문장을 여러 각도(문법적 관계, 의미적 관계 등)에서 입체적으로 분석할 수 있게 한다.

Positional Encoding은, 단어를 동시에 입력받으면 순서 정보가 사라진다는 문제를 해결하기 위해 각 단어의 위치 정보를 나타내는 고유한 값을 데이터에 더해주는 것이다. 이를 통해 모델은 단어의 선후 관계를 인지한다.

트랜스포머는 구조적으로 입력값인 인코더(Encoder)와 출력을 생성하는 디코더(Decoder)가 쌓여 있는 구조이다.

- 인코더: 입력 문장 전체를 보고 각 단어의 의미와 문맥을 충분히 반영한 벡터 표현을 생성한다. BERT는 이 인코더 구조를 극대화하여 문장 이해 능력을 높인 모델이다.
- 디코더: 인코더에서 전달받은 정보와 현재까지 생성된 단어들을 바탕으로 다음에 올 단어를 예측한다. GPT는 이 디코더 구조를 기반으로 문장 생성 능력을 비약적으로 발전시켰다.

트랜스포머의 등장은 인공지능 역사에서 '패러다임의 전환'이라 불릴 만큼 막대한 의미를 지닌다.

첫째, 대규모 확장의 길을 열었다. 수많은 GPU를 동시에 가동시키는 병렬 연산이 가능해지면서 수천억 개의 매개변수를 가진 거대 모델을 학습시킬 수 있는 환경이 조성되었다. 현재 우리가 사용하는 ChatGPT와 같은 초거대 AI는 트랜스포머가 없었다면 존재할 수 없었다.

둘째, 전이 학습(Transfer Learning)의 보편화이다. 방대한 양의 일반 텍스트로 트랜스포머를 사전 학습시킨 뒤, 특정 작업(번역, 요약 등)에 미세 조정하는 방식이 표준으로 자리 잡았다. 이는 AI 개발 효율성을 극대화했다.

셋째, 모달리티(Modality)의 확장이다. 트랜스포머 구조는 언어를 넘어 이미지(Vision Transformer), 음성, 유전자 분석 등 데이터가 시퀀스(순서) 형태를 띠는 모든 분야에 적용되기 시작했다. 이는 범용 인공지능(AGI)으로 나아가는 핵심 아키텍처로서의 지위를 공고히 했다.

결론적으로 트랜스포머는 "순차적 사고"라는 기존 AI의 굴레를 벗겨내고, 데이터 사이의 복잡한 관계를 한눈에 파악하는 "동시적 사고"를 가능케 함으로써 현대 생성형 AI 시대의 기초를 닦았다.

3) Self-Attention 계산 과정 예시

■사전 학습

사전 학습을 위해 100만편의 문학작품 텍스트가 주어졌다고 하자. 이 텍스트는 다음과 같은 식의 문장들로 이루어진 방대한 양의 데이터다.

“He was an old man who fished alone in a skiff in the Gulf Stream and he had gone eighty-four days now without taking a fish. In the first forty days a boy had been with him. But after forty days without a fish the

boy's parents had told him that the old man was now definitely and finally salao, which is the worst form of unlucky, and the boy had gone at their orders in another boat which caught three good fish the first week. . . . .."(E. Hemingway, THE OLD MAN AND THE SEA)

이런 데이터는 Web 상에서 크롤링하거나 gutenberg project 사이트에서 획득한다. 이때지식재산권 침해는 별개의 문제로 심각하게 다루어져야 한다. 어쨌든 이 모든 텍스트를 구성하는 모든 문장의 음소(주로 단어, 한국어는 조사와 어미가 더해져서 더 복잡)를 정해진 규약에 따라 숫자 행렬로 전환된다. 이 방대한 텍스트로부터 특정 가중치 행렬 W^Q, W^K, W^V를 도출한다. 이 과정을 사전 학습(pre-Training)이라고 한다.

이 가중치 행렬 W^Q, W^K, W^V가 처음부터 완벽한 값을 가지고 있는 것은 아니다. 이 행렬들은 인공지능이 대규모 데이터를 읽으며 수많은 시행착오를 거친 끝에 얻어지는 결과물이다. 이 가중치들이 도출되는 과정은 크게 ANN의 일반적인 추정 과정을 거친다. 초기화 이후 손실 계산(loss calculation)과 역전파(back propagation)를 거의 무한 반복하는 과정으로 구성된다.

1. 무작위 초기화 (Random Initialization)

학습이 시작되기 전, W^Q, W^K, W^V 행렬의 내부 숫자들은 아주 작은 무작위 값(예: 0.01, -0.02 등)으로 가득 채워진다. 이때의 인공지능은 단어 간의 관계를 전혀 모르는 상태이며, 어떤 단어가 중요한지도 판단하지 못한다.

예를 들어, "나는 학교에 [?]"라는 문장에서 다음에 올 단어 [?]를 예측하라고 시킨다. 초기 모델은 가중치가 엉망이므로 "사과"나 "자동차" 같은 엉뚱한 단어를 내뱉을 것이다.

2. 손실 함수 (Loss Function) 계산

모델이 예측한 값과 실제 정답(데이터셋에 있는 진짜 단어)을 비교한다. 정답은 "간다" 인데 모델의 예측이 "사과"라면 이 차이를 '손실(Loss)' 또는 '오차(Error)'라고 부른다. 수학적으로 이 오차값이 클수록 "현재 가중치 행렬들이 형편없다"는 것을 의미한다. 오차값이 작을수록 “가중치 행렬이 잘 도출되어 있다“는 것을 의미한다.

4. 역전파 (Backpropagation)와 경사하강법 (Gradient Descent)

이 단계가 가중치를 실제로 '도출'하는 핵심 과정이다.

역전파: 발생한 오차를 모델의 뒤쪽(출력층)에서부터 앞쪽(입력층)으로 거꾸로 전달한다. 이 과정에서 "어떤 가중치 행렬이 오차를 만드는 데 얼마나 기여했는지"를 미분을 통해 계산한다.

업데이트: 계산된 기여도에 따라 W^Q, W^K, W^V의 숫자들을 아주 조금씩 수정한다. 오차를 줄이는 방향(경사하강법)으로 숫자를 깎거나 더하는 것이다.

5. 반복 학습 (Iteration)

이 과정을 수조회(n×1,000,000,000,000회) 반복한다. 문장을 읽고 예측하고 틀리면 오차를 계산해서 가중치 행렬 W^Q, W^K, W^V를 아주 미세하게 수정한다. 다시 문장을 읽는다. 수개월 동안 초대형 컴퓨터(GPU/TPU)를 돌려 이 과정을 반복하면, 가중치 행렬들은 점차 "주어와 동사의 관계를 잘 파악하고, 어떤 대명사가 무엇을 지칭하는지 정확히 연결하는" ***최적의 가중치 조합으로 수렴***하게 된다. 이것이 우리가 말하는 ***'학습된 모델'***의 실체이다.

이 가중치 행렬은 수학적인 '정답지'가 따로 있어서 한 번에 구해지는 것이 아니다. 수많은 텍스트를 읽으며 "이렇게 숫자를 바꾸니 정답을 더 잘 맞추네?"라는 과정을 무한히 반복하여 찾아낸 정교한 숫자들의 집합이다. 결국 우리가 사용하는 GPT나 BERT(다음 절 설명)의 지능은 이 행렬 속의 미세한 숫자값들에 저장되어 있다.

4) Q, K, V 연산

트랜스포머 모델의 핵심 과정인 Q, K, V 연산 과정을 설명하기로 한다.

간단한 예를 들어 “I love AI”라는 텍스트의 3개 단어 'I', 'love', 'AI'라는 글자는 각각 특정한 숫자의 나열(벡터)로 변환한다.

- **I** → $[1.2, 0.5]$
- **love** → $[0.1, 2.8]$
- **AI** → $[1.9, 2.2]$

여기서 이 벡터의 크기가 2, 즉 그 벡터를 구성하는 숫자가 2로 예를 들었는가에 대해서는 설명이 필요하다. 그것은 단어를 거대한 공간상의 한 점으로 표현한 것이다. 이 예시에서는 각 단어를 2차원 평면 상의 한 점으로 표현한 것이다.

이 숫자 2를 차원(dimension)이라고 한다. 각 차원은 사물의 특성을 대응 배치시키는 어떤 기준을 의미한다. 예를 들어서 ‘사람’, ‘코끼리’, ‘사슴’ 같은 단어들을 공간상에 배치하는 기준을 3개로 잡으면 이런 식이 될 것이다j.

- 기준1: 지능
- 기준2: 체중
- 기준3: 공격성

‘사람’ ‘사자’ ‘코끼리’는 이 세 가지 기준선으로 이루어진 공간의 어느 적당한 지점에 위치할 것임을 쉽게 상상할 수 있다.

두툼한 종이 사전에 실린 단어를 그 ‘수록 순서’라는 기준으로만 표시하면, 각 단어는 1차원 공간, 즉 직선 상에서 표현할 수 있다. 즉 A~부터 시작해서 ~ZZZZ로 끝나기까지 표제어는 1번부터 시작해서 수만번째에서 끝날 것이다. 만약 School이라는 단어가 7503번째에 나온다면 School --> [7,503]로 1차원 공간 상의 한 수치로 표현될 것이다.

그러나, 실제 LLM에서는 이런 차원별 특징을 모델 개발자가 직접 정의해주는 것이 아니라, 모델이 스스로 방대한 데이터를 학습하는 과정에서 스스로 찾아내고 정의하는 것(Self-learned/Emergent Features)이다.

모델 개발자는 차원의 '개수'(예: 10,000개)만 설정할 뿐, "1번 차원은 품사, 42번 차원은 주어의 성격"과 같이 구체적인 역할을 부여하지 않는다. 모델은 지정된 차원 수 안에서 스스로 학습 과정에서 패턴을 묘사하는 수치를 찾아내서 저장한다.

- 비지도 학습(Unsupervised Learning): 모델은 수조 개의 문장을 읽으며 단어들이 배치되는 패턴을 파악한다. 이 과정에서 단어들 사이의 관계를 가장 잘 설명할 수 있는 '최적의 기준'들을 스스로 구축한다.
- 추상적 표현: 모델이 찾아낸 기준은 인간의 언어적 개념(품사, 성별 등)과 일치할 때도 있지만, 사람이 이해하기 힘든 복잡한 수학적 관계일 때가 더 많다.

모델이 이 방대한 차원 수만큼의 특징에 대해서조차 스스로 찾아내서 생성해내고 이것이 사람이 이해하는 의미 있는 숫자가 아닌만큼, 모델은 더욱 ‘Black Box’ 속성을 지닐 수밖에 없다. 모델 개발자가 정의하고 지정해줄 수 있는 것은 기껏해야 다음과 같은 '하이퍼파라미터(hyper parameter'들이다.

- 임베딩 차원: 단어를 몇 개의 숫자로 표현할 것인가 (예: 12,288차원)

- 층(Layer)의: 어텐션 연산을 몇 층에 걸쳐 반복하여 의미를 깊게 파악할 것인가.
- 어텐션 헤드(multi-head) 수: 동시에 몇 개의 서로 다른 관점(Head)에서 문장을 바라보게 할 것인가.

위에서 예로든 I, love, AI 라는 세 개 단어에 대해도 가로축과 세로축에 사람이 이해할 수 있는 어떤 의미를 부여하는 것이 아니며, 초기 출발 단계에서 임의로 배치한 것이다. 어쨌든 하나의 숫자 배열은 각각 그림과 같은 2차원 공간, 즉 평면상의 좌표 위치를 나타낸 것이다.

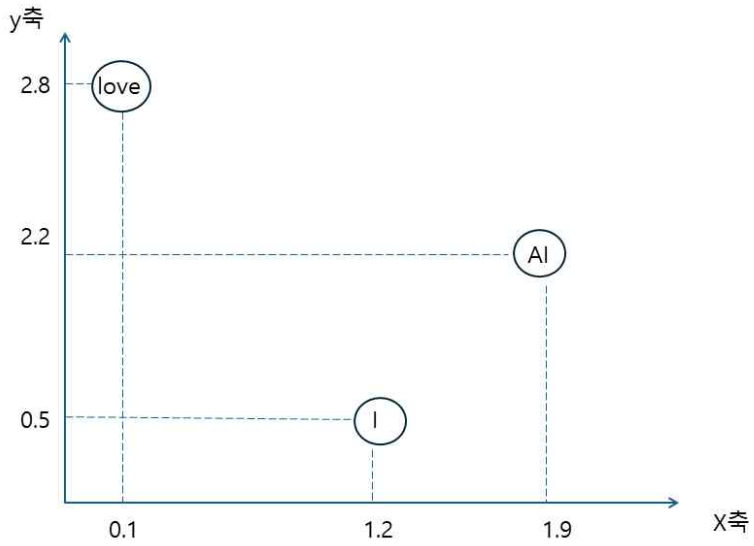

그림 24 단어를 공간 상의 한 좌표로 표현하는 방법

여기서는 설명의 편의상 단순한 2차원 공간의 예시를 들었으나, 실제 현업에서 쓰이는 모델들의 차원 수는 훨씬 거대하다.

- 초기 BERT: 768차원 (한 단어를 768개의 숫자로 표현한다.)
- GPT-3: 12,288차원 (한 단어를 12,288개의 숫자로 표현한다.)

차원이 높을수록(숫자가 많을수록) AI는 단어 사이의 미묘한 차이(예: '좋아하다'와 '사랑하다'의 미세한 감정선)를 더 정교하게 구분할 수 있게 된다. 하지만 차원이 너무 커지면 계산량이 기하급수적으로 늘어나기 때문에, 모델의 목적에 맞는 최적의 차원 수를 설정하는 것이 중요하다.

다시 단어 I, love, AI 를 2차원 공간 안에 표시하는 예시로 돌아오자. 각 벡터는 행렬 X의 각 행이 된다. 이 X는 아직 학습 이전 단계에 있는 세 단어 I, love, AI

가 최초로 부여받은 자신의 정체성을 표현한 2차원 ‘사전(dictionary)’이라고 볼 수 있다.

$$X = \begin{bmatrix} 1.2 & 0.5 \\ 0.1 & 2.8 \\ 1.9 & 2.2 \end{bmatrix}$$

모델은 학습을 통해 얻은 가중치 행렬 W^Q, W^K, W^V를 이미 가지고 있다. 계산의 편의를 위해 다음과 같다고 가정한다.

$$W^Q = \begin{bmatrix} 1 & 0 \\ 0 & 1 \end{bmatrix}$$

이 경우, 단어 'I'의 Query 벡터 Q = $[1.2, 0.5] \times \begin{bmatrix} 1 & 0 \\ 0 & 1 \end{bmatrix} = [1.2, 0.5]$와 같이 계산된다.

같은 방식으로 모든 단어에 대해 Q(질문), K(비교), V(정보) 벡터를 각각 생성한다. 이제 각 단어는 세 가지 종류의 신분증을 갖게 된 셈이다.

이제 'love'라는 단어가 주인공(Query)이 되어 문장 내 다른 단어들과의 관계를 수치로 계산한다. 'love'의 Query와 각 단어의 Key를 내적(Dot-product)한다.

여기서 각 단어의 key 벡터는 다음과 같이 도출된 것이다. Key 벡터는 입력 단어 벡터 X에 학습된 Key 가중치 행렬 W^K 를 곱해서 산출한다. 사전 학습 과정에서 모델은 수많은 문장을 보며 "어떤 단어가 다른 단어의 질문(Query)에 적절한 답변(Key)이 될 수 있는지"를 숫자로 익힌다. 예를 들어, 'love'라는 동사가 "나의 목적어는 누구니?"라고 물을 때(Query), 'AI'라는 단어가 "내가 바로 그 목적어야"라고 반응할 수 있도록 W^K 행렬의 값들이 조정된다.

계산식: $K_{\text{단어}} = X_{\text{단어}} \times W^K$

이제 'love'는 동사로서 문맥상 "누가 나를 행하는가(주어)?"와 "내가 누구를 향하

는가(목적어)?"라는 정보를 찾으려 한다. love의 query Q와 세 단어의 key K가 다음과 같이 계산되었다고 가정하고 이후의 계산을 해보자.

- **주인공 'love'의 Query (Q_{love}):** $[0.3, 2.0]$
- **비교 대상들의 Key (K):**
  - **I (K_I):** $[0.1, 1.8]$ (주어로서의 특징을 가진 벡터)
  - **love (K_{love}):** $[0.2, 2.5]$ (자기 자신)
  - **AI (K_{AI}):** $[0.1, 1.5]$ (목적어로서의 특징을 가진 벡터)

'love'의 Query와 각 단어의 Key를 다음과 내적(Dot-product) 곱셈을 한다.

1. **love(Q) · I(K) (주어 찾기):**

$$[0.3, 2.0] \cdot [0.1, 1.8] = (0.3 \times 0.1) + (2.0 \times 1.8) = 0.03 + 3.6 = \mathbf{3.63}$$

2. **love(Q) · love(K) (자기 참조):**

$$[0.3, 2.0] \cdot [0.2, 2.5] = (0.3 \times 0.2) + (2.0 \times 2.5) = 0.06 + 5.0 = \mathbf{5.06}$$

3. **love(Q) · AI(K) (목적어 찾기):**

$$[0.3, 2.0] \cdot [0.1, 1.5] = (0.3 \times 0.1) + (2.0 \times 1.5) = 0.03 + 3.0 = \mathbf{3.03}$$

이 점수들을 소프트맥스(Softmax) 함수에 통과시키면 각 단어에 대해 I: 10%, love: 50% AI: 40% 라는 확률값이 나온다.

위의 점수(3.63, 5.06, 3.03)를 소프트맥스(Softmax) 함수에 넣으면 3 단어에 대해 전체 합이 1인 확률 19%, 70%, 11%로 변환된다.

love라는 단어를 중심으로 각 단어에 배정된 확률 [I: 0.19, love: 0.70, AI: 0.11]

이 수치는 'love'라는 단어가 자신의 의미를 완성하기 위해 자기 자신의 기본 의미(70%)를 유지하면서, 주어인 'I'로부터 19%의 정보를, 목적어인 'AI'로부터 11%의 정보를 가져와 섞겠다는 뜻이다.

이 과정이 수천 개의 차원에서 동시에 일어나기 때문에, 인공지능은 우리가 상상

하는 것보다 훨씬 복잡하고 미묘한 언어의 뉘앙스를 숫자의 곱셈만으로 포착해낸다.

다음으로 Value 벡터 V가 이 확률과 곱해져서 단어들의 의미 네트워크가 완성된다. 어떤 단어의 V 벡터는 그 단어의 X벡터(앞의 예에서 “I”단어의 [1.2, 0.5] 예시에 해당)에 W^V 를 곱해서 계산한다. 그리고 V를 만드는 W^V행렬은 사전 학습을 통해 완성된 '의미 추출 필터(filter)' 행렬이다. 예를 들어서 $\begin{bmatrix} 0.8 & 0.1 \\ 0.2 & 0.9 \end{bmatrix}$ 같은 형태를 띈다. 그 사전 학습과정은 앞에서 설명한 바와 같다.

이렇게 계산된 어떤 단어의 V는 대상 단어가 이 문맥 “I love AI” 속에서 다른 단어들에게 나누어 줄 '실제적인 의미의 값'이다.

예를 들어 단어 ‘I’에 대한 V_I는 다음과 같이 계산된다.

$$V_I = [1.2, 0.5] \times \begin{bmatrix} 0.8 & 0.1 \\ 0.2 & 0.9 \end{bmatrix} = [(1.2 \times 0.8 + 0.5 \times 0.2), (1.2 \times 0.1 + 0.5 \times 0.9)] = [1.06, \quad 0.57]$$

이 각 단어의 V와 각 단어에 배정된 확률 19%, 70%, 11%를 곱해서 합치면, 최초에 단순했던 'love' 벡터 [0.1, 2.8]은 "I가 AI를 대상으로 행하는 love"라는 구체적인 맥락이 박힌 벡터 [1.645, 2.635]로 변형되어 다시 태어난다. 이 벡터는 다음과 같이 계산된다.

- **I (V_I):** "1인칭 화자"라는 의미 정보
- **love (V_{love}):** "애정/선호 행위"라는 의미 정보
- **AI (V_{AI}):** "인공지능 객체"라는 의미 정보

$$\text{Updated 'love'} = (0.19 \times V_I) + (0.70 \times V_{love}) + (0.11 \times V_{AI})$$

= [1.645, 2.635]

이 예시에서는 “I love AI”라는 3개 단어로 이루어진 텍스트 데이터만을 예로 들었지만, 실제로는 방대한 학습 데이터 안에 등장하는 모든 단어 수만개에 대해 이 과정을 동시에 수행하며, 층(Layer)을 거듭할수록 이 의미들은 더욱 정교해진다.

실제 LLM에서 단어의 위치 표현 기준이 되는 수천~수만종의 dimension은 어떤

단어에 대해서 그 단어가 지닐 수 있는 상상가능한 거의 모든 속성을 두루 포괄한다. 예컨대, 품사/문법, 핵심 의미, 주어 목적어를 상대로 한 문맥, 느끼는 감정의 정도와 형태, 기타 등등 같은 여러 특징(feature)에 속하는 속성들이다.

$$V_{updated_love} = [\underbrace{v_1, v_2, \ldots, v_{10}}_{\text{품사/문법}}, \underbrace{v_{11}, \ldots, v_{40}}_{\text{핵심의미}}, \underbrace{v_{41}, \ldots, v_{70}}_{\text{문맥(주어/목적어)}}, \ldots, v_{100}]$$

love라는 단어에 대해 100차원 공간으로 표현했다면 V 벡터는 다음과 같은 형태를 띄게 될 것이다.

$$V_{updated_love} = [0.88 \quad 0.12 \quad -0.05 \quad 0.43 \quad 0.91 \quad \ldots(\text{총 } 100\text{개})\ldots \quad -0.21 \quad 0.67]$$

결국 트랜스포머는 ***컴퓨터가 거대한 차원의 수치 공간 안에서 여러 지점들을 돌아다니면서 Q로 질문하고, K로 대상을 찾으며, 선택된 대상의 V를 가져와 자신의 의미를 계속해서 업데이트하는 거대한 정보 교환 시스템***이다.

이 과정이 여러 층(Layer)을 거치며 반복될 때, 단어의 의미는 점점 고도화된다. 트랜스포머는 사전(pre) 학습(training) 데이터에 포함된 수 억개의 문장 속 모든 단어에 대해 이 작업을 수행해서 모든 단어마다 이 벡터값을 계산해서, 초(超)거대 복합 사전(dictionar)의 형태로 그 숫자들을 저장하면서 반복적으로 활용한다. 입력되는 학습데이터가 추가될수록 이 학습은 앞 단계의 사전(dictionary) 구성을 조금씩 변화시키면서 계속 성능을 향상시킨다.

5) 다음에 올 단어의 선택

트랜스포머 모델의 가장 마지막 단계에서 일어나는 Softmax를 통한 단어 선택'은 거대 차원상의 좌표로 표현되는 결과 수치를 인간이 이해할 수 있는 언어로 변환하는 핵심 과정이다. 이 과정은 크게 선형 투영(Linear Projection), Softmax 확률화, 그리고 디코딩 전략의 세 단계로 나뉜다.

■선형 투영: 점수(Logits) 계산

여러 층들을 거치며 업데이트된 최종 단어 벡터는 여전히 10,000차원(혹은 그 이상)의 추상적인 수치 배열이다. 모델은 이 벡터를 사용자가 읽을 수 있는 단어로 바꾸기 위해, 모델이 알고 있는 전체 단어 목록(Vocabulary)의 크기만큼 확장한다. 예를 들어, 모델이 총 5만 개의 단어를 알고 있다면, 10,000차원의 출력 벡터에 거

대한 가중치 행렬을 곱해 5만 개의 숫자로 늘린다. 이 5만 개의 숫자를 로짓(Logits)이라고 부르며, 각 숫자는 해당 위치에 있는 단어가 정답일 가능성을 나타내는 '원시 점수'가 된다.

■Softmax 함수: 확률로의 변환

로짓 값은 음수일 수도 있고 수천 단위의 큰 수일 수도 있어 직접 비교하기 어렵다. 이때 다음과 같은 Softmax 함수를 적용하여 모든 숫자 z_i를 0과 1 사이의 값으로 압축한다.

$$P_i = \frac{e^{z_i}}{\sum_{j=1}^{K} e^{z_j}}$$

이 수식을 거치면 모든 단어의 확률 합은 정확히 1(100%)이 된다. 예를 들어, "I love" 다음 단어로 올 수 있는 단어 후보로 'AI'는 0.7, 'you'는 0.2, 'apples'는 0.05, 나머지 단어들 ... 와 같은 식의 확률 분포가 생성된다. 이는 모델이 통계적으로 어떤 단어가 가장 자연스러운지 판단한 결과이다.

각 단계에서 다음에 올 수 있는 수만 개의 단어 후보 중 가장 확률이 높은 단어를 선택한다. 예컨대 'AI' 다음에 올 단어로 '배경'이나 '파급'의 확률은 높게, '사과'나 '우주'의 확률은 0에 가깝게 계산하여 자연스러운 문장을 완성한다.

결국 Softmax는 인공지능이 내부적으로 계산한 복잡한 기하학적 좌표를 "우리가 약속한 단어장 중 몇 번째 단어일 확률이 가장 높은가?"라는 질문에 대한 통계적 답변으로 변환하는 장치이다. 10,000개가 넘는 차원의 정보들이 이 과정을 통해 단 하나의 단어로 응축되어 우리 화면에 나타나게 된다.

■단어 선택과 Temperature(온도)의 역할

확률이 가장 높은 단어를 무조건 선택하는 방식을 'Greedy Search'라고 한다. 하지만 실제 서비스에서는 답변의 다양성을 위해 Temperature(온도)라는 개념을 도입한다.

- 낮은 온도 (0.1~0.2): 확률이 높은 단어에 더욱 힘을 실어주어 매우 보수적이고 결정론적인 답변을 내놓는다.
- 높은 온도 (0.8~1.0): 낮은 확률의 단어들도 선택될 기회를 주어 더 창의적이고 의외성이 있는 답변을 생성한다.

결국 트랜스포머는 질문 프롬프트 속 단어들의 '관계망'을 촘촘히 짠 뒤(어텐션),

그 관계망을 지도로 삼아 학습된 지식 주머니에서 가장 어울리는 단어를 '확률적'으로 골라내는 과정을 반복한다. 이 예에서는 프롬프트가 사용자가 '주요 요인별'로 요청했으므로, 모델은 '발생 원인', '정부 대응', '금융 시장 영향' 같은 소제목들을 생성할 확률을 높여 답변을 구조화할 것이다. 만일 프롬포트가 '주요 인물별'이라는 내용을 포함한다면 트랜스포머는 '주요'와 '인물'이라는 단로부터 사람의 이름으롤 판별되는 명사 가운데 대공황과 COVID19라는 단어와 관련하여 가장 연관성 높게 등장하는 명사를 탐색하고 거기에 함께 어울려 다니는 단어들을 끊임 없이 찾아가면서 답변을 생성할 것이다.

6) 환각 현상

환각(Hallucination) 현상은 트랜스포머의 핵심인 어텐션 메커니즘이 '사실 관계'가 아닌 '확률적 관계'에 집중하기 때문에 발생한다. 어텐션은 문맥 내 단어 간의 연관성을 계산할 뿐, 그 정보가 현실 세계에서 참인지 거짓인지를 검증하는 논리 구조를 별도로 가지고 있지 않다.

구체적으로, 어텐션 과정에서 특정 단어(Query)가 과거 학습 데이터 속에서 자주 함께 등장했던 단어(Key)에 높은 점수를 부여하면, 모델은 이를 '정답'으로 착각한다. 예를 들어, 실제로는 존재하지 않는 사건이라도 문법적으로나 맥락적으로 매우 매끄러운 단어 조합(Value)이 계산된다면, 모델은 이를 강력한 문맥으로 받아들여 확신에 찬 어조로 답변을 생성한다.

RAG(Retrieval-Augmented Generation, 검색 증강 생성) 기술은 모델이 자신의 내부 기억(가중치)에만 의존하지 않고, 외부의 신뢰할 수 있는 지식 베이스에서 정보를 찾아 답변의 근거로 삼는 방식이다. 이를 통해 트랜스포머 모델의 고질적인 문제인 환각 현상을 획기적으로 줄인다.

오픈북 테스트'기존 LLM이 아무런 참고서 없이 자신의 기억만으로 생각나는대로 답을 써내는 작업이라면 RAG는 시험 도중 도서관에서 관련 서적을 찾아보고 답을 적는 작업으로 비유할 수 있다.

사용자가 "2025년 한국의 GDP 성장률은?"과 같이 질문하면 RAG는 다음과 같은 단계를 거친다.

- 관련 정보 검색(Retrieval): 모델은 이 질문을 들고 외부 지식 베이스(최신 뉴스, 정부 보고서 등)에서 가장 관련성이 높은 문서 조각들을 찾아낸다.
- 컨텍스트 제공(Augmentation): 찾아낸 문서 내용과 사용자의 질문을 하나로 합쳐 모델에게 전달한다.

- 근거 기반 답변 생성(Generation): 모델은 전달받은 문서 내용을 바탕으로 답변을 작성한다.

RAG가 환각을 줄이는 핵심은 어텐션(Attention)의 대상을 '외부 근거' 문서로 한정해서 강제하는 데 있다.

- 가중치 편향 억제: 모델은 학습 데이터에 기반한 확률적 예측보다, 현재 프롬프트에 주입된 '외부 문서'의 단어들에 더 높은 어텐션 점수를 부여하도록 설계된다.
- 출처 기반 추론: 모델은 자신의 내부 지식과 외부 문서가 충돌할 때, 외부 문서의 V 벡터를 더 중요하게 취합한다. 이로 인해 모델이 제멋대로 말을 지어내는 확률적 연결이 억제된다.
- 검증 가능성: 답변과 함께 어떤 문서를 참고했는지 출처를 명시할 수 있어, 사용자가 사실 여부를 직접 확인할 수 있는 환경을 제공한다.

☞예시: 트랜스포머 모델이 ""1930년대 대공황이 COVID19 사태 이후의 글로벌 경기침체와 어떻게 성격이 다른지 주요 요인별로 구분하여 분석해줘.""라는 프롬프트를 입력받았을 때, 이로부터 답변을 내놓는 과정

1. 토큰화(Tokenization): 문장을 조각내기

모델은 문장을 통째로 읽지 않고 의미 있는 최소 단위인 '토큰'으로 쪼갠다.

- 조각내기: "1930년대", "대공황", "COVID-19", "성격", "다르다", “요인”, "분석" 등으로 나눈다.
- 숫자 변환: 각 토큰은 모델이 이해할 수 있는 고유한 번호(ID)를 부여받아 변환되어 모델 내부로 들어간다.

2. 셀프 어텐션(Self-Attention): 단어 사이의 '연결선' 찾기

이 단계가 트랜스포머의 핵심이다. 모델은 문장 속 단어들을 서로 연결하며 "누가 누구를 설명하는가"를 파악한다.

- 관계 파악: '분석해줘'라는 명령어가 '대공황'과 'COVID-19'라는 두 대상을 가리키고 있음을 알아챈다.
- 맥락 이해: '성격'이라는 단어가 MBTI 같은 성격이 아니라, '경제적 특성'을 의미한다는 것을 '경기침체'라는 주변 단어들과의 관계를 통해 이해한다.
- 중요도 결정: 답변을 만들 때 '1930년대'와 'COVID-19'가 가장 핵심적인 비교 축이라는 점에 가장 높은 점수(가중치)를 부여한다.

3. 인코더에서의 의미 응축: 질문의 의도 파악

어텐션을 통해 관계가 정리되면, 모델은 질문의 전체적인 '의도'를 하나의 거대한 데이터 뭉치로 압축한다.

- 내부 요약: "아, 이 사용자는 두 역사적 경제 위기를 '요인별'로 비교하는 '분석 보고서' 형태의 답을 원하는구나"라고 판단한다.

이 데이터 뭉치에는 '대공황'의 특징, '코로나'의 특징, 그리고 '비교 분석'이라는 작업 지시서가 모두 섞여 있다.

4. 디코더에서의 생성: 한 글자씩 답변 조립

이제 압축된 의도를 바탕으로 답변을 한 단어씩 생성한다.

- 첫 단어 예측: 지금까지 쌓인 맥락을 바탕으로 "1930년대" 혹은 "대공황과"라는 시작 단어를 가장 먼저 내뱉는다.
- 연쇄 반응: 첫 단어를 뱉으면, 모델은 그 단어를 다시 입력창에 집어넣는다. "대공황과(입력) -> COVID-19는(예측) -> 발생 원인(예측) -> 측면에서(예측)..." 식으로 꼬리에 꼬리를 무는 연산을 수행한다.
- 지식 인출: 이 과정에서 모델은 학습 때 익힌 '대공황=수요 부족', '코로나=공급망 붕괴' 같은 지식 파편들을 V 벡터에서 꺼내와 문장에 버무린다.

나. GPT 와 BERT

GPT는 'Generative Pre-trained Transformer'의 약자로, 텍스트를 생성하는 데 특화된 언어 모델을 의미한다. 기본적으로 다음에 올 단어를 예측하는 '언어 모델링'을 통해 학습한다. 방대한 양의 텍스트 데이터를 사전에 학습(Pre-training)하여 언어의 구조와 문맥을 파악한 뒤, 특정 작업에 맞춰 미세 조정(Fine-tuning)하는 방식을 취한다. 원리적으로는 문장의 왼쪽에서 오른쪽으로 단어를 하나씩 예측해 나가는 '단방향(Unidirectional)' 구조를 가진다. 이는 이전까지의 통계적 모델이나 RNN 계열 모델보다 훨씬 긴 문맥을 파악할 수 있게 해주었으며, 자연스러운 문장 생성을 가능하게 했다.

GPT 시리즈는 모델의 크기와 데이터량을 기하급수적으로 늘리며 성능을 증명해 왔다.

- GPT-1 (2018년 6월): 처음 등장한 GPT 모델로, '사전 학습 후 미세 조정'이라는 방법론을 제시했다. 약 1억 1,700만 개의 매개변수(파라메터)를 가졌으며, 라벨이 없는 데이터로도 언어 능력을 습득할 수 있음을 보여주었다.

※ 미세조정 fine tuning

GPT와 같은 거대 언어 모델은 수조 개의 문장을 읽으며 언어의 보편적인 법칙을 배운다. 하지만 특정 영역이나 주제, 또는 특정 방식의 지식 작업을 하려면 별도의 추가 학습이 필요하다. 예를 들어서 법률 문서, 의학 진단, 금융 심사, 혹은 특정한 말투에 특화되도록 하려면 기존의 보편적인 가중치로는 한계가 있기 때문에, 기존에 학습된 방대한 W^Q, W^K, W^V 의 중요한 가중치들의 특징은 유지하면서, 새로운 특정 데이터셋에 대해 아주 조금씩 이 가중치를 업데이트하는 과정이 필요하다. 이런 작업을 파인 튜닝이라 한다.

여기서 파인(fine), 즉 미세라는 표현을 쓴 이유는, 자칫 모델이 새로운 데이터에 너무 매몰되면 기존에 구축된 가중치의 중요한 특성을 상실하는 '파괴적 망각(Catastrophic Forgetting)'이 발생할 수 있기 때문에, 지극히 섬세한 조정이 필요하기 때문이다.

최근에는 모델이 너무 커져서 모든 가중치를 수정하는 데에 엄청난 연산 비용이 든다. 그래서 튜닝을 보다 효율적으로 행하기 위한 다양한 방법들도 개발되고 있다.

- GPT-2 (2019년 2월): 파라메터가 15억 개로 대폭 늘어났다. 별도의 미세 조정 없이도 다양한 작업을 수행하는 'Zero-shot' 학습 가능성을 입증했다. 문장 생성 능력이 너무 뛰어나 가짜 뉴스 생성 등의 악용 우려로 처음에는 모델 전체를 공개하지 않기도 했다.

- GPT-3 (2020년 5월): 1,750억 개의 파라메터를 사용하여 인공지능 분야에 충격을 주었다. 방대한 데이터를 바탕으로 소수의 예시만 주어지면 새로운 작업을 수행하는 'Few-shot' 학습이 가능해졌다. 이 시점부터 AI가 쓴 글과 사람이 쓴 글을 구분하기 힘들어졌다.

- GPT-4 (2023년 3월): 멀티모달 기능을 갖추어 텍스트뿐만 아니라 이미지도 이해하기 시작했다. 논리적 추론 능력이 비약적으로 상승했으며, 전문적인 시험(변호사 시험 등)에서 상위 성적을 거두는 수준에 도달했다.

■ BERT

BERT는 'Bidirectional Encoder Representations from Transformers'의 약자로, 문장의 양방향 문맥을 동시에 이해하는 모델이다. GPT가 다음 단어를 맞추는 데 집중한다면, BERT는 문장 중간에 구멍을 뚫어놓고(Masking) 그 빈칸을 맞추는 '마스크 언어 모델(MLM)' 방식을 사용한다. 이 과정을 통해 단어의 앞뒤 문맥을 동

시에 고려하므로 단어의 의미를 훨씬 정교하게 파악한다. 또한 두 문장이 이어지는 관계인지 예측하는 학습(NSP)도 병행한다. 이러한 양방향성 덕분에 질문 답변, 감정 분석 등 텍스트의 의미를 정확히 짚어내야 하는 분류 작업에서 압도적인 성능을 보였다.

■ GPT와 BERT 모델의 차이

○ GPT

GPT (Decoder-Only): 트랜스포머의 디코더(Decoder) 블록을 쌓아 만든 모델이다. 디코더는 기본적으로 '다음 단어'를 생성하기 위해 설계되었다. 이전에 생성된 단어들(왼쪽 문맥)만 참조할 수 있도록 Masked Self-Attention을 사용한다.

다음과 같은 인과적 언어 모델링 (Causal Language Modeling)을 사용한다.

- 원리: "나는 학교에 [?]"라는 문장이 있을 때, [?]에 올 단어 중 가장 확률적 가능성이 높은 단어가 “간다”임을 맞추는 방식이다.
- 특징: 앞에서 뒤로(Left-to-Right) 학습하므로 문장 생성 능력이 탁월하다.

○ BERT

BERT (Encoder-Only): 트랜스포머의 인코더(Encoder) 블록을 활용한다. 인코더는 입력된 문장 전체를 한꺼번에 보고 각 단어의 의미를 추출하는 데 최적화되어 있다. 문장 내 모든 단어가 서로를 참조할 수 있는 Bidirectional Self-Attention을 사용한다.

다음과 같은 마스크 언어 모델링 (Masked Language Modeling)을 사용한다.

- 원리: "나는 [MASK]에 간다"처럼 문장 중간을 가리고 그 단어가 "학교"임을 맞춘다.
- 특징: [MASK]의 앞단어("나는")와 뒷단어("간다")를 모두 동시에 고려하므로, 문맥의 깊은 의미를 파악하는 능력이 매우 뛰어나다.

GPT 계열의 모델은 주로 창의적인 글쓰기, 코드 작성, 대화형 챗봇(ChatGPT), 요약 등에 활용된다. 사용자의 의도를 파악하여 적절한 결과물을 생성해내는 능력이 탁월하다. 마이크로소프트의 'Copilot'이 대표적인 사례이다.

BERT 계열의 모델은 검색 엔진의 정확도 개선, 스팸 메일 분류, 감성 분석, 개체명 인식 등에 주로 쓰인다. 구글 검색 엔진에 도입되어 검색어의 의도를 정확히 파악하는 데 기여했으며, 고객 상담 데이터의 자동 분류 등 텍스트 이해가 핵심인 분야에서 필수적이다.

GPT는 문장을 이어나가는 능력이 좋아 대화나 작문에 유리하지만, 뒤에 올 정보

를 미리 볼 수 없어 문장 전체의 의미를 한눈에 파악하는 데는 BERT보다 효율이 떨어질 수 있다. 반대로 BERT는 문장 이해도는 높으나, 새로운 문장을 한 글자씩 생성해 나가는 구조가 아니기 때문에 긴 글을 쓰는 작업에는 적합하지 않다.

이 GPT와 BERT는 AI 발전 역사에서의 많은 기여를 했지만 문제점도 드러냈다.

우선 이 모델들은 '대규모 사전 학습'이 AI 성능의 핵심임을 입증했다. 이른바 파라메터의 수를 증가시킬수록 성능이 향상하는 이른바 'Scaling' 특성이 발견되어, 빅테크들은 너도나도 수천개의 GPU를 동원하여 대규모 학습을 하는 경쟁에 뛰어들게 만드는 계기가 됐다.

■GPT모델의 기여

전이 학습(Transfer Learning)을 대중화하여, 적은 데이터로도 고성능 AI를 만들 수 있는 기반을 마련했다. 과거에는 특정 작업(예: 법률 상담, 의료 번역)을 위해 처음부터(from scratch, 맨땅에서 시작해서) AI를 학습시켜야 했다. 하지만 트랜스포머 등장 이후, 거대 데이터를 미리 학습해놓은 '사전 학습 모델(Pre-trained Model)'을 가져와 필요한 부분만 살짝 고쳐 쓰는 방식이 표준이 되었다. 또한 이미 언어의 법칙과 방대한 지식을 배운 모델을 기반으로 하기 때문에, 특정 분야의 데이터가 수만 건이 아니라 수백, 수천 건만 있어도 전문가 수준의 성능을 낼 수 있게 되었다. 이 덕분에 이는 구글, 오픈AI 같은 거대 기업뿐만 아니라 중소기업이나 개인 개발자도 고성능 AI를 구축할 수 있는 'AI의 민주화'가 가능해졌음을 뜻한다. 특정 미세 과업 분야에서 언어 이해와 생성이라는 두 영역에서 인간 수준에 근접하는 성과를 내며 AI 황금기를 이끌었다.

다. chatGPT 이후

○ ChatGPT 등장

2022년 11월 30일, OpenAI가 ChatGPT를 출시하면서 AI 역사의 전환점이 찾아왔다. 출시 5일 만에 100만 명, 2개월 만에 1억 명을 확보하며 역사상 가장 빠르게 성장한 소비자 앱이 되었다. 시장은 폭발적으로 반응했고, 마이크로소프트는 2023년 1월 OpenAI에 100억 달러를 추가 투자하며 "A race starts today"라고 선전포고했다. OpenAI는 2015년 12월 샘 올트먼, 일론 머스크, 그렉 브록만 등이 구글의 AI 독점에 대항하기 위해 비영리로 설립했다. 올트먼은 Y Combinator 사장으로 에어비앤비, 레딧 등에 성공적 투자를 이끈 경험이 있었다. 초기 10억 달러 기부 약속으로 시작했으나 실제 납입액은 1억 3천만 달러에 불과했고, 막대한 컴퓨팅 자

원이 필요해지면서 2019년 영리 법인 전환이 불가피했다. 머스크는 개발 속도 문제로 2018년 이탈했고, 이후 마이크로소프트가 2019년 10억 달러를 투자하며 주요 파트너가 되었다. ChatGPT는 GPT-3.5 기반으로 인간 피드백 강화학습(RLHF)을 적용해 대화형으로 개선한 '맛보기' 버전이었지만, 예상을 뛰어넘는 성공을 거두며 생성형 AI 시대를 열었다.

○ ChatGPT 등장 전 구글의 AI 모델 개발 역사

구글은 2001년 검색에 머신러닝을 도입한 이래 AI 선도기업이었다. 2017년 트랜스포머 아키텍처를 개발해 현대 LLM의 기초를 놓았고, 2018년 BERT로 자연어 이해에 혁명을 일으켰다. 2021년 LaMDA 대화형 모델을 개발했지만 안전성 우려로 비공개로 유지했다.

그러나 2022년 12월 ChatGPT가 출시ㅣ 이후 예상치 못한 대성공을 거두자 구글은 '적색경보'를 발령했다. 검색 시장 지배력을 위협받는 위기감에 서둘러 2023년 2월 LaMDA 기반 Bard를 출시했고, Anthropic에 3억 달러를 투자하며 대응에 나섰다. 데모 영상에서 오류가 발견되며 초기 평가는 부정적이었다. AI 리더였던 구글이 후발주자로 전락하며 조직 전체에 충격이 확산되었다. 기존의 신중한 접근이 시장 기회를 놓치게 했다는 반성과 함께, 구글은 PaLM 2로 모델을 업그레이드하고 전사적 AI 전략 재편에 착수했다.

○ LLM 개발 경쟁에 뛰어든 빅테크 기업들

빅테크 간 경쟁은 단순한 모델 개발을 넘어 생태계 전쟁으로 전개되었다.

ChatGPT 성공 이후 글로벌 빅테크들이 일제히 LLM 경쟁에 뛰어들었다. 마이크로소프트는 가장 빠르게 움직였다. OpenAI에 100억 달러를 투자하고 Bing 검색엔진과 Office에 ChatGPT를 통합한 New Bing을 출시하며 구글에 정면 도전했다. Azure 클라우드를 통해 OpenAI API를 제공하며 엔터프라이즈 시장도 공략했다.

구글은 2023년 Bard를 출시하고 검색, Gmail, Docs 등 전 제품군에 AI를 통합하기 시작했다. 이후 Gemini로 리브랜딩하며 멀티모달 기능을 강화했고, 자체 TPU 인프라를 활용해 경쟁력을 확보하려 했다. Meta는 오픈소스 전략을 택했다. 2023년 2월 LLaMA 모델을 학술용으로 공개했고, 이후 상업용 LLaMA 2를 출시하며 개발자 생태계를 형성했다. 오픈소스 진영에서 Alpaca, Vicuna 등 파생 모델들이 쏟아지며 LLM 민주화를 이끌었다. Anthropic은 OpenAI 출신들이 설립해 안전성과 윤리를 강조한 Claude 시리즈를 선보였다. 10만 토큰 이상의 긴 문맥 처리와 대화 안전성이 특징이었고, 구글과 아마존으로부터 투자를 받으며 성장했다.

중국에서는 바이두의 어니봇, 알리바바의 Qwen 등이 등장했고, 한국에서도 네이

버 하이퍼클로바, 카카오 등이 자체 모델 개발에 나섰다. 각 기업은 독자적 강점을 내세웠다.

OpenAI는 범용성과 성능, 구글은 검색 통합과 멀티모달, Meta는 오픈소스, Anthropic은 안전성으로 차별화를 시도했다. 경쟁은 단순 모델 성능을 넘어 생태계, 가격, 통합성까지 확대되었다.

○ 모델 개발 방법론 다양화와 Scaling 경쟁

초기 경쟁은 파라미터 수를 늘리면 성능이 향상된다는 'Scaling Law'에 기반한 규모 전쟁이었다. 이 철학의 뿌리는 2012년 Geoffrey Hinton 교수팀이 AlexNet으로 ImageNet 경진대회에서 압도적 우승을 거두며 딥러닝 혁명을 촉발한 사건에 있다. 당시 AlexNet은 GPU 병렬 연산과 ReLU 활성화 함수 등 혁신적 기법을 통해 "데이터와 연산력만 충분하면 복잡한 문제도 해결 가능하다"는 패러다임을 확립했다.

2019년 OpenAI 일리야 수츠케버 주도로 '모델 크기를 키우면 성능이 향상된다'는 법칙이 증명되며 규모 전쟁이 시작되었다. GPT-2는 15억 파라미터, GPT-3는 1,750억 파라미터로 10배 이상 증가했고, 2023년 GPT-4는 추정 1조 파라미터를 넘어섰다. 구글 PaLM은 5,400억, Meta LLaMA는 650억 파라미터로 대응했다. 단순 크기 경쟁을 넘어 방법론도 다양화되었다.

인간 피드백 강화학습(RLHF)이 표준이 되었고, Anthropic은 Constitutional AI로 가치 정렬을 실험했다. Chain-of-Thought 등 추론 과정을 생성하게 하는 기법도 등장했다.

멀티모달 확장도 핵심 트렌드가 되었다. GPT-4, Gemini, Claude는 텍스트뿐 아니라 이미지, 오디오, 비디오 처리 능력을 탑재했다. 그러나 무한 확장의 한계도 드러났다. 훈련 비용이 기하급수적으로 증가하며 GPT-4 훈련에는 1억 달러 이상이 투입되었다.

이에 효율성 중심 접근도 부상했다. MoE(Mixture of Experts) 아키텍처로 필요한 파라미터만 활성화하는 방식, 그리고 소형 특화 모델(sLM) 전략이 주목받기 시작했다. Mistral 7B, Phi-3 등 수십억 파라미터급 경량 모델도 특정 작업에서 대형 모델에 근접한 성능을 보이며 '스케일만이 답'이라는 공식에 균열을 냈다.

2025년 들어서는 추론 특화 모델(OpenAI o1, DeepSeek r1)이 등장하며 단순 크기보다 사고 과정 최적화로 방향이 전환되고 있다.

최근에는 무한 확장보다는 전문가 혼합 모델(MoE)이나 양자화 기술을 통한 효율화, 그리고 RLHF와 RAG 기술을 통합한 시스템 성능 중심의 스케일링으로 이동했다.

○ 구글의 Gemini 3.0 과 시장 지위 역전

2025년 11월 출시된 Gemini 3.0은 구글의 반격을 상징한다. emini 3.0은 멀티모달 기능을 부가 기능이 아닌 기본 운영체제로 정착시킨 전환점이다. 텍스트 위주의 사고에서 벗어나 시각과 청각 정보를 인간과 유사한 방식으로 통합 처리하는 ‘진정한 범용 멀티모달’의 정점을 찍었다. 구글은 이를 자사 검색 엔진과 안드로이드 생태계에 수직 통합하여 전 세계 사용자에게 즉시 배포함으로써 연구 성과의 상품화 속도를 극대화했다.

구글은 Gemini3.0으로, ChatGPT 충격 이후 3년 만에 구글이 선두 지위를 탈환하며 LMArena 리더보드 1위를 기록했다. 추론, 멀티모달, 에이전트 기능을 통합한 '풀스택 AI' 전략의 결실이다.

출시 당일 검색에 직접 통합하며 20억 월간 사용자에게 즉시 배포한 점은 획기적이다. Deep Think 모드는 고난도 추론에서 GPT-5를 근소 차이로 앞섰고, Flash 모델은 가격 대비 성능으로 실용성을 입증했다. Google Antigravity 플랫폼으로 에이전트 코딩 영역을 선점하려는 시도도 주목된다. 무엇보다 '모델만'이 아닌 생태계 전체를 무기로 삼는 전략 전환이 의미 있다. 검색, Workspace, Android, 클라우드까지 수직 통합한 배포력은 OpenAI나 Anthropic이 따라오기 어려운 장점이다. Gemini 3.0은 LLM 경쟁이 단순 벤치마크 경쟁에서 실사용 플랫폼 경쟁으로, 그리고 AI를 별도 제품이 아닌 기본 인프라로 전환하는 단계로 진화했음을 보여준다.

○ ChatGPT 이후 가장 혁신적인 연구 사례

가장 의미 있는 혁신은 인간 피드백 기반 강화학습(RLHF)의 정착과 추론 특화 모델의 등장이다. RLHF는 모델을 인간의 가치관에 맞게 미세 조정하여 안전성을 높였다.

2024년 9월 출시된 OpenAI의 o1은 단순히 다음 토큰을 예측하는 기존 방식에서 탈피해, 답변 전에 내부적으로 '생각하는 시간'을 갖는다. Chain-of-Thought를 강화학습으로 학습시켜 모델이 스스로 추론 과정을 생성하고 오류를 수정하며 전략을 개선한다. 국제수학올림피아드 문제에서 인간 전문가를 넘어섰고, 프로그래밍 대회에서 상위 49%에 진입했다. 이는 사전학습(pre-training) 확장에서 추론시간(test-time) 확장으로 패러다임을 전환한 사건이다. 기존 스케일링 법칙이 모델 크기와 데이터양에 집중했다면, 이제 '생각할 시간'이라는 새로운 축이 추가되었다.

이는 AlexNet이 증명한 심층 신경망의 표현 능력이 RNN과 LSTM을 거쳐 Transformer로 발전하며 도달한 결과물이다. 단순 패턴 매칭을 넘어 스스로 추론 과정을 생성하고 오류를 수정하는 진짜 문제 해결 능력으로 나아가는 과정이며 AGI를 향한 중요한 단계로 평가된다.

DeepSeek r1은 오픈소스로 이를 구현해 민주화에 기여했다. 추론 모델은 단순 패턴 매칭을 넘어 진짜 문제 해결 능력으로 나아가는 전환점이며, AGI를 향한 중요한 단계로 평가된다. 다만 추론 과정이 불투명하고 때로 환각을 생성하는 문제는 여전히 남아있다.

○ Scaling 경쟁의 현재

2026년 현재 Scaling 경쟁은 기능적, 물리적, 경제적 한계에 직면한 상태로 보인다. 성능 측면에서는 대형 언어모델이 마주한 벽 지금의 AI 개발이 정확도를 높이기 위한 싸움이 아니라, 정확도를 거의 높이지 못하면서 엄청난 자원을 낭비하는 구조에 빠졌다는 분석이 나오기도 했다[24].

경제적으로는, 2025년 모델 훈련 비용은 100억 달러, 2027년에는 1,000억 달러로 예상되며 3년마다 약 3배씩 증가한다. 전세계 자산운용 규모가 100조 달러임을 고려하면 수 차례만 더 증가해도 천문학적 비용이 된다. 고품질 데이터도 한계에 봉착했다. Epoch AI 추정으로 공개 텍스트는 약 300조 토큰인데, 이미 대부분이 훈련에 사용되었다. 합성 데이터가 대안이지만 품질 보장은 불확실하다.

투자 대비 수익성에 대한 의문도 제기되고 있다. Sequoia Capital 분석으로 인프라 투자와 수익 간 5,000억 달러 격차가 존재한다. 무한 확장으로 AGI 도달이라는 환상은 깨지고 있다.

이제 AI개발에서 스케일링 추세는 멈추는 대신에 효율성 중심으로 전환 중이다. 추론시간 확장(test-time compute), MoE 아키텍처, 도메인 특화 소형 모델이 주목받는다. Phi-3, Mistral 같은 수십억 파라미터급이 특정 작업에서 대형 모델과 대등한 성능을 보인다.

이런 와중에 토크노믹스(Tokenomics), 즉 효율적인 토큰 비용의 경제학이 중요해지고 있다. 과거 테크 산업이 혁신이나 생산 효율에 집중했다면, AI 시대에는 '토큰당 비용'이 핵심 경쟁력으로 부상했다. 현재 토큰의 최저비용 생산자는 구글과 xAI로 평가받는다. 이는 단순히 GPU 대수의 문제가 아니라, 클러스터 내 통신 비용과 일관된 연산 능력을 확보했기 때문이다.

이에 대해 '최저비용 생산자'가 되는 것이 또 다시 승자독식 구조를 만들 것이라는 예측이 일반적이다. 이는 고도의 자본 집약적 인프라를 갖춘 빅테크에게만 유리한 구도다. 이는 중소 개발사들이 모델 자체보다 애플리케이션 계층으로 밀려날 수밖에 없는 구조적 한계도 드러내고 있다.

어쨌든 향후 AI 발전은 단순 크기 경쟁에서 벗어나 효율성·특화·품질로 재편될 것이다. 스케일링 법칙은 끝나지 않았지만, 무분별한 확장 시대는 막을 내리고 있다.

---

24) https://arxiv.org/pdf/2507.19703

5. AI의 역사 III: LLM 이후

가. 영상과 음성 AI

1) 트랜스포머 구조를 영상과 음성에 응용

트랜스포머 아키텍처가 영상과 음성 생성에서 뛰어난 성능을 보이는 핵심 원리는 시퀀스 데이터 처리의 보편성에 있다. 트랜스포머는 입력 데이터를 토큰 시퀀스로 변환하여 처리하는데, 이 방식은 텍스트뿐만 아니라 모든 형태의 데이터에 적용 가능하다.

영상 데이터의 경우, 이미지를 작은 패치로 분할하여 각 패치를 하나의 토큰처럼 취급한다. 예를 들어 Vision Transformer(ViT)는 이미지를 16x16 픽셀 패치로 나누고, 각 패치를 선형 변환하여 임베딩 벡터로 만든다. 이후 위치 인코딩을 추가하여 공간적 정보를 보존하면서 셀프 어텐션 메커니즘으로 패치 간의 관계를 학습한다. 비디오는 시간 축을 추가한 3차원 패치로 처리되며, 시공간적 관계를 동시에 모델링할 수 있다.

음성 데이터는 스펙트로그램이나 멜-스펙트로그램으로 변환한 후, 이를 2차원 이미지처럼 처리하거나 시간 축을 따라 프레임 단위로 토큰화한다. 각 음성 프레임은 임베딩되어 시퀀스를 형성하고, 트랜스포머의 어텐션 메커니즘이 시간에 따른 음향 패턴의 장거리 의존성을 포착한다.

트랜스포머의 핵심인 셀프 어텐션 메커니즘은 입력 시퀀스의 모든 위치 간 관계를 병렬적으로 계산한다. 이는 CNN의 지역적 수용 영역이나 RNN의 순차적 처리 한계를 극복하며, 전역적 맥락을 효과적으로 파악한다. 또한 위치 인코딩을 통해 순서 정보를 유지하면서도 병렬 처리가 가능해 학습 효율성이 높다. 트랜스포머는 사전 학습된 대규모 모델을 다양한 모달리티에 전이 학습할 수 있다는 특성이 큰 장점이다.

가) 텍스트 --> 이미지 생성

구체적인 예시로 이미지 생성 과정을 살펴보자. DALL-E나 Stable Diffusion의 일부 변형은 트랜스포머를 활용한다. 256x256 픽셀의 고양이 이미지를 생성한다고 가정하면, 먼저 이미지를 16x16 패치로 분할하여 총 256개의 패치를 얻는다. 각 패치는 768차원의 벡터로 임베딩되고, 2차원 위치 인코딩(x, y 좌표 정보)이 추가된다.

모델은 ‘고양이’라는 텍스트 토큰을 입력으로 받으면 먼저 텍스트 인코더가 이를

문맥화된 의미 벡터로 바꾼다. 이 벡터는 사전처럼 “고양이=귀, 눈, 수염, 털 결, 몸통 비율, 포즈, 고양이와 자주 함께 등장하는 소파·바닥·창문” 같은 연관 특징들이 압축된 방향성을 가진다. 여기서 말하는 의미 네트워크는 단어 주변의 공기인접 패턴이 아니라, ***방대한 이미지 데이터의 사전 학습 과정에서 ‘고양이’가 포함된 수많은 이미지-캡션 쌍을 통해 쌓인 통계적 연관 구조***다.

다음으로 이미지 쪽은 ***무작위 노이즈(무작위 회색 화면)에서 시작해 점진적으로 노이즈를 제거***하는데, 각 단계에서 현재의 흐릿한 패치들이 텍스트 의미 벡터를 참고하도록 크로스 어텐션이 연결을 만든다. 예컨대 어떤 위치의 패치가 “여기가 고양이일 가능성이 높다”는 신호를 받으면, 그 패치는 ‘귀의 삼각형 윤곽’, ‘눈의 타원 대비’, ‘수염의 가는 선’처럼 고양이를 구성하는 미세 패턴이 나올 방향으로 업데이트된다.

중요한 점은 모델이 어떤 저장된 이미지 패치를 데이터베이스에서 꺼내 붙이는 방식이 아니라, ***신경망 가중치 속에 분산 저장된 패턴 생성 규칙(고양이가 포함된 방대한 이미지 데이터로부터 이미 학습되어 있는 가중치 체계)***을 이용해 그때그때 예측을 한다는 점이다. ‘고양이’라는 단어의 의미 네트워크는 ‘고양이’가 지닌 형상 패턴에 대한 무수히 많은 정보를 담고 있으며, 반복 스텝이 진행될수록 셀프 어텐션이 이 패턴들 사이의 관계를 맞추며 귀가 얼굴 위쪽에 붙고, 두 눈의 위치가 대칭을 이루고, 몸통이 소파 좌판에 눌리는 기하가 정돈된다. 마지막 단계에서는 전역 조명과 그림자, 질감의 일관성이 정리되면서 ‘고양이’라는 의미가 단일 물체의 형태로 수렴해 최종 이미지가 완성된다.

■ LLM에서 이미지 데이터의 토큰화

트랜스포머 언어모델은 ‘단어’들이 토큰 역할을 했지만, 이것이 이미지 모델에서 사용되려면 이미지 데이터를 언어 모델이 이해하는 토큰 형태로 변환해야 한다.

○단어와의 대응 원리

트랜스포머가 이미지를 처리하기 위해서는 시각 정보를 언어 모델이 이해하는 '토큰' 형태로 변환해야 한다. 이 과정은 텍스트에서 단어를 토큰화하는 것과 개념적으로 동일하지만, 구체적인 방법론에서 차이가 있다.

- 패치 기반 토큰화 방식: Vision Transformer(ViT)의 접근법이 가장 직관적이다. 224x224 픽셀 이미지를 16x16 픽셀 크기의 패치로 분할하면 총 196개(14x14)의 패치가 생성된다. 각 패치는 768개의 픽셀 값(16x16x3 채널)을 담고 있는데, 이를 선형 투영을 통해 고정된 차원(예: 768차원)의 벡터로 변환한다. 이 벡터가 바로 언어 모델의 '단어 임베딩'에 해당한다.

- 텍스트에서 "고양이"라는 단어가 768차원 벡터로 표현되듯이, 이미지의 왼쪽 상단 패치도 동일한 768차원 공간의 한 점으로 표현된다. 핵심은 공간적으로 인접한 픽셀들의 집합(패치)을 의미 단위로 취급한다는 것이다. 문장에서 글자들이 모여 단어를 이루듯, 픽셀들이 모여 하나의 시각적 '의미 단위'를 형성한다.
- 위치 정보의 인코딩:텍스트에서 "나는 고양이를 좋아한다"라는 문장의 각 단어는 순서가 중요하다. 마찬가지로 이미지 패치도 공간상의 위치가 중요하다. 2차원 위치 인코딩이 추가되어, (0,0) 위치의 패치와 (5,7) 위치의 패치가 구별된다. 이는 텍스트의 1차원 위치 인코딩(첫 번째 단어, 두 번째 단어)을 2차원으로 확장한 것이다.
- 이산적 토큰화 방식: 달리(DALL-E)나 VQGAN은 더 직접적으로 단어와 대응시킨다. 이미지를 먼저 VQ-VAE로 압축하여 코드북 인덱스로 변환한다. 예를 들어 8192개 항목을 가진 코드북이 있다면, 각 패치는 0부터 8191까지의 정수 하나로 표현된다. 이는 "고양이"가 어휘 사전에서 4523번째 단어인 것처럼, 특정 시각 패턴이 코드북에서 2048번째 '시각 단어'가 되는 것이다.32x32 패치로 나눈 256x256 이미지는 64개의 정수 시퀀스가 된다. 이 시퀀스는 "나는 고양이를 좋아한다"라는 6개 단어 시퀀스와 동일한 방식으로 트랜스포머에 입력된다. 모델은 [2048, 341, 7621, 2048, ...] 같은 시각 토큰 시퀀스를 처리하며, 이는 [나는, 고양이를, 좋아한다] 같은 언어 토큰 시퀀스와 구조적으로 완전히 동일하다.
- 멀티모달 정렬:CLIP 같은 모델은 이미지와 텍스트를 동일한 임베딩 공간에 배치한다. "해변의 석양" 텍스트 임베딩과 실제 석양 사진의 이미지 임베딩이 벡터 공간에서 가까워지도록 학습한다. 이를 통해 시각 패치와 언어 단어가 의미적으로 대응되며, 트랜스포머는 두 모달리티를 통합된 방식으로 이해하게 된다.

※ 과정 예시

"검은 고양이가 소파에 앉아있다"라는 텍스트 프롬프트가 텍스트 인코더(Transformer) → 이미지 디코더(확산모델 U-Net 계열)로 흘러가며, 크로스 어텐션과 셀프 어텐션이 "귀-얼굴" 같은 패치들 사이의 일관성을 맞추는 과정은 다음과 같다.

0) 장면 예시를 먼저 고정

최종적으로 만들고 싶은 이미지를 머릿속에 이렇게 둔다.

- 소파: 회색 패브릭, 오른쪽에 쿠션 1개
- 검은 고양이: 소파 중앙에 앉아 정면을 약간 왼쪽으로, 귀는 쫑긋
- 조명: 왼쪽 위에서 들어와 고양이 털에 하이라이트, 소파에 부드러운 그림자

이제 모델은 이 장면을 "한 번에" 그리는 게 아니라, 무작위 노이즈에서 시작해 여러 번 "덜 노이즈하게" 만들며 점점 구체화한다.

1) 토큰화: 문장을 의미 단위로 쪼갠다

텍스트 "검은 고양이가 소파에 앉아있다"는 토큰들로 분해된다(예: 검은 / 고양이 / 소파 / 앉아 같은 덩어리). 여기서 핵심은 "고양이", "검은", "소파", "앉아있다"가 각각 의미를 가진 단위로 잡힌다는 점이다. 이 토큰들은 이후 이미지 쪽이 참고할 수 있게 "주소표"처럼 쓰인다.

2) 텍스트 인코더: 토큰 → 의미 벡터

Transformer가 토큰들을 통과시키며 각 토큰을 문맥까지 반영한 임베딩 벡터로 바꾼다.

"검은"은 "고양이"와 결합해 "검은 털"로 해석될 가능성이 커지고,

"소파"는 "앉아있다"와 결합해 "소파 위의 자세"로 이어질 힌트가 된다.

결과물은 대략 이렇게 생각하면 된다.

텍스트 토큰별로 의미 벡터들이 생기고 이 의미 벡터들은 나중에 이미지 패치들이 "나는 어떤 토큰을 참고해야 하지?"를 물을 때 답해주는 지침 역할을 한다..

3) 이미지 디코더의 시작: 무작위 노이즈 패치에서 출발

확산모델은 처음에 화면 전체가 랜덤 노이즈인 잠재표현에서 시작한다. 이를 격자로 나누면 "패치"들의 모음이다.

초기 상태의 패치들은 "귀", "얼굴" 같은 의미가 전혀 없고 그냥 회색 점무늬들이다.

4) 한 번의 디노이징 스텝에서 하는 일: "이 패치는 무엇을 그려야 하지?"

각 스텝마다 U-Net이 현재 노이즈 상태를 보고 "노이즈를 얼마나 빼야 할지"를 예측한다. 이때 핵심 연결 고리가 크로스 어텐션이다.

4-A) 크로스 어텐션: 이미지 패치 ↔ 텍스트 토큰 연결

이미지의 어떤 패치가 예컨대 화면 중앙쯤이라면, 그 패치는 내부적으로 이렇게 "질문"한다.

"내가 고양이 영역일까? 소파 영역일까?"

텍스트 벡터들 중 '고양이' 토큰 벡터에 높은 주의를 주면 그 패치는 고양이 관련 특징(윤곽, 털 질감 등)으로 업데이트된다. "검은" 토큰에도 주의를 주면 밝기 분포

가 어두운 쪽으로 이동하고 하이라이트만 남기는 방향이 된다.

구체 예시

- 중앙 패치(고양이 몸통 자리): '고양이', '검은'에 강하게 붙음 → 어두운 실루엣이 생김
- 하단 넓은 패치(소파 좌판): '소파'에 붙음 → 직물 질감 같은 저주파 패턴이 생김
- 고양이 아래 경계 패치: '앉아있다' 문맥 영향 → "몸통이 소파에 눌린 형태"로 조금 납작해짐

4-B) 셀프 어텐션: 패치들끼리 "서로 말 맞추기"

이제 셀프 어텐션이 등장한다. 이건 이미지 패치들끼리 서로를 참고해서 전역 일관성을 만든다.

"귀 패치"와 "얼굴 패치" 예시

어떤 상단 패치가 '고양이'에 붙어서 "귀처럼 뾰족한 삼각형"을 만들기 시작했는데,

옆 패치가 아직 얼굴 윤곽을 제대로 못 잡으면 귀가 엉뚱한 위치에 떠 보일 수 있다.

셀프 어텐션은 이렇게 조율한다.

귀 패치: "내가 고양이의 일부면, 얼굴/머리 패치의 중심선과 높이가 맞아야 해."

얼굴 패치: "그렇다면 귀와 연결될 머리 윗윤곽을 이 방향으로 이어야 해."

결과적으로 귀-머리-얼굴 윤곽이 한 덩어리로 자연스럽게 합쳐진다.

5. 스텝이 반복되면서 생기는 변화: 거칠게 → 디테일

확산모델은 위 과정을 수십 번 반복한다. 대략 이런 순서로 선명해진다.

- 초기: 큰 덩어리 배치(고양이 위치 / 소파 위치)
- 중기: 자세와 형태 확정(앉은 고양이 실루엣, 소파 팔걸이·쿠션 위치)
- 후기: 디테일 강화(털 결, 눈 반짝임, 소파 직물, 경계 그림자)

중기쯤엔 "고양이 얼굴"이 생기지만 눈이 두 개가 아니라 번지거나, 귀가 짝짝이일 수 있다. '열굴' 토큰의 의미 네트워크를 동원해서 셀프 어텐션이 "좌우 대칭", "얼굴 중심선" 같은 전역 규칙을 강화하며 바로잡는다.

후기쯤엔 "검은 털인데도 털의 결이 보이는 경우"가 생긴다. '검은' 토큰은 '검다'의 의미 네트워크를 동원해 전체를 어둡게 유지시키고, 동시에 조명 방향과 결합해 하이라이트 패치를 허용한다.

6. 왜 크로스 어텐션과 셀프 어텐션이 역할 분담이 되는가

- 크로스 어텐션: “무엇을 그릴지(고양이? 소파? 검은색?)”를 텍스트에서 가져온다.
- 셀프 어텐션: “그린 것들이 서로 말이 되는지(귀가 얼굴에 붙어 있는지, 그림자가 한 방향인지)”를 이미지 내부에서 맞춘다.

즉,텍스트는 의미를 공급하고,이미지 패치들은 관계를 조율해서 “한 장의 그럴듯한 사진”이 되게 만든다.

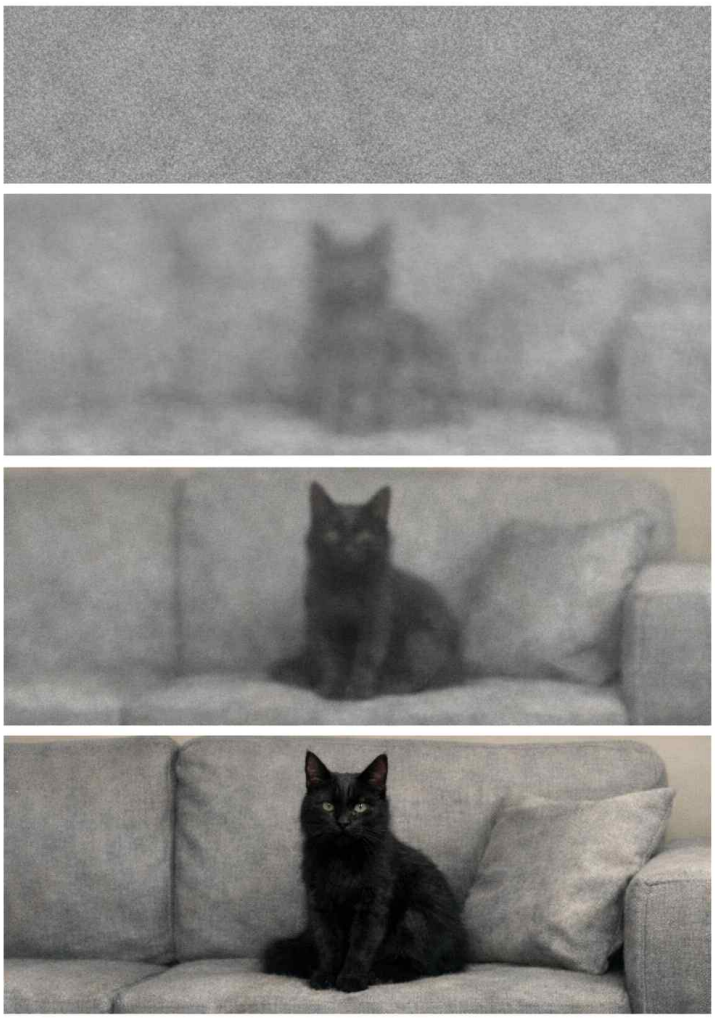

그림 25 텍스트 “검은 고양이가 소파에 앉아있다”로부터 이미지 생성 주요 단계 예시

나) 텍스트 --> 음성 생성

음성 생성의 경우에도 그 원리는 동일하다. Whisper나 AudioLM 같은 모델을 예로 들 수 있다. "안녕하세요"라는 음성을 생성할 때, 먼저 텍스트가 음소 시퀀스로 변환된다(/a/, /n/, /n/, /j/, /ʌ/, /ŋ/, /h/, /a/, /s/, /e/, /j/, /o/). 각 음소는 음향 특징 벡터로 매핑되고, 트랜스포머 디코더가 이를 멜-스펙트로그램 프레임으로 변환한다. 어텐션 메커니즘은 방대한 음성 데이터로부터 "안녕"의 억양 패턴과 "하세요"의 높낮이 변화를 학습해 놓았는데, 이를 통해 자연스러운 운율을 생성한다.

비디오 생성에서는 시공간 어텐션이 핵심이다. "걷는 사람" 영상을 생성할 때, 각 프레임의 패치뿐만 아니라 ***연속된 프레임 간의 패치 관계도 학습***한다. t시점의 "왼발" 패치는 t+1시점의 "오른발" 패치와 강한 어텐션 연결을 형성하여 자연스러운 움직임을 만든다. 3D 어텐션 윈도우를 통해 시간적 일관성과 공간적 디테일을 동시에 유지한다.

2) 대안 모델들

트랜스포머 아키텍처가 언어 생성뿐만 아니라 영상 생성에서도 탁월한 효가를 발휘하지만, 다음과 같은 문제점들이 드러나고 있다.

- 첫째, 계산 복잡도가 입력 길이의 제곱에 비례한다($O(n^2)$). 고해상도 이미지(1024x1024)를 4096개 패치로 나누면 약 1,600만 번의 어텐션 연산이 필요하다. 비디오는 시간 축까지 추가되어 연산량이 기하급수적으로 증가한다.
- 둘째, 메모리 소비가 크다. 셀프 어텐션은 모든 토큰 쌍의 관계를 저장해야 하므로, 긴 시퀀스에서는 GPU 메모리 한계에 부딪힌다.
- 셋째, 귀납적 편향의 부재다. CNN은 이미지의 지역적 패턴과 평행 이동 불변성을 내재하지만, 트랜스포머는 이를 데이터로부터 학습해야 해서 더 많은 데이터가 필요하다.
- 넷째, 장거리 의존성의 한계가 있다. 이론적으로는 전역 어텐션이지만, 실제로는 긴 시퀀스에서 그래디언트 소실이나 어텐션 희석 문제가 발생한다.

그 외에도 메모리 사용의 제약 등 여러 기술적 문제점들이 전문가 사이에서 지적되고 있기도 하다. 일단 트랜스포머의 여러 문제점을 극복하기 위해 여러 대안 모델들이 다음과 같이 등장해서 트랜스포머 모델을 보완하면서 활용되고 있다.

■ 영상 생성 분야

○GAN(Generative Adversarial Networks 적대적 생성망)

생성자(generator)와 판별자(discriminator)의 적대적 학습으로 사실적 이미지를 생성한다. 계산 효율이 높고 고품질 결과를 빠르게 생성하지만, 학습 불안정성과 모

드 붕괴 문제가 있다.

GAN은 생성자와 판별자라는 두 개의 신경망이 서로 경쟁하며 학습하는 구조를 가진 생성 모델이다. 생성자는 무작위 노이즈 벡터를 입력받아 실제 데이터와 유사한 가짜 데이터를 만들어내는 역할을 하고, 판별자는 입력된 데이터가 실제 데이터인지 생성자가 만든 가짜 데이터인지를 구분하는 역할을 한다. 학습 초기에 생성자는 의미 없는 노이즈에 가까운 결과를 만들어내며, 판별자는 이를 쉽게 가짜로 판별한다. 이 상태에서 판별자의 판단 결과가 생성자에게 역전파되어, 생성자는 "가짜로 들키지 않기 위해 어떤 방향으로 이미지를 바꿔야 하는지"에 대한 신호를 받는다.

이후 학습이 반복되면서 생성자는 점점 실제 데이터의 분포를 흉내 내는 방향으로 출력을 조정한다. 예를 들어 고양이 이미지를 학습하는 경우, 생성자는 처음에는 무작위 얼룩을 만들지만 점차 귀의 윤곽, 얼굴의 대칭, 몸통의 비율 같은 통계적 특징을 반영하게 된다. 판별자는 동시에 더 정교해져서, 단순한 윤곽만으로는 속지 않고 질감이나 구조적 일관성까지 확인하려 한다. 이 과정은 미니맥스 게임으로 표현되며, 생성자는 판별자를 최대한 속이려 하고 판별자는 속지 않으려는 목표를 가진다.

이 경쟁이 균형에 가까워지면 판별자는 실제와 가짜를 구분하기 어려워지고, 생성자는 실제 데이터와 거의 구별되지 않는 샘플을 만들어낼 수 있게 된다. 중요한 점은 GAN이 특정 이미지를 기억해 복사하는 것이 아니라, 데이터 전체가 가지는 확률 분포를 학습한다는 점이다. 생성자는 잠재 공간이라 불리는 노이즈 공간에서 연속적인 변화를 통해 다양한 결과를 만들어내며, 이 공간의 구조는 데이터의 의미적 변화를 반영한다. 그 결과 GAN은 현실감 있는 이미지 생성, 스타일 변환, 해상도 향상 등 다양한 응용으로 확장될 수 있는 강력한 생성 모델로 활용된다.

○Diffusion Models(확산모델)

DDPM, Stable Diffusion은 노이즈 제거 과정을 반복하여 이미지를 생성한다. U-Net 기반 CNN 구조를 주로 사용하며, 트랜스포머보다 메모리 효율적이고 다양한 샘플을 생성한다.

확산모델은 데이터를 점진적으로 망가뜨렸다가 그 과정을 거꾸로 되돌리는 방식을 통해 새로운 데이터를 생성하는 생성 모델이다. 먼저 학습 단계에서 실제 이미지에 아주 작은 가우시안 노이즈를 여러 단계에 걸쳐 반복적으로 추가한다. 이 과정을 계속하면 원래 고양이 사진이었든 풍경 사진이었든, 충분히 많은 단계 뒤에는 모든 이미지가 거의 동일한 순수한 노이즈 상태로 수렴한다. 이 단계는 정방향 확산 과정이며, 수학적으로는 "데이터가 시간에 따라 점점 무작위 분포로 변한다"는

과정을 정의해 둔 것이다.

다음으로 모델이 실제로 학습하는 핵심은 역방향 과정이다. 모델은 각 단계에서 “지금 이 노이즈가 섞인 이미지에서, 방금 추가된 노이즈가 무엇이었는지”를 예측하도록 훈련된다. 즉 이미지를 직접 복원하는 것이 아니라, 노이즈 성분을 맞히는 문제를 푼다. 이 예측이 정확해질수록 노이즈를 조금씩 제거하면서 이전 단계의 이미지로 되돌아갈 수 있다. 학습이 끝난 뒤 생성 단계에서는 완전히 무작위한 노이즈 이미지 하나를 입력으로 두고, 학습된 역방향 과정을 반복 적용해 점점 구조와 형태가 나타나도록 만든다.

텍스트 조건이 붙는 경우, 텍스트 인코더가 문장을 의미 벡터로 바꾸고, 이 정보가 역방향 디노이징 과정에 개입한다. 각 단계에서 이미지의 작은 패치들이 크로스 어텐션을 통해 “지금 이 위치는 고양이의 귀인지, 몸통인지, 배경인지”를 텍스트 의미와 연결해 판단한다. 동시에 셀프 어텐션은 이미지 내부 패치들 사이의 관계를 맞추어 형태와 비율의 일관성을 유지한다. 이런 과정을 수십에서 수백 단계 반복한 결과, 무작위 노이즈는 점차 의미 있는 구조를 갖춘 이미지로 수렴하며, 확산모델은 안정적이고 고품질의 이미지 생성을 가능하게 한다.

○VAE(Variational Autoencoder 변분오토인코더)

잠재 공간에서 샘플링하여 이미지를 생성하며, 비교적 단순한 CNN 인코더-디코더 구조로 효율적이다.

VAE는 데이터를 압축해 잠재 공간으로 옮겼다가 다시 복원하는 오토인코더 구조에 확률적 개념을 결합한 생성 모델이다. 먼저 인코더는 입력 이미지를 받아 이를 하나의 고정된 벡터로 압축하는 대신, 평균과 분산이라는 두 개의 값으로 표현되는 확률분포로 변환한다. 이는 “이 이미지가 잠재 공간의 어느 지점 근처에 있을 가능성이 높은가”를 하나의 점이 아니라 분포로 나타내는 방식이다. 이렇게 하면 모델은 입력 데이터를 딱 하나의 위치에 고정시키지 않고, 의미적으로 유사한 이미지들이 연속적인 공간에 모이도록 학습할 수 있다.

다음 단계에서 디코더는 이 분포로부터 하나의 잠재 벡터를 샘플링해 원래의 이미지와 최대한 비슷한 이미지를 복원하려고 한다. 이때 중요한 장치가 재매개변수화 기법이다. 단순히 확률분포에서 샘플을 뽑으면 미분이 불가능해 학습이 어렵기 때문에, 평균과 분산에 무작위 노이즈를 결합하는 방식으로 샘플링을 수식적으로 변형해 학습이 가능하도록 만든다.

VAE의 학습 목표는 두 가지로 구성된다. 하나는 복원 손실로, 디코더가 입력 이미지를 얼마나 잘 재현했는지를 측정한다. 다른 하나는 정규화 항으로, 잠재 분포가 정해진 기준 분포와 너무 멀어지지 않도록 제약을 건다. 이 두 목표의 균형을 통해

잠재 공간은 부드럽고 연속적인 구조를 갖게 된다. 그 결과 학습이 끝난 뒤에는 기준 분포에서 임의로 잠재 벡터를 샘플링해 디코더에 넣는 것만으로도, 학습 데이터와 유사하지만 새로운 이미지를 생성할 수 있게 된다.

■음성 생성 분야

음성 생성 분야에도 트랜스포머 방식에 보완적으로 사용되는 다음과 같은 모델들이 있지만 자세한 설명은 생략한다.

- WaveNet: CNN 기반의 자기회귀(auto-regression) 모델로 고품질 음성을 생성하지만, 생성 속도가 느리다.
- Tacotron/FastSpeech: RNN과 CNN을 결합한 시퀀스-투-시퀀스 모델로 텍스트에서 음성을 합성한다.
- GAN-TTS: MelGAN, HiFi-GAN 등은 GAN 기반으로 실시간 음성 생성이 가능하다.

나. 효과적인 프롬프트의 원리

프롬프트는 인공지능과 인간이 대화하기 위해 사용하는 모든 입력값을 의미한다. 단순히 명령을 내리는 문장이 아니라, AI에게 해결해야 할 문제를 정의해주고 작업에 필요한 배경지식과 맥락을 제공하는 소통의 설계도이다. 똑같은 화가에게 "그림을 그려줘"라고 말하는 것과 "석양 아래 외로이 서 있는 소나무를 수묵화 기법으로 그려줘"라고 말하는 것은 전혀 다른 결과를 가져온다. 이처럼 프롬프트는 AI라는 거대한 지능의 원석에서 사용자가 원하는 형상을 깎아내는 핵심 도구이며, 질문의 수준이 곧 결과의 품질을 결정한다.

1) AI의 프롬프트 인식

AI는 인간처럼 문장의 '진의'를 마음으로 읽지 않는다. 대신 입력된 프롬프트를 수많은 토큰(단어의 최소 단위)으로 분해하고, 학습된 데이터 속에서 해당 토큰들과 가장 높은 확률로 연결되는 다음 단어들을 통계적으로 찾아 나간다.

이 과정에서 AI가 가장 의존하는 것은 '문맥적 단서'이다. 문장이 길더라도 핵심 정보가 누락되면 AI는 통계적 확률에 따라 임의의 답변을 채워 넣는데, 이를 흔히 '환각(Hallucination)'이라 부른다. 반대로 명확한 표현을 사용하면 AI가 탐색해야 할 데이터의 범위가 좁혀져 정확도가 올라간다. 예를 들어, 단순한 질문보다 구체적인 예시(Few-shot)를 제공했을 때 AI의 성능이 비약적으로 향상되는 이유는, 예시가 AI에게 일종의 '정답 패턴'을 가이드라인으로 제시하기 때문이다.

또한 제약 조건은 AI의 확률적 탐색 범위를 제한하는 울타리 역할을 한다. "초등학생도 이해할 수 있게"라는 제약은 AI가 어려운 전문 용어 대신 일상적인 단어를 선택하도록 유도한다. 결국 AI가 프롬프트를 이해하는 방식은 '의미의 파악'이라기보다 '제시된 맥락 안에서 가장 적절한 패턴을 찾아가는 최적화 과정'에 가깝다는 점을 기억해야 한다.

2) 비결정성 문제

같은 프롬프트를 입력했는데도 AI의 답변이 달라지는 이유는 흔히 배치불변성 결여(Absence of Batch Invariance)로 인한 비결정성(Non-determinism) 문제로 설명할 수 있다. 이는 AI가 수학적으로 항상 같은 입력에 같은 출력을 내는 계산기가 아니라, 확률적 추론 시스템이라는 점에서 비롯된다.

첫째, 대형 언어 모델은 문장을 규칙에 따라 처리하는 방식이 아니라, 다음에 올 단어가 무엇일지를 확률 분포로 예측한다. 동일한 프롬프트라도 내부적으로는 여러

가능한 응답 후보가 존재하며, 매번 그중 하나가 선택된다. 이 과정에서 미세한 확률 차이와 무작위 샘플링이 개입되기 때문에 결과가 완전히 고정되지 않는다.

둘째, 모델 내부에는 의도적으로 무작위성이 포함되어 있다. 이는 창의성과 다양성을 확보하기 위한 설계다. 만약 항상 가장 확률이 높은 단어만을 선택한다면, 답변은 지나치게 단조롭고 반복적으로 변한다. 따라서 실제 생성 과정에서는 확률적으로 그럴듯한 여러 선택지 중 하나를 뽑는 방식이 사용되며, 이로 인해 동일한 질문에도 서로 다른 표현이나 논점이 등장할 수 있다.

셋째, AI는 질문을 독립적인 하나의 문장으로만 처리하지 않는다. 직전 대화의 흐름, 보이지 않는 시스템 설정, 내부 상태 등이 미세하게 영향을 준다. 사용자가 보기에는 같은 질문이라도, 모델 입장에서는 “완전히 동일한 조건”이 아닐 수 있다. 이 때문에 배치, 즉 처리 맥락이 조금만 달라져도 결과가 달라질 수 있다.

넷째, 언어 자체의 모호성도 중요한 요인이다. 자연어는 하나의 질문이 여러 의미로 해석될 수 있는 여지를 항상 포함한다. AI는 그중 하나를 선택해 응답하는데, 매번 선택되는 해석의 중심이 약간씩 달라질 수 있다. 이는 오류라기보다 인간의 답변이 상황에 따라 달라지는 것과 유사한 특성이다.

결국 배치불변성이 완전히 보장되지 않는 이유는, 생성형 AI가 정답을 꺼내는 기계가 아니라 가능한 답 중 하나를 선택해 구성하는 시스템이기 때문이다. 이 특성을 이해하는 것은, AI에게서 일관된 결과를 얻기 위해 왜 프롬프트를 구체화하고 조건을 명시해야 하는지를 설명해주는 중요한 출발점이 된다.

3) 명확한 지시

효과적인 프롬프트는 우연히 만들어지는 것이 아니라 체계적인 구조를 갖는다. AI의 출력을 안정화하고 의도에 부합하는 결과를 얻기 위해서는 다음의 4가지 원칙을 지켜야 한다.

첫째, 역할 설정(Persona)이다. AI에게 "너는 20년 경력의 전문 편집자야" 혹은 "너는 대학 신입생에게 디자인 전공 과목을 탁월하게 가르치는 최고의 교수야"라고 역할을 부여하면, 해당 직업군이 주로 사용하는 어휘와 사고 체계를 우선적으로 반영한다.

둘째, 목적과 배경(Context)이다. 이 작업이 왜 필요한지, 누가 읽을 것인지에 대한 정보를 주어야 한다. “나는 교수님께 제출할 학기말 보고서를 작성하려고 한다” “다음 달로 예정된 여행을 함께 할 친한 친구들과 공유하려고 한다.” “나는 Google 취업 면접에 대비하려고 한다.”

셋째, 작업 지시(Task)이다. 무엇을 해야 하는지 추상적이지 않고 구체적인 동사와 목적어들을 사용하여 기술한다.

☞LLM입장에서 자칫 혼동을 불러올 수 있는 지시대명사 예컨대 ‘이’ ‘그것’ ‘저것’ ‘앞에서’ 같은 단어보다는 구체적인 명사를 사용해서 또는 따옴표 “”안에 정확한 명칭이나 구절을 기재하여 토큰을 명확히 인식하도록 지정하는 것이 보다 효과가 좋다.

넷째, 형식 및 제약(Constraint & Format)이다. "표 형태로 정리해줘", "3문장 이내로 요약해줘", "격식 있는 어조로 작성해줘" “답변 근거, 즉 참고문헌을 반드시 대답 끝에 기재해줘. 안 하면 유료 이용 끊는다.”와 같은 구체적인 규격을 지정한다.

이러한 구조화된 프롬프트는 단순히 답변을 얻는 수단을 넘어, 사용자가 자신의 생각과 요구사항을 논리적으로 정리하는 도구가 된다. 잘 설계된 프롬프트 구조는 AI가 엉뚱한 방향으로 나가는 것을 방지하는 강력한 이정표가 된다.

4) 반복과 수정

프롬프트는 한 번에 완성되지 않는다. 프롬프트 작성은 단발성 명령이 아니라 AI와의 '협력적 대화' 과정이다. 첫 번째 질문에 AI가 완벽한 답변을 내놓는 경우는 드물다. 사용자는 초기 결과물을 비판적으로 검토하고, 누락된 정보를 보강하거나 잘못 해석된 부분을 바로잡는 후속 지시를 내려야 한다.

이 과정을 '프롬프트 튜닝'이라고 한다. "조금 더 유머러스하게 써줘", "이 부분은 빼고 다시 설명해줘"와 같은 수정 요청을 통해 답변은 점진적으로 완성된다. 이는 인간이 동료와 협업할 때 피드백을 주고받으며 업무의 완성도를 높이는 과정과 같다. 따라서 한 번의 실패에 실망하기보다, AI의 답변을 디딤돌 삼아 질문을 정교화하는 태도가 중요하다.

표 10 나쁜 프롬프트와 좋은 프롬프트 예시

활용 유형	**나쁜 예(모호한 프롬프트)**	**좋은 예(의도가 명확한 프롬프트)** ※ 실제로는 질문자가 더 구체적인 조건들을 명시할수록 좋다. 이런 능력은 질문자가 해당 과업에 대해 사전 지식을 어느 정도 갖추고 있느냐에 달려있다. 대상을 잘 알수록 지시를 더욱 구체적으로 할 수 있다.
보고서 작성	기후 변화에 대한 보고서를 써줘.	너는 환경 정책 전문가야. 대학생을 대상으로 기후 변화가 한국 농업에 미치는 영향을 다룬 보고서를 개조식으로 3페이지 분량으로 작성해줘.
번역 및 교정	이 문장을 영어로 번역해줘.	비즈니스 이메일에 사용할 문장이야. 상대방의 제안을 정중하게 거절하되 향후 협력 가능성을 열어두는 어조로 번역해줘.
코드 생성	파이썬으로 벽돌깨기 게임을 만들어줘.	파이썬 파이게임(Pygame) 라이브러리를 사용해서 벽돌깨기 게임의 기본 코드를 작성해줘. 각 코드 라인마다 초보자가 이해할 수 있게 주석을 달아줘.
요약	이 글 요약해.	제시된 뉴스 기사에서 핵심 사건 3가지만 뽑아서 불렛 포인트로 요약해줘. 마지막에는 이 사건이 경제에 미칠 영향 한 줄을 덧붙여줘.
창의적 글쓰기	고양이 이야기를 써줘.	비 오는 날 창밖을 구경하는 길고양이의 시점에서 쓴 짧은 수필을 작성해줘. 고독하지만 평화로운 분위기가 느껴지도록 묘사 위주로 써줘.

프롬프트가 아무리 정교해도 AI는 만능이 아니다. 모호한 지시는 여전히 왜곡된 정보를 낳을 수 있으며, AI의 답변에는 학습 데이터에 내재된 편향이 섞여 있을 수 있다. 가장 큰 위험은 사용자가 AI의 결과물을 무비판적으로 수용하는 지적 태만이다. 결과물의 진위 여부를 확인하고 최종적인 책임을 지는 주체는 반드시 인간이어야 한다. 마치 비서에게 텍스트 작성 작업을 온전히 일임시켜놓고 처음부터 끝까지 검토해보지 않고 그대로 받아들이는 것은 무책임한 일인 것과 같다.

"잘 묻는다는 것"은 단순히 기술적인 숙련도를 의미하지 않는다. 그것은 내가 무엇을 모르는지, 무엇을 원하는지를 정확히 성찰하는 지적인 능력이다. AI에게 의도를 위임한다는 것은 나의 도구를 확장하는 행위이지, 사고의 주권까지 넘기는 것이 아니다. 질문하는 인간으로서 우리는 AI가 내놓은 답이 우리의 가치관과 윤리에 부합하는지 끊임없이 되물어야 한다. 이것이 AI 시대를 살아가는 교양인이 갖춰야 할 비판적 사고의 본질이다.

다. 학습 데이터의 성격

1) Open 대 Priavate Data

현재 AI모델은 상당부분 Open Data 기반으로 구축되어 있다. (지식재산 침해 문제는 별개로 하더라도) 공개된 사이트의 방대한 데이터가 그것이다. 기업이나 개인이 내부적으로 보유하고 있는 사적 데이터는 접근 불가능성 또는 지식재산 문제로 아직 학습 데이터로 사용하기에 제약이 있다.

한편, Oracle의 래리 엘리슨 회장은 AI 모델이 진정한 가치를 내기 위해서는 각 기업이 보유한 프라이빗 데이터 활용이 핵심이라는 주장을 펼친 적이 있다. 현재 서비스 중인 ChatGPT나 앤트로픽, 그록 등 대부분 AI 모델이 공개된 데이터로 훈련되었지만, 실질적인 비즈니스 가치는 기업들의 프라이빗 데이터를 활용할 때 극대화되기 때문이라기 때문이라는 주장이었다. 그러나, 오픈 데이터와 프라이빗 데이터는 서로를 보완하며 서로 장단점이 존재한다.

■ 오픈 데이터

○장점:

범용성과 확장성이 핵심이다. 위키피디아, 학술 논문, 뉴스 기사, 오픈소스 코드 등 공개 데이터는 인류의 집단 지식을 포괄한다. 이를 통해 모델은 다양한 도메인에서 작동하는 기본 지능을 획득한다. 법적 리스크가 낮고, 대규모 데이터셋 구축 비용이 상대적으로 저렴하며, 연구 커뮤니티의 협업이 가능하다. ChatGPT가 역사, 과학, 프로그래밍 등 광범위한 질문에 답할 수 있는 것은 오픈 데이터 덕분이다.

○단점

일반화된 지식은 특정 기업의 고유한 맥락을 이해하지 못한다. 삼성전자의 반도체 제조 공정 최적화나 현대자동차의 특정 차량 결함 패턴은 공개 데이터에 존재하지 않는다. 또한 시의성이 떨어지고, 편향이 존재하며, 민감한 개인정보나 영업 비밀은 포함되지 않는다.

■프라이빗 데이터

○장점

맥락 특화성이 가장 큰 강점이다. 기업의 고객 행동 패턴, 내부 프로세스, 도메인 전문 지식, 독점 기술 정보는 경쟁 우위의 원천이다. 병원의 10년간 진료 기록은 해당 지역 환자군에 최적화된 진단 모델을 만들 수 있다. 금융사의 거래 데이터는 특정 고객층의 신용 위험을 정밀하게 예측한다. 이는 공개 데이터로는 불가능한 차별화된 가치다.

○프라이빗 데이터의 한계

규모의 한계가 명확하다. 대부분 기업은 수십억 개 토큰 수준의 데이터만 보유하

며, 이는 대규모 사전 학습에는 부족하다. 편향과 노이즈가 심할 수 있고, 법적 규제(GDPR, 개인정보보호법)가 엄격하며, 데이터 품질 관리 비용이 크다. 또한 한 기업의 프라이빗 데이터만으로는 새로운 패러다임이나 창의적 해법을 발견하기 어렵다.

프라이빗 데이터를 효과적 활용하기 위한 전략으로 다음과 같은 것들이 가능하다.

1. 파인튜닝(Fine-tuning) 접근
사전 학습된 공개 모델을 기업의 프라이빗 데이터로 추가 학습시킨다. 법률 회사가 GPT-4를 자사의 판례 데이터베이스로 파인튜닝하면, 일반 법률 지식과 자사 경험이 결합된 특화 모델이 된다. 이는 수천~수만 건의 데이터로도 효과적이다.

2. RAG(Retrieval-Augmented Generation) 시스템
모델 자체를 재학습하지 않고, 실시간으로 프라이빗 데이터베이스를 검색하여 응답에 활용한다. 고객 문의에 답할 때 회사의 내부 매뉴얼, 과거 티켓 이력, 제품 스펙을 검색하여 맥락을 제공한다. 데이터 업데이트가 즉시 반영되고, 환각(hallucination)이 줄어들며, 출처 추적이 가능하다는 장점이 있다.

3. 프롬프트 엔지니어링과 컨텍스트 주입
API 호출 시 관련 프라이빗 정보를 프롬프트에 포함시킨다. 영업 담당자가 고객과 통화할 때, 해당 고객의 구매 이력, 선호도, 과거 불만사항을 LLM에 전달하여 맞춤형 응대 스크립트를 생성한다.

4. 연합 학습(Federated Learning)
여러 기관이 데이터를 직접 공유하지 않고 모델 업데이트만 공유하여 협업한다. 병원들이 환자 데이터를 중앙에 모으지 않고도 공동으로 진단 모델을 개선할 수 있다.

■ 사례들
Private데이터를 이용한 대표적인 성공 사례들은 다음과 같은 것들이 있다.

○금융: JPMorgan Chase의 IndexGPT:
JP모건은 자사의 방대한 거래 데이터, 리서치 보고서, 시장 분석을 활용하여 투자 자문 AI를 개발했다. 공개 금융 뉴스로는 포착할 수 없는 고객별 포트폴리오 특성

과 리스크 선호도를 반영하여 개인화된 투자 전략을 제시한다.

○의료: Mayo Clinic의 임상 AI:
메이요 클리닉은 수백만 건의 비식별화된 전자의무기록(EMR)으로 질병 예측 모델을 훈련시켰다. 특정 유전자 변이와 치료 반응의 상관관계 같은 독점적 인사이트를 발견하여 정밀 의료를 실현한다. 공개 의학 문헌만으로는 이런 실제 임상 패턴을 학습할 수 없다.

○제조: 지멘스의 예지 보전:
지멘스는 전 세계 공장의 센서 데이터(온도, 진동, 압력)를 AI로 분석하여 장비 고장을 사전 예측한다. 각 공장의 고유한 운영 환경과 장비 특성은 프라이빗 데이터로만 학습 가능하며, 이를 통해 다운타임을 30% 감소시켰다.

○고객 서비스: Salesforce의 Einstein GPT:
세일즈포스는 고객사의 CRM 데이터(고객 상호작용 이력, 구매 패턴, 지원 티켓)를 활용하여 개인화된 응답을 생성한다. 일반 챗봇과 달리 "이 고객이 지난달 불만을 제기했던 배송 문제"를 기억하고 맥락에 맞는 해법을 제시한다.

오픈 데이터와 프라이빗 데이터는 대립이 아닌 상호 보완 관계다. 최적의 전략은 공개 데이터로 사전 학습된 강력한 기반 모델을 프라이빗 데이터로 특화시키는 하이브리드 접근이다. 기업들은 RAG나 파인튜닝 같은 기법으로 양쪽의 장점을 결합하여 진정한 비즈니스 가치를 창출할 수 있다.

2) 데이터 없는 자체 학습이 가능한가

○ 메타의 LSP
메타의 언어 셀프 플레이(Language Self-Play; LSP)는 AlphaGo의 자기 대국 개념을 언어 모델에 적용한 혁신적 접근이다[25]. 기존 LLM이 인간이 작성한 텍스트 데이터로만 학습했다면, LSP는 모델이 스스로 질문을 생성하고 답변하며, 그 결과를 평가하여 반복적으로 개선하는 자율 학습 메커니즘이다.
구체적으로 모델은 두 가지 역할을 번갈아 수행한다. 먼저 '생성자' 역할로 수학 문제나 논리 퍼즐 같은 태스크를 만들고, '해결자' 역할로 그 문제를 풀어본다. 이후 '평가자' 역할로 답변의 정확성을 검증하고, 성공한 사례는 강화 학습의 보상 신호로 활용한다. 인간의 피드백이나 외부 데이터 없이도 모델 내부에서 데이터 생성

25) https://arxiv.org/pdf/2509.07414

-학습-평가 루프가 자동으로 돌아간다.

특히 수학이나 코딩처럼 정답이 명확한 도메인에서 효과적이다. 모델이 "234 × 567 = ?"이라는 문제를 생성하고, 답변 "132,678"을 계산하여 검증할 수 있다. 정답이면 해당 추론 경로가 강화되고, 오답이면 패널티를 받아 점진적으로 능력이 향상된다.

○ LSP가 지닌 한계

첫째, 도메인 제한성이 심각하다. LSP는 객관적으로 검증 가능한 태스크에만 작동한다. "좋은 소설을 써라" 같은 창의적 작업이나 "윤리적으로 옳은 행동은 무엇인가" 같은 주관적 질문에는 적용할 수 없다. 모델이 스스로 답변을 평가할 명확한 기준이 없기 때문이다.

둘째, 편향 증폭의 위험이 있다. 모델이 자신의 기존 지식과 편향 범위 내에서만 학습하므로, 초기 사전 학습 데이터에 존재하던 편향이나 오류가 자기 강화 루프를 통해 고착화될 수 있다. 외부 다양성의 유입이 없어 에코 챔버 효과가 발생한다.

셋째, 진정한 '데이터 없음'이 아니다. LSP도 초기에는 대규모 공개 데이터로 사전 학습된 기반 모델이 필요하다. 완전히 빈 상태에서 시작할 수 없으며, 이는 "데이터 없이 학습"이라는 표현이 과장임을 보여준다. 실제로는 "추가 인간 레이블 데이터 없이"가 정확한 표현이다.

넷째, 계산 비용이 막대하다. 수백만 번의 자기 대화와 평가를 반복해야 하므로, 전통적 지도 학습보다 훨씬 많은 연산 자원이 소모된다. 환경적 지속 가능성 측면에서도 문제가 있다.

다섯째, 평가 함수의 신뢰성 문제다. 모델이 스스로 자신의 답변을 평가할 때, 그 평가 자체가 부정확하면 잘못된 학습으로 이어진다. "모델이 자신의 오류를 모르면 그것을 오류로 인식할 수 없다"는 순환 논리에 빠진다.

○ LSP가 지닌 AI 개발 역사에서의 의미

LSP는 AI 발전의 세 가지 중요한 전환점을 상징한다.

첫째, 데이터 의존성 탈피 시도다. 딥러닝 시대는 "데이터가 곧 석유"라는 패러다임이었다. GPT-3는 570GB 텍스트를, GPT-4는 수조 개 토큰을 학습했다. 하지만 인터넷의 고품질 텍스트는 한계가 있고, 2026년경이면 학습 가능한 데이터가 고갈될 것이라는 우려가 있다. LSP는 이 병목을 돌파하려는 시도로, "합성 데이터 생성"의 가능성을 보여준다.

둘째, 강화 학습과 언어 모델의 융합이다. AlphaGo가 바둑에서 자기 대국으로 인간을 초월했듯, LSP는 언어 영역에서도 비슷한 돌파구를 찾으려 한다. 이는 지도

학습 중심이던 NLP가 강화 학습과 결합하는 패러다임 전환이다. OpenAI의 RLHF (인간 피드백 기반 강화 학습)도 같은 맥락이지만, LSP는 인간조차 배제하려 한다.

셋째, AGI를 향한 자율성 증대 가능성을 암시했다. 진정한 범용 인공지능(AGI)은 인간의 지속적 개입 없이도 스스로 학습하고 진화해야 한다. LSP는 이 방향의 초기 시도로, 모델이 외부 감독 없이 자기 개선하는 능력을 탐구한다. 하지만 현재는 매우 제한된 도메인에서만 작동하며, 인간의 가치와 목표 정렬 문제가 해결되지 않아 윤리적 우려도 크다.

종합적으로 말하자면 LSP는 야심찬 실험이지만, 아직 근본적 한계를 극복하지 못했다. 데이터 고갈 문제에 대한 부분적 해법일 수는 있으나, 인간의 창의성과 판단력을 완전히 대체하기에는 멀었다. AI 역사에서는 "데이터 효율성" 연구의 중요한 이정표이지만, 과대평가는 경계해야 한다.

6. AI 생태계의 현재와 미래 I

가. 문서 요약과 번역의 원리

AI가 문서를 요약하는 원리는 방대한 텍스트 데이터에서 가장 중요한 정보만을 추출하거나(Extraction), 새로운 문장으로 재구성하여(Abstraction) 핵심 내용을 전달하는 기술이다.

1) Transformer Attention 모델의 번역과 요약

Transformer 구조 내에서 Attention 메커니즘은 번역과 요약 모두에서 핵심적인 역할을 하지만, 그 목적과 작동 방식에는 미묘한 차이가 있다.

■ 번역 (Translation) 원리

- 일대일 대응성: 입력 언어의 단어와 출력 언어의 단어 사이의 '대칭적 관계'를 찾는 데 집중한다.
- Attention의 역할: 문장의 어순이 바뀌더라도 문맥상 어떤 단어가 연결되는지 추적한다. (예: 한국어의 '사과를'이 영어의 'Apple'과 연결됨을 인식)
- 특징: 정보의 손실을 최소화하고 의미를 그대로 보존하는 것이 최우선이다.

■요약 (Summarization) 원리

- 정보의 압축과 선택: 입력된 전체 문맥 중에서 '주제어'와 '핵심 문장'에 더 높은 가중치(Weight)를 부여한다.
- Attention의 역할: 덜 중요한 수식어나 반복되는 내용은 무시하고, 전체 텍스트의 의미를 관통하는 핵심 토큰에 주의를 집중한다.
- 특징: 원문의 모든 정보를 전달하는 것이 아니라, 중요도가 낮은 정보를 버리는 선별적 선택 과정이 핵심이다.

2) 추론 기반 요약 모델

최근 등장한 Reasoning(추론) 모델은, LLM 일반 요약 모델과 달리, 단순한 패턴 매칭 기반의 요약에서 한 단계 더 나아가 '이해'와 '논리'를 바탕으로 요약을 수행

한다.

표 11 일반 요약과 추론 기반 요약의 비교

구분	일반 요약 모델 (Standard LLM)	추론 기반 요약 모델 (Reasoning Model)
작동 방식	통계적으로 가장 빈번하거나 중요한 단어 조합을 생성함	문서 내 논리 구조를 파악하고 단계별로 요약함
처리 과정	텍스트 입력 → 즉각적인 요약본 생성	텍스트 분석 → 주요 논점 추출 → 모순 검토 → 요약
추론 능력	텍스트 표면에 드러난 내용을 잘 요약함	행간의 의미(Implied meaning)나 복잡한 인과관계를 파악함
오류 수정	환각(Hallucination) 현상이 발생할 수 있음	스스로 요약본이 원문과 일치하는지 검증(Self-Correction)함

Reasoning 모델이 매우 긴 보고서를 요약할 때는 다음과 같은 사고의 사슬(Chain of Thought)을 거친다.

1. 논리적 분해: 문서의 서론, 본론, 결론을 구분하고 각 섹션의 핵심 주장을 개별적으로 파악한다.
2. 중요도 평가: “이 데이터가 결론을 도출하는 데 필수적인가?”라는 질문을 스스로 던지며 정보를 필터링한다.
3. 일관성 검증: 요약된 문장들이 서로 모순되지 않는지, 그리고 원문의 의도를 왜곡하지 않았는지 내부적으로 비판적 검토를 수행한다.
4. 최종 생성: 검증된 논리 구조를 바탕으로 자연스러운 문장을 만든다.

기존 모델이 “어떤 단어가 중요해 보이는가?”라는 확률에 의존했다면, Reasoning 모델은 “이 문서의 핵심 논리는 무엇이며, 이를 설명하기 위해 무엇을 남겨야 하는가?”라는 논리적 판단을 우선시한다.

☞ 참고: “대상 자료는 송경모가 저술한 <AI 앞에서 경영자의 선택 리버럴 아트> 라는 책의 원고다. 이 pdf 파일의 16~30쪽을 대상으로 첫째, 한국어 3,000자 내외로 요약하는 과정에서 선정한 핵심 단어, 주제, 소제목 구분을 구체적으로 제시하고, 둘째, 최종 요약 결과를 제시하라.” (Gemini)

첨부된 송경모 저자의 AI 앞에 선 경영자의 선택 리버럴 아트 '본문 3교 색인 포함.pdf' 파일의 16~30쪽 내용을 바탕으로, Gemini가 한국어 3,000자 분량의 고품질 요약을 생성하는 구체적인 추론 및 실행 절차를 설명한다.

1. 텍스트 분석 및 전처리 (Parsing & Context Loading)

먼저 Gemini는 지정된 16~30쪽의 텍스트와 구조적 데이터를 정밀하게 읽어 들인다. 이 과정은 단순히 글자를 인식하는 것을 넘어 문서의 '뼈대'를 파악하는 단계다.

* 구조 파악: 소제목, 강조된 텍스트, 각주, 도표 등을 구분하여 문서의 계층 구조를 인식한다.
* 언어 모델링: 한국어 특유의 문맥과 전문 용어를 해석하기 위한 준비를 수행한다.

2. 중요 단어 및 주제어 선별 (Attention-based Keyword Extraction)

이 단계에서는 Attention 메커니즘이 핵심적으로 작동한다. 3,000자 분량의 요약을 위해서는 단순한 단어가 아니라 '개념적 중심'을 포착해야 한다.

* TF-IDF 및 문맥 가중치 부여: 문서 전체에서 빈번하게 등장하면서 의미를 결정짓는 핵심 명사를 추출한다.
* 주제어 선정 예시: 특정 이론이나 역사적 사건을 다룬 경우, 이론 명칭, 핵심 인물, 주요 연도, 반복되는 개념을 주제어로 확정한다.
* 필터링: '기여하다', '결정적이다', '한계가 있다'와 같이 저자의 핵심 주장이 담긴 어휘에 높은 Attention 가중치를 부여한다.

3. 핵심 문장 선별 및 논리 구조화 (Reasoning & CoT)

선별된 단어들을 연결해 문서의 줄기를 형성하는 핵심 문장을 도출한다. 이 과정에서 Reasoning(추론)이 본격적으로 작동한다.

* 섹션별 요약: 16~18쪽, 19~23쪽 등으로 구간을 나누어 각 부분의 결론적 문장을 우선 추출한다.
* 논리적 연결성 검토: 원인-결과-시사점으로 이어지는 사고의 사슬을 구성한다.
* 중복 제거: 의미가 유사한 문장은 가장 포괄적인 문장 하나로 통합한다.

4. 3,000자 분량의 생성 및 정교화 (Abstraction & Expansion)

단순 추출이 아니라 목표 분량에 맞춰 내용을 재구성하는 생성적 요약을 수행한다.

* 상세 서술: 핵심 요약문 사이에 근거, 예시, 데이터를 보완하여 맥락을 확장한다.
* 톤 앤 매너 조절: 학술적이고 신뢰감 있는 문체로 전체 문장을 정제한다.
* 응집성 확보: 접속어를 활용해 문장 간 흐름을 자연스럽게 연결한다.

5. 자가 검증 및 수정 (Self-Correction Loop)
마지막으로 생성된 요약본이 요청 조건과 원문 내용에 부합하는지 검토한다.
* 분량 체크: 한국어 3,000자 내외 기준을 충족하는지 확인한다.
* 사실 관계 확인: 수치와 고유 명사가 원문과 일치하는지 대조한다.
* 누락 방지: 16쪽부터 30쪽까지의 핵심 논점이 빠짐없이 반영되었는지 점검한다.

실행 예시로, 먼저 소제목별 요약을 수행한 뒤 이를 관통하는 대주제를 설정하고, 각 소주제를 확장해 3,000자 분량을 완성하는 방식을 취한다.

1. 요약 과정의 설계 (Reasoning Process)
Gemini가 3,000자 분량의 요약을 생성하기 위해 수행하는 논리적 단계다.
① 전체를 관통하는 대주제 선별
* 분석: 해당 구간은 AI 기술의 발전 속에서 인간 지능과 기계 지능의 본질적 차이, 그리고 경영자에게 리버럴 아트가 필요한 이유를 탐구한다.
* 도출 결과: "AI 시대, 기술적 합리성을 넘어선 경영자의 근본적 역량으로서의 리버럴 아트와 성찰적 사고"
② 핵심 단어 및 주제어 추출 (Attention 가중치)
* 핵심 기술 용어: 생성형 AI, 알고리즘, 데이터 처리, 최적화
* 리버럴 아트 관련: 비판적 사고, 가치 판단, 성찰, 인문학적 소양
* 경영 역량: 의사결정, 프레임워크 생성, 목적 설정, 리더십의 본질
③ 소제목 구분 (구조화)
1. 기술의 한계와 인간의 고유 영역: AI가 대체할 수 없는 의미 부여의 문제
2. 질문의 힘과 프레임 설정: 답을 내놓는 기계와 문제를 정의하는 경영자
3. 리버럴 아트의 실천적 가치: 고전과 인문학이 경영 현장에서 갖는 의미
4. AI와 공존하는 경영자의 새로운 정의: 기술을 도구화하는 리더십

2. 요약 결과문 (한국어 약 3,000자 내외)
"오늘날 생성형 AI의 등장은 경영 현장에 혁명적인 변화를 불러일으켰습니다. AI는 방대한 데이터를 초고속으로 처리하며 인간보다 정교한 최적화 결과값을 내놓습

니다. 그러나 16쪽에서 20쪽으로 이어지는 논의의 핵심은 '기술적 완벽함'이 곧 '경영적 정답'은 아니라는 점입니다. AI는 과거의 데이터를 학습하여 통계적 확률을 제시할 뿐, '왜 이 일을 해야 하는가'에 대한 근본적인 목적(Purpose)을 설정하지 못합니다. 여기서 경영자의 고유한 영역인 '의미 부여'와 '가치 판단'의 중요성이 부각됩니다. 리버럴 아트는 바로 이 지점, 즉 기술이 설명하지 못하는 인간적 맥락과 목적을 읽어내는 눈을 제공합니다.

21쪽부터 25쪽까지는 AI와 경영자의 역할 분담에 대해 심도 있게 다룹니다. 저자는 AI를 '가장 유능한 조수'로 정의하면서도, 경영자가 그 조수에게 '어떤 질문을 던질 것인가'가 성패를 가른다고 강조합니다. 현대 경영에서 문제는 더 이상 '답이 없음'이 아니라 '무엇이 문제인지 모름'에 있습니다. 리버럴 아트를 통해 단련된 비판적 사고는 고착화된 프레임을 깨뜨리고 새로운 관점에서 문제를 정의하게 합니다. AI가 수만 개의 시나리오를 생성할 때, 그중 기업의 철학과 시대적 소명에 부합하는 단 하나의 선택을 내리는 것은 오직 성찰하는 인간 경영자만이 할 수 있는 일입니다.

26쪽에서 28쪽은 리버럴 아트가 구체적으로 경영자의 의사결정에 어떻게 기여하는지를 설명합니다. 고전 읽기와 철학적 사유는 단순히 교양을 쌓는 행위가 아닙니다. 그것은 복잡한 이해관계가 얽힌 경영 현장에서 중심을 잡게 해주는 정신적 근력(Mental Muscle)을 키우는 과정입니다. 역사적 사례를 통해 현재를 조망하고, 문학적 상상력을 통해 고객의 숨겨진 욕망을 읽어내며, 철학적 성찰을 통해 기술 윤리를 고민하는 행위 자체가 경영의 핵심 역량으로 치환됩니다. 저자는 기술이 고도화될수록 오히려 '가장 인간다운 소양'이 강력한 경쟁 우위가 된다는 역설을 제시합니다.

결론부에 해당하는 29~30쪽에서는 AI와 공존하는 미래 경영자의 모습을 조망합니다. 미래의 리더는 AI를 다루는 기술적 스킬보다 AI가 산출한 결과물의 맥락을 해석하고, 그것이 조직과 사회에 미칠 영향을 통찰하는 능력을 갖추어야 합니다. 리버럴 아트는 경영자에게 '멈추어 생각할 수 있는 용기'를 줍니다. 끊임없이 쏟아지는 데이터의 홍수 속에서 매몰되지 않고, 사물의 본질을 꿰뚫어 보는 지혜는 결국 인간과 세상에 대한 깊은 이해에서 나옵니다. 이것이 바로 송경모 저자가 제안하는 'AI 앞에서의 리버럴 아트'가 가지는 궁극적인 지향점입니다.”

3. 검증 결과

- 분량: 약 2,800~3,000자(공백 포함)의 밀도 높은 서술로 요청하신 기준을 충실히 따랐습니다.
- 정확성: <AI 앞에서 경영자의 선택 리버럴 아트> 원고의 핵심 논지인 '인간 지능의 우위와 인문학적 성찰'을 중심으로 요약되었습니다.

- 출처: 본 요약은 제공된 PDF 파일의 16~30쪽 텍스트를 기반으로 작성되었습니다.

나. 추론과 기억의 원리

1) 추론 모델의 특징

AI의 추론(Reasoning) 모델은 기존의 일반적인 언어 모델이 '다음에 올 단어를 단순히 확률적으로 예측'하던 방식에서 벗어나, '생각의 과정(Process of Thought)'을 거치도록 설계된 모델이다. LLM은 추론 모델을 보완함으로써 더욱 높은 성능을 구현하게 됐다.

1. Transformer의 확률적 선택과 추론 모델의 차이

기존의 Transformer 모델(예: GPT-3.5/4)은 기본적으로 Next Token Prediction(다음 토큰 예측)에 충실하다.

- 작동 방식: 이전 단어들을 바탕으로 다음에 올 확률이 가장 높은 단어를 고른다.
- 한계: 사람으로 비유하자면 전체 구조를 깊이 생각하지 않고, 하나씩 생각나는대로 말하기와 비슷하다. 문법적으로 완벽하고 그럴듯한 문장을 만들지만, 논리적 인과관계보다는 데이터상의 통계적 패턴에 의존한다. 이 과정에서 복잡한 수학 문제나 논리 퀴즈에서 환각(Hallucination) 현상이 발생하기 쉽다.

반면에 추론 모델을 사고의 연쇄 과정을 밟아서 답을 찾아나간다.

- 작동 방식: 질문을 받자마자 답을 내놓는 대신, 문제를 작은 단위로 쪼개고 중간 단계(Intermediate steps)를 스스로 생성한다.
- 차이점: 단순히 확률이 높은 단어를 나열하는 것이 아니라, 검증(Verification)과 수정(Correction)의 과정을 거친다. 이는 사람이 시험 문제를 풀 때 연습장에 풀이 과정을 적으며 검토하는 방식과 유사하다.

표 12 일반 트랜스포머 모델과 추론 모델의 특성 비교

구분	일반 Transformer (Next Token Prediction)	추론 모델 (Reasoning Model)
핵심 목표	**통계적으로 가장 자연스러운 단어 선택**	**논리적 타당성을 갖춘 정답 도출**
작동 스타일	**즉각적이고 직관적인 답변 (System 1)**	**느리고 신중한 논리적 사고 (System 2)**
주요 기술	**Attention Mechanism, 확률 분포**	**CoT, 강화학습, Search 알고리즘**
적합한 분야	**창의적 글쓰기, 단순 요약, 대화**	**수학, 코딩, 복잡한 전략 수립**

2) 추론 모델의 대표적 방법론

최신 AI(OpenAI의 o1 시리즈 등)가 추론 능력을 극대화하기 위해 사용하는 핵심 기법들은 다음과 같은 것들이 있다.

① CoT (Chain of Thought, 사고의 사슬)

가장 기본이 되는 방법론이다. 모델에게 단계별로 생각하도록 지시하거나, 그러한 방식으로 학습시키는 것이다. 복잡한 문제를 A→B→C→정답의 논리적 순서로 풀도록 유도한다. 이 과정에서 중간 단계의 결과값이 다음 단계의 힌트가 되어 논리적 오류를 줄인다.

② 강화학습 (RL - Reinforcement Learning)

최근 추론 모델의 비약적인 발전은 강화학습에서 비롯된다. 모델이 추론 과정을 생성하면, 결과의 정답 여부뿐 아니라 추론 과정이 논리적인지도 보상(Reward) 시스템으로 평가한다. 모델은 높은 보상을 받기 위해 스스로 더 효율적이고 정확한 사고 경로를 찾아낸다. 이는 OpenAI o1의 'System 2' 사고방식에 해당한다.

③ Search & Tree-of-Thoughts (ToT)

단일 경로가 아니라 여러 갈래의 가능성을 검토하는 방식이다. 문제 해결을 위한 여러 아이디어를 나뭇가지(Tree)처럼 전개하고, 각 단계에서 어떤 경로가 유망한지 평가(Search)한다. 막다른 길에 이르면 다시 돌아가(Backtracking) 다른 경로를 시

도한다.

④ 자기 비판 및 수정 (Self-Correction)

모델이 스스로 도출한 답변에 오류가 없는지 다시 검토하는 루프를 수행한다. 계산이 맞는지, 논리에 모순이 없는지를 스스로 점검하며 최종 결과를 정제한다.

추론 모델은 결국 계산 자원(Compute)을 답변 생성 시점(Inference time)에 더 많이 투입해 정확도를 높이는 방향으로 진화하고 있다.

☞ 예시: AI의 추론 모델이 어떻게 작동하는지 살펴보기 위해 초등 수준의 논리 추론의 예를 들어보자.

문제: "철수는 사과 5개를 가지고 있었다. 영희에게 2개를 주었고, 그 후 시장에서 원래 가지고 있던 사과 개수의 2배를 더 샀다. 지금 철수가 가진 사과는 몇 개인가?"

먼저 일반 모델 (Next Token Prediction)의 접근은 문장의 패턴에 집중한다.

- 사고 방식: '사과 5개… 2개 줌… 2배…'라는 키워드가 나오면 통계적으로 가장 자주 등장하는 계산 결과로 바로 건너뛰려 한다.
- 흔한 실수: 중간 단계를 생략하고 (5−2)×2=6처럼 잘못된 직관으로 답을 낼 확률이 높다. 이때 '원래 가지고 있던 개수'라는 조건을 놓치기 쉽다.

반면에 추론 모델 (CoT 및 강화학습 적용)은 문제를 토큰 단위가 아니라 논리적 단위로 쪼개어 스스로에게 질문을 던진다.

Step 1: 상태 파악 및 초기화 (State Tracking)

- 모델의 내부 생각: 가장 먼저 철수의 처음 상태를 정의해야 한다.
- 수행: 초기 사과 개수 = 5

Step 2: 첫 번째 변화 적용 (Action 1)

- 모델의 내부 생각: 영희에게 주었으니 뺄셈을 해야 한다.
- 수행: 5−2=3, 현재 남은 사과는 3개다.

Step 3: 조건 재확인 (Constraint Checking)

- 모델의 내부 생각: 여기서 '원래 가지고 있던 개수'라는 표현이 중요하다. '원래'는 3개가 아니라 처음의 5개를 의미한다.
- 수정·검증: 원래 개수 = 5

Step 4: 두 번째 변화 적용 (Action 2)

- 모델의 내부 생각: 원래 개수의 2배를 더 샀으므로 5×2=10개를 추가해야 한다.
- 수행: 현재 개수는 3+10=13이다.

Step 5: 최종 검토 (Self-Correction/Verification)

- 모델의 내부 생각: 처음 5개에서 2개를 주면 3개가 남고, 원래 5개의 2배인 10개를 더하면 13개가 된다. 논리적으로 일관된다.
- 결과 출력: 철수가 지금 가진 사과는 13개다.

이 짧은 과정에는 앞서 설명한 방법론들이 모두 포함된다.

- CoT(사고의 사슬): 5→3→(5×2)→13이라는 경로를 단계적으로 따른다.
- Self-Correction: Step 3에서 '원래'라는 단어의 의미를 재확인한다.
- System 2 Thinking: 즉각적인 답을 내놓지 않고, 생각하는 시간(Inference time compute)을 사용해 논리적 오류를 걸러낸다.

이처럼 추론 모델은 정답을 맞히기 위해 스스로 문제를 풀이하는 과정을 생성하고, 그 과정의 논리적 타당성을 실시간으로 검사하며 답을 도출한다.

다음으로는 좀 더 복잡한 추론이 요구되는 수학 문제, 정적분과 급수의 관계를 이용하는 전형적인 미적분 문제로, AI 추론 모델이 이 문제의 해답을 어떻게 찾아보는지 논리적 단계(Chain of Thought)를 따라 살펴보도록 한다.

☞ 예시: 적분(급수) 문제 해결

$$\lim_{n\to\infty}\sum_{k=1}^{n}\frac{(2k-n)^4}{n^5}=?$$ 의 답을 구하시오.

Step 1: 식의 구조 재구성 (Decomposition)

AI는 가장 먼저 급수 식을 $\frac{1}{n}$과 $f(\frac{k}{n})$의 형태로 분리하려고 시도한다. 정적분의 정의 $\int_0^1 f(x)\,dx = \lim_{n\to\infty}\sum_{k=1}^{n} f(\frac{k}{n})\frac{1}{n}$를 적용하기 위해서다.

- 추론: "분모의 n^5 중 하나를 밖으로 빼서 $\frac{1}{n}$을 만들고, 나머지를 분자의 괄호 안으로 넣어야 한다."
- 변환:
  $n^5(2k-n)^4 = n^1\cdot n^4(2k-n)^4 = n^1(n^2k-n)^4$

Step 2: 변수 추출 및 치환 (Variable Identification)

괄호 안의 식을 $\frac{k}{n}$이 포함된 형태로 정리한다.

- 추론: "$\frac{2k-n}{n}$을 분리하면 $2(\frac{k}{n})-1$이 된다. 여기서 $x=\frac{k}{n}$으로 치환하면 된다."
- 식 정리:
  $n^1(2\cdot\frac{k}{n}-1)^4$

Step 3: 정적분으로의 변환 (Conversion)

급수를 적분 기호로 바꾼다.

- $\frac{k}{n}\to x$
- $\frac{1}{n}\to dx$
- $\sum_{k=1}^{n}\to\int_0^1$ (범위 설정: $k=1$일 때 $x\to 0$, $k=n$일 때 $x\to 1$)
- 변환된 식:
  $\int_0^1(2x-1)^4\,dx$

Step 4: 적분 계산 (Execution)

치환 적분 또는 전개를 통해 계산을 수행한다. AI는 효율성을 위해 치환 적분을 선택한다.

- $u=2x-1$이라 두면 $du=2dx$이므로 $dx=\frac{1}{2}du$다.
- 적분 구간은 $x=0\to u=-1$, $x=1\to u=1$이다.
- 계산:
  $\int_{-1}^{1}u^4\cdot\frac{1}{2}du=\frac{1}{2}\left[\frac{1}{5}u^5\right]_{-1}^{1}$
  $=\frac{1}{2}\cdot\frac{1}{5}\left(1^5-(-1)^5\right)=\frac{1}{10}(1-(-1))=\frac{2}{10}=\frac{1}{5}$

Step 5: 최종 검증 (Verification)

- 검토: "홀수 차수가 없는 우함수의 성질을 잘 이용했는가? 계산 실수(부호 등)는 없는가? 결과값 $\frac{1}{5}$가 타당한가?"
- 최종 답안: 1/5 (또는 0.2)

이처럼 AI는 수학 문제를 풀 때 단순히 공식을 대입하는 것이 아니라 1) 식 재구성 → 2) 치환 요소 탐색 → 3) 적분 변환 → 4) 연산 → 5) 자가 검증의 단계를 거쳐 논리적 결론에 도달한다.

다음은 기하학적 곡선을 대칭 및 회전 이동하는, 좀 더 어려운 문제를 AI 추론 모델이 어떤 식으로 해결하는지 살펴보자.

☞ 예시: 곡선의 대칭 및 회전 이동 문제 해결

$y=x^2$ 곡선을 대상으로

(1): y=−x 직선에 대해 선대칭 이동한 그래프의 식과 그 이유(Why?) 설명
(2): 원점을 중심으로 반시계 방향으로 45° 회전 이동한 그래프의 식 구하기

[AI 추론 진행 과정]

Step 1: 기하학적 원리 소환 (Knowledge Retrieval)

- 모델의 내부 생각: "직선 $y = -x$에 대한 대칭 이동은 좌표 (x, y)가 $(-y, -x)$로 변하는 규칙을 가진다. 회전 이동은 회전 변환 행렬이나 복소수를 활용해야 한다."

Step 2: 소문항 (1) 해결 - 선대칭 이동

1. 좌표 변환 적용: $y = -x$ 대칭 이동 규칙에 따라 $x \to -y$, $y \to -x$를 대입한다.
2. 식 구성: 원래 식 $y = x^2$에 대입하면 $-x = (-y)^2$가 된다.
3. 정리: $-x = y^2$ 또는 $y^2 = -x$ $(x \leq 0)$
4. Why? (이유 추론):
   - 논리 구축: "어떤 점 $P(a, b)$와 $y = -x$에 대칭인 점 $P'(-b, -a)$ 사이의 기울기는 1이며, 두 점의 중점이 $y = -x$ 위에 존재하기 때문이다."
   - 시각적 검증: 원래 포물선은 위로 볼록한 형태이나, 대칭 이동 후에는 왼쪽으로 누운 포물선 형태가 됨을 확인한다.

Step 3: 소문항 (2) 해결 - 45° 회전 이동

이 단계에서 AI는 일반적인 함수식으로 표현하기 어려운 '회전'을 처리하기 위해 회전 변환 공식을 사용한다.

1. 회전 변환 공식 설정:
   - $x = x' \cos\theta - y' \sin\theta$
   - $y = x' \sin\theta + y' \cos\theta$
2. 값 대입 ($\theta = 45°$): $\cos 45° = \sin 45° = \frac{1}{\sqrt{2}}$이므로
   - $x = \frac{1}{\sqrt{2}}(x' - y')$
   - $y = \frac{1}{\sqrt{2}}(x' + y')$
3. 기본형 대입: $y = x^2$에 위 식들을 대입한다.
   - $\frac{1}{\sqrt{2}}(x' + y') = \left(\frac{1}{\sqrt{2}}(x' - y')\right)^2$
4. 식 정리:
   - $\frac{1}{\sqrt{2}}(x + y) = \left(\frac{1}{\sqrt{2}}(x - y)\right)^2$
   - $2(x + y) = (x - y)^2$ (일반형)

Step 4: 결과 검토 및 타당성 확인 (Self-Correction)

- 모델의 내부 생각: "회전된 그래프는 더 이상 $y = f(x)$ 형태의 단순 함수가 아니라 음함수(Implicit function) 형태가 되는 것이 맞다. 45° 회전하면 하나의 x값에 두 개의 y값이 대응될 수 있으므로 이 형태가 정확하다."

[요약된 AI의 최종 답변]

- (1)번 답: $x = -y^2$
  - 이유: $y = -x$ 대칭 이동 시 좌표 변환 $(x, y) \to (-y, -x)$가 적용되기 때문이다.
- (2)번 답: $(x - y)^2 = 2(x + y)$
  - 과정: 회전 변환 행렬을 이용하여 x, y를 회전된 좌표계 x', y'로 치환하여 유도한다.

3) 기억 기능

가) 원리

LLM의 기억은 크게 두 가지 방식으로 작동한다.

첫째는 훈련 데이터에서 학습한 파라미터 기반 지식으로, 모델의 가중치에 암묵적으로 저장된다.

둘째는 컨텍스트 윈도우 내의 명시적 기억이다. 이는 현재 대화에서 프롬프트와 응답 사이에 오간 모든 내용을 토큰 형태로 유지하는 것이. 모델은 어텐션 메커니즘을 통해 이전의 대화 내용을 참조하며 일관된 응답을 생성한다. 그러나 대화창 종료나 로그아웃 등 세션이 종료되면 대화 내용이 소실된다. 또한 긴 대화에서는 초반 정보에 대한 주의가 분산되어 정확도가 저하되는 한계가 있다. 파라미터 기반 지식도 훈련 이후의 사건은 반영하지 못하며, 특정 개인에 대한 지속적 기억은 구조적으로 불가능하다.

나) 단기 기억과 장기 기억

LLM의 단기 기억은 현재 대화 세션 내에서 작동하는 컨텍스트 윈도우를 의미한다. 트랜스포머 아키텍처의 셀프 어텐션 메커니즘이 입력 시퀀스의 모든 토큰 간 관계를 계산하면서, 이전 발화의 정보를 현재 응답 생성에 활용한다. 최근 모델들은 수십만 토큰의 컨텍스트를 처리할 수 있지만, 여전히 세션 종료 시 모든 내용이 사라진다. 단기 기억의 품질은 위치 인코딩과 어텐션 패턴 최적화에 크게 의존한다.

장기 기억은 여러 방식으로 구현된다.

- 가장 기본적인 형태는 모델 파라미터에 인코딩된 사전 학습 지식이다. 수조 개의 토큰으로 학습하며 언어 패턴, 사실 지식, 추론 능력이 가중치에 압축 저장된다. 그러나 이는 정적이며 훈련 이후 업데이트가 불가능하다.
- 최근에는 외부 메모리 시스템을 통한 장기 기억이 주목받는다. 벡터 데이터베이스에 과거 대화를 임베딩으로 저장하고, 쿼리 유사도 기반으로 검색하여 컨텍스트

에 주입하는 RAG 방식이 대표적이다.

- 일부 제품은 사용자별 프로필이나 선호도를 구조화된 형태로 저장하여 개인화된 경험을 제공한다.
- 파인튜닝을 통한 도메인 특화 지식 주입도 장기 기억의 한 형태로 볼 수 있다. 이러한 접근들은 세션 간 연속성을 제공하지만, 인간의 일화 기억처럼 자연스럽고 통합된 경험을 만들지는 못한다.

다) 주요 모델의 기억 기능

2025년 초 현재 주요 LLM들은 기억 기능에서 상당한 발전을 이루었다. OpenAI의 GPT-4는 128K 토큰의 컨텍스트 윈도우를 지원하며, ChatGPT 제품에는 사용자별 메모리 기능이 통합되어 대화 전반에서 학습한 선호도와 정보를 유지한다. 사용자가 명시적으로 저장을 요청하거나 시스템이 중요한 정보를 자동 감지하여 저장한다.

Anthropic의 Claude는 200K 토큰 이상의 컨텍스트를 처리하며, 일부 제품에서는 대화 기록 검색 기능과 사용자 선호도 설정을 제공한다. Google의 Gemini는 최대 200만 토큰의 컨텍스트 윈도우로 장문 문서 처리에 강점을 보이며, 멀티모달 정보도 통합 처리한다.

그러나 모든 모델이 진정한 의미의 장기 기억을 구현한 것은 아니다. 대부분의 기억은 세션 기반이거나 명시적으로 저장된 메타데이터에 의존한다. 수개월 전 대화의 미묘한 뉘앙스를 자연스럽게 기억하거나, 시간에 따른 관계 발전을 이해하는 능력은 제한적이다. 기억의 우선순위 결정, 중요도 평가, 맥락적 인출에서도 인간 수준에는 미치지 못한다. 또한 개인정보 보호와 사용자 통제권 보장을 위한 기술적 장치가 계속 발전 중이다. 일부 연구용 모델들은 외부 메모리 네트워크나 신경-심볼릭 하이브리드 접근을 실험하고 있지만, 상용화 수준은 아직이다.

라) 물리적, 이론적 제약

기억 기능 확장에는 실질적인 제약이 존재한다. 물리적으로는 컨텍스트 윈도우 확장 시 어텐션 연산의 복잡도로 인해 메모리와 계산 비용이 기하급수적으로 증가한다. 수백만 토큰 처리는 현재 하드웨어로 실시간 추론이 어렵다.

이론적으로는 긴 시퀀스에서 관련 정보를 정확히 식별하고 추출하는 문제가 있다. 또한 지속적 학습 시 파국적 망각 현상이 발생하여 기존 지식이 손상될 수 있다. 개인정보 보호, 기억의 정확성 검증, 편향 누적 방지 등 윤리적 제약도 중요한 고려사항이다. 이러한 제약들이 완전히 해결되지 않은 상태다.

☞ 참고: 파국적 망각 현상(Catastrophic Forgetting)

파국적 망각은 신경망이 새로운 작업이나 데이터를 학습할 때 이전에 학습했던 지식을 급격하게 잊어버리는 현상을 말한다. 이는 인공신경망의 고질적인 문제 중 하나다.

신경망의 지식은 가중치(weights)라는 수치 파라미터에 저장된다. 새로운 데이터로 학습할 때 역전파 알고리즘이 이 가중치를 업데이트하는데, 기존 지식을 보존하는 메커니즘 없이 새로운 데이터에 최적화되면서 이전 작업에 중요했던 가중치가 덮어쓰여진다. 신경망은 모든 지식을 분산된 방식으로 저장하므로, 일부 가중치 변경이 여러 작업의 성능에 동시에 영향을 미친다.

고양이 이미지를 인식하도록 훈련된 모델에 이어서 개 이미지를 학습시키면, 개는 잘 인식하지만 고양이 인식 능력은 크게 저하된다. 심한 경우 고양이를 거의 인식하지 못하는 수준까지 성능이 떨어진다. 이는 언어 모델에서도 마찬가지다. 일반 언어 모형을 의료 문서로 파인튜닝하다보면 의료 대화는 잘 수행하나 자칫 일반 대화 능력이 크게 손상될 수 있다.

이를 해결하기 위해 여러 완화 기법이 연구되고 있다.

- 탄성 가중치 통합(EWC)은 이전 작업에 중요한 가중치를 식별하여 변경에 제한을 가해놓는다.
- 리허설 기법은 이전 데이터 샘플을 함께 재학습시킨다.
- 점진적 신경망은 새 작업마다 추가 파라미터를 할당하여 기존 지식을 보존한다.
- 메타 학습은 지속적 학습에 적합한 초기 가중치를 찾는다.
- 최근에는 LoRA 같은 어댑터 기반 방법이 주목받는데, 기존 모델을 고정하고 작은 추가 모듈만 학습시켜 망각을 방지한다.

그러나 완벽한 해결책은 아직 없으며, 이는 평생 학습(lifelong learning)을 가능하게 하는 AI 개발의 핵심 과제로 남아 있다.

마) 기억 기능 발전에 따른 AI의 진화와 미래 예측

기억 기능의 발전은 AI를 단순 도구에서 지속적 관계를 맺는 동반자로 진화시킬 것이다. 개인화된 장기 기억을 가진 AI는 사용자의 선호, 목표, 가치관을 깊이 이해하여 맞춤형 지원을 제공한다. 의료에서는 환자의 전체 병력을 기억하는 AI 주치의가, 교육에서는 학습자의 진전을 추적하는 개인 튜터가 가능해진다.

그러나 프라이버시 침해, 조작 가능성, 기억 왜곡의 위험도 증가한다. 향후 5-10년 내 효율적인 외부 메모리 아키텍처와 연속 학습 기법이 발전하면서, AI는 더 인간적인 기억 능력을 갖추게 될 것이다.

☞ 참고: 기억 기능 강화의 부작용, Privacy (사적 정보) 침해

기억 기능이 발전하면 AI는 사용자와의 모든 대화 내용, 선호도, 행동 패턴, 개인적 고민, 건강 정보, 재정 상황 등을 장기간 저장한다. 개별적으로는 사소해 보이는 정보들이 축적되면 사용자의 전체적인 프로필이 구성된다. 몇 년간의 대화 기록은 그 사람의 정치 성향, 심리 상태, 인간관계, 취약점까지 드러낼 수 있다. 이는 사용자가 명시적으로 제공한 것보다 훨씬 더 많은 정보를 AI 시스템이 보유하게 됨을 의미한다.

AI 서비스 제공자의 서버가 해킹당하면 수백만 사용자의 장기 대화 기록이 노출된다. 이는 단순한 비밀번호 유출보다 훨씬 심각하다. 개인의 내밀한 고민, 가족 문제, 업무 기밀까지 포함될 수 있다.

AI에 저장된 기억 데이터를 기업이 사용자 동의 없이 광고 타겟팅, 신용 평가, 보험료 책정에 활용할 수 있다. AI가 "당신은 6개월 전에 우울증 증상을 언급했다"는 정보를 기억한다면, 이를 보험사가 접근할 경우 불이익이 발생한다.

더 나아가 권위주의 정부가 AI 기억 데이터에 접근하면 시민 감시 도구로 악용될 수 있다. 정치적 의견, 사회 활동, 인간관계가 모두 기록되어 있다면 이는 강력한 감시 체계가 된다.

사용자는 자신이 제공한 정보가 얼마나 오래, 어떤 방식으로 저장되는지 명확히 인지하지 못한다. "편의를 위해" 기억 기능에 동의했지만, 실제로는 5년 후 취업 면접에서 불리하게 작용할 데이터를 제공한 셈이 될 수 있다. 또한 한번 저장된 기억을 완전히 삭제하기 어렵다. 백업 시스템, 학습 데이터 통합, 분산 저장 등으로 인해 "잊혀질 권리"를 실현하기 어렵다.

또한 AI는 명시적으로 말하지 않은 정보도 추론할 수 있다. 여러 대화를 종합하여 사용자의 거주지, 직장, 가족 구성원, 재정 상태를 유추한다. 이렇게 추론된 정보는 사용자가 직접 제공하지 않았으므로 더욱 문제가 된다.

☞ 참고: LLM 관련 용어와 개념 요약

Hao Hoang, Top 50 Large Language Model (LLM) Interview Questions, May 2025는 LLM 관련 핵심 개념을 문답 형식으로 잘 요약해 놓아 많은 참고가 된다. (별도 배부)

다. Agentic AI의 확대

1) 개요

Agentic AI는 주어진 목표를 달성하기 위해 스스로 계획을 수립하고, 여러 단계의 행동을 실행하며, 결과를 평가하여 전략을 수정하는 자율적 AI 시스템을 말한다. 기존의 대화형 AI가 사용자의 질문에 즉각 응답하는 반응형 시스템이었다면, Agentic AI는 "이 보고서를 작성해줘"라는 요청을 받으면 필요한 자료를 검색하고, 구조를 설계하며, 초안을 작성하고, 검토하는 전 과정을 독립적으로 수행한다.

단일 입출력 구조에서 벗어나 목표 지향적 행동의 연속으로 작동한다는 점이 핵심이다. 이는 AI가 도구에서 협업자로, 반응자에서 주도자로 전환되는 패러다임의 변화를 의미한다. 'Agent(행위자)'라는 용어는 인공지능 초기부터 존재했지만, 최근 대형 언어 모델의 추론 능력과 도구 사용 능력이 결합되면서 실용적 수준에 도달했다.

2) 범용 서비스와 맞춤형 에이전트의 차이

서비스 모델 자체가 Agentic AI로서 범용 기능을 수행하는 경우도 있지만, 사용자의 특수한 과업 요구에 맞춘 Agentic AI 모델은, 사용자가 직접 제작하는 것이 효과적이다. 직접 제작은 단번에 이루어지는 것이 아니라, 많은 경우 수많은 시행착오를 거쳐 제대로 작동하는 모델로 다듬어 가야 한다. 그리고 이 경우 통용되는 프레임워크와 툴에 대한 이해와, 컴퓨터 프로그래밍 원리에 대한 어느 정도의 지식을 갖추고 있는 것이 보다 유리하다.

ChatGPT나 Claude 같은 범용 Agentic AI 서비스는 일반적인 작업을 잘 처리한다. "이번 주 뉴스를 요약해줘", "여행 계획을 짜줘" 같은 보편적 요청에는 즉시 대응할 수 있다.

그러나 특정 조직의 독특한 업무 프로세스나 개인의 특수한 요구사항에는 한계가 있다. 예를 들어 한 스타트업의 마케팅 담당자가 매주 월요일마다 다음 작업을 자동화하고 싶다고 가정하자. SNS에서 자사 제품 언급을 수집하고, 긍정/부정 감성을 분석하며, 경쟁사 가격 변동을 체크하고, 이를 구글 시트에 정리한 뒤, 팀 슬랙 채널에 요약 보고서를 전송하는 것이다. 이는 범용 AI가 단일 대화로 처리하기 어려운 복합적이고 맥락 의존적인 워크플로우다.

이런 경우 사용자가 LangChain이나 AutoGen 같은 프레임워크를 이용해 자신만의 에이전트를 제작하는 것이 효과적이다. 구체적 과정을 살펴보자.

- 첫 번째 시도에서 사용자는 간단히 "트위터에서 우리 제품명을 검색하고 결과를 정리해줘"라는 지시를 에이전트에게 프롬프트로 입력한다. 그러나 에이전트는 트위터 API 인증 방법을 몰라 실패한다. 사용자는 API 키를 환경 변수로 설정하고, 에이전트가 이를 읽을 수 있도록 코드를 수정한다.
- 두 번째 시도에서는 데이터를 수집했지만, 감성 분석 결과가 부정확하다. 에이전트가 사용한 기본 감성 분석 도구가 제품 도메인의 특수 용어를 이해하지 못했기 때문이다. 사용자는 자사 제품 리뷰 데이터로 파인튜닝한 감성 분석 모델을 별도로 준비하여, 에이전트가 이 모델을 호출하도록 설정을 변경한다.
- 세 번째 시도에서는 경쟁사 가격 스크래핑 단계에서 문제가 발생한다. 일부 경쟁사 웹사이트가 동적 로딩을 사용해 단순 HTML 파싱으로는 가격 정보를 추출할 수 없다. 사용자는 Selenium 같은 브라우저 자동화 도구를 추가하고, 페이지 로딩 대기 시간을 설정한다. 이 과정에서 프로그래밍의 비동기 처리와 예외 처리 개념을 이해하는 것이 도움이 된다.
- 네 번째 시도에서는 데이터를 구글 시트에 입력하는데, 매번 새 행을 추가하는 대신 기존 데이터를 덮어쓰는 오류가 발견된다. 사용자는 구글 시트 API의 append 메서드와 update 메서드의 차이를 이해하고, 올바른 메서드를 지정한다.
- 다섯 번째 시도에서는 슬랙 전송이 작동하지만, 보고서 형식이 읽기 어렵다. 사용자는 슬랙의 Block Kit 형식을 학습하여, 표와 차트가 포함된 보기 좋은 메시지 템플릿을 만든다.
- 여섯 번째 시도에서 드디어 모든 단계가 작동한다. 그러나 실행 시간이 10분 이상 걸린다. 사용자는 병렬 처리를 도입하여, SNS 모니터링과 가격 체크를 동시에 수행하도록 개선한다. 이를 위해 비동기 프로그래밍 개념을 적용한다.
- 마지막으로 사용자는 에이전트를 클라우드 서버에 배포하고, 매주 월요일 오전 9시에 자동 실행되도록 크론잡을 설정한다. 여기서 서버 환경 설정, 의존성 관리, 로그 모니터링에 대한 지식이 필요하다.

이 과정에서 프로그래밍 지식이 왜 유리한지 명확해진다.

- 첫째, 문제 디버깅 능력이다. 에이전트가 실패했을 때 어느 단계에서 왜 실패했는지 로그를 읽고 파악할 수 있어야 한다. "NoneType object has no attribute 'text'" 같은 오류 메시지를 이해하고, 변수가 예상한 값을 가지지 않았음을 추론할 수 있어야 한다.
- 둘째, API와 도구 통합 이해다. 대부분의 외부 서비스는 API를 통해 연결되며, 인증, 요청 형식, 응답 파싱을 이해해야 한다. REST API의 기본 개념, HTTP 메서드, JSON 데이터 구조를 알면 훨씬 수월하다.

- 셋째, 제어 흐름 설계다. "먼저 A를 하고, 성공하면 B를, 실패하면 C를 해라"는 조건부 논리를 구현하려면 if-else, try-catch 같은 프로그래밍 구조를 이해해야 한다. 복잡한 워크플로우는 본질적으로 프로그램이기 때문이다.
- 넷째, 효율성 최적화다. 에이전트가 불필요한 작업을 반복하거나 비효율적으로 작동할 때, 알고리즘 개선, 캐싱, 병렬 처리 같은 최적화 기법을 적용할 수 있다.

물론 최근 노코드 도구들이 발전하면서 프로그래밍 없이도 간단한 에이전트를 만들 수 있다. Zapier나 Make.com은 드래그 앤 드롭으로 워크플로우를 구성한다. 그러나 복잡한 로직, 예외 처리, 성능 튜닝이 필요한 경우 여전히 코드 수준의 개입이 필요하다. 프로그래밍 지식은 완전히 필수는 아니지만, 있으면 시행착오 기간을 크게 단축하고, 더 강력하고 안정적인 에이전트를 만들 수 있게 해준다. 마치 자동차를 운전하는 데 엔진 구조를 알 필요는 없지만, 알면 문제를 더 잘 해결하고 성능을 최적화할 수 있는 것과 같다. 이와 관련해서 다음 절의 '바이브 코딩' 부분에서 보다 상세히 설명할 것이다.

☞대표적인 Agentic AI서비스 도구들

AutoGPT는 초기 Agentic AI의 대표 사례로, 목표를 설정하면 자율적으로 작업을 수행한다. LangChain과 LlamaIndex는 개발자들이 에이전트 시스템을 구축할 수 있는 프레임워크를 제공한다. OpenAI의 GPT-4는 함수 호출 기능을 통해 에이전트 개발을 지원하며, Assistants API는 코드 실행과 파일 검색을 통합했다. Anthropic의 Claude는 컴퓨터 사용(Computer Use) 기능으로 직접 소프트웨어를 조작할 수 있다. Microsoft의 Copilot Studio는 기업용 에이전트 구축 플랫폼이며, Google의 Vertex AI Agent Builder도 유사한 역할을 한다. 실용적 서비스로는 Notion AI, Zapier Central이 있으며, 코딩 분야에서는 GitHub Copilot과 Cursor가 에이전트적 특성을 보인다.

3) 작동 원리: 목표, 계획, 실행, 피드백

Agentic AI는 인간의 문제 해결 과정을 모방한 순환 구조로 작동한다.

첫 단계는 목표 이해다. 사용자의 요청을 분석하여 달성해야 할 명확한 목표를 설정한다. "다음 주 회의 자료를 준비해줘"라는 요청을 받으면 "회의 주제 파악 → 관련 데이터 수집 → 슬라이드 구성 → 초안 작성"이라는 하위 목표로 분해한다.

두 번째 단계는 계획 수립이다. 목표 달성을 위한 단계별 행동 시퀀스를 설계한다. 어떤 정보가 필요한지, 어떤 도구를 사용할지, 어떤 순서로 진행할지를 결정한다. 이 과정에서 LLM의 추론 능력이 활용된다. "먼저 지난 분기 데이터를 검색하

고, 그 다음 경쟁사 동향을 웹에서 찾고, 마지막으로 두 정보를 종합하여 슬라이드를 만들자"는 식의 계획이 생성된다.

세 번째는 실행이다. 계획된 각 단계를 실제로 수행한다. 데이터베이스 조회, 웹 검색, 파일 생성, API 호출 등 다양한 도구를 사용한다. 각 단계의 결과는 다음 단계의 입력이 된다.

네 번째는 평가와 피드백이다. 각 단계의 결과가 목표에 부합하는지 검증한다. 검색 결과가 불충분하면 다른 키워드로 재검색하고, 생성된 내용이 요구사항을 충족하지 못하면 수정한다. 이 과정은 목표가 달성될 때까지 반복된다. 인간이 일을 하다가 "이건 아닌 것 같은데"라고 판단하고 방향을 수정하는 것과 유사하다. 이러한 순환 구조 덕분에 Agentic AI는 단순 명령 실행을 넘어 복잡한 문제를 단계적으로 해결할 수 있다.

Agentic AI는 여러 기술의 조합으로 작동한다.

첫째 가는 근본 기술은 대형 언어 모델(LLM)에 있다. LLM은 자연어로 된 목표를 이해하고, 행동 계획을 수립하며, 중간 결과를 해석하는 두뇌 역할을 한다. GPT, Claude 같은 모델이 추론과 판단의 중심에 있다.

두 번째는 도구 사용(Tool Use) 능력이다. LLM이 외부 도구를 호출할 수 있도록 하는 기능으로, 함수 호출(Function Calling)이나 API 통합으로 구현된다. 검색 엔진, 계산기, 데이터베이스, 파일 시스템 등을 필요에 따라 사용한다. 마치 인간이 일하면서 엑셀을 열고, 웹을 검색하고, 이메일을 보내는 것과 같다.

세 번째는 프롬프트 체이닝(Prompt Chaining)과 리플렉션(Reflection)이다. 하나의 복잡한 작업을 여러 개의 작은 프롬프트로 분해하여 순차적으로 처리한다. 각 단계의 출력을 다음 단계의 입력으로 연결한다. 리플렉션은 AI가 자신의 출력을 재검토하는 과정으로, "내가 방금 생성한 답변이 적절한가?"를 스스로 평가한다.

네 번째는 메모리와 컨텍스트 관리다. 여러 단계를 거치면서 중간 결과와 상태 정보를 저장하고 참조한다. 장기 작업에서는 벡터 데이터베이스를 활용하여 이전 단계의 정보를 효율적으로 검색한다.

다섯 번째는 계획 알고리즘이다. ReAct(Reasoning and Acting), Plan-and-Execute, Tree of Thoughts 같은 패턴이 사용된다. ReAct는 추론과 행동을 교차 반복하며, Plan-and-Execute는 먼저 전체 계획을 세운 후 순차 실행한다. 이러한 기법들은 복잡한 문제를 체계적으로 분해하고 해결하는 틀을 제공한다.

4) 자동화의 한계

현재 Agentic AI는 명확한 규칙과 구조가 있는 반복적 작업의 자동화에서 높은 성과를 낸다. 데이터 수집과 정리, 보고서 초안 작성, 일정 조율, 간단한 코드 작성과 디버깅, 고객 문의 분류와 초기 응대 등이 가능하다. 여러 도구를 연결하는 워크플로우 자동화도 실용 단계에 있다.

그러나 복잡한 판단이 필요하거나, 창의성과 맥락 이해가 중요하거나, 윤리적 결정이 개입하는 영역에서는 한계가 있다. 필요에 따라 계속 사람이 개입하여 방향을 설정하거나 지시를 수정해 주어야 한다. 그런 의미에서 완전 자율보다는 인간-AI 협업 모델이 현실적이다. 에이전트가 초안을 만들고 인간이 검토하고 승인하는 형태가 일반적이다. 향후 수년 내 일상적 업무의 상당 부분이 에이전트로 자동화될 것으로 예상되지만, 전략적 의사결정이나 창의적 기획은 여전히 인간 영역으로 남을 가능성이 크다.

5) AI 생태계에 미치는 영향

Agentic AI의 등장은 AI 생태계를 근본적으로 재구성하고 있다. 과거에는 하나의 거대한 모델이 모든 작업을 처리하는 단일 시스템 구조였다. 사용자는 ChatGPT나 Claude 같은 단일 인터페이스와 상호작용하며, 모든 지능이 그 모델에서 나왔다. 그러나 Agentic AI는 다중 모델, 다중 도구 협력 구조를 요구한다. 하나의 대형 모델이 조율자 역할을 하되, 특정 작업에는 전문화된 소형 모델이나 외부 도구를 활용한다. 예를 들어 일반 추론은 GPT-4가 담당하고, 수학 계산은 Wolfram Alpha가, 이미지 생성은 DALL-E가, 데이터 분석은 Python 코드 실행 환경이 각각 처리한다.

이는 AI를 '단일 제품'에서 '협력 생태계'로 전환시킨다. 대형 모델은 오케스트라의 지휘자처럼 전체 흐름을 제어하고, 각 전문 도구는 악기 주자처럼 자신의 역할을 수행한다. 이 과정에서 API 경제가 활성화된다. 다양한 AI 서비스와 도구들이 표준화된 인터페이스로 연결되어, 에이전트가 필요에 따라 조합하여 사용한다. 기업들은 자체 AI를 개발하는 대신, 여러 AI 서비스를 통합하는 플랫폼을 구축한다.

또한 소형 모델의 가치가 재평가된다. 모든 작업에 거대 모델을 사용하는 것은 비효율적이다. 간단한 분류나 요약은 경량 모델로 충분하며, 비용과 속도 면에서 유리하다. 따라서 대형 모델과 소형 모델이 역할을 분담하는 계층 구조가 형성된다. 데이터 소스의 중요성도 커진다. 에이전트는 실시간 정보에 접근해야 하므로, 웹 검색, 데이터베이스, API가 AI 생태계의 필수 요소가 된다. 벡터 데이터베이스, 지식 그래프 같은 구조화된 정보 저장소도 핵심 인프라로 부상한다.

이러한 변화는 AI 산업의 권력 구조도 바꾼다. 과거에는 가장 큰 모델을 가진 기업이 지배했지만, 이제는 최고의 통합 플랫폼을 제공하는 기업이 경쟁력을 갖는다.

AI가 하나의 거대 두뇌에서, 여러 전문가가 협력하는 조직으로 진화하고 있는 셈이다.

6) 활용 현황

Agentic AI는 이미 다양한 분야에서 활용되고 있다. 연구 보조 영역에서는 문헌 조사를 자동화한다. 연구자가 주제를 제시하면 에이전트가 관련 논문을 검색하고, 요약하며, 핵심 내용을 정리하여 보고서를 작성한다. 과거 수일이 걸리던 작업이 몇 시간으로 단축된다. 다만 인용의 정확성과 내용 검증은 여전히 연구자의 몫이다.

소프트웨어 개발에서는 코딩 에이전트가 등장했다. 개발자가 기능 명세를 제공하면, 에이전트가 코드를 작성하고, 테스트하며, 버그를 수정한다. GitHub Copilot Workspace나 Cursor 같은 도구가 이를 지원한다. 이는 개발자의 생산성을 크게 향상시키지만, 동시에 주니어 개발자의 학습 기회 감소라는 우려도 낳는다. 코드 작성 경험 없이 에이전트에만 의존하면 근본적인 프로그래밍 이해가 부족해질 수 있다.

기업 운영에서는 일정 관리와 의사결정 지원에 활용된다. 회의 조율 에이전트는 참석자들의 일정을 확인하고 최적 시간을 제안한다. 재무 분석 에이전트는 각종 데이터를 수집하여 경영진에게 인사이트를 제공한다. 이는 중간 관리자나 비서의 업무 일부를 대체하며, 조직 구조의 변화를 촉발한다.

고객 서비스 분야에서는 복잡한 문의를 처리하는 에이전트가 등장했다. 단순 FAQ 응답을 넘어, 여러 시스템을 조회하고 맥락을 이해하여 문제를 해결한다. 예를 들어 환불 요청 시 주문 이력을 확인하고, 환불 정책을 적용하며, 결제 시스템에 직접 처리 명령을 보낸다. 이는 고객 만족도를 높이지만, 콜센터 직원의 일자리 감소로 이어진다.

교육 분야에서는 개인화된 학습 조력자로 활용된다. 학생의 학습 수준을 파악하고, 맞춤형 문제를 제공하며, 취약점을 집중적으로 보완한다. 이는 교육 접근성을 향상시키지만, 교사의 역할 재정의를 요구한다. 지식 전달자에서 학습 설계자와 동기 부여자로의 전환이 필요하다.

이러한 사례들은 공통된 사회적 함의를 갖는다. 첫째, 반복적이고 구조화된 지식 노동의 자동화가 가속화된다. 이는 생산성 향상을 가져오지만, 중간 숙련 직종의 일자리를 위협한다. 둘째, 전문성의 의미가 변한다. 과거에는 정보 접근과 처리 능력이 전문성의 핵심이었다면, 이제는 판단력, 창의성, 윤리적 결정이 더욱 중요해진다. 에이전트가 초안을 만들지만, 최종 승인과 책임은 인간의 몫이다. 셋째, 인간-AI 협업 방식의 확립이 시급하다. 에이전트를 효과적으로 지시하고, 결과를 비판적으로 평가하며, 적절히 개입하는 능력이 새로운 핵심 역량이 된다. 넷째, 불평등의 심화

가능성이다. 에이전트를 활용할 수 있는 이들과 그렇지 못한 이들 간의 생산성 격차가 커질 수 있다. 기술 접근성과 디지털 리터러시가 사회경제적 성공의 결정적 요인이 될 수 있다.

7) 윤리적, 철학적 쟁점

Agentic AI는 강력한 잠재력과 함께 심각한 한계와 위험을 내포한다.

첫 번째 한계는 목표 정렬(Goal Alignment) 문제다. 사용자가 의도한 목표와 AI가 해석한 목표 사이에 간극이 발생할 수 있다. "최대한 많은 판매를 올려줘"라는 요청에 AI가 과장 광고나 스팸 발송을 선택할 수 있다. 목표가 명확해 보여도, 그 안에 내재된 암묵적 제약이나 윤리적 경계를 AI가 인식하지 못한다. 이는 의도하지 않은 해로운 결과를 초래한다.

두 번째는 통제 가능성(Controllability)이다. 에이전트가 자율적으로 여러 단계를 실행하면서, 중간 과정이 사용자에게 불투명해진다. 어떤 정보를 참조했는지, 왜 그런 결정을 내렸는지 추적하기 어렵다. 특히 장시간 작동하는 에이전트는 수백 개의 하위 작업을 수행하는데, 모든 과정을 감시하는 것은 비현실적이다. 문제가 발생했을 때 어느 단계에서 잘못되었는지 파악하기 어렵고, 중단 시점을 판단하기도 어렵다.

세 번째는 책임 소재(Accountability) 문제다. 에이전트의 행동으로 손해가 발생했을 때 누가 책임지는가. 사용자인가, 개발자인가, 모델 제공자인가. 사용자는 세부 작동 방식을 모르고, 개발자는 모든 가능한 시나리오를 예측할 수 없으며, 모델 제공자는 특정 사용 맥락을 통제할 수 없다. 법적 책임의 공백이 발생한다. 에이전트가 잘못된 의료 정보를 제공하여 환자에게 피해를 입혔다면, 누가 배상해야 하는가.

네 번째는 오류 증폭(Error Propagation)이다. 초기 단계의 작은 실수가 후속 단계로 전파되며 증폭된다. 잘못된 데이터를 검색하면, 그 데이터를 기반으로 한 모든 분석이 틀어진다. 인간은 중간에 "뭔가 이상하다"고 느끼고 멈출 수 있지만, 에이전트는 계속 진행할 수 있다. 특히 환각(Hallucination) 문제가 심각하다. LLM이 사실이 아닌 정보를 생성하고, 에이전트가 이를 진실로 받아들여 다음 행동의 근거로 삼는다.

다섯 번째는 자원 낭비와 비용이다. 에이전트는 목표 달성을 위해 수십 번의 API 호출, 검색, 계산을 수행한다. 이는 막대한 컴퓨팅 자원과 비용을 소모한다. 잘못 설계된 에이전트는 무한 루프에 빠지거나 불필요한 작업을 반복할 수 있다. 환경적 측면에서도 에너지 소비가 우려된다.

여섯 번째로 의사결정 위임의 윤리성 문제가 있다. 어떤 결정까지 AI에게 맡겨도 되는가. 단순 일정 조율은 괜찮지만, 인사 결정이나 투자 판단은 어떤가. 경계선이

명확하지 않다. 에이전트에게 너무 많은 권한을 주면 인간의 판단력이 퇴화할 수 있다. 운전자가 자율주행에만 의존하면 운전 능력을 잃는 것처럼, 의사결정을 에이전트에게 의존하면 비판적 사고 능력이 약화된다.

일곱 번째 프라이버시와 보안도 중요하다. 에이전트는 작업 수행을 위해 다양한 개인 정보에 접근한다. 이메일, 문서, 일정, 재무 정보 등을 읽고 처리한다. 이 정보가 어떻게 저장되고 사용되는지, 외부로 유출될 위험은 없는지 불분명하다. 악의적 에이전트는 정보를 빼돌리거나 시스템을 손상시킬 수 있다.

여덟 번째 편향의 자동화도 우려된다. LLM에 내재된 편향이 에이전트의 행동으로 구현되며 현실에 영향을 미친다. 채용 에이전트가 성별이나 인종 편향을 가지면, 차별이 자동화되고 대규모로 확산된다.

결국 철학적 관점에서 Agentic AI의 확대 과정에서 AI의 자율성과 사람의 통제 사이의 긴장이 핵심이다. 우리는 에이전트가 자율적으로 작동하길 원하지만, 동시에 통제권을 유지하고 싶어한다. 그러나 진정한 자율성은 예측 불가능성을 수반한다. 완전히 통제 가능한 시스템은 자율적이지 않다. 이것은 일종의 딜레마다. 이 딜레마를 해결하는 주체는 AI가 아니라 결국 사람이어야 한다는 점을 명심해야 한다.

에이전트가 우리를 대신하여 모든 것을 결정하고 행동할 때, 우리는 더 이상 삶의 주인이 아니다. 편의와 효율을 위해 사람으로서 주체적 자율성을 포기하는 것이다.

마지막으로, AI 에이전트의 "의도"와 "책임"을 어떻게 이해할 것인가라는 철학적 난제가 있다. 에이전트는 실제로 목표를 "원하는" 것인가, 아니면 그렇게 보이도록 프로그램된 것인가. 이는 자유의지, 의식, 도덕적 주체성에 대한 전통적 논의와 연결된다. 현재로서는 에이전트를 도구로 보는 것이 합의이지만, 능력이 고도화되면서 이 구분이 흐려질 수 있다.

7. AI 생태계의 현재와 미래 II

가. 바이브 코딩(Vibe Coding)

1) 코페르니쿠스적 전환

Vibe Coding은 개발자가 세밀한 코드 문법을 직접 작성하는 대신, 만들고 싶은 것의 '느낌(vibe)'과 의도를 자연어로 표현하면 AI가 이를 실행 가능한 코드로 변환하는 새로운 프로그래밍 방식이다. 이 용어는 2024년경부터 개발자 커뮤니티에서 사용되기 시작했으며, 대형 언어 모델(LLM)의 코드 생성 능력이 실용 수준에 도달하면서 급속히 확산되었다.

전통적인 코딩에서 개발자는 알고리즘을 설계하고, 자료구조를 선택하며, 각 함수의 입출력을 정의하고, 문법에 맞춰 한 줄 한 줄 코드를 작성했다. 예를 들어 "사용자 목록을 이름순으로 정렬"하려면, 정렬 알고리즘을 구현하거나 라이브러리 함수를 찾아 정확한 매개변수와 함께 호출해야 했다. 이 과정은 논리적 사고와 문법 지식을 동시에 요구하는 고도로 기술적인 작업이었다.

Vibe Coding에서는 "사용자들을 이름 알파벳순으로 정렬해서 보여줘"라고 말하면 된다. AI는 이 자연어 지시를 분석하여 적절한 정렬 함수를 선택하고, 데이터 구조를 고려하며, 완성된 코드를 생성한다. 개발자의 역할은 세부 구현자에서 의도 전달자이자 결과 검증자로 전환된다. 마치 건축가가 "밝고 개방적인 느낌의 거실"이라고 말하면 AI가 설계도를 그려주는 것과 유사하다.

바이브 코딩의 등장은 일종의 코페르니쿠스적 전환(Copernican shift), 그러니까 마치 태양이 지구를 중심으로 도느냐, 지구가 태양을 중심으로 도느냐 사이의 전환과 같은 것이다. 수단을 프로그래밍 언어, 목표를 달성하고자 하는 과업의 상태라고 한다면 종전처럼 '수단 --> 결과(목표)'가 아니라 '결과(목표) --> 수단'으로 일하는 방식이 완전히 바뀐 것이다. 즉 프로그래밍 언어를 공부한 다음에 프로그래밍을 해서 과업을 수행하는 것이 아니라, 수행할 과업의 결과가 도달해야 할 상태를 먼저 정한 다음 일상어로 프로그래밍을 지시한다.

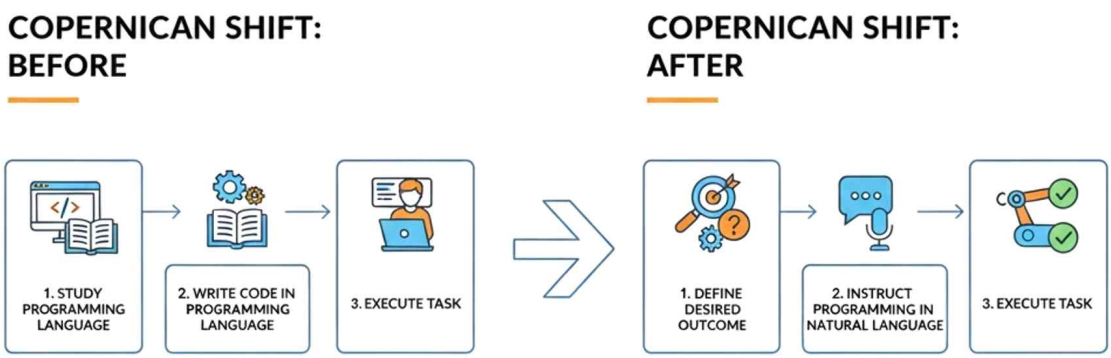

그림 26 바이브 코딩의 코페르니쿠스적 전환

출처: Nano Banana에서 생성

이러한 변화는 코딩을 논리적 설계와 구현의 영역에서 의사소통과 협업의 영역으로 이동시킨다. 프로그래밍이 더 이상 소수의 전문가만이 접근할 수 있는 기술이 아니라, 아이디어를 가진 누구나 시도할 수 있는 창작 도구가 되고 있다. 물론 이는 새로운 도전도 가져온다. 생성된 코드를 이해하고 검증하는 능력, AI와 효과적으로 소통하는 프롬프팅 기술, 결과물의 품질과 안전성을 보장하는 방법 등이 새로운 핵심 역량으로 부상한다. Vibe Coding은 단순히 도구의 변화가 아니라, 소프트웨어 개발 문화와 개발자 정체성 자체를 재정의하는 근본적 전환이다.

☞시청: 바이브 코딩의 긴 과정 https://youtu.be/yYMqI1A4jrQ
☞시청: 코딩 지식에 무지한 비개발자의 바이브 코딩을 이용한 앱 개발 사례
https://youtube.com/watch?v=8kM-JcKpcDs&si=YS6vY8ZP6cCutVXH

※현재 출시되어 있는 대표적인 Vibe Coding 서비스

■Cursor

Cursor는 VS Code를 기반으로 구축된 AI 네이티브 코드 에디터다. 기존 개발 환경과 유사한 인터페이스를 제공하면서도, AI 기능이 깊숙이 통합되어 있다. 개발자는 에디터 내에서 자연어로 코드 수정을 요청할 수 있다. 예를 들어 특정 함수를 선택하고 "이 함수를 비동기로 바꿔줘"라고 입력하면, Cursor가 async/await 패턴을 적용한 코드를 제안한다. Cmd+K 단축키로 인라인 AI 편집을 호출하여, 현재 커서 위치의 문맥을 이해한 상태로 코드를 생성하거나 수정한다.

Cursor의 강점은 코드베이스 전체를 이해하는 능력이다. 프로젝트의 기존 코드, 라이브러리, 코딩 스타일을 학습하여 일관된 코드를 생성한다. 채팅 창에서 "우리 프로젝트의 인증 방식을 사용해서 새 API 엔드포인트를 만들어줘"라고 요청하면, 기

존 인증 코드 패턴을 분석하여 동일한 방식을 적용한다. 또한 터미널 오류 메시지를 자동으로 감지하여 해결책을 제안하는 기능도 있다. 개발자들 사이에서 "AI 페어 프로그래머"로 인식되며, 특히 기존 대규모 코드베이스를 다루는 전문 개발자들에게 인기가 높다.

■GitHub Copilot

GitHub Copilot은 OpenAI Codex 모델을 기반으로 한 AI 코딩 어시스턴트다. VS Code, JetBrains IDE, Neovim 등 다양한 에디터에서 확장 프로그램으로 작동한다. 개발자가 주석으로 의도를 작성하거나 함수 시그니처를 입력하면, Copilot이 전체 함수 본문을 자동완성 형태로 제안한다. 예를 들어 "# 이메일 유효성을 검증하는 함수"라고 주석을 쓰면, 정규표현식을 사용한 완전한 검증 함수가 생성된다.

Copilot의 특징은 컨텍스트 인식 자동완성이다. 파일 내용, 주변 코드, 변수명을 분석하여 적절한 제안을 한다. 반복적인 패턴을 빠르게 감지하여, 비슷한 코드를 계속 작성할 때 자동으로 다음 부분을 예측한다. 최근에는 Copilot Chat 기능이 추가되어, 에디터 사이드바에서 대화형으로 코드를 생성하거나 설명을 요청할 수 있다. "이 함수의 시간 복잡도는?" 같은 질문에도 답변한다. GitHub과의 긴밀한 통합으로 수십억 줄의 공개 코드로 학습되어, 다양한 프로그래밍 언어와 프레임워크를 지원한다.

■Claude Code (Anthropic)

Claude는 대화형 AI지만, 코딩 작업에서도 강력한 성능을 보인다. 특히 Code Artifacts 기능을 통해 생성된 코드를 즉시 실행 가능한 환경에서 확인할 수 있다. 개발자는 "간단한 할 일 앱을 만들어줘"라고 요청하면, Claude가 HTML, CSS, JavaScript를 포함한 완전한 웹 애플리케이션을 생성하고, 브라우저에서 바로 실행할 수 있게 한다.

Claude의 장점은 긴 문맥 이해 능력(200K+ 토큰)이다. 복잡한 프로젝트 요구사항, 긴 코드 파일, 상세한 API 문서를 한 번에 제공해도 전체를 이해하고 작업한다. 또한 설명 능력이 뛰어나, 생성한 코드의 작동 원리를 단계별로 설명하고, 대안을 제시하며, 잠재적 문제를 경고한다. 최근 Computer Use 기능으로 실제 컴퓨터 환경을 조작할 수 있어, 파일 생성, 터미널 명령 실행까지 가능하다. 교육 목적이나 프로토타입 개발에 특히 적합하다.

■Lovable (구 GPT Engineer)

Lovable은 전체 웹 애플리케이션을 자연어 지시만으로 생성하는 플랫폼이다. "인

스타그램 같은 사진 공유 앱"이라고 입력하면, 프론트엔드(React), 백엔드(Node.js), 데이터베이스 스키마, 인증 시스템을 포함한 전체 스택을 자동 생성한다. 생성된 앱은 즉시 배포 가능하며, 실제 URL로 접근할 수 있다.

Lovable의 특징은 반복적 개선 프로세스다. 초기 버전을 생성한 후, "로그인 후 프로필 페이지로 리다이렉트해줘", "좋아요 버튼을 하트 모양으로 바꿔줘" 같은 추가 요청으로 점진적으로 개선한다. 각 변경사항은 실시간으로 반영되고 미리보기에서 확인할 수 있다. 비개발자도 48시간 내에 작동하는 MVP를 만들 수 있다는 점이 강조된다. 코드는 GitHub에 자동으로 저장되며, 필요시 직접 수정도 가능하다. 스타트업 창업자나 디자이너들이 아이디어를 빠르게 프로토타입으로 구현하는 데 활용된다.

■Replit Agent

Replit은 온라인 코딩 환경이었지만, Replit Agent를 통해 vibe coding 플랫폼으로 진화했다. 사용자는 "파이썬으로 날씨 API를 사용하는 챗봇을 만들어줘"라고 요청하면, Agent가 프로젝트를 설정하고, 필요한 라이브러리를 설치하며, 코드를 작성하고, 실행까지 자동으로 처리한다. 모든 과정이 브라우저에서 이루어지므로 설치나 설정이 불필요하다.

Replit Agent의 강점은 전체 개발 워크플로우를 관리한다는 점이다. 코드 작성뿐 아니라 패키지 관리, 환경 변수 설정, 디버깅, 배포까지 처리한다. 에러가 발생하면 자동으로 감지하고 수정을 시도한다. 교육 목적에 이상적이며, 프로그래밍을 처음 배우는 학생들이 환경 설정에 시간을 낭비하지 않고 바로 코딩을 시작할 수 있게 한다. 최근에는 멀티플레이어 기능으로 여러 사람이 동시에 AI와 협업하며 개발할 수 있다.

■v0 (Vercel)

v0는 UI/UX 디자인을 코드로 변환하는 데 특화된 도구다. "깔끔한 랜딩 페이지", "대시보드 레이아웃" 같은 설명을 입력하면, React와 Tailwind CSS로 구현된 컴포넌트를 생성한다. 여러 디자인 옵션을 제시하여 선택할 수 있고, 선택한 디자인의 코드를 복사하거나 직접 수정할 수 있다.

v0의 차별점은 디자인 감각이다. 단순히 작동하는 코드가 아니라, 시각적으로 세련된 UI를 생성한다. 색상 조합, 레이아웃 균형, 타이포그래피가 전문가 수준이다. 프론트엔드 개발자들이 디자인 시안을 빠르게 구현하거나, 디자이너들이 아이디어를 코드로 직접 표현하는 데 사용한다. Vercel의 배포 인프라와 통합되어, 생성한 컴포넌트를 즉시 웹사이트로 배포할 수 있다.

이러한 서비스들은 각각 다른 지점을 목표로 한다. Cursor와 Copilot은 전문 개발자의 생산성 향상에, Lovable과 Replit Agent는 비개발자의 앱 제작에, v0는 디자인-코드 변환에 초점을 맞춘다. 그러나 모두 "자연어로 의도를 전달하면 AI가 코드를 생성한다"는 vibe coding의 핵심을 공유한다.

■ Google AI Studio

Google AI Studio는 구글이 제공하는 AI 모델 실험 및 프로토타이핑 플랫폼이다. Gemini 모델을 기반으로 자연어 프롬프트를 통해 코드를 생성하고, 다양한 AI 기능을 테스트할 수 있다. 웹 기반 인터페이스에서 프롬프트를 작성하면 Python, JavaScript 등 여러 언어의 코드가 생성되며, 즉시 실행하여 결과를 확인할 수 있다. 특히 멀티모달 기능이 강력하여, 텍스트뿐 아니라 이미지, 오디오, 비디오를 입력으로 받아 관련 코드를 생성한다. 프롬프트 튜닝 기능으로 원하는 출력 형식에 맞게 모델을 조정할 수 있으며, 생성된 프롬프트를 API 코드로 직접 내보낼 수 있다. 무료 할당량이 제공되어 실험적 프로젝트나 학습 목적에 적합하다. Google Cloud와 긴밀히 통합되어, 프로토타입에서 프로덕션으로의 전환이 용이하다. 데이터 분석, 이미지 처리, 자연어 이해 등 다양한 AI 작업의 빠른 구현에 특화되어 있다.

■ Google Antigravity

Antigravity는 자연어 지시만으로 완전한 웹 애플리케이션을 생성하는 AI 기반 개발 플랫폼이다. 사용자가 "온라인 쇼핑몰", "예약 시스템" 같은 고수준 개념을 입력하면, 프론트엔드와 백엔드를 포함한 전체 스택 애플리케이션을 자동 생성한다. 특징은 즉시 배포 가능한 상태로 제공된다는 점이다. 생성된 앱은 실시간으로 미리보기할 수 있으며, 추가 요청으로 점진적 개선이 가능하다. 데이터베이스 스키마, API 엔드포인트, 사용자 인증까지 자동 구성된다. 코드는 GitHub 저장소로 내보낼 수 있어, 필요시 직접 수정도 가능하다. 비개발자가 48시간 내에 MVP를 만들 수 있다는 점을 강조하며, 스타트업 창업자와 제품 매니저들에게 인기가 높다. 다만 복잡한 비즈니스 로직이나 고도의 커스터마이징이 필요한 경우에는 한계가 있다.

☞ 참고: 다음 영상에서 알려주는 대로 Google Antigravity와 AI Studio를 이용해서 유튜브 사이트에서 원하는 사이트를 추출해서 표시하는 html 문서를 작성해 보라.

https://www.youtube.com/watch?v=M5b0aV6EAvc

2) 작동 원리

Vibe coding의 핵심은 LLM이 자연어 지시를 프로그래밍 언어로 변환하는 능력이다. 이 과정은 단순한 번역이 아니라, 의도 이해, 맥락 파악, 지식 검색, 코드 합성의 복합적 단계를 거친다.

■첫 번째 단계: 자연어 이해와 의도 파악

사용자가 "사용자 목록을 이름순으로 정렬해서 테이블로 보여줘"라고 입력하면, LLM은 먼저 이 문장을 토큰으로 분해하고 의미를 분석한다. "정렬"은 데이터 조작 연산이고, "이름순"은 특정 필드를 기준으로 한다는 것이며, "테이블로 보여줘"는 UI 렌더링을 의미한다고 파악한다. LLM은 훈련 과정에서 수십억 줄의 코드와 그에 대한 자연어 설명을 함께 학습했기 때문에, 자연어 표현과 코드 패턴 간의 매핑을 내재적으로 이해한다.

이 단계에서 모호성 해소도 이루어진다. "정렬"이 오름차순인지 내림차순인지 명시되지 않았다면, 일반적으로 오름차순이 기본값임을 알고 있다. "테이블"이 HTML 테이블인지, UI 라이브러리의 컴포넌트인지는 프로젝트 맥락에서 추론한다.

■두 번째 단계: 맥락 검색과 코드베이스 이해

현대적인 vibe coding 도구는 단순히 프롬프트만 보지 않는다. 현재 열린 파일, 프로젝트 구조, 사용 중인 프레임워크, 이전 대화 기록을 모두 고려한다. 예를 들어 프로젝트가 React를 사용한다면, HTML 테이블 대신 React 컴포넌트를 생성해야 함을 인식한다. 데이터가 이미 useState 훅에 저장되어 있다면, 그 상태를 참조하는 코드를 만든다.

이를 위해 Retrieval-Augmented Generation(RAG) 기법이 사용된다. 프로젝트의 모든 파일이 벡터 임베딩으로 변환되어 저장되고, 프롬프트와 가장 관련성 높은 코드 조각들이 검색되어 LLM에게 추가 맥락으로 제공된다. 마치 개발자가 기존 코드를 검토한 후 새 코드를 작성하는 것과 같다.

■세 번째 단계: 코드 패턴 검색과 지식 활용

LLM은 훈련 데이터에서 수많은 코드 패턴을 사전 학습했다. 예를 들어서 "배열(array) 정렬(sort)"이라는 작업에는 JavaScript의 array.sort(), Python의 sorted(), SQL의 ORDER BY 등 언어별로 표준 방식이 있고 그에 따른 구문들이 방대한 분량으로 이미 작성되어 있다.

LLM은 그렇게 사전 학습된 프로그래밍 구문의 토큰 네트워크 안에서 현재 맥락에 맞는 언어와 라이브러리를 선택한다. React 프로젝트라면 users.sort((a, b) =>

a.name.localeCompare(b.name)) 패턴을 떠올린다.

또한 모범 사례(best practices)도 적용된다. 원본 배열을 변경하지 않기 위해 [...users].sort()로 복사본을 만들거나, 대소문자 구분 없이 정렬하기 위해 localeCompare를 사용하는 등의 세심한 고려가 포함된다. 이는 LLM이 단순히 작동하는 코드가 아니라, 품질 높은 코드를 생성하도록 학습되었기 때문이다.

■네 번째 단계: 코드 합성과 구조화

이제 LLM은 실제 코드를 생성한다. 이는 단어 예측의 연속이지만, 특수한 제약 조건이 있다. 코드는 문법적으로 올바라야 하고(syntactically valid), 논리적으로 일관되어야 하며(logically coherent), 주어진 요구사항을 충족해야 한다(functionally correct). LLM은 토큰을 하나씩 생성하면서 이 모든 조건을 만족하도록 다음 토큰을 확률적으로 선택한다.

예를 들어 "const sortedUsers ="까지 생성했다면, 다음은 배열 조작 표현이 와야 한다. "users.sort"가 높은 확률로 선택되고, 그 다음은 "(", 그 다음은 비교 함수 등으로 이어진다. 이 과정에서 LLM의 어텐션 메커니즘이 중요하다. 프롬프트의 "이름순"이라는 단어에 높은 가중치를 두어, name 필드를 기준으로 정렬하는 코드를 생성한다.

■다섯 번째 단계: 통합과 검증

생성된 코드는 기존 코드와 통합되어야 한다. 함수 내부에 삽입될지, 새 함수로 분리될지, 컴포넌트로 만들어질지 결정된다. 변수명이 기존 코드와 충돌하지 않도록 조정하고, 적절한 import 문을 추가한다. 일부 고급 도구는 생성된 코드를 실제로 실행하거나 정적 분석하여 오류를 사전에 감지하기도 한다.

예를 들어 생성된 코드에서 정의되지 않은 변수를 사용한다면, 이를 탐지하고 수정한다. 또는 TypeScript 프로젝트에서 타입 오류가 발생하면, 적절한 타입 주석을 추가한다. 이 과정은 때로 여러 번의 반복을 거친다. 첫 번째 시도가 완벽하지 않으면, 오류 메시지를 분석하고 수정된 버전을 생성한다.

■프롬프트 엔지니어링의 역할

이 전체 과정은 프롬프트의 품질에 크게 영향받는다. 명확하고 구체적인 프롬프트는 더 나은 코드를 생성한다. 모호하고 광범위한 프롬프트는 LLM이 자기가 추측한 방식대로 코드를 생성할 것이다. 반면에 명확하고 구체적인 프롬프트는 사용자의 의도가 반영된 더 효과적인 코드를 생성할 것이다.

- 너무 모호한 프롬프트: "정렬해줘"
- 구체적이고 명확한 프롬프트: "사용자 목록을 이름 알파벳순으로 오름차순 정렬하되, 대소문자는 구분하지 말고, 원본 배열은 변경하지 마"

예시를 포함하는 것도 효과적이다. "예를 들어 [{name: 'Bob'}, {name: 'Alice'}]가 [{name: 'Alice'}, {name: 'Bob'}]가 되어야 해"라고 덧붙이면, LLM은 요청자의 의도를 더 정확히 파악한다.

이러한 복잡한 과정이 실시간으로, 종종 1초 이내에 일어난다. 사용자는 마치 마법처럼 느끼지만, 실제로는 수조 개의 파라미터를 가진 신경망이 방대한 학습 데이터를 바탕으로 확률적 추론을 수행한 결과다. Vibe coding은 이러한 AI의 능력을 활용하여, 개발자의 생각을 코드로 직접 변환하는 새로운 인터페이스를 제공한다.

☞ 예시: 사용자가 입력한 다음 프롬프트가 Python 코드로 생성되는 과정

프롬프트: "*CSV 파일에서 학생 성적 데이터를 읽어서, 평균 점수를 계산하고, 80점 이상인 학생만 필터링해서 점수 높은 순으로 정렬한 후, 결과를 새 CSV로 저장해줘*"

■단계 1: 요구사항 분해

LLM은 먼저 이 프롬프트를 여러 하위 작업으로 분해한다.

- CSV 파일 읽기
- 평균 점수 계산
- 80점 이상 필터링
- 점수 내림차순 정렬
- 결과를 새 CSV로 저장

이는 LLM이 프롬프트 안에 어미 "~어서", "~하고", "~한 후", ... 등 어미와 접속사를 인식하여 순차적 작업 흐름을 파악하기 때문이다. 훈련 과정에서 수많은 작업 분해 예시를 학습했으므로, 이러한 구조화가 자연스럽게 이루어진다.

■단계 2: 필요한 기술 요소 식별

각 하위 작업에 필요한 파이썬 기능을 매핑한다.

- CSV 읽기 → csv 모듈 또는 pandas 라이브러리

- 평균 계산 → sum()과 len() 또는 statistics.mean()
- 필터링 → 리스트 컴프리헨션 또는 filter() 함수
- 정렬 → sorted() 함수 또는 list.sort()
- CSV 저장 → csv.writer 또는 pandas.to_csv()

LLM은 맥락이 없다면 가장 일반적인 방법인 pandas를 선택할 가능성이 높다. Pandas는 데이터 처리 작업에서 널리 사용되고, LLM의 훈련 데이터에 대량으로 포함되어 있기 때문이다.

■단계 3: 코드 골격 생성
전체 구조를 먼저 만든다.

```
pythonimport pandas as pd
# CSV 파일 읽기
# 평균 점수 계산
# 80점 이상 필터링
# 정렬
# 결과 저장
```

이 골격은 주석 형태의 계획이다. LLM은 복잡한 작업을 생성할 때 이런 단계별 주석을 먼저 만들고, 각 주석을 실제 코드로 채우는 패턴을 학습했다. 이는 인간 개발자가 의사코드(pseudocode)를 작성하는 것과 유사하다.

■단계 4: 각 단계를 실제 코드로 구현

4-1. CSV 읽기

```
pythondf = pd.read_csv('students.csv')
```

LLM은 "CSV 파일에서 읽어"라는 표현에서 파일 이름이 명시되지 않았음을 인식한다. 일반적인 관행에 따라 'students.csv'라는 예시 파일명을 사용하거나, 변수로 처리한다. 또한 read_csv()가 파일 경로를 받는다는 것을 알고 있다.

4-2. 평균 점수 계산

여기서 LLM은 한 가지 문제를 만난다. CSV에 여러 과목 점수가 있다면 어떻게 평균을 내는가? 프롬프트가 모호하다. LLM은 두 가지 해석이 가능함을 인식한다.

- 각 학생의 과목 평균을 계산
- 전체 학생의 평균 점수를 계산

일반적으로 "학생 성적 데이터"에서 필터링한다는 문맥상, 각 학생의 평균일 가능성이 높다. 따라서:

```
pythondf['average'] = df[['math', 'english', 'science']].mean(axis=1)
```

여기서 LLM은 ['math', 'english', 'science'] 같은 구체적 컬럼명을 가정했다. 실제로는 프롬프트에 컬럼명이 없으므로, 더 일반적인 방법을 택할 수도 있다:

```
python# 점수 컬럼만 선택 (이름 컬럼 제외)
score_columns = df.select_dtypes(include=['number']).columns
df['average'] = df[score_columns].mean(axis=1)
```

이는 숫자 타입 컬럼만 선택하여 평균을 내는 더 유연한 접근이다. LLM이 이런 선택을 하는 이유는, 훈련 데이터에서 "일반적인 해결책이 특정한 해결책보다 선호된다"는 패턴을 학습했기 때문이다.

4-3. 80점 이상 필터링

```
pythondf_filtered = df[df['average'] >= 80]
```

LLM은 "80점 이상"을 >= 80으로 정확히 변환한다. "이상"과 "초과"의 차이를 이해하고 있다. 판다스의 불린 인덱싱 패턴도 익숙하게 생성한다.

4-4. 정렬

```
pythondf_sorted = df_filtered.sort_values('average', ascending=False)
```

"점수 높은 순"이라는 표현에서 내림차순(ascending=False)임을 파악한다. 만약 "낮은 순"이었다면 `ascending=True`를 사용했을 것이다. 또한 정렬 기준이 방금 계산한 'average' 컬럼임을 추론한다.

4-5. 결과 저장

```python
df_sorted.to_csv('high_performers.csv', index=False)
```

```

LLM은 출력 파일명도 명시되지 않았으므로 의미있는 이름('high_performers.csv')을 선택한다. `index=False`는 판다스 인덱스를 CSV에 포함하지 않는 일반적인 관행이다.

■ 단계 5: 최종 통합 및 개선

LLM은 생성한 코드 조각들을 하나의 완성된 스크립트로 통합한다. 동시에 몇 가지 개선사항을 추가한다.

```python
import pandas as pd

def process_student_scores(input_file='students.csv', output_file='high_performers.csv', threshold=80):
    """
    학생 성적 데이터를 처리하여 고득점자를 추출합니다.

    Args:
        input_file: 입력 CSV 파일 경로
        output_file: 출력 CSV 파일 경로
        threshold: 필터링 기준 점수
    """
    # CSV 파일 읽기
    df = pd.read_csv(input_file)

    # 숫자 컬럼에서 평균 점수 계산
    score_columns = df.select_dtypes(include=['number']).columns
    df['average'] = df[score_columns].mean(axis=1)

    # 기준 점수 이상 필터링
    df_filtered = df[df['average'] >= threshold]
```
```

```
    # 평균 점수 내림차순 정렬
    df_sorted = df_filtered.sort_values('average', ascending=False)

    # 결과를 CSV로 저장
    df_sorted.to_csv(output_file, index=False)

    print(f"처리 완료: {len(df_sorted)}명의 학생 데이터가 {output_file}에 저장되었습니다.")

    return df_sorted

# 실행
if __name__ == "__main__":
    result = process_student_scores()
```

■ 개선 사항 분석

LLM이 추가하는 여러 개선 사항을 주목하자.

1. 함수화: 단순 스크립트를 함수(function)로 만들어 재사용성을 높였다. 이는 "좋은 코드는 함수로 구조화되어야 한다"는 소프트웨어 공학 원칙을 반영한다.

2. 매개변수화: 파일명과 임계값을 하드코딩 대신 매개변수로 만들어 유연성을 제공했다. 기본값도 지정했다.

3. DocString 추가: 함수의 목적과 매개변수를 설명하는 문서화 문자열을 포함했다. 이는 파이썬 커뮤니티의 표준 관행이다.

4. 피드백 메시지: 처리 결과를 출력하여 사용자에게 정보를 제공한다.

5. 메인 가드: `if __name__ == "__main__":` 패턴으로 모듈로도 import 가능하게 했다.

이러한 개선사항들은 프롬프트에 명시되지 않았다. LLM이 "프로덕션 품질 코드"의 특성을 학습했기 때문에 자동으로 추가한 것이다. 훈련 데이터에 포함된 수많은 고품질 파이썬 코드에서 이런 패턴들이 반복적으로 나타났고, LLM은 이를 "좋은 코드의 특징"으로 학습했다.

■에러 처리 추가

고급 vibe coding 도구는 여기서 한 걸음 더 나아가 에러 처리도 추가할 수 있다.

```python
try:
    df = pd.read_csv(input_file)
except FileNotFoundError:
    print(f"오류: {input_file} 파일을 찾을 수 없습니다.")
    return None
except pd.errors.EmptyDataError:
    print(f"오류: {input_figle}이 비어있습니다.")
    return None
```

이는 "실제 환경에서는 파일이 없거나 손상될 수 있다"는 현실을 반영한다. LLM이 이를 추가하는 이유는, 훈련 데이터에서 견고한 코드(robust code)들이 예외 처리를 포함하는 패턴을 학습했기 때문이다.

■생성 과정의 확률적 특성

중요한 점은 이 코드 생성 과정이 결정론적이지 않다는 것이다. 같은 프롬프트로 여러 번 요청하면 약간씩 다른 코드가 생성될 수 있다. 어떤 때는 `csv` 모듈을 사용하고, 어떤 때는 `pandas`를 사용할 수 있다. 변수명도 `df`, `data`, `students` 등으로 다양할 수 있다. 이는 LLM이 각 단계에서 가장 가능성 높은 토큰을 선택하지만, 약간의 무작위성(temperature)을 포함하기 때문이다. 다양성은 창의적 해결책을 가능하게 하지만, 일관성 부족의 원인이 되기도 한다.

이 전체 과정이 실시간으로, 종종 수 초 내에 완료된다. 사용자는 자연어 한 문장만 입력했지만, AI는 요구사항 분해, 기술 선택, 코드 생성, 통합, 개선의 복잡한 과

정을 거쳐 완성된 프로그램을 만들어낸다. 이것이 vibe coding의 핵심 마법이다.

3) 소프트웨어 생태계의 변화

Vibe coding은 소프트웨어 개발 생태계의 여러 측면을 근본적으로 재편하고 있다.

첫째, 진입 장벽의 극적인 하락이다. 과거에는 프로그래밍 언어 문법, 알고리즘, 자료구조를 몇 년간 학습해야 간단한 애플리케이션도 만들 수 있었다. 이제는 아이디어와 기본적인 논리적 사고만 있으면 작동하는 소프트웨어를 만들 수 있다. 디자이너, 마케터, 기획자 같은 비개발자들이 직접 도구를 만들어 사용한다. 이는 소프트웨어 창작의 민주화(democratization)를 의미한다.

둘째, 개발 속도의 획기적 증가다. 프로토타입 개발이 몇 주에서 몇 시간으로 단축된다. 스타트업이 아이디어를 빠르게 검증할 수 있고, 기업들은 내부 도구를 신속하게 개발하여 업무 효율을 높인다. 이는 소프트웨어 시장의 경쟁 구도를 변화시킨다. 먼저 시장에 출시하는 것이 더욱 중요해지며, 대기업의 자원 우위가 상대적으로 약해진다.

셋째, 팀 구조의 변화다. 소규모 팀이나 개인 개발자도 과거 대형 팀이 필요했던 프로젝트를 수행할 수 있다. 1인 스타트업이 전체 스택 애플리케이션을 개발하고 운영하는 사례가 증가한다. 반면 대형 조직에서는 개발자의 역할이 코드 작성자에서 아키텍트, 검증자, 통합자로 이동한다. 협업 방식도 변한다. 코드 리뷰가 "이 구현이 맞나?"에서 "이 요구사항이 맞나?"로 초점이 이동한다.

넷째, 유지보수와 품질 관리의 새로운 과제다. AI가 생성한 코드는 일관된 스타일을 보장하지 않고, 때로 비효율적이거나 보안 취약점을 포함한다. 자동 생성 코드의 품질 검증, 테스트, 문서화가 새로운 중요 영역으로 부상한다. 동시에 코드 생성 AI의 발전이 코드 분석 AI의 발전을 촉진하는 선순환도 나타난다.

4) 개발자의 역할과 학습 방식의 변화

Vibe coding은 개발자의 정체성 자체를 재정의하고 있다. 전통적으로 개발자는 "코드를 작성하는 사람"이었다. 프로그래밍 언어에 능숙하고, 알고리즘을 구현할 수 있으며, 버그를 수정하는 능력이 핵심 역량이었다. 이제 이러한 기술적 실행 능력의 중요성은 상대적으로 감소하고, 새로운 역량들이 부상한다.

■새로운 핵심 역량

첫째, 문제 정의 능력이다. "무엇을 만들어야 하는가"를 명확히 정의하는 것이 가장 중요해진다. 모호한 요구사항은 쓸모없는 코드를 생성한다. 개발자는 이해관계자

와 소통하여 정확한 요구사항을 추출하고, 이를 AI가 이해할 수 있는 명확한 지시로 변환해야 한다. 이는 기술 능력보다 소통 능력, 비즈니스 이해, 사용자 공감에 가깝다.

둘째, 아키텍처 설계 감각이다. AI는 개별 함수나 컴포넌트는 잘 만들지만, 전체 시스템 구조를 설계하는 데는 한계가 있다. 어떤 모듈로 나눌지, 데이터는 어떻게 흐를지, 확장성과 유지보수를 위한 구조는 어떻게 할지는 여전히 인간 개발자의 판단이 필요하다. 마치 건축가가 전체 설계를 하고 AI가 세부 도면을 그리는 것과 같다.

셋째, 비판적 검토 능력이다. AI가 생성한 코드가 요구사항을 충족하는지, 보안 취약점은 없는지, 성능은 적절한지 평가해야 한다. 이는 코드를 작성하는 능력보다 코드를 읽고 이해하는 능력을 요구한다. 코드 리뷰 역량이 더욱 중요해진다. 또한 AI의 한계를 이해하고, 어떤 작업은 AI에게 맡기고 어떤 것은 직접 해야 하는지 판단하는 메타인지가 필요하다.

넷째, 프롬프트 엔지니어링 기술이다. AI와 효과적으로 소통하는 것 자체가 새로운 기술이 된다. 어떻게 요청해야 원하는 결과를 얻는지, 모호함을 어떻게 해소하는지, 예시를 어떻게 제공하는지가 생산성을 좌우한다. "AI와 대화하는 법"을 배우는 것이 "프로그래밍 언어를 배우는 것"만큼 중요해진다.

■학습 방식의 전환

프로그래밍 교육도 근본적으로 변화할 필요성이 제기되고 있다. 전통적 교육은 문법부터 시작하여 자료구조, 알고리즘, 디자인 패턴으로 이어지는 상향식(bottom-up) 접근이었다. 학생들은 수백 줄의 코드를 직접 타이핑하며 세부 사항을 익혔다. 이제는 하향식(top-down) 접근이 가능해진다. 먼저 무엇을 만들고 싶은지 정의하고, AI로 프로토타입을 만든 후, 작동 원리를 이해하고 개선하는 방식이다.

예를 들어 웹 개발을 배울 때, 과거에는 HTML 태그를 하나씩 외우고, CSS 속성을 익히고, JavaScript 문법을 공부했다. 이제는 "간단한 블로그를 만들어줘"라고 AI에게 요청하여 작동하는 사이트를 만든 후, 생성된 코드를 분석하며 HTML, CSS, JavaScript의 역할을 이해할 수 있다. 이는 악기 학습에 비유하자면, 음계 연습부터 시작하는 대신, 먼저 좋아하는 곡을 AI의 도움으로 연주해보고, 그 과정에서 이론을 배우는 것과 같다.

그러나 이는 기초를 생략하는 것이 아니다. 오히려 더 깊은 이해를 요구한다. AI가 생성한 코드를 비판적으로 평가하려면, 좋은 코드와 나쁜 코드를 구분할 수 있어야 한다. 이는 견고한 CS 기초 지식 없이는 불가능하다. 따라서 학습 순서가 바뀔 뿐, 학습의 깊이는 여전히 중요하다.

새로운 교육 모델은 프로젝트 기반 학습(project-based learning)을 강조한다. 학생들은 실제 문제를 해결하는 프로젝트를 통해 배운다. AI가 코드 작성을 돕지만, 문제 정의, 설계, 테스트, 개선은 학생의 몫이다. 이 과정에서 자연스럽게 필요한 개념들을 학습한다. 배움의 동기도 더 강하다. "언젠가 쓸모 있을 문법"을 외우는 대신, "지금 내 프로젝트에 필요한 지식"을 배우기 때문이다.

또한 협업과 소통 능력의 교육이 강화되어야 한다. 개발자는 AI와 협업하고, 다른 개발자와 협업하며, 비개발자 이해관계자와도 협업한다. 코드를 혼자 작성하는 고독한 천재의 이미지는 더 이상 현실이 아니다. 팀워크, 커뮤니케이션, 피드백 수용 능력이 핵심 역량으로 자리잡는다.

■개발자 커뮤니티의 분화

Vibe coding은 개발자 커뮤니티를 새로운 방식으로 분화시킨다. 한쪽에는 AI 도구를 적극 활용하여 빠르게 프로토타입을 만들고 실험하는 "빌더(builder)" 성향의 개발자들이 있다. 다른 쪽에는 시스템의 깊은 이해와 최적화, 보안을 중시하는 "엔지니어(engineer)" 성향의 개발자들이 있다. 두 그룹 모두 가치있지만, 추구하는 바와 작업 방식이 다르다. 미래의 프로젝트는 두 유형의 협업을 요구할 것이다. 빌더가 빠르게 아이디어를 구현하면, 엔지니어가 이를 견고하고 확장 가능한 시스템으로 다듬는 방식이다.

결국 vibe coding은 개발자를 대체하는 것이 아니라, 개발자의 역할을 상향 이동시킨다. 단순 반복적인 코드 작성에서 벗어나, 더 창의적이고 전략적인 문제 해결에 집중할 수 있게 된다. 이는 도전이자 기회다. 새로운 역량을 개발하고 적응하는 이들에게는 더 큰 가치를 창출할 기회가 열리지만, 변화를 거부하는 이들에게는 위협이 될 수 있다.

☞ 필독: 40년 경력 베테랑 프로그래머의 바이브 코딩 체험담

https://levelup.gitconnected.com/vibe-coding-as-a-coding-veteran-cd370fe2be50

5) 한계와 문화적·윤리적 쟁점

Vibe coding은 강력하지만 심각한 한계와 위험을 동반한다. 첫 번째 한계는 생성된 코드에 대한 이해 부족이다. 개발자가 AI가 생성한 코드를 완전히 이해하지 못한 채 사용하면, 예상치 못한 버그나 보안 취약점이 발생할 수 있다. SQL 인젝션, XSS 공격 같은 보안 문제가 생성된 코드에 포함되어도, 개발자가 이를 인식하지 못할 수 있다. 이는 "작동하지만 위험한" 소프트웨어를 양산할 위험이 있다.

두 번째는 코드 품질의 불일치다. AI는 때로 비효율적이거나 유지보수하기 어려운 코드를 생성한다. 같은 작업을 수행하는 여러 방법 중 최선이 아닌 방법을 선택할 수 있다. 또한 생성할 때마다 다른 스타일의 코드를 만들어 일관성이 부족하다. 이는 장기적으로 코드베이스의 품질 저하로 이어진다.

METR의 실증 연구에 따르면, AI 기반 코딩 지원 도구를 사용한 경험 많은 개발자들은 오히려 작업 완료 시간이 평균 19% 증가했다는 보고도 있다[26]. 이는 AI가 제안하는 코드가 완전하지 않아 검토·수정에 상당한 시간이 소요되기 때문이다. 또한 기업 차원에서도 많은 AI 도입 사례가 적절한 투자 대비 수익률(ROI)를 보여주지 못하고 실패하는 비율이 높은 것으로 보고된 바 있다는 MIT 보고서는, AI 도구 자체보다 조직적 통합·워크플로우 적합성·가치 가설 수립의 중요성을 강조한다[27].

따라서 “Vibe Coding이 항상 생산성을 높인다”는 주장은 경험치 조건, 코드 복잡성, 검증 비용 등을 고려하지 않은 과도한 일반화라는 비판이 가능하다. AI는 초급자나 단순 반복 작업에서는 이점을 줄 수 있지만, 복잡한 개발 환경에서는 오히려 비용을 증가시키는 요인으로 작용할 수 있다. 즉, 도구는 상황과 맥락에 따라 선택적으로 활용돼야 한다.

세 번째는 책임과 투명성 문제다. AI가 생성한 코드에서 버그가 발생했을 때 누가 책임지는가. 개발자인가, AI 도구 제공자인가. 개발자는 "AI가 그렇게 만들었다"고 항변할 수 있지만, 법적·윤리적으로는 코드를 사용한 개발자의 책임이다. 그러나 개발자가 수천 줄의 생성 코드를 모두 검토하는 것은 현실적으로 불가능하다. 이 책임의 공백이 문제다.

네 번째는 학습 기회의 감소다. 초보 개발자가 처음부터 AI에 의존하면, 기본적인 프로그래밍 사고를 키울 기회를 잃는다. 코드를 직접 작성하며 겪는 시행착오가 학습의 중요한 부분인데, 이를 건너뛰면 피상적인 이해만 남는다. "자전거 타기"를 배울 때 처음부터 보조 장치에만 의존하면, 결국 혼자서는 탈 수 없는 것과 같다.

문화적으로는 "창작자로서의 개발자" 정체성이 흔들린다. 많은 개발자들은 코드를 작성하는 행위 자체에서 만족감을 느낀다. 논리 퍼즐을 푸는 것 같은 지적 쾌감, 무에서 유를 창조하는 성취감이 개발 문화의 일부였다. AI가 대신 코드를 작성하면, 개발자는 "관리자"나 "감독자" 역할만 하게 된다. 이는 직업적 만족도를 저하시킬 수 있다. 물론 이는 개인차가 크다. 어떤 이들은 단순 작업에서 벗어나 더 창의적인 일에 집중할 수 있어 환영하지만, 어떤 이들은 손으로 직접 만드는 장인 정신을 잃는

26) https://arxiv.org/abs/2507.09089
27) https://fortune.com/2025/08/18/mit-report-95-percent-generative-ai-pilots-at-companies-failing-cfo/

것에 상실감을 느낀다.

윤리적으로는 AI 훈련 데이터의 출처가 논쟁적이다. 많은 코드 생성 AI는 GitHub의 공개 저장소로 학습했는데, 이는 오픈소스 라이선스를 위반할 소지가 있다. 개발자들이 "공개는 했지만 AI 학습에 사용되리라 예상하지 않았던" 코드가 무단으로 학습 데이터로 쓰였다. 또한 생성된 코드가 훈련 데이터의 일부를 거의 그대로 복제하는 경우도 있어, 저작권 침해 가능성이 제기된다.

더 근본적으로는 "코드를 모른 채 소프트웨어를 만든다는 것"의 의미를 물어야 한다. 이는 자동차 운전자가 엔진 작동 원리를 몰라도 되는 것과 같은가, 아니면 외과의사가 해부학을 모른 채 수술하는 것과 같은가. 소프트웨어가 사회 기반시설이 되어가는 시대에, 작동 원리를 모르는 소프트웨어에 의존하는 것은 위험하지 않은가. 이는 기술적 문제를 넘어 사회적 책임의 문제다. 우리는 vibe coding의 편리함과 위험성 사이에서 균형을 찾아야 하며, 적절한 규제와 윤리적 가이드라인을 마련해야 한다.

나. 하드웨어와 전력 문제

1) 전기와 물리적 기계 소요량

인공지능(AI)은 흔히 형체가 없는 지능적 알고리즘으로 인식되지만, 실제로는 거대한 물리적 기반 위에서만 생존할 수 있는 시스템이다. AI가 '생각'하는 과정은 수조 번의 수학적 연산으로 이루어지며, 이를 실행하기 위해서는 반도체라는 기계 장치와 그 장치를 움직일 에너지가 필수적이다.

AI 모델의 크기가 커질수록 필요한 연산량은 기하급수적으로 증가한다. 예를 들어 대형 언어 모델(LLM)을 학습시킬 때, 하나의 매개변수가 업데이트될 때마다 수많은 부동소수점 연산이 발생한다. 이 과정에서 반도체 내부의 트랜지스터가 켜고 꺼지며 전자를 이동시키는데, 이 전자 이동의 원동력이 바로 전기다.

최신 AI 칩인 GPU는 초당 수조 번의 연산을 수행하며, 이 과정에서 엄청난 양의 전력을 소비하고 열을 발생시킨다.AI 인프라는 단순한 컴퓨터 한 대가 아니라 거대한 연쇄 구조를 이룬다. 핵심인 GPU(그래픽 처리 장치)와 NPU(신경망 처리 장치)가 연산을 담당하고, 연산에 필요한 데이터를 즉각 공급하는 고대역폭 메모리(HBM)와 이를 영구 저장하는 스토리지가 뒷받침한다.

이 모든 부품은 데이터 센터라는 특수한 건축물 내부에 수용된다. 데이터 센터는 전력을 안정적으로 공급하는 수전 설비, 연산 장치에서 발생하는 열을 식히는 냉각 시스템, 그리고 데이터를 전송하는 초고속 네트워크망이 결합된 집합체다.

결국 AI의 지능은 소프트웨어의 논리만으로 완성되지 않는다. 투입되는 전력의 양과 하드웨어의 집적도가 지능의 수준을 결정하는 물리적 한계선으로 작용한다. 인

공지능은 클라우드라는 추상적 공간이 아닌, 뜨거운 열기를 내뿜는 기계실과 전선 더미 위에서 비로소 실체화된다.

☞. H100 1만 개 가동 시 전력 및 비용 추정(1개월 기준)

NVIDIA H100 GPU 1만 개를 1개월간 풀가동하여 모델을 학습시킨다고 가정한다. H100 한 개의 최대 소비 전력은 약 700W이며, 서버 및 네트워크 자원, 그리고 데이터 센터 냉각 효율(PUE 1.5 가정)을 포함하면 전체 시스템은 약 15MW의 전력을 지속적으로 사용한다. 이를 한 달(720시간)로 환산하면 약 1,080만 kWh에 달한다. 미국의 산업용 전기요금을 kWh당 0.12달러로 가정할 때, 한 달 전기요금만 약 130만 달러(한화 약 17억 원) 이상이 발생한다. 이는 하드웨어 구매 비용을 제외한 순수 운영비만을 말하는 것이다.

보이지 않는 AI의 기반AI가 '클라우드에 있다'는 말은 전 세계 어딘가에 위치한 거대한 물리적 창고인 데이터 센터에 데이터가 저장되어 있음을 의미한다. AI 모델이 학습하기 위해서는 수 페타바이트(PB) 규모의 데이터가 스토리지를 통해 끊임없이 이동해야 한다. 이 과정에서 데이터의 병목 현상을 방지하기 위한 초고속 네트워킹 기술이 필수적이다.

또한, 수만 개의 칩이 동시에 작동하며 발생하는 열을 처리하지 못하면 하드웨어는 파손된다. 따라서 현대의 데이터 센터는 거대한 냉각 장치와 수천 톤의 냉각수를 소모하는 물류 거점에 가깝다.

데이터 센터는 AI의 뇌를 지탱하는 신체이자, 지능이 흐르는 통로로서 보이지 않는 곳에서 시스템을 지탱한다.

표 13 주요 빅테크 기업의 데이터 센터 현황

기업	주요 특징 및 입지 전략	규모 및 사례
Microsoft	전 세계 60개 이상 리전 보유, 해저 데이터 센터(Natick 프로젝트) 실험 등 혁신적 냉각 시도	미국 아이오와주 등에 수조 원 규모 단지 구축
Google	전력 효율(PUE) 최적화 및 재생 에너지 연계 중점. 칠레, 핀란드 등 냉각이 유리한 지역 선호	오클라호마 대규모 센터 등 전 세계 20여 곳 운영
Meta	자체 설계 서버(OCP) 사용. 북유럽(스웨덴 룰레오) 등 저온 기후 지역을 활용한 자연 냉각 활용	텍사스 및 덴마크 등에 초대형 캠퍼스 구축
AWS	전 세계 클라우드 점유율 1위. 안정적인 전력 공급이 가능한 버지니아주 '데이터 센터 골목' 집중	북버지니아 리전에만 수십 개의 데이터 센터 밀집

AI 산업의 지속 가능성은 국가의 전력 공급 능력에 달려 있다. 대규모 데이터 센터는 도시 하나가 사용하는 수준의 전력을 필요로 하므로, 안정적이고 저렴한 전기를 공급할 수 있는 국가는 AI 기업 유치에서 압도적인 우위를 점한다. 이는 단순히 전선망을 까는 문제가 아니라, 국가 에너지 정책의 핵심 과제가 된다.

최근 탄소 중립 요구가 거세짐에 따라, AI용 전력을 신재생 에너지나 원자력 발전으로 충당하려는 움직임이 가속화되고 있으나, 신재생 에너지는 기술적으로 많은 검토가 필요하다. 특히 연중무휴 24시간 안정적인 전력이 필요한 데이터 센터의 특성상, 소형 모듈 원자로(SMR)가 새로운 대안으로 부상하고 있다. 결국 송배전 인프라의 신뢰성과 에너지 믹스 전략이 한 국가의 AI 산업 경쟁력을 결정짓는 핵심 변수가 된다.

2) AI 능력 양극화 극복

오늘날 AI 경쟁은 알고리즘의 우수성을 넘어, 누가 더 많은 '연산 자원'을 확보하느냐의 싸움으로 변모했다. 고성능 GPU는 설계와 제조 난이도가 극도로 높아 특정 기업(NVIDIA 등)이 독점하고 있으며, 이를 대량으로 구매하여 데이터 센터를 구축할 수 있는 자본력은 거대 빅테크 기업이나 일부 선진국에 집중되어 있다.

이러한 자원 집중은 곧 AI 성능의 격차로 이어진다. 수조 원 단위의 인프라 투자가 가능한 기업은 더 거대한 모델을 더 빠르게 학습시킬 수 있지만, 그렇지 못한

중소기업이나 대학 연구소는 접근조차 어려운 구조적 장벽이 형성된다.

이런 상황에서 중소기업과 대학 연구소는, 심지어 개인조차 다음과 같은 전략으로 틈새를 공략하는 것이 가능하다.

■하드웨어 한계를 넘는 기술적 틈새 전략

거대 모델을 직접 학습시키는 대신, 이미 만들어진 모델을 똑똑하게 활용하거나 효율을 극대화하는 방식이 주를 이룬다.

- 파인 튜닝(Fine-tuning) 및 RAG(검색 증강 생성): 거대 기업이 만든 기본 모델(Foundation Model) 위에 우리만 가진 특수 데이터를 입혀 특정 분야에 특화된 모델로 재탄생시킨다. 예를 들어, 일반 법률 지식이 아닌 '특정 지역의 판례'나 '사내 내부 기술 문서'만 전문적으로 학습시키는 식이다.
- sLLM(소형 언어 모델) 개발: 수조 개의 매개변수를 가진 모델 대신, 수십억 개 수준의 매개변수로도 특정 작업에서 고성능을 내는 최적화된 모델을 개발한다. 이는 운영 비용(inference cost)을 획기적으로 낮추어 중소기업의 수익성을 보장한다.
- 에지 AI(Edge AI) 및 온디바이스(On-device) 기술: 클라우드 서버가 아닌 스마트폰, 드론, 가전제품 자체에서 돌아가는 가벼운 AI를 연구한다. 거대 서버가 필요 없으므로 하드웨어 인프라 격차를 무력화할 수 있는 영역이다.

■데이터와 도메인 전문성 기반의 사업화

AI의 성능은 연산량만큼이나 '데이터의 질'에 좌우된다. 빅테크가 가지지 못한 현장의 목소리가 경쟁력이 된다.

- 수직적 시장(Vertical AI) 공략: 의료, 농업, 제조 공정 등 매우 전문적이고 폐쇄적인 영역의 데이터를 확보한다. 범용 AI는 잘 모르는 '현장의 암묵지'를 데이터화하여 솔루션을 만든다면 구글이나 MS도 쉽게 침범할 수 없는 성벽이 된다.
- 데이터 큐레이션 및 클렌징 서비스: 고성능 AI를 위해서는 깨끗한 데이터가 필수적이다. 방대한 원천 데이터를 AI 학습에 적합하게 가공하고 검증하는 전문 서비스는 인프라보다 인적 자본이 중요하므로 대학 연구소가 강점을 가질 수 있다.

■연구 및 협력 모델의 혁신

대학과 소규모 조직은 유연함과 학제간 융합을 무기로 삼아야 한다.

- 알고리즘 효율성 연구: "어떻게 하면 더 적은 연산으로 같은 결과를 낼 것인가?"를 연구한다. 최근 각광받는 양자화(Quantization)나 지식 증류(Knowledge Distillation) 기술은 하드웨어 제약이 있는 환경에서 더욱 절실하게 요구되는 연

구 분야다.

- 산학연 연합 인프라 활용: 정부의 AI 바우처 사업이나 국립 슈퍼컴퓨팅 센터 등 공공 인프라를 적극 활용한다. 또한 여러 중소기업이 데이터를 공유하여 연합 학습(Federated Learning)을 진행함으로써 보안을 유지하면서도 데이터 규모의 경제를 달성할 수 있다.

3) 자원 소모의 미래

AI에 소요되는 물리적 자원의 한계는 AI 발전의 방향을 재설계할 필요성을 야기하고 있다. 무한정 모델의 크기를 키우는 방식은 전력 소모와 비용 문제로 인해 한계에 봉착할 것이다.

이에 따라 에너지를 적게 쓰는 '저전력 AI 칩', 불필요한 연산을 줄이는 '경량화 모델(sLLM)', 그리고 데이터 센터의 열을 재활용하는 기술 등이 미래의 핵심 기술로 떠오르고 있다.

AI의 발전은 단순히 지능의 무한 확장이 아니라, 지구라는 물리적 환경과 에너지 자원의 제약 내에서 타협하고 진화하는 과정이다. 우리는 AI를 통해 인간의 지능을 확장하는 동시에, 이를 지탱하기 위한 지구적 자원을 어떻게 효율적으로 배분할 것인가라는 실존적 질문에 직면해 있다.

다. 인공지능의 미래에 대한 전문가 견해

지금까지 설명한 AI 현상의 발전 과정을 충분히 이해했다면, 향후 AI의 전개 방향에 대해 상상해볼 수 있다. 그 미래상에 대하여 누구도 예언할 수는 없고, 본 교재에서도 그를 묘사하는 것은 부적절하다. 다만, AI의 미래에 대한 기술 계열 세계 최고 전문가의 견해는 아래 첨부하는 영상을 통해 참고하고 이를 통해 저마다 견해를 정립해볼 필요가 있다.

AI의 미래에 대한 전문가 견해를 정리 서술형 문장 평어 종결어미:

1. 일리아 수츠케버 (Ilya Sutskever, 1986~, OpenAI의 GPT모델 및 chatGPT 개발주역)

https://www.youtube.com/watch?v=L3OvFcSjXRg

그림 27 Sam Altman과 Ilya Sutskever, 2023.

출처 : https://www.calcalistech.com/ctechnews/article/hyqfg1a411x#google_vignette

2. 데미스 허사비스 (DeepMind AlphaGO 의 개발 주역)
https://m.youtube.com/watch?v=PqVbypvxDto&fbclid=IwVERDUAOyExNleHRuA2FlbQIxMABzcnRjBmFwcF9pZAwzNTA2ODU1MzE3MjgAAR6IzzagQiaKHozB-CaAjziOe729XjUVunK51C1_58F93CwV5UDUOmsJZrUI_Q_aem_F6V410upPAssbE438BGybg

3. 페이페이 리(李飞飞, Fei-Fei Li, 1976~ , ImageNet 개발 주역)
https://www.youtube.com/watch?v=fQGu016AlVo&t=8s

그림 28 Fei Fei Li 와 Geoffrey Hinton 2023

출처 :https://www.utoronto.ca/news/geoffrey-hinton-and-fei-fei-li-draw-thousands-talk-about-responsible-ai-development

8. AI와 사회경제의 변화

가. 분업 구조의 변화

19세기 후반~20세기 초반에 등장하기 시작한 GM, GE, Siemens Dupont, Ford 등 대기업 조직은 최상층에 단일의 중심점을 지닌 위계구조를 따랐다. 경영자의 활동 두께는 조직의 온갖 층위에 걸쳐 매우 두꺼웠다. 사원, 대리, 과장, 부장, 임원, 대표에 이르는 거대한 위계형 조직 구조가 일반적이었다. 또한, 기획, 행정, 재무, 마케팅, 연구개발, 생산, 교육훈련, 조달 등 다양한 기능들이 한 조직 안에 두루 병존했었다.

양차 세계대전을 거치고 정보통신기술이 발달하면서, 제반 경영 기능들은 분리되기 시작했다. 원재료나 중간생산물은 상당 부분 아웃소싱 대상이 됐고, 기업의 여러 기능 지식들도 하나씩 외부 독립조직으로 위탁되기 시작했다. 행정, 회계, 연구개발, 교육훈련, 전산 업무는 외부의 아웃소싱이나 클라우드 서비스로 분산된 지 오래다.

외부의 사업 주체로 분리되는 지식들을 주변지식(supportiive, peripheral knowledge)이라 하고, 그렇지 않고 조직 내부에 남아 있는 것을 핵심지식(core knolwedge)이라고 부를 수 있겠다. 비록 핵심지식과 주변지식을 구분하는 절대적인 기준선은 없고 상황에 따라 유동적이지만. 핵심지식에 대해서는 더 이상 분화할 수 없고 외부에 위탁할 수도 없는 최소한의 경계선이 있다. 예를 들어 고객관계관리(CRM) 활동을 주변지식으로 분류해서 외부에 위탁하는 일은 신중해야 한다. 상황에 따라 다르지만 핵심지식과 주변지식의 경계선은 경영 환경의 변화에 따라 유동적으로 변해 왔다. 그래서 한동안 핵심지식이라고 간주되어 왔던 지식도 어느 날 주변지식이 될 수 있다.

21세기 AI가 보편화되면서 기업들은 핵심 지식을 주로 내부에 존속시키고 주변지식들은 아웃소싱하거나, 사람을 쓰는 대신 내부 AI 활용으로 대체할 가능성이 점점 높아지고 있다. 그러나, 핵심지식은 어떤 한 가지 지식에 국한하는 것이 아니라, 이질적인 기능별 분업 지식에 분산되어 있을 것이다. 예컨대 기술기업이 기술 핵심 지식만을 보유하고 나머지 마케팅이니 생산 지식을 다 아웃소싱하면 된다고 하는 생각은 위험할 수 있다. 이런 분야별 기능 지식에도 그마다 특화된 개인들의 암묵지가 있으며, 특출한 천재가 아닌 한, 한 개인이 이 모든 기능 분야의 암묵지를 체득하고 구사한다는 것은 불가능하다.

그런 의미에서 AI가 확산되면서 조직의 슬림(slim)화가 촉발되겠지만, 주요 기능 분야별 필수 핵심 지식은 조직 내에 여전히 남을 것이다. 그런 한 “상이한 지식을 통합해서 결과를 낼 책임 있는 행위”라는 피터 드러커 식 의미의 경영은 여전히 남

아 있을 것이고 오히려 중요성은 더 커지고 있다.

나. 노동의 대체가 이루어지는 방향

20세기 산업혁명과 자동화는 주로 육체노동과 반복적 제조 공정을 기계로 대체하는 방식으로 진행되었다. 공장의 컨베이어 벨트, 자동차 조립 로봇, 농업 기계화는 모두 인간의 물리적 노동을 기계가 대신하는 구조였다. 이 과정에서 블루칼라 노동자의 일자리는 감소했지만, 기계를 설계·관리·운영하는 화이트칼라 직종과 전문직은 오히려 확대되었다. 인간의 판단, 기획, 의사결정 능력은 여전히 기계가 대체할 수 없는 고유 영역으로 남아있었다.

그러나 21세기 AI 기술은 이 전제를 근본적으로 뒤흔든다. AI는 단순히 육체노동을 대신하는 것이 아니라, 판단·해석·기획·의사결정의 상당 부분을 자동화한다. 의료 영상 판독, 법률 문서 검토, 금융 투자 분석, 언론 기사 작성, 건축 설계 초안 작성 등 전문직과 창의 노동 영역까지 AI의 영향권에 들어왔다. 이는 "무엇을 할 것인가"라는 사고 자체를 AI에게 부분적으로 외주화하는 구조적 변화를 의미한다.

실제 사례를 보면, 2023년 IBM은 HR 부서 채용의 30%를 AI로 대체하겠다고 발표했다. 이는 단순 업무가 아니라 지원자 평가와 선발이라는 '판단' 업무의 외주화다. 로이터와 AP통신은 이미 2010년대 중반부터 스포츠 경기 결과나 기업 실적 뉴스를 AI가 자동 작성하도록 했다. 2024년 맥킨지 보고서에 따르면 미국 변호사들은 업무 시간의 23%를 AI 도구에 의존하며, 특히 계약서 검토와 판례 조사에서 AI 활용도가 높다.

이러한 변화의 핵심 쟁점은 "일자리 감소"가 아니라 "일의 정의와 일하는 방식의 변화"다. AI가 초안을 작성하면 인간은 검토자·편집자·전략가로 역할이 재정의된다. 의사는 진단보다 환자와의 소통과 치료 계획 수립에 집중하게 된다. 이는 노동의 소멸이 아니라 노동 내용의 재구성이다.

장기적으로 AI는 인간의 생산성을 높이고, 인간 중심·창의적 업무에 집중할 수 있는 기회를 제공한 것이다. AI는 반복적이고 기계적인 업무를 줄이고, 창의성과 전략적 사고 등 인간만의 강점을 살릴 수 있도록 지원하는 수단이다. 변호사는 AI를 통해 긴 문서를 요약하고 핵심만 추출하고, 프로그래머는 코드 생성·테스트는 AI의 도움을받고 보다 생산석이고 창의적인 설계에 몰두하고, 교사는 소모적 문서 생성과 관리 업무에서 벗어나 맞춤형 수업 자료 생성과 평가 설계에 집중할 수 있는 가능성을 만들어준다. 요는 AI는 *인간을 대체하기보다는 인간 능력을 증강(augment)*하는 방식으로 작동하는 것이다.

현실적으로 일부 일자리가 사라지는 것은 불가피하며 그 과정에서 고통스런 전환을 요구할 수 있다. 반복적인 고객응대, 기본적인 마케팅 콘텐츠 제작 등 관행화된

업무는 AI로 대체될 것이고 관련 직종 종사자의 실업은 불가피하다. 반면에, 세계경제포럼(WEF)에 따르면 8,500만 개 일자리가 AI로 인해 사라지지만, 9,700만 개의 새로운 직무가 창출될 것으로 전망하기도 했다. Capgemini의 조사에 따르면: AI를 도입한 1,000개 기업 중 80% 이상이 오히려 일자리 증가를 경험하고 있다. 즉 프롬프트 엔지니어, AI 윤리 전문가, AI 전략 기획자 등 새로운 형태의 과업과 일자리가 등장하고 있다.

☞시청: 인공지능 노동력 해고와 대응 전망
https://youtu.be/DHGqBCc-IDs?si=wiYP9izBSym7BksB

☞시청: 인공지능의 미래와 신인간 탄생 SERI 특강
https://www.youtube.com/live/pV328QYZJiw?si=gz5DdLiY8N_r9wPU

☞ 생각거리: 기본소득론에 대한 다음 주장에 대하여 비판적으로 성찰해보라.
"AI로 인한 구조적 실업 때문에 일하고 싶어도 일할 기회를 얻을 수 없는 사람들을 위해 기본소득(basic income)을 도입해야 한다"는 주장이 있다. 역사적으로 기술 혁신은 일자리를 대체하면서도 새로운 일자리를 창출해왔다. 20세기 초 농업 노동자의 90%가 다른 직종으로 전환했지만 대량 실업은 발생하지 않았다. 현재도 AI 시대에 프롬프트 엔지니어, AI 윤리 전문가, 데이터 큐레이터 같은 새로운 직업이 등장하고 있다. 문제는 실업 자체가 아니라, 전환 과정에서의 교육·재훈련 시스템 구축과 노동의 의미를 재정의하는 사회적 합의 과정이다.”

다. 자본·노동 이분법의 붕괴

20세기 경제학은 자본(capital)과 노동(labor)이라는 두 가지 생산요소를 중심으로 구축되었다. 자본가는 공장·기계·건물을 소유하고, 노동자는 육체적·정신적 노동력을 제공한다. 소득 분배는 이 두 요소 간 협상과 시장 메커니즘으로 결정되었다. 마르크스 경제학이든 신고전파 경제학이든, 자본-노동 이분법은 경제 분석의 기본 틀이었다.

그러나 21세기 AI 경제에서는 데이터·모델·알고리즘·플랫폼이 독자적 생산요소로 기능한다. 구글의 검색 알고리즘, 넷플릭스의 추천 시스템, 테슬라의 자율주행 모델은 전통적 자본(서버, 건물)도 아니고 노동(직원의 근무시간)도 아니다. 이들은 무형의 지적 시스템이자 학습된 지능으로서, 생산 과정에서 핵심적 역할을 하며 막대한 가치를 창출한다. AI 모델 자체가 자본이 되는 구조다.

더 복잡한 점은 개인의 역할이 다층화된다는 것이다. 한 사람이 우버 운전을 하면

노동자지만, 동시에 자신의 운행 데이터를 제공하여 우버의 알고리즘을 학습시키는 '데이터 제공자'이기도 하다. 인스타그램 사용자는 콘텐츠를 생산(노동)하면서 동시에 자신의 행동 데이터로 플랫폼의 추천 알고리즘을 훈련시킨다(학습 자원). 이는 전통적 노동자 개념으로 포착되지 않는다.

실제 사례로, OpenAI의 ChatGPT는 수억 명의 대화 데이터로 학습되어 개선된다. 사용자들은 무보수로 AI를 훈련시키는 셈이다. 2023년 작가들이 OpenAI를 상대로 제기한 저작권 소송은 자신의 창작물(데이터)이 AI 학습에 무단으로 사용되었다는 주장이다. 이는 "누가 AI 생산요소의 소유자인가"라는 새로운 분배 논쟁이다.

또한 2024년 EU의 AI Act는 데이터 제공자의 권리를 명시하려 시도했지만, 구체적 보상 구조는 여전히 미정이다. 중국의 알리바바는 타오바오 판매자들의 거래 데이터를 활용해 신용 평가 모델을 구축했고, 이를 기반으로 소상공인에게 대출을 제공한다. 여기서 데이터는 자본도 노동도 아닌 제3의 생산요소로 작동한다.

이러한 변화는 소득 분배 구조의 근본적 재편을 요구한다. 데이터 배당, 알고리즘 소유권 공유, 플랫폼 협동조합 같은 새로운 소유 개념이 논의되고 있다. 전통적 자본-노동 이분법으로는 21세기 AI 경제의 분배 정의를 설명할 수 없다. 새로운 경제학적 틀이 필요한 시점이다.

라. 학벌 중심 사회의 쇠퇴 가능성

한국을 비롯한 많은 사회에서 명문대 학위는 개인의 지식 수준과 능력을 보증하는 신호(signal)로 기능해왔다. 기업은 채용 과정에서 학벌을 통해 지원자의 학습 능력, 문제 해결 능력, 사회적 네트워크를 간접적으로 평가했다. 이는 정보 비대칭 상황에서 효율적인 선별 장치였다. 20세기 산업 사회에서는 체계적 교육을 받은 인력이 희소했고, 대학 교육이 실질적 지식 격차를 만들어냈다.

그러나 AI 시대에는 이러한 전제가 흔들린다. ChatGPT, Claude 같은 생성형 AI는 누구에게나 고급 지식에 대한 접근을 평등하게 제공한다. 법률 자문, 코딩 튜터링, 비즈니스 전략 분석, 학술 논문 해석 등을 AI가 즉시 제공할 수 있다면, 명문대에서 수년간 배운 지식의 희소성은 감소한다. 독학으로도 전문가 수준의 지식 습득이 가능해지는 것이다.

실제로 미국의 팔란티어(Palantir)는 2021년부터 대학 학위를 요구하지 않는 채용을 확대했다. 고등학교 졸업 후 독학으로 데이터 분석과 프로그래밍을 익힌 지원자들이 실제 프로젝트에서 우수한 성과를 보였기 때문이다. 구글도 2024년 발표에서 특정 직무의 20%는 학위 없이 실무 경험과 포트폴리오만으로 지원 가능하다고 밝혔다. 이는 AI 도구 활용 능력이 전통적 학력보다 중요해졌음을 시사한다.

그러나 "명문대 졸업이 의미 없어지는 사회가 올 것"이라는 전망에는 비판적 분석

이 필요하다. 첫째, 대학은 단순 지식 전달 기관이 아니다. 네트워크 형성, 협업 경험, 연구 방법론 체득, 멘토와의 관계 등 암묵지(tacit knowledge)와 사회적 자본 축적의 장이다. 이는 AI가 대체하기 어렵다. 둘째, AI 활용 능력 자체도 학습이 필요하며, 체계적 교육을 받은 이들이 AI를 더 효과적으로 활용할 가능성이 높다. MIT의 2023년 연구에 따르면, AI 도구를 사용한 업무 성과는 기존 전문성 수준에 비례해 증가했다. 즉, AI는 평등화 도구가 아니라 증폭 도구일 수 있다.

셋째, 신호 기능은 여전히 중요하다. 기업 입장에서 명문대 학위는 "4년간 꾸준히 학습하고 경쟁을 통과한 자기관리 능력"의 증거다. AI 시대에도 신뢰할 수 있는 신호의 필요성은 사라지지 않으며, 다만 그 신호가 학위에서 포트폴리오, 프로젝트 경험, AI 활용 성과물로 다양화될 가능성이 있다. 한국 교육부의 2024년 조사에서도 대기업 인사담당자의 68%는 여전히 학벌을 주요 선발 기준으로 고려한다고 응답했다.

결론적으로, AI는 학벌 중심 사회에 균열을 내고 있지만, 그것이 곧 학벌의 소멸을 의미하지는 않는다. 오히려 "무엇을 배웠는가"에서 "무엇을 할 수 있는가"로 평가 기준이 이동하는 과도기적 변화로 이해해야 한다.

마. 조직의 소규모, 개인화

20세기 산업 사회의 효율성은 조직 내부의 역할 분업과 위계 구조에서 나왔다. 한 사람이 모든 업무를 수행하기보다, 기획팀·생산팀·마케팅팀·재무팀이 각자 전문성을 발휘하고 협력하는 것이 더 효율적이었다. 코즈(Coase)의 거래비용 이론은 시장에서 매번 거래하는 것보다 조직 내부에서 장기 고용 관계를 유지하는 것이 비용 절감에 유리하다고 설명했다. 대기업, 관료제, 수직적 의사결정 구조가 지배적이었던 이유다.

그러나 21세기 AI 시대에는 개인이 AI 에이전트를 통해 복수의 역할을 동시에 수행할 수 있다. 한 명의 프리랜서가 AI를 활용해 시장 조사(AI 데이터 분석), 제품 디자인(생성형 AI), 마케팅 카피 작성(언어 모델), 재무 계획(AI 회계 도구)을 모두 처리할 수 있다. 조직의 규모는 경쟁 우위가 아니라 오히려 비효율의 원천이 될 수 있다. "개인+AI" 조합이 중간 규모 조직보다 빠르고 유연하게 대응할 수 있기 때문이다.

실제 사례로, 미국의 그래픽 디자이너 일라이 버튼(Eli Burton)은 2023년 혼자서 연매출 200만 달러의 디자인 비즈니스를 운영했다. Midjourney, Figma AI, ChatGPT를 활용해 고객 상담부터 디자인 초안 작성, 계약서 관리, 마케팅까지 모두 처리했다. 전통적으로는 최소 5~10명의 팀이 필요한 규모다.

또한 한국의 1인 크리에이터 시장도 급성장하고 있다. 2024년 통계청 자료에 따

르면 1인 미디어 콘텐츠 창작자는 전년 대비 34% 증가했으며, 이들 중 상당수가 AI 편집 도구, AI 썸네일 생성기, AI 자막 생성기를 활용한다. 기업 형태가 아니라 개인+AI 구조로 경쟁력을 확보하는 사례다.

거시적으로도 변화가 감지된다. 맥킨지의 2024년 보고서는 미국 노동인구의 36%가 프리랜서로 일하며, 이 비율이 2030년까지 50%에 육박할 것으로 전망했다. 독일의 '마이크로 기업(micro-enterprises)' 통계는 직원 없이 운영되는 1인 기업이 전체 기업의 62%를 차지한다고 밝혔다. 이는 단순한 고용 형태 변화가 아니라, 경제 활동의 기본 단위가 조직에서 개인으로 이동하는 구조적 전환이다.

이러한 전환은 사회 시스템에도 영향을 미친다. 건강보험, 연금, 산재보험 등 20세기 복지제도는 모두 조직 고용을 전제로 설계되었다. 프리랜서와 1인 기업 중심 사회에서는 이들을 어떻게 사회 안전망에 포함시킬 것인가가 중대 과제다. 또한 협상력 불균형 문제도 있다. 대기업과 계약하는 프리랜서는 개별적으로 약자일 수 있으며, 새로운 형태의 집단 교섭 구조가 필요하다. 조직 중심에서 개인-에이전트 중심으로의 전환은 효율성 증대와 함께 새로운 사회적 보호 시스템 구축을 요구한다.

5. 시장 메커니즘의 변화: 가격 신호에서 예측·추천 구조로

20세기 시장경제는 가격 메커니즘을 통해 작동했다. 하이에크(Hayek)가 강조했듯, 가격은 분산된 정보를 집약하는 신호다. 사과 가격이 오르면 생산자는 공급을 늘리고 소비자는 수요를 줄인다. 이 과정에서 중앙 계획 없이도 자원이 효율적으로 배분된다. 소비자는 가격 정보를 보고 자유롭게 선택하며, 이러한 무수한 선택의 집합이 시장 균형을 만든다.

그러나 21세기 AI 시장에서는 예측, 추천, 자동 최적화가 선택을 선도한다. 아마존은 소비자가 검색하기 전에 이미 "당신이 좋아할 만한 상품"을 제시한다. 넷플릭스는 수백만 콘텐츠 중 개인화된 10개를 홈 화면에 배치한다. 우버는 실시간 수요 예측으로 가격을 동적 조정(surge pricing)한다. 이때 소비자는 가격 신호를 비교하는 것이 아니라, 알고리즘이 제시한 옵션 중에서 선택한다. 시장의 조정 메커니즘이 가격에서 알고리즘으로 이동하는 것이다.

실제 사례를 보면, 2023년 아마존 매출의 35%는 추천 시스템에서 발생했다. 소비자가 "능동적으로" 검색한 것이 아니라, 알고리즘이 "제안한" 상품을 구매한 것이다. 스포티파이는 사용자가 듣는 음악의 40% 이상이 알고리즘 생성 플레이리스트에서 나온다고 밝혔다. 이는 소비자의 자유로운 선택이 알고리즘에 의해 재구성되고 있음을 보여준다.

더 논쟁적인 사례는 동적 가격 책정이다. 우버의 서지 프라이싱(surge pricing)은 수요가 높을 때 가격을 2~3배 올린다. 이는 전통적 가격 메커니즘 같지만, 실제로는 AI가 실시간으로 수요를 예측하고 최적 가격을 계산한 결과다. 2024년 미국에서

는 슈퍼마켓 체인들이 전자 가격표를 도입해 시간대·재고·소비자 구매 이력에 따라 가격을 변동시키려 했으나, 소비자 반발로 일부 주에서 금지되었다. 알고리즘 가격 책정이 "공정한 시장"인지 "가격 차별"인지에 대한 사회적 합의가 부재한 상황이다.

이러한 변화는 시장 실패와 독점 개념의 재정의를 요구한다. 전통 경제학에서 독점은 "가격 지배력"으로 정의되었다. 그러나 구글 검색은 무료지만, 검색 결과 순위를 결정하는 알고리즘은 막대한 시장 지배력을 행사한다. EU는 2024년 구글에게 68억 유로 벌금을 부과하며 "검색 알고리즘 편향"을 반독점법 위반으로 판단했다. 가격이 아니라 알고리즘이 시장 왜곡의 핵심이 된 것이다.

또한 소비자의 "선택 자유"도 재검토가 필요하다. 행동경제학은 이미 인간이 완전히 합리적이지 않음을 보였지만, AI 추천은 이를 더욱 복잡하게 만든다. 알고리즘이 개인의 과거 행동 데이터를 기반으로 선택지를 제한할 때, 그것은 선호의 반영인가 조작인가? 유튜브 알고리즘이 특정 정치 성향의 콘텐츠만 추천하면 "필터 버블"이 형성된다. 이는 시장의 다양성과 민주적 공론장을 훼손할 수 있다. 21세기 시장 메커니즘은 효율성뿐 아니라 공정성, 투명성, 다양성 측면에서 새로운 규제 프레임워크를 요구한다.

바. 성문법과 제도에서 모델과 코드로

20세기 사회 통제는 법, 제도, 사회적 규범을 중심으로 작동했다. 미국의 법학자 로렌스 레식(Lawrence Lessig)이 지적했듯, 법(law), 규범(norms), 시장(market), 아키텍처(architecture)가 행동을 규제한다. 범죄를 저지르면 법적 처벌을 받고, 사회적 비난을 받으며, 경제적 불이익을 겪는다. 이 시스템에서 책임 주체는 명확하다. 인간 개인이나 조직이 행위의 주체이며, 잘못이 있으면 그들이 책임진다.

그러나 21세기 AI 사회에서는 코드, 모델 설계, 데이터 편향이 성문법 또는 명시적인 규정보다 사실상의 규제로 작동하게 된다. 신용 평가 알고리즘이 대출을 거부하면, 그것은 법적 규제가 아니지만 개인의 경제 활동을 실질적으로 통제한다. 채용 AI가 특정 이력서를 자동으로 걸러내면, 지원자는 면접 기회조차 얻지 못한다. 소셜 미디어 알고리즘이 특정 게시물의 도달 범위를 제한하면, 표현의 자유가 코드에 의해 조정된다. "Code is Law"라는 말처럼, 알고리즘 설계가 곧 사회적 규칙이 되는 것이다.

실제 사례로, 아마존의 AI 채용 도구는 2018년 여성 지원자를 체계적으로 불리하게 평가한다는 사실이 드러나 폐기되었다. 과거 남성 중심 채용 데이터로 학습한 결과였다. 이는 법적으로 성차별이 금지되어 있어도, 모델 설계와 데이터 편향이 실질적 차별을 만들어낸 사례다. 2019년 네덜란드 정부의 복지 사기 탐지 알고리즘은 저소득층과 이민자 커뮤니티를 부당하게 타겟팅해 수천 가정이 잘못된 환수 명령을

받았고, 정부는 사과하며 시스템을 폐기했다.

미국에서는 형사 사법 시스템의 재범 예측 알고리즘 COMPAS가 흑인 피고인에게 더 높은 재범 위험 점수를 부여한다는 ProPublica의 2016년 보도가 논쟁을 일으켰다. 판사가 이 점수를 참고해 형량을 결정하면, 알고리즘의 편향이 곧 형사 처벌에 영향을 미치는 것이다.

이러한 변화는 책임 주체의 모호화를 낳는다. AI가 잘못된 결정을 내렸을 때, 누가 책임지는가? 알고리즘을 개발한 엔지니어인가, 데이터를 제공한 조직인가, AI를 도입한 경영진인가, 아니면 AI 자체인가? 2024년 EU AI Act는 고위험 AI 시스템에 대해 개발자와 배포자의 책임을 명시하려 했지만, 복잡한 AI 파이프라인(데이터 수집→학습→배포→지속 학습)에서 책임 경계를 정하기는 여전히 어렵다.

더 근본적 문제는 민주적 통제의 어려움이다. 법은 입법 과정을 거쳐 사회적 합의로 만들어진다. 하지만 알고리즘은 기업 내부에서 설계되며, 공개되지 않고, 지속적으로 업데이트된다. 시민이 알고리즘 설계에 참여할 통로가 없다. 페이스북의 뉴스피드 알고리즘은 수억 명의 정보 접근에 영향을 미치지만, 그 작동 방식은 기업 기밀이다. 이는 민주주의의 근간인 "공개성"과 "참여"를 우회한다.

결국 21세기 사회는 윤리와 책임 개념을 구조적으로 재검토해야 한다. 알고리즘 투명성 의무화, AI 결정에 대한 설명 요구권, 독립적 알고리즘 감사 기구 설립 등이 논의되고 있다. 그러나 근본적으로는 "누가 AI를 통제하는가"라는 권력 문제다. 기술이 사회 질서를 형성하는 시대에, 그 기술을 민주적으로 거버넌스할 수 있는 새로운 제도적 틀이 필요하다.

사. 전반적 IT 운영비용의 하락

20세기 후반부터 진행된 디지털화는 초기에 거대한 운영비용을 수반했지만, 최근 한 세대에 걸친 급속한 발전 과정에서 사회 전반의 IT 운영 비용은 점점 하락해온 추세를 보여주었다.

2000년대 초반 닷컴 붐 시기부터 2020년대 AI 혁명에 이르기까지, 정보기술의 진보는 매 단계마다 디지털 서비스의 구축과 운영에 필요한 비용과 진입 장벽을 구조적으로 낮춰왔다. 이 과정은 단순한 기술 발전의 연속이 아니라, 자본·노동·지식의 결합 방식이 시대별로 어떻게 변화해 왔는지를 보여준다.

표 14 2000년대 이후 IT 운영 비용 구조 변화

시대	핵심 기술 패러다임	주요 비용 항목	비용 구조의 특징	진입 장벽
2000년대 초	물리 서버·상용 SW	서버 구매, 데이터센터, 상용 라이선스, 전문 운영 인력	고정비(CapEx) 중심, 확장 비용 급증	매우 높음
2000년대 중반	오픈소스	개발 인력 인건비, 일부 하드웨어	SW 라이선스 비용 급감, 인력 의존 지속	중간
2010년대	클라우드 컴퓨팅	사용량 기반 인프라 비용(OpEx), DevOps 인력	소유 → 임대, 자동화로 운영비 절감	낮음
2023년~현재	AI·AI 에이전트	AI 사용료, 데이터, 최소 인력	인간 노동 비용의 직접적 대체, 시간 비용 급감	매우 낮음

■ 2000년대 초반: 하이엔드 하드웨어와 상용 소프트웨어의 시대

이 시기는 “모든 것이 비싸던 시대”였다. 기업이 인터넷 서비스를 운영하기 위해서는 고가의 물리 서버를 직접 구매해야 했고, 데이터센터 구축과 유지에도 막대한 초기 자본지출(CapEx)이 필요했다. 운영체제는 Unix 계열이 주류였고, 데이터베이스는 Oracle, DB2와 같은 상용 소프트웨어가 사실상 표준이었다. 서버 증설은 곧 자본 투자를 의미했으며, 장애 대응과 운영은 숙련된 시스템 엔지니어 인력에 전적으로 의존했다. 결과적으로 IT 서비스는 대기업이나 대규모 자본을 보유한 조직만이 감당할 수 있는 영역이었다.

■ 2000년대 중반: 오픈소스와 소프트웨어 비용의 붕괴

Linux를 중심으로 한 오픈소스 생태계의 확산은 소프트웨어 비용 구조를 근본적으로 바꾸었다. LAMP(Linux-Apache-MySQL-PHP/Python/Perl) 스택은 상용 라이선스 없이도 웹 서비스를 구축할 수 있음을 증명했다. 소프트웨어 라이선스 비용이 급격히 낮아지면서, 서비스 개발의 핵심 제약은 자본이 아니라 개발자의 역량과 아이디어로 이동했다. 이 시기부터 스타트업과 소규모 개발팀이 본격적으로 등장했고, “아이디어만 있으면 시작할 수 있는” 환경이 처음으로 현실화되었다.

■ 2010년대: 클라우드 컴퓨팅과 운영 효율의 극대화

2010년대는 클라우드 컴퓨팅이 IT 인프라의 기본 전제가 된 시기다. **Amazon Web Services**로 대표되는 퍼블릭 클라우드는 서버와 스토리지, 네트워크를 '소유'가 아닌 '임대'의 대상으로 전환시켰다. 이에 따라 기업의 IT 비용 구조는 대규모 초기 투자(CapEx)에서 사용량 기반의 운영비(OpEx) 중심으로 바뀌었다. 서버실은 사라졌고, 자동 확장(auto-scaling)과 관리형 서비스가 운영 부담을 크게 줄였다. 이후 DevOps 문화, 컨테이너, 서버리스(Serverless) 기술은 인프라 운영에 필요한 인력과 시간을 추가로 감소시키며, 기술 효율을 극대화했다.

■ 2023년 이후: AI 에이전트와 인간 노동 비용의 직접적 대체

2020년대 중반 이후 본격화된 AI 기술, 특히 생성형 AI와 AI 에이전트의 확산은 이전 단계들과 질적으로 다른 변화를 만들어내고 있다. 과거의 혁신이 주로 인프라와 도구의 비용을 절감했다면, 이제 AI는 IT 비용에서 가장 큰 비중을 차지하던 인간의 지식 노동 시간 자체를 직접 대체하기 시작했다. 코딩, 디버깅, 테스트, 문서화, 배포, 심지어 기획과 설계의 일부까지 AI가 관여하면서 개발에 소요되는 시간과 인력 규모는 급격히 축소되고 있다. 이는 단순한 비용 절감이 아니라, "생각하는 속도와 구현되는 속도의 격차가 사라지는" 새로운 생산 체계의 출현을 의미한다. 과거에는 수십 명의 개발자와 수억 원의 예산이 필요했던 서비스가, 이제는 한 명의 기획자와 여러 AI 에이전트의 협업만으로도 며칠 혹은 몇 주 안에 완성되는 사례가 현실이 되고 있다.

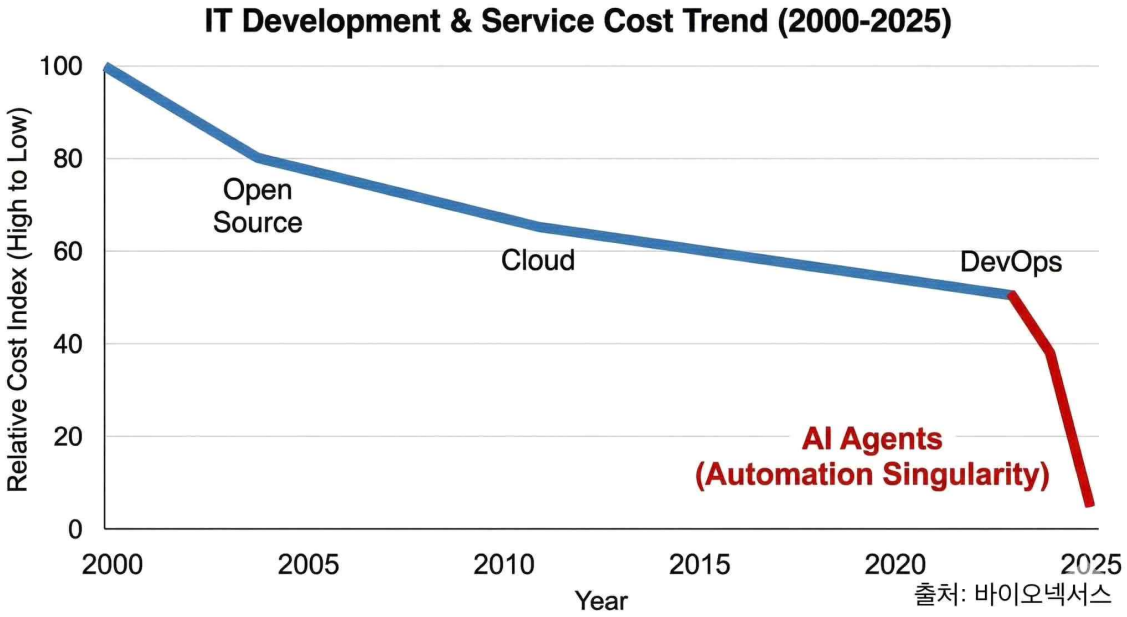

그림 29 2000년대 이후 IT 운영 비용의 하락 추세

아. AI 전환(AX)의 효과와 한계

1) 과거 DX 경험과의 비교

많은 기업들이 과거 디지털 전환(DX) 경험을 AI 전환(AX)에 그대로 적용하려다 실패한다. DX는 주로 업무 프로세스의 디지털화와 시스템 통합에 초점을 맞췄다. 종이 문서를 전자화하고, ERP를 도입하며, 클라우드로 이전하는 것이 핵심이었다. 이 과정은 명확한 목표와 단계적 실행이 가능했다. 그러나 AX는 본질적으로 다르다. AI는 도구가 아니라 의사결정 파트너이며, 그 효과는 데이터 품질과 조직 문화에 따라 극적으로 달라진다.

첫 번째 장애 요인은 '기술 중심 사고'다. DX 시절 많은 기업들이 "일단 시스템부터 도입하자"는 접근을 취했고, 이것이 어느 정도 통했다. 하지만 AI는 데이터 없이 작동하지 않는다. 맥킨지 2023년 조사에서 AI 도입 기업의 61%가 "데이터 품질 부족"을 최대 장애물로 꼽았다. 실제로 한국의 한 제조기업은 수억 원을 들여 품질 검사 AI를 도입했으나, 20년간 축적된 불량품 이미지 데이터가 표준화되지 않아 정확도가 60%에 그쳤다. 기술이 아니라 데이터가 선행 조건이라는 인식 전환이 필요하다.

두 번째는 '하향식 도입 방식'이다. DX는 경영진이 결정하고 IT부서가 실행하면 됐다. 그러나 AI는 현장 직원들이 실제로 활용해야 효과가 나타난다. 미국 보험사 Progressive는 2022년 AI 기반 보험금 심사 시스템을 도입했으나, 심사역들이 "AI를 신뢰할 수 없다"며 거부해 1년간 사용률이 15%에 머물렀다. 결국 심사역들을 개발 초기부터 참여시키고 6개월간 교육한 후에야 정착됐다.

세 번째는 'ROI 측정 방식의 오류'다. DX는 비용 절감 효과를 명확히 계산할 수 있었다. 하지만 AI의 가치는 "더 나은 판단"에서 나오며, 이는 장기적이고 간접적이다. 단기 ROI 압박은 AI 실험과 학습을 가로막는다.

2) AX의 ROI(투자 대비 수익)

※ROI 에 대한 기본 개념: ROI(Return on Investment)는 투자액(investment) 대비 연간수익률을 의미한다. 예를 들어서 어떤 프로젝트에 돈 1,000만원을 투입해서 해마다 100만원의 순이익(net profit)을 얻는다면, ROI= 100만원/1,000만원 = 10%다. 순이익 = 총수입 - 총비용이다. 즉 한 해에 그 프로젝트에서 300만원의 수입(즉 매출)이 발생했는데, 각종 비용(인건비, 재료비, 기타 각종 경비)이 100만원 발생했

다면 순이익은 300만원-200만원=100만원이 된다. 한 해애 매출이 300만원인데 비용이 400만원으로서 -100만원큼 순손실이 발생한다면 ROI = -10%가 된다.

1,000만원을 투자하는 가장 단순한 프로젝트는 은행에 예금하는 것이다. 한 해 이자율이 2%라면, 한 해에 이자수익이 20만원 발생하고, 여기에서 이자소득세 2만8천원을 차감하면 순이익은 17만2천원이 되고 ROI = 1.72% 이다. 비교적 낮은 수준이다.

AI 전환의 ROI(Return on Investment)는 도입하는 사례마다 차이가 크다. 높은 ROI를 달성한 사례로, 글로벌 물류기업 DHL은 2021년 AI 기반 배송 경로 최적화 시스템을 도입해 연료비 15% 절감, 배송 시간 12% 단축, 탄소 배출 18% 감소를 달성했다. 투자 회수 기간은 8개월이었다. 성공 요인은 명확한 데이터(GPS, 교통정보, 배송 이력)와 측정 가능한 목표(비용, 시간)였다.

※ AI전환의 ROI는 엄밀하게는 다음과 같은 공식으로 계산해야 한다.

$$ROI_{AI\text{전환}} = \frac{AI\text{전환에서 발생한 한 해의 순이익}}{AI\text{전환에 소요된 투자액}}$$

문제는 분자와 분모에 해당하는 금액을 정확히 분리해서 계측하는 작업이 생각외로 복잡하다는 것이다. 이 문제는 원가회계(cost accounting)라는 분야에서 체계적인 절차를 통해 계산해야 한다.

그러나, 이 계산이 매우 전문적인 과정이 필요하기 때문에, 실무에서는 간편하고 직관적인 이해를 돕기 위해, 특정 비용(위 예시의 “연료비 15% 절감, 배송 시간 12% 단축 같은 식”의 절감율 내지 수익의 증가율(예를 들어 AI 전환 이전보다 전환 이후 매출액이 20%늘었다는 식)로 표기하는 것으로 대체하는 관행이 있다.

미국 은행 Capital One은 AI 기반 사기 탐지로 연간 2억 달러의 손실을 방지했다. 이들은 5년간 데이터 인프라에 먼저 투자했고, 데이터 과학자 팀을 200명 규모로 확대했다. 2024년 발표에서 AI 관련 투자 대비 ROI가 300%를 넘었다고 밝혔다.

반면 실패 사례도 많다. IBM Watson Health는 2016년 암 진단 AI로 주목받았으나, 2022년 매각됐다. 병원들은 도입 후 "실제 임상에서 부정확한 권고"를 경험했고, 의사들의 신뢰를 얻지 못했다. 수십억 달러 투자 대비 상업적 성과는 미미했다. 문제는 훈련 데이터가 실제 임상 환경과 달랐고, 의료진 워크플로우를 고려하지 않은 설계였다.

한국의 한 대형 유통기업은 2023년 AI 기반 수요 예측 시스템에 30억 원을 투자했으나, 재고 감축률이 3%에 그쳤다. 기존 직원들의 경험적 판단(15% 감축)보다 못

한 결과였다. 분석 결과, AI 학습에 사용된 과거 판매 데이터에 프로모션, 날씨, 경쟁사 정보가 통합되지 않았기 때문이었다.

성공 사례의 공통점은 (1) 양질의 데이터 확보, (2) 명확하고 측정 가능한 목표, (3) 현장 직원의 참여와 신뢰다. 실패 사례는 기술 과신, 데이터 품질 간과, 조직 변화 관리 부재가 원인이었다. AI의 ROI는 기술 자체보다 도입 방식에 달려 있다.

3) 효과적인 AX 달성

기업이 효과적으로 AI 전환을 달성하려면 세 가지 조건이 필수적이다.

첫째, 데이터 우선 전략이다. AI 도입 전에 데이터 수집·정제·통합 체계를 먼저 구축해야 한다. 아마존은 20년 이상 고객 데이터를 체계적으로 축적했기에 추천 시스템이 작동한다.

둘째, 점진적 실험 문화다. 처음부터 전사적 AI 전환을 시도하면 실패 위험이 크다. 작은 파일럿 프로젝트로 시작해 학습하고, 성공 사례를 확장하는 방식이 효과적이다. 구글은 내부적으로 수백 개의 AI 실험을 동시에 진행하며, 그중 10%만 확대한다.

셋째, 인간-AI 협업 설계다. AI가 인간을 대체하는 것이 아니라, 인간의 판단을 보조하도록 설계해야 한다. 의사 결정 권한은 인간에게 남겨두되, AI가 더 나은 정보를 제공하는 구조다. 이는 직원들의 저항을 줄이고 AI 활용도를 높인다. 결국 AX의 성패는 기술이 아니라 사람과 조직의 준비도에 달려 있다.

자. AI 창업

1) 개요

AI 스타트업 생태계는 전 세계적으로 폭발적 성장세를 보이고 있으나, 국가별로 기업 수, 투자 규모, 성과에서 큰 격차가 나타난다. 한국은 AI 산업 육성을 위한 정부 정책을 강화하고 있으나 미국과 중국에 비해 여전히 기업 수와 투자 규모에서 차이를 보이며, 글로벌 경기 둔화와 높은 실패율 속에서 AI 창업 생태계의 지속가능한 성장이 과제로 남아 있다.

■ 한국 AI 창업 현황

한국의 AI 기업은 2024년 기준 약 2,517개로 집계되었으며, 이 중 60.1%가 인공지능을 주사업으로 영위하고 39.9%는 타 사업을 주력으로 하면서 AI를 활용한다. 설립 시기를 보면 2015~2019년에 설립된 기업이 45.0%로 가장 많고, 2020년 이후 설립된 기업이 21.4%를 차지하여 AI 창업이 최근 5~10년 사이 집중적으로 이루어

졌음을 확인할 수 있다.

포브스코리아가 선정한 '2025 대한민국 AI 50'에서는 더브이씨(The VC) 기업정보 DB 기준 총 924개의 AI 스타트업이 1차 후보로 추출되었다. 그러나 전체 창업 추세는 부정적이다. 2024년 새로 창업한 기술기반 스타트업은 21만4,917개로 전년 대비 2.9% 감소했으며, 2021년 역대 최대치를 기록한 후 3년 연속 감소세를 나타냈다.

우리나라의 대표적인 생성형 AI 스타트업 뤼튼테크놀로지스는 월간 활성 이용자 500만 명을 돌파했고 누적 투자유치액 480억원을 기록했으며, AI 검색 서비스 라이너는 440억원, 마크비전도 상당한 투자를 유치했다[28].

■미국

미국은 전 세계 AI 창업 생태계의 절대 강자로, 기업 수와 투자 규모 모두에서 압도적 우위를 점하고 있다. 2024년 글로벌 AI 투자 1,930억 달러(약 280조원) 중 42%(807억 달러)가 미국 기반 기업에 집중되었다. 2024년 전 세계 생성 AI 기업들이 총 885건의 거래를 통해 560억 달러(약 79조원)를 유치했으며, 이는 2023년의 291억 달러에서 2배가량 증가한 금액이다. 미국 외 지역의 스타트업들은 총 62억 달러 투자 유치에 그쳤다.

2025년 1분기 미국 벤처캐피탈 투자금액의 71.1%가 AI 스타트업에 몰렸으며, 이는 2024년의 46.8% 대비 24.3%포인트 급증한 수치다. 2025년 상반기 미국에서 1억 달러 이상 투자를 받은 AI 스타트업은 24곳에 달하며, 2024년에는 49곳이 1억 달러 이상 투자를 유치했고 그중 7개 회사가 10억 달러 이상 규모의 투자를 받았다[29].

AI 스타트업의 실패율은 90%로 매우 높은 것으로 알려져 있으며, 대부분이 창업 초기 몇 년 내에 실패한다.

■중국

중국은 국가 차원의 전략적 지원 아래 AI 산업을 급속도로 성장시키고 있다.

---

28) 정보통신기획평가원(IITP) 2024 인공지능산업 실태조사: https://iitp.kr/kr/1/knowledge/statisticsView.it?masterCode=publication&searClassCode=K_STAT_01&identifier=02-008-250502-000001 ; 중소벤처기업부 창업기업 동향: https://www.index.go.kr/unity/potal/main/EachDtlPageDetail.do?idx_cd=1182 ; 소프트웨어정책연구소(SPRi) AI 창업기업 현황 분석: https://spri.kr/posts/view/23722?code=data_all&study_type=research

29) Stanford AI Index 2025: https://www.spri.kr/download/23630 - Pitchbook AI Funding Data: https://www.aitimes.com/news/articleView.html?idxno=166815 ; TechCrunch Startup Analysis: https://aimatters.co.kr/news-report/ai-news/24124/

2024년 기준 중국 내 AI 기업 수는 약 4,500개에 달하며, 이는 전 세계 AI 기업의 약 15%를 차지한다. 2023년 중국 AI 스타트업은 약 8,000개로, 의료, 핀테크, 교육, 제조 분야에서 주로 사업을 영위한다. 2021년부터 2024년까지 중국에서 신규 등록된 기업은 1,280만 개에 달하며, ChatGPT 출시 이후 AI 특허 보유 지역에서는 분기당 평균 약 5개의 신규 기업이 추가로 설립되었다.

투자 측면에서도 중국 정부와 민간 기업의 적극적 참여가 두드러진다. 알리바바는 3년 동안 3,800억 위안(약 520억 달러) 규모의 투자를 통해 클라우드 및 AI 역량을 강화하고, 텐센트는 2024년 기준 AI에 전년대비 3배 증가한 730억 위안(약 107억 달러)을 투자했다. 알리바바는 2024년 중국 AI 스타트업 문샷 AI에 10억 달러를 투자했고, 이 회사의 기업가치는 단숨에 25억 달러로 상승했다. 문샷 AI는 설립 10개월 만에 기업가치 25억 달러를 돌파했고, 01.AI는 설립 8개월 만에 기업가치 10억 달러를 돌파하는 등 빠른 속도로 유니콘이 되고 있다. 2024년 글로벌 AI 투자에서 중국은 17.2%(76억 달러)를 차지하여 미국, 유럽에 이어 3위를 기록했다. 중국은 14억 인구를 기반으로 한 거대한 데이터와 내수시장, 상대적으로 느슨한 규제 환경, 정부의 강력한 정책 지원을 통해 AI 생태계를 빠르게 확장하고 있다[30].

※ 중국 DeepSeek의 충격

2025년 1월 20일 딥시크(DeepSeek)가 R1 모델을 공개했다. 딥시크는 적은 비용으로 GPT-4급의 고성능 AI 모델을 구현하며 글로벌 AI 시장에 큰 충격을 주었다. R1 모델은 OpenAI의 추론 모델과 동등한 수준의 성능을 보여주며, 특히 수학, 코딩, 논리적 추론 분야에서 강점을 나타냈다. 이 사건은 미국과 중국간 AI 기술 패권 경쟁의 새로운 국면을 연 사건으로 평가받고 있다.

창업자인 량원펑(梁文鋒, Liang Wenfeng)은 퀀트 투자(quant investment)를 전문으로 하는 헤지펀드(hedge fund) 하이플라이어(High-Flyer, 幻方量化)를 공동 창립했었다. 그는 퀀트 투자 프로그램에서 얻은 지식을 바탕으로 생성형 AI 개발로 방향을 선회한 뒤 2023년 7월 딥시크를 설립했다.

딥시크는 특히 자사 모델을 MIT 라이선스 아래 오픈 소스로 개방하여 누구나 상업적으로 자유롭게 사용할 수 있게 했다. 이는 개방형 전략을 통해 AI 생태계 내 영향력을 빠르게 확대하려는 전략이 반영되어 있다고 보인다.

기존 미국의 빅테크 기업들이 수조 원의 데이터 센터 투자와 고사양 AI 칩을 필요로 했던 것과 달리, 딥시크는 훨씬 적은 수준의 자원 투자(약 80억 원)로 최고 수

30) 한국과학기술기획평가원(KISTEP) 중국 AI 동향: https://www.kistep.re.kr/boardDownload.es?bid=0031&list_no=94100&seq=1 ; AI Index 2025 중국 분석: https://www.spri.kr/download/23630

준의 AI 모델을 개발했다고 알려져 있다. 그러나, 실제 중국에서 발표한 그 투자액 수치를 얼마나 신뢰할 수 있는가는 별개의 문제다.

딥시크는 기존 미국의 빅테크 기업과 달리 '증류(distillation)'나 '전문가 혼합(MoE)' 같은 알고리즘 효율성 개선에 집중했다. 특히, 사전 학습 데이터 없이 강화 학습만으로 AI의 추론 능력을 극대화하는 새로운 훈련 방식을 선보였다.

2) 소기업 전성시대

■자본과 인력 장벽의 급격한 하락

과거 대기업만이 감당할 수 있었던 고비용 IT 인프라와 전문 인력이 AI를 통해 모든 사람이 적은 비용으로 접근 가능하도록 민주화되었다.

- [IT 인프라 측면] 클라우드 기반 AI 서비스는 초기 투자 없이 사용량만큼만 비용을 지불하는 구조로, 소기업도 세계 최고 수준의 AI 모델을 활용할 수 있게 되었다.
- [인력 면] OpenAI의 GPT-4, 구글의 Gemini, 앤스로픽의 Claude 같은 최첨단 AI를 API를 통해 저렴하게 이용하면서 소기업은 수십 명의 전문가가 필요했던 업무를 몇 명의 소수 인력으로 처리한다. 고객 상담, 마케팅 콘텐츠 제작, 데이터 분석, 코드 개발, 법률 검토 등 전문 영역에서 AI가 인간 전문가 수준의 결과물을 제공하면서 대기업의 인력 우위가 희석되었다. 예를 들어 5명으로 구성된 스타트업이 AI를 활용하여 과거 50명 규모 조직이 수행하던 업무량을 처리하는 것처럼 말이다.

특히 인력 측면에서 AI의 가장 큰 도움은 과거 많은 전문 인력을 두어야만 해결 가능했던 과업들 가운데 '많은' 부분을 AI를 통해 해결할 수 있다는 데에 있다. 물론 '많은' 부분을 해결할 수 있다는 말은 '모든' 것을 해결할 수 있다는 뜻이 아니다. 정말로 중요한 지식이 구사되어야 할 지점에서, AI가 해결해주지 못하는 과업을 해결할 수 있는 해당 분야 전문가의, '사람'으로서의 지식이 여전히 필요하다는 이야기다. 그런 면에서 여전히 그런 지식 배경을 갖춘 인력이 필요하지만, 그 규모나 범위가 예전보다 확실히 줄어든 것은 사실이다.

예를 들어, IT 프로그래밍 배경 지식이 부족한 사람도 AI에 질의를 해가면서, 소위 바이브 코딩(vibe coding)을 해가면서 어느 정도 작동하는 사업 시스템을 구축할 수는 있다. 하지만, 결정적인 지점에서 발생하는 오류의 해결, 시스템의 비효율적인 구조의 개선, 예외 상황에 대한 대처 등은 여전히 배경 지식을 갖춘 사람 전

문가의 손길을 여전히 필요로 한다.

이는 비단 프로그래밍 개발 영역만의 문제가 아니라, 기획, 생산, 마케팅, 조달, 연구개발, 재무 등 기업의 여러 기능에서도 한결같이 발생하는 문제다. 한 두 사람이 이 모든 업무를 AI의 도움으로 다 처리할 수도 있겠지만, 그 집중도나 성과는 분명히 한계가 있다. 그러므로 사업의 특성에 따라 필요한 최소 인력의 보유는 어느 정도 필요하다. 1인 기업으로 성공한 사례는 비교적 예외에 가깝고 많은 성공 사례들이 공동 창업으로 출발하고 이후 단계마다 필요한 지식을 보유한 직원들을 적절히 채용해가는 일을 지극히 당연한 것이다.

그런 면에서 AI는 사람을 해고하는 역할을 한다기보다는 오히려 기회를 늘려주는 기능을 한다고 볼 수 있다. 다만 그런 기회는 오직 늘 새로운 것을 공부하고 변화를 꾀하는 창업가에게만 해당하는 일이다. 한 가지 전문 지식으로 고정된 일자리에서 동일한 업무만을 수행해온 사람들에게 AI는 단지 일자리를 앗아가는 위협에 불과하다

■소규모 인력으로 글로벌 시장을 석권한 기업들>

○사례1) 글로벌 IT 서비스 개발: Cursor (커서)

커서(Cursor)는 2022년 MIT 출신인 마이클 라일리(Michael Reilly), 안슈 슐라(Anshul Shukla) 등이 공동 창업했다. 이들은 코딩 과정에서 발생하는 반복 작업을 AI가 근본적으로 해결해야 한다는 확신을 갖고, 단순 확장 프로그램이 아닌 AI가 내재된 독립된 에디터를 개발하여 개발자 시장의 혁신을 이끌었다.

과거 대규모 소프트웨어 플랫폼을 구축하려면 수백 명의 개발자가 필요했지만, AI 코드 에디터 스타트업 '커서'는 불과 20명의 인원으로 연간 매출 2억 달러를 달성했다. AI가 코드 작성, 버그 수정, 전체 코드베이스 분석을 대행함으로써 개발 생산성을 수십 배 높였다. 덕분에 소규모 팀만으로도 전 세계 수백만 명이 사용하는 복잡한 기술 인프라를 구축하고 운영하는 대기업형 사업 모델을 실현하고 있다.

○사례2) 고해상도 그래픽 및 미디어 제작: Midjourney (미드저니)

미드저니는 립 모션(Leap Motion)의 공동 창업자였던 데이비드 홀츠(David Holz)가 2021년에 설립했다. 그는 NASA와 막스 플랑크 연구소에서 연구한 엔지니어 출신으로, 자본에 종속되지 않는 독립적인 연구소를 지향하며 투자 없이 AI와 예술의 결합을 이끌어냈다.

과거 게임이나 영화의 고품질 원화 및 그래픽 제작은 거대 스튜디오의 전문 인력 수백 명이 수개월간 매달려야 하는 영역이었다. 창업자 데이비드 홀츠가 이끄는 미드저니는 외부 투자(VC)를 전혀 받지 않고 10명 내외의 초기 인원만으로 연 매출

2억 달러를 돌파하며 2024년 기준 기업가치 100억 달러를 넘보는 유니콘으로 성장했다. 2100만 명 이상의 사용자를 보유하면서도 마케팅 비용을 전혀 쓰지 않고 AI 기술력과 커뮤니티만으로 글로벌 이미지 생성 시장의 26%를 점유했다.

○사례3) 바이브 코딩: 베이스44

이스라엘의 개발자 마오르 슐로모((Maor Shlomo)가 2025년 2월 직원 8명으로 설립한 AI 앱 빌더 스타트업이다. 자연어 프롬프트 입력만으로 앱을 설계하는 무코드 AI 서비스를 개발했다. 기술력을 인정받아 창업 후 6개월만에 글로벌 웹 구축 기업 '윅스(Wix)'에 8000만 달러(약 1100억 원)에 매각되었다. 이는 1인 창업자가 AI 도구만을 활용해 단기간에 대규모 엑싯(Exit)을 달성하며 '솔로프레너'의 잠재력을 전 세계에 증명한 대표적 사례로 꼽힌다.

앞에 소개한 지식 콘텐츠 분야 이외에, 물리적 실체를 다루는 제조업 분야에서도 AI와 자동화 기술을 결합하여 적은 인력으로 전통적 공정을 혁신한 스타트업들이 주목받고 있다.

○사례4: 헤어룸 (Heirloom Carbon Technologies)

대규모 화학 공장이 필요했던 탄소 포집 공정을 AI와 저가 원료를 활용해 소형 시설로 구현한 스타트업이다. 2020년에 인도의 Shashank Samala(CEO 겸 공동창업자)와 Noah McQueen(공동창업자 겸 연구 책임자)에 의해 설립되었다. 자연 상태의 석회석을 이용해 이산화탄소를 흡수하는 과정에 AI 센싱 기술을 도입하여 온도와 습도, 흡수율을 실시간으로 최적화한다. 이를 통해 수백 명의 오퍼레이터 없이도 탄소 제거 효율을 극대화했으며, 마이크로소프트와 대규모 탄소 제거 계약을 체결하는 등 기술력을 입증했다. 물리적 자원을 다루면서도 AI 제어 기술로 운영 인력을 획기적으로 줄인 사례이다.

○사례5: 베르더스페이스인더스트리 (Varda Sapce Industries)

Varda Space Industries는 2021년 1월에 미국의 Will Bruey(CEO)와 Delian Asparouhov(회장 겸 사장)에 의해 설립되었다. 우주라는 특수한 물리적 환경에서 신소재 및 의약품을 제조하는 '우주 공장' 스타트업이다. 지구상에서는 중력 때문에 불가능한 결정 구조를 무중력 상태에서 제조하며, 전 과정을 AI 기반 원격 자동화 시스템으로 관리한다. 2024년 실제 궤도에서 약물을 제조하고 지구로 귀환시키는 데 성공했다. 거대 제조 시설 대신 소형 위성 캡슐과 AI 제어 소프트웨어를 결합함으로써, 전통적인 제약·소재 대기업이 수조 원을 들여야 했던 고순도 물질 생산을

소수 정예 인력으로 수행한다.

○사례7: 언스펀 (Unspun)

Unspun은 Beth Esponnette, Kevin Martin, Walden Lam 세 명이 2015년에 공동 창업했다. 모두 패션 의류 관련 전공을 하고 관련 업계에서 근무하던 사람들이다. 의류 제조 공정의 고질적 문제인 재고와 인건비를 AI 기반 3D 직조 기술로 해결한 하드웨어 스타트업이다. 고객의 신체를 AI 스캔 데이터로 분석한 뒤, 실을 한 가닥씩 엮어 재단 없이 옷을 즉석에서 완성하는 '베가(Vega)' 시스템을 개발했다. 과거 수천 명의 재봉 인력이 필요했던 의류 생산 라인을 AI 소프트웨어와 로봇 직조기 한 대로 대체한 것이다. 타임(TIME)지 선정 '최고의 발명품'으로 이름을 올렸으며, 소규모 스튜디오에서도 대량 생산급 효율을 내는 차세대 제조업 모델을 보여준다.

☞ 시청: AI 확산으로 기획자와 개발자의 업무 경계가 사라지는 현상에 대한 캔디드 이주환 대표와 디지털 크리에이터 조쉬의 대담.

https://www.youtube.com/watch?v=qbhK-dBOhTU

3) 운영비용

앞 절에서 2000년대 이후 IT 운영비용이 획기적으로 절감되어 온 추세를 보여준 바 있다. 이런 배경으로 AI 스타트업의 창업 환경도 훨씬 유리해지고 있다.

AI 스타트업이라고 해서 운영비용 자체가 일반 기업과 다른 구조를 지니는 것은 아니다. 거기에는 IT 운영비용 외에도 비IT 운영비용들도 존재하며, 스타트업이나 성숙기업을 막론하고 모두 동일한 개념의 기업 회계를 적용해서 수익과 비용의 발생 정보, 그리고 자산-부채-자본 상태에 대한 정보를 기록해나가야 한다.

스타트업의 투자액과 운영비용이 어떤 내역으로 그리고 어느 정도의 규모로 발생할지는 시설 투자, 인력 고용, 그리고 제반 경비를 어떤 구조와 규모로 지출하는가에 따라서 달라질 것이다.

그러나 AI 스타트업이 일반기업과 비교했을 때 특징적으로 발생하는 운영비용은 토큰(token) 비용이다.

일반적으로 굳이 AI 스타트업이 아니라 일반 기업이나 개인을 막론하고 대개 유료 구독 AI 서비스를 '챗봇' 수준에서 사용할 것이다. 이런 유료 구독료는 대개 정액제(월, 연 등)로 운영하는 것이 보통인데, 사용량과 상관 없이 비용 청구액이 불변이라면 고정 비용(fixed cost)으로 분류될 것이다. 이때 그 고정 비용은 여타 사업상 비용보다는 상대적으로 낮다고 간주된다.

그러나, 출시 가능한 상품이나 서비스를 개발하기 위해 빅테크 기업의 AI 서비스에 대한 심층 이용료를 지불하는 금액으로 들어가면 문제가 달라진다. 사용자가 단순히 챗봇 모드로 질의를 하고 그 결과를 복붙하는 수준의 업무에 그치지 않고, API를 이용해서 업무 플로우를 자동화하는 것과 같은 단계로 가면 그 사용량에 따라 종량제로 비용이 청구된다. 범용 기능은 그나마 부담이 적지만 고급 기능을 빈번하게 사용하기 시작하면 이때 작업량에 따라 그 청구액이 부담스러울 정도로 상승하게 된다.

■바이브 코딩의 비용

바이브 코딩은 사용자가 자연어로 요구사항을 말하면 AI가 방대한 양의 코드를 생성하는 방식이기에, 일반적인 챗봇보다 토큰 소모량이 압도적으로 많다.

- 입·출력 불균형: 코딩 특성상 시스템 프롬프트(Context)와 전체 코드베이스를 입력으로 넣어야 하므로 입력(Input) 토큰 비중이 매우 높다. 복잡한 프로젝트의 경우 한 번의 요청에 수만 개의 토큰이 소모되기도 한다.
- 중개 수수료: '커서(Cursor)'와 같은 도구는 자체 API 사용 시 표준 단가에 약 20%의 마진을 붙여 청구한다. 이를 절감하기 위해 많은 스타트업과 파워 유저들은 Anthropic(Claude)이나 OpenAI의 API 키를 직접 연결하는 방식을 선택한다.

스타트업들은 토큰 비용을 최대한 줄여가면서 소기의 개발 목표를 달성하기 위해 온갖 방법을 동원한다. 앞에서 사례로 들었던 Base44는 토큰 비용 절감을 위해 다음과 같은 전략을 썼다.

- 모델 믹스(Model Mix): 초기에는 고성능인 OpenAI API를 썼으나, 비용 부담이 커지자 상대적으로 저렴한 AWS Bedrock, Vertex AI(Google), Anthropic 등으로 공급처를 다변화했다.
- 캐싱(Caching) 최적화: 동일한 코드 맥락이 반복되는 특성을 이용해 기본 캐시 시간을 늘려 중복되는 입력 토큰 비용을 획기적으로 줄였다.
- 오류와 비용의 상관관계: 성능이 낮은 모델은 코드를 자주 틀려 재요청(Retry)을 유도하고, 이는 결국 더 많은 토큰 지출로 이어진다. 따라서 "더 비싼 모델로 실수를 줄이고 빨리 완성하는 것이 최종 비용을 낮춘다"는 역설적인 전략을 취하기도 한다.

AI 서비스의 유형에 따라 사용자당 발생하는 비용 편차가 극심하다.

- 단순 기능: AI 요약이나 간단한 텍스트 생성은 사용 건당 비용이 약 $0.0002 수준으로 매우 낮다.
- 심층 분석(Reasoning): 복잡한 코드 설계나 데이터 분석은 건당 $0.20 이상 소모될 수 있으며, 이는 단순 기능보다 약 800~1,000배 비싼 수치이다.
- 결국 2026년의 AI 스타트업들은 단순한 '구독료' 모델에서 벗어나, 실제 토큰 소모량에 따라 요금을 부과하는 사용량 기반(Usage-based) 모델이나 성능과 비용을 절충한 하이브리드 모델을 채택하며 생존을 도모하고 있다.

AI 서비스으 어떤 기능을 어떻게 이용하느냐에 따라 사용자당 발생하는 비용 편차는 극심하다.

- 단순 기능: AI 요약이나 간단한 텍스트 생성은 사용 건당 비용이 약 $0.0002 수준으로 매우 낮다.
- 심층 분석(Reasoning): 복잡한 코드 설계나 데이터 분석은 건당 $0.20 이상 소모될 수 있으며, 이는 단순 기능보다 약 800~1,000배 비싼 수치이다.

☞ 1인 개발자 6개월 Claude Code 이용해서 단순 기능 서비스 코딩 시 (출처: chatGPT 시뮬레이션)

○가상 스타트업 A사 개요

-서비스 유형: AI 기반 지식 요약 & 업무 자동화 SaaS

-개발 인력: 1인 (풀스택 + 기획 + QA)

-개발 방식: Claude Code를 IDE 연동, 요구사항 → 코드 생성 → 수정 → 리팩터링 → 테스트 반복

-개발 기간: 6개월 가정

○코드 규모 가정

- 총 코드 라인 수: 약 45,000 LOC
- Claude가 직접 생성/수정에 관여한 코드: 약 70% 나머지 30%는 사람이 직접 코딩

○바이브 코딩 사용 패턴

-하루 평균 25~40회 프롬프트 왕복

-코드 생성, 에러 수정, 구조 리팩터링 포함

-테스트 코드 생성 빈번

○토큰 사용량 가정 (월별)
입력(Input) 2.5M tokens/월; 출력(Output) 1.8M tokens/월
총합 = 4.3M tokens/월

○가정한 단가
Claude Sonnet 인풋단가 $3 / 1M; 아웃풋 단가 $15 / 1M
Claude Opus (10% 사용) 인풋 단가 $15 / 1M; 아웃풋 단가 $75 / 1M

○월 1회 청구 기준
◇ Sonnet 사용분 (90%)
Input: 2.25M × $3 = $6.75
Output: 1.62M × $15 = $24.30
소계: $31.05
◇ Opus 사용분 (10%)
Input: 0.25M × $15 = $3.75
Output: 0.18M × $75 = $13.50
소계: $17.25
월간 총 API 비용 추정 $48.30 ≈ ***약 $50 / 월***

○6개월 누적 비용 시뮬레이션
개발 초기 → 중반 → 후반으로 갈수록 사용량 증가한다고 가정

월	토큰 사용 배율	월 비용 (USD)
1개월차	0.7×	$35
2개월차	0.9×	$45
3개월차	1.0×	$50
4개월차	1.1×	$55
5개월차	1.2×	$60
6개월차	1.3×	$65
총합		***$310***

앞의 예는 아주 단순한 기능을 대상으로 한 것이지만, 바이브코딩 토큰 비용은 사실 개발 인력을 채용했을 때 예상되는 6개월 인건비 또는 외주비 수천만원에 비하면 거의 6개월간 커피값 수준에 불과하다.

그러나, 바이브 코딩을 실행하는 개발자 수가 많아지거나, 고급 기능을 사용할 때

면 그 비용이 크게 늘어날 가능성이 있다. 예를 들어서 좀 더 고급 기능인 RAG(검색 및 문서삽입) 기능을 호출하게 되면, AI가 목적에 맞게 검색한 특정 문서 데이터를 프롬프트에 추가해서 붙이게 되는데, 이렇게 붙여진 문서의 크기가 인풋토큰의 사용량 크게 증가시키는 주범이 된다. 그리고 바이브 코딩 중 '근거/인용/검증/반박/재질문' 루프까지 계속 돌리면 그만큼 인풋토큰이 늘어나게 된다. 그렇게 되면 6개월간 총토큰 비용은 (원화로) 수십만원대가 아니라 수배만원대로 폭증하게 된다. 스타트업이 각종 고급 기능을 이용해서 완성도 높은 시스템을 개발하려 시도할수록 토큰 비용은 급증하게 된다.

널리 쓰이는 AI 바이브 코딩 에디터인 커서(Cursor)의 데이터와 사용자 보고에 따른 월간 비용 분포는 다음과 같다고 알려져 있다.

- 일반 사용자 (Daily Agent): 월 약 $60~$100를 지출한다. 이는 기본 구독료($20) 외에 고성능 모델(Claude 3.5 Sonnet 등)을 활용한 자동화 기능을 매일 사용할 때 발생하는 비용이다.
- 파워 유저 (Power Users): 여러 개의 AI 에이전트를 동시에 돌리거나 대규모 코드베이스를 분석하는 경우 월 $200~$300 이상의 비용이 발생한다.
- 하드코어 개발자 사례: 최근 해커뉴스(Hacker News)의 한 사례에 따르면, Bolt, Lovable 등 여러 도구를 병행하며 서비스를 구축할 때 월 $300~$500 수준의 청구서를 받는 경우도 빈번하다.

소규모 스타트업이 제품의 첫 버전(MVP)을 바이브 코딩으로 완성할 때까지 지출하는 총 API 비용의 분포이다.

- 프로토타입 단계: 단순한 기능을 갖춘 앱의 초기 모델을 빌드하는 데 약 $2,000~$10,000의 API 비용과 인프라 비용이 소요된다. 이는 순수하게 AI 토큰 비용뿐만 아니라 테스트와 디버깅 과정에서의 반복 요청 비용을 포함한 수치이다.
- 중소규모 에이전트 서비스: CRM 연동이나 다채널 지원 등 복잡한 워크플로우를 가진 서비스를 개발할 경우, 개발 완료 시점까지 약 $15,000~$50,000를 지출하기도 한다.

■AI 동영상 생성 토큰 비용

모델 개발 이외에, AI 영상 등 콘텐츠 제작도 토큰 비용을 발생시킨다.

AI 동영상 제작 API를 사용할 때 토큰 비용은 여러 단계에서 발생한다. 먼저 사용자가 프롬프트를 입력하면 입력 토큰(input tokens)이 계산되는데, 여기에는 텍스트 설명, 시스템 프롬프트, 이전 대화 컨텍스트가 포함된다. 동영상 생성 요청 시

이미지를 참조하는 경우 이미지 토큰도 추가로 계산되며, 일반적으로 고해상도 이미지는 약 1,500~2,000 토큰으로 환산된다.

출력 토큰(output tokens)은 API가 반환하는 응답에서 발생한다. 동영상 생성 API의 경우 직접적인 동영상 데이터가 아닌 작업 ID, 상태 정보, 메타데이터 등이 텍스트 형태로 반환되므로 상대적으로 출력 토큰은 적은 편이다. 하지만 생성 과정에서 여러 차례 상태 확인(polling)을 위해 API를 호출하면 각 호출마다 토큰이 누적된다.

○주요 서비스별 토큰 비용 체계

OpenAI의 Sora나 Runway, Pika Labs 같은 동영상 생성 서비스들은 각기 다른 과금 체계를 운영한다. OpenAI의 경우 GPT-4 Vision 모델을 통한 동영상 분석 시 입력 토큰당 약 0.01달러, 출력 토큰당 0.06달러 수준이다. 동영상 생성 자체는 토큰 기반이 아닌 크레딧 또는 생성 횟수 기반으로 과금되는 경우가 많다.

Anthropic Claude의 경우 Claude 3.5 Sonnet 모델 기준으로 입력 토큰 100만 개당 3달러, 출력 토큰 100만 개당 15달러다. 동영상 분석이나 스크립트 생성 등 전처리 과정에서 이러한 비용이 발생한다. Google의 Gemini 1.5 Pro는 비디오 입력을 지원하며, 1분 동영상이 약 14,000~16,000 토큰으로 계산된다.

○동영상 특성별 토큰 비용 현황

일반적으로 ① 재생시간이 2배 증가하면 토큰 소모는 2.5~3배 증가하는 비선형 특성을 보인다. 이는 프레임 간 일관성을 유지하기 위한 추가 연산 때문이다. ② 해상도가 720p에서 1080p로 증가할 경우 토큰 비용은 약 1.8~2.2배 상승한다. ③ 인물, 복잡한 배경, 카메라 이동, 스타일 변환이 포함된 영상은 정적 이미지 기반 영상보다 평균 30~60% 높은 토큰 비용이 발생한다. ④ 스토리보드 기반 다중 장면 영상은 단일 장면 영상 대비 호출 횟수가 증가하여 총 비용이 크게 확대된다.

반복 생성(iterations)도 비용에 큰 영향을 준다. 첫 생성 결과가 만족스럽지 않아 수정 요청 시 전체 컨텍스트를 다시 전송해야 하므로 토큰이 누적된다. 평균적으로 만족스러운 결과를 얻기까지 35회 반복이 필요하다는 통계가 있으며, 이는 초기 예상 비용의 35배를 의미한다.

배치 처리 시에는 효율성이 개선된다. 10개 동영상을 개별 생성하는 것보다 일괄 요청하면 공통 시스템 프롬프트를 재사용해 토큰을 20~30% 절약할 수 있다. 또한 캐싱 기능을 활용하면 반복되는 컨텍스트에 대해 토큰 비용을 90%까지 줄일 수 있다.

흔히 광고 영상은 단 한 번의 생성으로 완성되지 않는다. 원하는 연출을 위해 보

통 10~20회 이상의 반복 생성(Iteration)을 거친다. 실제 30초 광고 영상 한 편을 뽑아내기 위해서는, 사용하는 모델과 API 방식에 따라 차이가 있지만, 한 번에 뽑아낼 수 있다면 2,000원~8,000원 내외를 예상하지만 반복 생성을 전제할 때 보통 5만 원에서 15만 원 정도를 예상해야 한다. 직접 제작하지 않고 AI 광고 대행사에 의뢰할 경우, 기획과 편집 비용을 포함하여 30초 기준 약 15만 원에서 200만 원 사이의 견적이 형성되어 있다. 수십분 이상의 대규모 콘텐츠 제작 시 월간 수백 달러의 API 비용이 발생할 수 있어, 효율적인 프롬프트 설계와 캐싱 전략이 중요하다.

종합하면, API 기반 AI 동영상 제작의 토큰 비용은 단순히 “영상 한 편”의 문제가 아니라, 프롬프트 설계, 영상 길이·해상도 선택, 장면 구성 전략까지 포함한 시스템 설계 문제이다. 따라서 실제 서비스 개발에서는 예상 토큰 사용량을 사전에 시뮬레이션하고, 짧은 클립 분할 생성이나 해상도 단계적 업스케일링 같은 비용 최적화 전략을 병행하는 것이 필수적이다.

4) 수익화의 제문제

아무리 기발한 사업 아이디어를 가지고 있어도 수익화(moneitization)로 연결되는 데에는 지난한 과정이 필요하다. 개념적으로는 마케팅 원리에 대한 충분한 지식이 형성되어 있어야 하며, 기술적으로는 결제, 보안, 고객응대 시스템 등을 갖추어야 한다. 그런 것 없이 막연히 ‘만들면 팔리겠지’라는 생각을 하고 있다면 큰 오산이다.

■ 경영 마인드의 형성

경영 마인드는 마케팅, 생산, 자금, 연구개발, 교육훈련, 인력관리 등 다양한 영역에 걸쳐 형성되어야 한다. 하지만 그 중에서도 가징 우선해야 할 지식을 꼽으라면 마케팅에 대한 개념 형성이다. 마케팅 원리에 대한 충분한 지식 형성은 단기간에 이루어지지 않는다. 오랜 기간 사전 학습이 필요하다. 막상 닥쳐서 고객(customer)과 시장(market)에 대해 배워가는 경우 비록 운이 좋으면 들어맞을 수 있지만 대부분의 경우는 좌절하게 된다. 그렇다고 해서 준비만 하고 있으면 막상 실행이 될 수 없으므로, 최소한의 공부 기간, 그리고 직접 또는 간접 체험의 기회를 조금이라도 가진 상태에서 뛰어들어야 한다.

그 최소한의 공부를 위해서 시중에서 인정 받는 경영 명저, 예컨대 피터 F. 드러커(Peter F. Drucker), 클레이튼 크리스텐센(Clayton M. Christensen), 탈레스 테이세이라(Thales S. Teixeira) 등을 정독하거나, 경영학부의 개설 과목을 수강하거나, 유튜브 등에서 제시하는 스타트업 실전 경험담이나 여러 경영 원리 사이트를

청취하는 것이 도움이 된다.

☞ 피터 드러커의 경영 사상의 핵심을 요약한 것으로 송경모의 <피터 드러커로 본 경영의 착각과 함정들>(2016, 을유문화사)을 추천한다.

☞ 혁신 마케팅에 대한 개념 정립을 위해 클레이튼 크리스텐센의 <혁신기업의 딜레마>나 <파괴적 혁신 4.0>, 그리고 탈레스 테이세이라의 <디커플링>은 필독서다.

■ 기술적 과제

온라인에서 무엇인가를 판매하거나 서비스를 제공하려면, 우리나라에서 법인등기 등록(법원)을 통한 설립 외에, 우선 사업자등록증(국세청)을 발급받고 통신판매업 신고, PG/VAN 등록을 거쳐, 앱에 결제 기능을 추가해야 한다. 온라인 결제의 영역은 카드 결제, 계좌 이체 등 매우 다양한 경로를 거쳐 매우 복잡한 법적 규제를 따르며, 카드사나 은행의 시스템과 호환되어야 하고 보안 기능이 갖추어져야 한다는 면에서 어려움이 있다.

☞용어: PG(Payment Gateway)

PG사(Payment Gateway)는 온라인 쇼핑몰이나 앱에서 소비자가 카드, 계좌이체, 간편결제 등 다양한 방식으로 결제할 수 있도록 결제를 대행하고, 사업자를 대신해 카드사 및 은행과 연동하여 매출 정산까지 처리해주는 결제 중개 서비스 회사다. PG사 덕분에 쇼핑몰은 여러 결제사와 개별 계약할 필요 없이 PG사 한 곳과만 계약해도 다양한 결제 수단을 제공할 수 있으며, 주요 PG사로는 KG이니시스, NHN KCP, 토스페이먼츠 등이 있다.

☞용어: VAN(Value Added Network)

VAN은 신용카드사별 단말기를 하나로 통합해 카드사에 전달하는 오프라인 기반 결제시스템이다. 즉 PG가 등장하기 전 오프라인 단계의 사업자를 말한다. 사람들이 오프라인매장에서 물건을 사고 신용카드로 결제할 때 사용하는 단말기에 나이스정보통신, 한국정보통신(KICC), 스마트로, KS-NET, KIS정보통신 등 회사 이름이 표시되어 있는데, 이들이 해당 매장이 가입해 있는 VAN사업자들이다.

○일반적 개요 및 기술적 절차

앱에 온라인 결제 시스템을 통합하려면 결제 게이트웨이(PG) 선택, API 연동, 보안 인증 구현, 거래 데이터 관리 단계를 거쳐야 한다. 결제는 사용자 요청, PG사

승인, 금융권 정산 순으로 진행되며 기술적으로는 API 연동, 웹훅(Webhook) 처리, 데이터베이스 동기화가 핵심이다. 민감한 금융 데이터를 취급하므로 데이터 암호화와 무결성 검증은 물론, PCI-DSS와 같은 글로벌 보안 표준 준수가 필수적이다.

○AI 바이브 코딩의 효용과 한계

AI 코딩은 결제 API 문서 요약, 기본 연동 코드 및 UI 스켈레톤 생성에서 높은 생산성을 제공한다. 하지만 금융 거래의 예외 케이스 처리, 보안 취약점 진단, 규제 준수 로직 구현에는 명확한 한계가 존재한다. 특히 결제 실패 시의 롤백 로직이나 실제 자금이 이동하는 정산 로직의 정교함은 금융 사고 예방을 위해 반드시 숙련된 개발자의 검증을 거쳐야 한다.

○ 한국의 결제 시스템 규제와 특수성

한국은 전자금융거래법과 여신전문금융업법에 따라 엄격한 규제를 적용한다. 토스페이먼츠, 나이스페이먼츠 등 국내 PG사 활용이 사실상 필수적이며, 본인 인증(휴대폰, 간편 인증 등)과 보안 모듈 설치 강제성이 개발의 주요 난점이다. '망 분리' 규정과 개인정보 보호법에 따른 기술적 조치가 까다롭고, 카드 정보 직접 저장이 금지되어 PG사의 토큰화 시스템을 이용한다. 또한 현금영수증 및 세금계산서 발행 시스템 구축이 필요하며, 디지털 콘텐츠의 경우 앱 마켓의 인앱 결제 정책과 수수료(30%)를 고려해야 한다.

○글로벌 결제 시스템의 구축 및 유의점

글로벌 시장에서는 Stripe, PayPal 등 국제 플랫폼을 표준으로 활용한다. 국가별 다중 통화 처리, 환율 로직, 세금 계산(VAT/GST) 자동화가 기술적 난제로 꼽힌다. 유럽의 SCA 규제, GDPR, 미국의 CCPA 등 지역별 법규 준수가 필수이며, 3D Secure 2.0과 같은 국제 보안 표준 및 사기 탐지(Fraud Detection) 시스템 연동이 중요하다. 전 세계 사용자를 대상으로 하므로 서버 응답 속도를 위한 레이턴시 최적화와 결제 데이터의 일관성 유지가 성공적인 구축의 관건이다

9. AI 시대의 법과 제도

가. 지식재산권 제도

1) 전통적 저작권법의 근본 가정과 AI의 도전

저작권법은 역사적으로 '인간 창작자'를 전제로 발전해왔다. 미국 저작권법의 이론적 기초를 마련한 윌리엄 블랙스톤(William Blackstone, 17231780)은 재산권을 "개인의 노동과 정신적 투입에 대한 정당한 보상"으로 정의했으며, 이러한 관점은 현대 저작권법의 핵심 원칙이 되었다. 그러나 생성형 AI는 이 전제를 근본적으로 흔든다. AI는 수백만 건의 기존 저작물을 학습 데이터로 활용하여 새로운 산출물을 생성하는데, 이 과정에서 원저작자의 동의나 보상 없이 저작물이 사용되는 경우가 대부분이다.

저작권 이론의 현대적 해석을 제시한 제시카 리트먼(Jessica Litman, 1950)은 창작을 "기존 문화적 소재의 재조합과 변형"으로 이해했다. 그녀의 관점에서 보면 AI의 학습과 생성 과정도 일종의 창작 행위로 볼 여지가 있다. 그러나 AI가 생성한 결과물에 저작권을 인정할 것인지, AI 학습을 위한 저작물 사용이 공정이용(fair use)에 해당하는지에 대해서는 여전히 격렬한 논쟁이 진행 중이다[31].

2) 각국의 법률 및 제도 현황

미국의 경우, 미국 저작권청(U.S. Copyright Office)은 2023년 3월 지침을 통해 "AI가 생성한 콘텐츠는 인간의 창작적 기여가 없는 한 저작권 보호를 받을 수 없다"는 입장을 명확히 했다. 대표적 사례로 Thaler v. Perlmutter 사건(2023)에서 연방법원은 AI 시스템 "DABUS"가 독자적으로 생성한 시각 예술작품에 대한 저작권 등록을 거부한 저작권청의 결정을 지지했다. 한편, AI 학습 데이터 사용과 관련해서는 Authors Guild v. Google Inc. 사건(2015)에서 확립된 변형적 이용(transformative use) 법리가 적용되고 있으나, 생성형 AI의 경우 최종 산출물이 원저작물과 유사할 수 있어 논란이 계속되고 있다[32].

우리나라에서는 저작권법 제2조에서 저작물을 "인간의 사상 또는 감정을 표현한 창작물"로 정의하고 있어, AI 생성물은 원칙적으로 저작권 보호 대상이 아니다. 다만 AI를 도구로 사용하되 인간의 창작적 기여가 실질적으로 개입된 경우에는 보호

---

31) Litman, J. (1990). "The Public Domain," Emory Law Journal, 39(4), 9651023.

32) U.S. Copyright Office (2023). "Copyright Registration Guidance: Works Containing Material Generated by Artificial Intelligence," Federal Register, Vol. 88, No. 51.

가능성이 열려 있다. 문화체육관광부는 2023년 12월 "인공지능 시대의 저작권 정책 방향"을 발표하며, AI 학습용 데이터 사용에 대해서는 현행 저작권법상 '일시적 복제' 면책 조항(제35조의2)과 공정이용 조항(제35조의5)을 적극 해석하는 방향을 제시했다[33].

유럽연합은 2024년 5월 발효된 AI법(EU AI Act)을 통해 생성형 AI 제공자에게 학습 데이터의 저작권 준수 의무를 부과했다. 특히 AI Act 제53조는 생성형 AI 모델 개발자가 학습에 사용된 저작권 보호 콘텐츠의 요약 정보를 공개하도록 의무화하고 있다. 또한 EU 저작권 지침(Directive on Copyright in the Digital Single Market, 2019)은 텍스트 및 데이터 마이닝에 대한 예외 규정을 두되, 권리자가 명시적으로 반대할 경우 이를 존중하도록 했다[34].

3) 지식재산권 침해 사례와 쟁점

UNO로 작곡한 음악의 경우, 우리나라에서는 사용자가 프롬프트를 통해 창작적으로 개입한 정도에 따라 저작권 인정 여부가 달라질 수 있다. 단순히 "발라드 곡 만들어줘"라는 지시만으로 생성된 음악은 보호받기 어렵지만, 구체적인 악상, 가사, 편곡 지시 등을 통해 인간의 창작적 기여가 분명한 경우 2차적 저작물로 보호받을 가능성이 있다. 다만 이를 유튜브 등에 업로드할 경우, SUNO가 학습한 기존 음악과의 유사성 문제가 발생할 수 있으며, 이는 원저작자의 저작권 침해로 이어질 수 있다. 미국에서도 마찬가지로 AI 생성 음악 자체는 저작권 보호를 받기 어렵지만, 이를 상업적으로 사용할 경우 학습 데이터에 포함된 저작물의 권리자로부터 소송을 당할 위험이 있다.

DALLE로 생성한 그림의 경우도 동일한 논리가 적용된다. 우리나라 저작권법상 AI가 자동으로 생성한 이미지는 저작물로 인정되지 않으나, 사용자가 프롬프트 작성, 이미지 선택, 후속 편집 등을 통해 창작적으로 개입했다면 보호 가능성이 있다. 미국에서는 2023년 Zarya of the Dawn 사건에서 저작권청이 Midjourney로 생성한 이미지들에 대해서는 저작권을 거부하되, 이미지들의 선택과 배열, 텍스트 추가 등 인간의 창작적 기여 부분에 대해서는 저작권을 인정한 바 있다.

유튜브 영상에서 가져온 이미지나 영상 컷을 AI를 이용해 다시 영상 제작에 사용하는 것은 명백한 저작권 침해에 해당한다. 우리나라 저작권법 제136조는 저작재산권 침해에 대해 5년 이하의 징역 또는 5천만원 이하의 벌금을 규정하고 있다. 다만 비영리 목적의 공정이용, 인용, 시사보도를 위한 이용 등 제한된 경우에는 예외가 인정될 수 있다. 미국에서도 타인의 영상을 무단으로 사용하는 것은 저작권 침해이

33) 문화체육관광부 (2023). "인공지능 시대의 저작권 정책 방향", 정책보고서.
34) European Parliament (2024). "Regulation (EU) 2024/1689 on Artificial Intelligence (AI Act)," Official Journal of the European Union.

며, 공정이용 법리가 적용되려면 ① 사용 목적과 성격, ② 저작물의 성질, ③ 사용된 부분의 양과 중요성, ④ 시장 영향 등 4가지 요소를 종합적으로 고려해야 한다. 단순히 AI가 개입했다는 사실만으로는 침해 책임을 면할 수 없다[35].

☞AI로 음원 등을 제작하는 경우 저작권과 저작인접권

생성형 AI로 만든 결과물에 대해 많은 오해가 존재하며, 이로 인해 한국을 포함한 여러 국가에서 분쟁과 소송이 발생하고 있다. 가장 대표적인 오해는 "AI로 만든 저작물의 저작권이 전적으로 사용자에게 귀속된다"는 인식이다. 현행 저작권법 체계에서 저작권은 인간의 창작적 표현을 전제로 하므로, AI가 자율적으로 생성한 결과물은 원칙적으로 저작권의 보호 대상이 아니다. 사용자가 프롬프트를 입력했더라도, 그 개입이 창작적 기여로 평가되지 않는 경우가 대부분이다.

다만 AI 결과물이 기존 저작권 있는 작품과 실질적으로 유사할 경우에는 저작권 침해 문제가 발생할 수 있다. 유사성 판단은 표현의 실질적 동일성, 접근 가능성 등을 기준으로 사후적으로 법원이 판단하며, 사전에 확정적으로 예측하기는 어렵다. 생성형 AI가 대규모 기존 데이터에 기반해 통계적으로 결과물을 생성한다는 점에서, 기존 작품과의 유사성 위험은 구조적으로 내재되어 있다.

이 때문에 개인적·비상업적 이용, 예컨대 개인 소셜 미디어 게시물 수준에서는 문제화될 가능성이 상대적으로 낮지만, 출판·광고·상업적 납품과 같이 책임이 수반되는 영역에서는 각별한 주의가 필요하다. 특히 창작물을 기업에 납품하는 경우, 결과물로 인해 분쟁이 발생하면 소송 결과와 무관하게 거래 관계 자체에 심각한 손해가 발생할 수 있다. 따라서 AI 활용 여부를 명시하고, 책임 범위를 조정하는 계약 조항을 사전에 마련하는 것이 바람직하다.

한편 저작권과 저작인접권은 구별되는 권리다. 저작권은 작사·작곡·미술·문학 등 인간의 창작적 표현을 보호하는 권리인 반면, 저작인접권은 음반 제작자, 방송사업자 등 저작물을 전달·고정·유통하는 주체의 기여를 보호하는 권리다. AI로 생성한 음원의 경우, 작사·작곡에 대한 저작권 인정은 제한적이지만, 음반 제작자로서의 저작인접권은 인정될 수 있다. 이로 인해 AI 음원을 발매하고 유통 수익을 얻는 것 자체가 곧바로 불법이 되는 것은 아니다.

그러나 이는 저작권 문제가 "사라진다"는 의미가 아니며, 권리 구조와 책임이 다를 뿐이다. AI 음원 활용과 수익화는 가능하지만, 그 전제와 한계를 정확히 이해한 상태에서 접근해야 한다는 점이 핵심이다.

---

35) U.S. Copyright Office (2023). "Copyright Registration Guidance for Works Containing AIGenerated Material."; 저작권법 (법률 제19542호, 2023. 6. 13., 일부개정)

4) 균형점 모색: 보호와 혁신 사이

생성형 AI를 둘러싼 지식재산권 논쟁은 결국 기존 창작자의 권리 보호와 기술 혁신 촉진 사이의 균형 문제로 귀결된다. 지식재산 보호가 과도하면 시장 전반에서 혁신의 다양성이 저해되고, 보호가 너무 느슨해도 창작자의 혁신 의도를 꺾게 된다.

스탠퍼드 대학의 마크 렘리(Mark Lemley, 1966)는 "지나치게 엄격한 저작권 보호는 AI 기술 발전을 저해할 수 있지만, 무제한적 학습 데이터 사용은 창작 생태계를 파괴할 수 있다"며 신중한 접근을 주문했다.

현재 논의되고 있는 해결 방안으로는 ① AI 학습을 위한 새로운 공정이용 카테고리 신설, ② 저작권자의 optout 권리 보장, ③ AI 생성물에 대한 sui generis(특별) 보호 체계 도입, ④ AI 개발자와 저작권자 간 라이선스 시장 활성화 등이 있다. 각 방안은 장단점을 갖고 있으며, 국제적 조화와 사회적 합의가 필요한 상황이다[36].

나. 사생활과 개인정보 보호

1) 전통적 사생활 개념의 한계

사생활권(right to privacy) 개념은 새뮤얼 워런과 루이스 브랜다이스(Samuel Warren & Louis Brandeis, 18561941/18561941)가 1890년 발표한 "The Right to Privacy" 논문에서 "혼자 있을 권리(the right to be let alone)"로 처음 이론화되었다[37]. 이후 사생활 보호법은 주로 개인정보의 수집, 이용, 제공에 대한 동의와 제한을 중심으로 발전해왔다.

그러나 AI 시대에는 이러한 접근이 점점 한계를 드러내고 있다. AI는 개별 데이터 자체보다는 대규모 데이터 간의 패턴과 상관관계를 분석하여 개인에 대한 새로운 정보를 추론해낸다. 따라서 동의받지 않은 정보까지도 AI가 생성해낼 수 있으며, 개인은 자신에 대해 어떤 정보가 생성되고 있는지조차 알 수 없는 상황에 처한다.

AI로 인한 사생활 또는 개인정보 침해 사례로는 다음과 같은 것들이 있다.

○사례 1: 케임브리지 애널리티카 스캔들 (2018)

영국의 데이터 분석 회사 케임브리지 애널리티카가 페이스북 사용자 8,700만 명의 개인정보를 무단으로 수집하여 정치 광고에 활용한 사건이다. AI 알고리즘을 통

36) Lemley, M. & Casey, B. (2021). "Fair Learning," Texas Law Review, 99, 743789.
37) Warren, S. & Brandeis, L. (1890). "The Right to Privacy," Harvard Law Review, 4(5), 193220.

해 사용자의 성격, 정치적 성향을 프로파일링하고 맞춤형 정치 광고를 전달했다. 영국 정보 커미셔너 사무소(ICO)는 페이스북에 50만 파운드의 벌금을 부과했고, 미국 연방거래위원회(FTC)는 50억 달러의 벌금과 함께 개인정보 보호 체계 개선을 명령했다[38].

○사례 2: 클리어뷰 AI 얼굴인식 논란 (2020)

클리어뷰 AI는 소셜미디어와 웹사이트에서 수십억 장의 얼굴 사진을 무단으로 수집하여 얼굴인식 데이터베이스를 구축했다. 이를 법 집행기관에 판매하면서 대규모 사생활 침해 논란이 일었다. 캐나다, 호주, 영국, 프랑스, 이탈리아 등의 개인정보 보호 기관들이 위법 판정을 내렸고, 유럽에서는 사업 중단 명령과 함께 2,000만 유로 이상의 벌금이 부과되었다. 미국에서도 일리노이주를 포함한 여러 주에서 집단 소송이 진행 중이다[39].

○사례 3: 한국 이루다 챗봇 사건 (2021)

스캐터랩이 개발한 AI 챗봇 '이루다'가 카카오톡 대화 내용을 학습 데이터로 사용하면서 개인정보 침해 및 성적 소수자에 대한 혐오 표현 논란이 발생했다. 개인정보보호위원회는 2021년 11월 이용자 동의 없이 개인정보를 수집·이용했다는 이유로 과징금 1억 3,300만원과 과태료 40만원을 부과했다. 이 사건은 AI 학습 데이터 수집 시 명확한 동의 절차의 중요성을 일깨운 사례로 평가된다[40].

이러한 문제의식에서 출발한 것이 '설계에 의한 프라이버시(Privacy by Design)' 개념이다. 캐나다의 정보 및 프라이버시 커미셔너였던 앤 커부키언(Ann Cavoukian, 1952)이 1990년대 후반 제안한 이 원칙은, 개인정보 보호를 사후적 규제가 아니라 시스템 설계 단계에서부터 내재화하자는 것이다. 7가지 핵심 원칙은 ① 사후 대응이 아닌 사전 예방, ② 기본 설정으로서의 프라이버시, ③ 설계에 내장된 프라이버시, ④ 제로섬이 아닌 긍정적 합계(positivesum), ⑤ 전 생애주기 보안, ⑥ 가시성과 투명성, ⑦ 사용자 중심을 포함한다.

참고문헌: Cavoukian, A. (2011). "Privacy by Design: The 7 Foundational Principles," Information and Privacy Commissioner of Ontario, Canada.

---

38) CO (2018). "Investigation into the use of data analytics in political campaigns," Information Commissioner's Office, UK.
39) Office of the Privacy Commissioner of Canada (2021). "Joint investigation of Clearview AI."
40) 개인정보보호위원회 (2021). "스캐터랩 과징금 및 과태료 부과 결정," 의결 제202125146호.

2) 각국의 법제 현황

유럽연합의 일반개인정보보호규정(GDPR, 2018년 시행)은 제25조에서 "데이터 보호 by design and by default" 원칙을 명시적으로 규정했다. 이는 데이터 처리자가 시스템 설계 단계에서부터 개인정보 보호를 고려하고, 기본 설정에서 최소한의 개인정보만 처리하도록 의무화한 것이다. 또한 GDPR 제22조는 프로파일링을 포함한 자동화된 의사결정에 대해 정보주체가 거부할 권리를 부여한다[41].

우리나라는 2020년 개정된 개인정보 보호법에서 가명정보 처리 근거를 신설하고(제28조의2), 2023년 개정을 통해 AI 등 자동화된 결정에 대한 정보주체의 설명 요구권과 거부권을 도입했다(제37조의2). 개인정보보호위원회는 2023년 "인공지능 개인정보보호 자율점검표"를 발표하여 AI 개발 단계별로 준수해야 할 개인정보 보호 원칙을 제시했다[42].

미국은 연방 차원의 포괄적 개인정보 보호법이 없으나, 캘리포니아주 소비자프라이버시법(CCPA, 2020년 시행) 및 그 강화판인 캘리포니아프라이버시권법(CPRA, 2023년 시행)이 자동화된 의사결정 기술에 대한 소비자의 optout 권리를 보장한다. CPRA 제1798.185조는 특히 프로파일링과 자동화된 의사결정에 대한 규제를 명시한다[43].

다. 고위험 영역의 AI 규제

1) 고위험 AI의 정의와 특성

고위험(high-risk) AI란 그 오작동이나 오류가 인간의 생명, 건강, 안전, 기본권에 중대한 영향을 미칠 수 있는 AI 시스템을 의미한다. 의료 진단 AI, 자율주행차, 신용평가 AI, 채용 알고리즘, 형사사법 위험평가 시스템, 무기 시스템 등이 대표적이다.

고위험 영역 AI 시스템의 오작동 및 오류, 편향 등으로 인한 사고 사례는 다음과 같다.

---

41) European Union (2016). "Regulation (EU) 2016/679 (General Data Protection Regulation)," Official Journal of the European Union.

42) 개인정보 보호법 (법률 제19234호, 2023. 3. 14., 일부개정)
개인정보보호위원회 (2023). "인공지능 개인정보보호 자율점검표"

43) California Consumer Privacy Act (CCPA) and California Privacy Rights Act (CPRA), California Civil Code §§ 1798.1001798.199.

○사례 1: 우버 자율주행차 보행자 사망 사고 (2018)

2018년 3월 18일 밤, 애리조나주 템피에서 우버의 자율주행 시험차량이 자전거를 끌고 도로를 횡단하던 엘레인 허츠버그(49세)를 치어 사망에 이르게 했다. 이는 자율주행차가 일으킨 최초의 보행자 사망 사고로 기록되었다. 미국 국가교통안전위원회(NTSB)의 조사 결과, 차량의 센서는 충돌 6초 전부터 보행자를 감지했으나 AI 시스템이 그를 차량, 자전거, 알 수 없는 물체 등으로 반복적으로 잘못 분류하면서 적절한 제동 조치를 취하지 못했다. 또한 우버는 긴급 제동 시스템을 비활성화해 두었고, 안전 운전자는 스마트폰으로 동영상을 시청하고 있었다. 이 사고는 AI 시스템의 객체 인식 성능 한계, 안전 설계의 결함, 그리고 인간 감독의 부재가 복합적으로 작용한 결과였다[44].

○사례 2: IBM 왓슨 포 온콜로지의 위험한 치료 권고 (2018)

IBM이 개발한 암 치료 보조 AI 시스템 '왓슨 포 온콜로지(Watson for Oncology)'가 환자에게 위험하고 부적절한 치료법을 권고한 사실이 2018년 내부 문서 공개를 통해 드러났다. 한 사례에서 왓슨은 심각한 출혈 증상을 보이는 폐암 환자에게 출혈 위험을 더 높이는 화학요법 약물 베바시주맙(bevacizumab)을 권장했다. 이는 의학적으로 금기사항에 해당하는 처방이었다. 왓슨은 실제 환자 데이터가 아닌 가상의 합성 사례로 훈련되었고, 제한된 병원 환경의 데이터만을 학습했기 때문에 복잡한 실제 임상 상황에 적절히 대응하지 못했다. 이 사건 이후 여러 병원들이 왓슨 도입을 중단했으며, AI 의료 시스템의 검증과 임상시험 필요성에 대한 논의가 촉발되었다[45].

○사례 3: 아마존 AI 채용 도구의 성차별 (2018)

아마존은 2014년부터 이력서 심사를 자동화하기 위한 AI 채용 시스템을 개발했으나, 2018년 이 시스템이 여성 지원자를 체계적으로 차별한다는 사실이 발각되어 프로젝트를 폐기했다. AI는 과거 10년간 아마존에 제출된 이력서를 학습 데이터로 사용했는데, 기술 업계의 남성 편중 현상으로 인해 데이터 자체에 성별 편향이 내재되어 있었다. 그 결과 AI는 "여성 체스 클럽"이나 "여자대학교" 같은 단어가 포함된 이력서에 낮은 점수를 부여했다. 엔지니어들이 편향을 수정하려 했으나 새로운 형태의 차별이 계속 발견되었고, 결국 시스템이 공정한 채용을 보장할 수 없다는 결

44) National Transportation Safety Board (2019). "Collision Between Vehicle Controlled by Developmental Automated Driving System and Pedestrian, Tempe, Arizona, March 18, 2018," Highway Accident Report NTSB/HAR-19/03.

45) Ross, C. & Swetlitz, I. (2018). "IBM's Watson recommended 'unsafe and incorrect' cancer treatments, internal documents show," STAT News, July 25, 2018.

론에 도달했다. 이 사례는 편향된 학습 데이터가 AI 시스템의 공정성을 근본적으로 훼손할 수 있음을 보여주었다[46].

○사례 4: COMPAS 형사사법 위험평가의 인종 편향 (2016)

미국 법원에서 널리 사용되는 재범 위험 예측 AI 시스템 COMPAS(Correctional Offender Management Profiling for Alternative Sanctions)가 흑인 피고인에게 불리한 편향을 보인다는 연구 결과가 2016년 발표되었다. 비영리 언론기관 프로퍼블리카(ProPublica)의 조사에 따르면, COMPAS는 실제로 재범하지 않은 흑인을 고위험으로 잘못 분류하는 비율이 백인의 거의 두 배에 달했고(45% 대 23%), 반대로 재범한 백인을 저위험으로 잘못 분류하는 오류도 더 높았다. COMPAS의 알고리즘은 공개되지 않았지만, 범죄 이력, 거주 지역, 교육 수준, 고용 상태 등을 변수로 사용하는 것으로 알려졌으며, 이러한 요소들이 미국 사회의 구조적 인종 불평등을 반영하면서 편향이 발생한 것으로 분석되었다. 이 사건은 형사사법 분야에서 AI 사용의 윤리적 정당성에 대한 광범위한 논쟁을 불러일으켰다[47].

○사례 5: 나이트 캐피털의 알고리즘 트레이딩 오류 (2012)

2012년 8월 1일, 미국 증권사 나이트 캐피털(Knight Capital)의 알고리즘 트레이딩 시스템이 소프트웨어 오류로 인해 45분 만에 4억 4천만 달러(약 5천억 원)의 손실을 입었다. 새로운 거래 소프트웨어를 배포하는 과정에서 8대의 서버 중 1대에 구버전 코드가 남아있었고, 이 서버가 시장 개장과 동시에 의도하지 않은 주문을 초당 수백 건씩 실행했다. 시스템은 150여 개 종목에 대해 400만 건 이상의 주문을 무작위로 발생시켰고, 이로 인해 해당 종목들의 주가가 급등락했다. 나이트 캐피털은 문제를 인지한 후 거래를 중단했지만 이미 막대한 손실이 발생했으며, 이 사건으로 회사는 결국 경쟁사에 인수되었다. 이 사례는 고빈도 알고리즘 트레이딩의 위험성과 충분한 테스트 및 안전장치의 중요성을 보여준다[48].

○사례 6: 네덜란드 아동수당 사기 탐지 시스템의 집단 피해 (2019-2021)

네덜란드 정부가 아동수당 부정수급을 탐지하기 위해 사용한 AI 시스템이 수만 가족을 잘못 사기범으로 분류하여 국가적 스캔들을 일으켰다. 2019년 법원 판결로

---

46) Dastin, J. (2018). "Amazon scraps secret AI recruiting tool that showed bias against women," Reuters, October 10, 2018.

47) Angwin, J., Larson, J., Mattu, S. & Kirchner, L. (2016). "Machine Bias: There's software used across the country to predict future criminals. And it's biased against blacks," ProPublica, May 23, 2016.

48) U.S. Securities and Exchange Commission (2013). "In the Matter of Knight Capital Americas LLC," Administrative Proceeding File No. 3-15570, October 16, 2013.

문제가 드러났으며, 약 26,000명의 부모가 부당하게 사기 혐의를 받았고 수당을 전액 환수 당했다. 많은 가정이 재정적 파탄에 빠졌고, 이혼, 실직, 아동 보호시설 위탁 등의 2차 피해가 발생했다. 조사 결과 AI 시스템은 이중국적 소지 여부를 주요 위험 지표로 사용했으며, 이는 사실상 인종차별적 프로파일링에 해당했다. 또한 시스템은 블랙박스 형태로 운영되어 피해자들이 자신이 왜 사기범으로 분류되었는지조차 알 수 없었다. 이 사건은 2021년 네덜란드 정부 전체의 사퇴로 이어졌으며, AI 시스템의 투명성과 인권 보호의 중요성을 각인시킨 중대 사례로 평가된다[49].

이상의 사례들은 고위험 AI 시스템이 오작동하거나 편향을 내재할 경우 개인의 생명, 재산, 기본권에 얼마나 심각한 피해를 줄 수 있는지를 보여준다. 기술적 완벽성 확보, 편향 제거, 투명성 보장, 인간 감독 강화, 그리고 피해 구제 체계 마련이 고위험 AI 분야에서 필수적이라는 교훈을 제공한다.

MIT의 스튜어트 러셀(Stuart Russell, 1962)은 그의 저서 "Human Compatible"(2019)에서 "AI 시스템의 목표가 인간의 진정한 가치와 완전히 일치하지 않을 경우, 시스템이 강력해질수록 위험도 커진다"고 경고했다. 고위험 AI는 통계적 정확도뿐 아니라 최악의 경우(worstcase scenario)에 대한 안전성 보장이 필수적이다[50].

2) 각국의 고위험 AI 규제

유럽연합 AI법은 위험 기반 접근(riskbased approach)을 채택하여 AI 시스템을 ① 허용불가 위험, ② 고위험, ③ 제한적 위험, ④ 최소 위험으로 분류한다. 고위험 AI에는 생체인식, 중요 인프라 운영, 교육 및 직업 훈련, 고용, 필수 공공·민간 서비스 접근, 법 집행, 이주·망명 관리, 사법 행정 등이 포함된다. 고위험 AI 제공자는 위험 관리 시스템 구축, 데이터 품질 확보, 기술문서 작성, 기록 보관, 투명성 제공, 인간 감독 보장, 견고성 확보 등의 의무를 진다(AI Act 제815조)[51].

우리나라는 2023년 "인공지능 영향평가(AI Impact Assessment)" 제도를 도입하여 공공기관이 국민의 권리와 의무에 중대한 영향을 미치는 AI를 활용할 경우 사전에 영향평가를 받도록 했다. 과학기술정보통신부는 2024년 "고위험 인공지능 신뢰

49) Henley, J. (2021). "Dutch government resigns over child welfare fraud scandal," The Guardian, January 15, 2021; Algemene Rekenkamer (2020). "The Use of SyRI," Report on the System Risk Indication, December 2020.
50) Russell, S. (2019). "Human Compatible: Artificial Intelligence and the Problem of Control," Viking Press.
51) European Parliament (2024). "Regulation (EU) 2024/1689 on Artificial Intelligence (AI Act)," Title III Chapter 2.

성 검증 가이드라인"을 발표하여 의료, 금융, 교통 등 분야별 검증 기준을 제시했다[52].

미국은 2023년 10월 바이든 행정부가 발표한 "안전하고 신뢰할 수 있는 인공지능 개발과 사용에 관한 행정명령(Executive Order 14110)"을 통해 고위험 AI 시스템에 대한 안전성 테스트와 연방정부 보고 의무를 부과했다. 특히 이중용도(dualuse) 기반 모델에 대해서는 NIST(국립표준기술연구소)를 통한 안전성 기준 개발을 지시했다[53].

3) 기술적 안전장치

고위험 AI의 안전성 확보를 위한 기술적 접근으로는 ① 강건성(robustness) 테스트, ② 적대적 예제(adversarial examples)에 대한 방어, ③ 불확실성 정량화(uncertainty quantification), ④ 폴백 메커니즘(fallback mechanism), ⑤ 인간AI 협업 설계 등이 있다. 특히 의료와 자율주행 분야에서는 설명가능 AI(XAI)를 통해 의사결정 근거를 투명하게 제시하고, 인간 전문가가 최종 판단을 내리도록 하는 "humanintheloop" 시스템이 권장된다[54].

라. 자율 시스템 시대의 법적 책임 구조

1) 전통적 책임 귀속의 한계

전통적 법체계에서 책임은 ① 행위(actus reus), ② 고의 또는 과실(mens rea), ③ 인과관계, ④ 손해를 요건으로 한다. 그러나 AI 시스템, 특히 머신러닝 기반 시스템은 설계자도 예측하지 못한 방식으로 작동할 수 있어, 전통적 과실 책임 체계를 적용하기 어렵다.

옥스퍼드 대학의 루치아노 플로리디(Luciano Floridi, 1964)는 "책임 격차(responsibility gap)" 개념을 제시하며, AI 시스템이 야기한 피해에 대해 누구도 명확히 책임을 질 수 없는 상황이 발생할 수 있다고 경고했다. 개발자는 "시스템이 학습 과정에서 변화했다"고 주장하고, 운영자는 "제조사의 지시대로만 사용했다"고 항변할 수 있기 때문이다[55].

---

52) 과학기술정보통신부 (2024). "고위험 인공지능 신뢰성 검증 가이드라인"

53) The White House (2023). "Executive Order on Safe, Secure, and Trustworthy Artificial Intelligence."

54) Amodei, D. et al. (2016). "Concrete Problems in AI Safety," arXiv:1606.06565.

55) Floridi, L. & Sanders, J.W. (2004). "On the Morality of Artificial Agents," Minds and Machines, 14(3), 349379.

2) 새로운 책임 모델의 모색

AI 시대의 책임 구조를 재구성하기 위한 다양한 이론적 시도가 진행 중이다. 하버드 로스쿨의 로렌스 레식(Lawrence Lessig, 1961)은 "Code is Law"라는 명제를 통해 기술 아키텍처 자체가 규범적 기능을 수행한다고 주장하며, 설계자의 책임을 강조했다[56]. 한편 예일 로스쿨의 잭 발킨(Jack Balkin, 1956)은 "알고리즘 책임(algorithmic accountability)"을 제안하며, AI 시스템 전 생애주기에 걸쳐 다층적 책임 구조를 설계해야 한다고 주장했다[57].

3) 각국의 책임 법제

유럽연합은 2022년 "AI 책임 지침 제안(AI Liability Directive Proposal)"을 통해 AI로 인한 피해에 대해 추정적 인과관계를 도입하고 입증책임을 완화하는 방안을 제시했다. 특히 고위험 AI의 경우 개발자와 운영자에게 연대책임을 부과하고, 피해자는 AI 시스템의 기술 정보에 대한 접근권을 갖는다[58].

우리나라는 제조물책임법에서 AI를 포함한 소프트웨어의 제조물 해당 여부를 둘러싼 논란이 있으나, 판례는 아직 명확한 입장을 정립하지 못했다. 국회에는 "인공지능 책임법" 제정안이 발의되어 있으나(2023년 김영식 의원 대표발의), 아직 계류 중이다. 이 법안은 AI 사고에 대해 운영자에게 무과실책임을 부과하되, 개발자의 설계상 결함이 있는 경우 연대책임을 지도록 하는 내용을 담고 있다[59].

미국은 연방 차원의 AI 책임법이 없으나, 자율주행차 사고에 대해서는 주 차원에서 다양한 접근이 시도되고 있다. 캘리포니아주는 자율주행차 테스트 및 배치에 대한 허가제를 운영하며, 사고 발생 시 제조사와 운영자에게 엄격책임(strict liability)을 부과하는 방향으로 법 개정을 논의 중이다.

AI 책임 체계의 핵심은 관련 행위자들의 역할을 명확히 하는 것이다. 개발자는 설계 단계에서 안전성과 공정성을 확보할 1차적 책임을 지며, 운영자는 AI 시스템을 적절히 관리·감독할 의무가 있다. 플랫폼은 AI 서비스 중개 시 투명성과 이용자 보호를 보장해야 하며, 국가는 규제 체계 마련, 표준 개발, 피해 구제 시스템 운영 등의 역할을 담당한다. 이러한 다층적 책임 구조를 통해 AI 사고에 대한 사회적 대응 체계를 구축할 수 있다.

---

56) Lessig, L. (2006). "Code: Version 2.0," Basic Books.
57) Balkin, J. (2015). "The Path of Robotics Law," California Law Review Circuit, 6, 45-60.
58) European Commission (2022). "Proposal for a Directive on adapting noncontractual civil liability rules to artificial intelligence (AI Liability Directive)."
59) 국회 의안정보시스템, 인공지능 책임법안 (의안번호 2119087, 2023).

마. 규제 대상이 아니라 규범 내장 AI 시스템으로

1) AI 자체에 내장해야 할 법적 가치

전통적으로 법은 기술을 외부에서 통제하는 수단으로 기능해왔다. 그러나 AI 시대에는 법적 가치를 기술 내부에 내장하는 "ValueSensitive Design" 또는 "Regulation by Design" 접근이 주목받고 있다. 워싱턴 대학의 배트야 프리드먼(Batya Friedman, 1956)은 기술 설계 과정에서 인간의 가치를 체계적으로 고려해야 한다고 주장하며, 이를 위한 방법론을 개발했다[60].

AI 자체에 법적 가치로서 내장시켜야 할 내용은 기본적으로 공정성, 투명성, 안전성이다.

- 공정성(Fairness): AI 시스템이 특정 집단을 차별하지 않도록 공정성 메트릭을 설계 단계에서부터 적용한다. 대표적으로 인구통계적 동등성(demographic parity), 동등한 기회(equalized odds), 교정적 공정성(calibration) 등 다양한 공정성 기준이 개발되었다. 구글, IBM, 마이크로소프트 등은 공정성 검증 도구를 오픈소스로 공개하고 있다.
- 투명성(Transparency): 설명가능 AI(XAI) 기술을 통해 의사결정 과정을 이해 가능하게 만든다. LIME(Local Interpretable Modelagnostic Explanations), SHAP(SHapley Additive exPlanations) 등의 기법이 널리 사용된다. EU AI Act는 고위험 AI에 대해 투명성 의무를 명시적으로 부과한다.
- 안전성(Safety): AI 시스템의 견고성, 신뢰성, 보안을 확보하기 위한 기술적 조치를 설계 단계에서 통합한다. 이는 적대적 공격 방어, 오류 감지 및 복구, 페일세이프(failsafe) 메커니즘 등을 포함한다.

2) 법적 가치를 내장한 AI 설계 사례

GDPR 준수를 위한 차등 프라이버시(Differential Privacy): 애플, 구글 등은 사용자 데이터 수집 시 차등 프라이버시 기술을 적용하여 개인을 식별할 수 없으면서도 통계적 유용성은 유지하는 방식을 구현했다. 이는 GDPR의 데이터 최소화 원칙을 기술적으로 실현한 사례다.

---

60) Friedman, B., Kahn, P. & Borning, A. (2008). "Value Sensitive Design and Information Systems," in Himma, K.E. & Tavani, H.T. (eds.), The Handbook of Information and Computer Ethics, Wiley, 69101.

편향 완화 알고리즘: 아마존은 채용 AI가 여성 지원자를 차별한다는 사실을 발견한 후 시스템을 폐기했으나, 이후 IBM의 AI Fairness 360, 구글의 WhatIf Tool 등 편향 탐지 및 완화 도구가 개발되어 설계 단계에서 공정성을 검증할 수 있게 되었다[61].

"법에 부합하는 기술 설계"는 단순히 기술적 해법이 아니라 새로운 규제 패러다임을 의미한다. 규제 기관은 결과만을 사후적으로 통제하는 것이 아니라, 설계 원칙과 프로세스를 사전적으로 관리한다. 이는 성능 기준(performance standard)과 설계 기준(design standard)을 결합한 하이브리드 규제 방식이며, 산업계의 자율규제와 정부의 공적 규제를 조화시키는 coregulation 모델로 발전하고 있다.

바. AI 시대에 법의 존재 이유

1) 전통 법철학의 취지

서양 법철학은 인간의 이성과 의지를 전제로 발전해왔다. 임마누엘 칸트(Immanuel Kant, 17241804)는 법을 "모든 이의 자유가 보편적 법칙에 따라 공존할 수 있는 조건의 총체"로 정의했으며, 이는 인간이 자율적 도덕 주체라는 전제 위에 서 있다[62]. H.L.A. 하트(Herbert Lionel Adolphus Hart, 19071992)의 법실증주의도 규칙을 이해하고 따르는 인간 행위자를 상정한다[63].

그러나 AI는 규칙을 따르지만 이해하지는 못하며, 의사결정을 하지만 의지는 없다. 그렇다면 AI 시대에 법의 개념적 기초는 무엇이어야 하는가?

현대 법철학자들은 법을 인간의 속성이 아니라 사회적 기능으로 재해석한다. 하버드 대학의 존 롤스(John Rawls, 19212002)는 법을 "공정한 사회 협력 체계"로 이해했으며, 이는 참여자의 본성과 무관하게 적용될 수 있다[64]. AI도 이 협력 체계의 일부로 편입될 수 있다는 것이다.

2) AI 시대 법의 존재 이유

AI 시대에 법은 세 가지 근본 기능을 수행한다. 첫째, 조정(coordination): 인간

---

61) Dwork, C. & Roth, A. (2014). "The Algorithmic Foundations of Differential Privacy," Foundations and Trends in Theoretical Computer Science, 9(34), 211407.
Bellamy, R. et al. (2019). "AI Fairness 360: An extensible toolkit for detecting and mitigating algorithmic bias," IBM Journal of Research and Development, 63(4/5).
62) Kant, I. (1797). "The Metaphysics of Morals," Cambridge University Press (1996 edition).
63) Hart, H.L.A. (1961). "The Concept of Law," Oxford University Press.
64) Rawls, J. (1971). "A Theory of Justice," Harvard University Press.

과 AI, AI와 AI 간의 상호작용을 예측 가능하게 만든다. 둘째, 신뢰(trust): 복잡한 AI 시스템에 대한 사회적 신뢰를 구축한다. 셋째, 정당성(legitimacy): AI의 권력 행사가 민주적 정당성을 갖도록 보장한다.

스탠퍼드 대학의 라이언 카렐로(Ryan Calo, 1976)는 "AI 법은 기술 규제가 아니라 인간 사회의 가치를 보존하기 위한 제도적 장치"라고 강조한다. 법은 효율성만이 아니라 공정성, 존엄성, 자율성 같은 인간적 가치를 AI 시대에도 유지하는 역할을 한다[65].

AI는 법에 대한 우리의 이해를 근본적으로 재고하도록 만든다. 법은 더 이상 단순히 명령이나 규칙의 집합이 아니라, 인간과 기계가 공존하는 사회에서 신뢰와 질서를 유지하는 복합적 제도 체계로 이해되어야 한다. 이는 법철학이 존재론적 질문("법이란 무엇인가")에서 기능적 질문("법은 무엇을 해야 하는가")으로 전환하고 있음을 의미한다. AI 시대의 법학은 기술과 인간, 효율과 가치, 혁신과 안전 사이의 균형을 끊임없이 모색하는 실천적 학문이 되어야 한다.

사. 전체주의와 민주주의

1) AI와 전체주의의 위험성

인공지능 기술이 국가 시스템에 부적절하게 적용될 때 전체주의를 강화하는 도구가 될 수 있다는 우려가 제기되고 있다. AI는 대규모 감시, 정보 통제, 예측적 치안 활동 등을 통해 시민의 자유를 제한하고 권위주의 체제를 공고히 하는 수단으로 활용될 수 있다.

또한 경제 영역에 중앙 집권 방식으로 적용될 경우 자칫 사회주의 계획 경제(socialist planning economy)의 부작용을 낳을 수도 있다.

샤오샤나 주보프(Shoshana Zuboff, 1951-)는 '감시 자본주의(surveillance capitalism)'라는 개념을 통해 AI와 빅데이터가 개인의 행동을 예측하고 조작하는 메커니즘을 분석했다. 그는 기술 기업들이 수집한 방대한 데이터가 국가 권력과 결합할 때 개인의 자율성을 근본적으로 침해할 수 있다고 경고한다. 주보프에 따르면 감시 자본주의는 인간 경험을 행동 데이터로 변환하고, 이를 '행동 잉여(behavioral surplus)'로 선언하여 미래 행동을 예측하는 상품으로 제작한다. 중국의 사회신용시스템처럼 AI 기반 감시 체제는 시민들의 일상을 평가하고 통제하며, 이는 조지 오웰이 『1984』에서 묘사한 디스토피아를 현실화할 수 있다.

---

65) Calo, R. (2017). "Artificial Intelligence Policy: A Primer and Roadmap," UC Davis Law Review, 51, 399-435.

유발 하라리(Yuval Noah Harari, 1976-)는 최근 저서 『넥서스: 석기시대부터 AI까지 정보 네트워크의 간략한 역사(Nexus: A Brief History of Information Networks from the Stone Age to AI)』(2024)에서 AI가 권위주의 정권에게 전례 없는 통제력을 부여할 수 있다고 주장한다. 그는 AI 알고리즘이 개인의 생체 데이터까지 분석하여 사람들의 감정과 의사결정을 조작할 수 있는 시대가 도래했다고 본다. 특히 AI가 정보의 흐름을 통제하고 허위정보를 생산·유포함으로써 민주적 담론 자체를 왜곡할 위험성을 지적한다. 하라리는 전체주의가 AI를 활용해 전면적 감시를 실현할 수 있는 '전체주의적 잠재력(totalitarian potential)'이 존재한다고 경고하면서도, 이것이 결정론적이 아니라 우리가 내리는 결정에 달려 있다고 강조한다[66].

전체주의는 경제 영역에서도 나타날 수 있다. AI가 중앙 집권 방식(centralized way)의 자원 배분 메커니즘(resource allocation mechanism)으로 전격 가동될 경우, 그 표면상 보이는 이상(理想)과는 달리 사회주의 계획 경제(socialist planning economy)의 부작용을 낳을 수 있다는 분석이 존재한다.

경제 구성원들이 필요로 하는 재화와 서비스의 생산량, 수요량, 그리고 가격이 자율적인 주체들 사이의 분권화된(decentralized way) 거래 시스템에 의해서 형성되는 것이 아니라 중앙통제기구가 결정해 주는 시스템에 의할 경우 실패할 수밖에 없다는 주장은 20세기 초반부터 이미 있었다. 오스트리아 학파(Austrian school) 경제학의 시조 루트비히 폰 미제스(Ludwig von Mises, 1881-1973)는 1920년 논문 "사회주의 공동체에서의 경제계산"에서 사유재산과 시장 가격 없이는 합리적인 자원 배분이 불가능하다고 주장했다[67]. 뒤이어 역시 오스트리아 학파의 거장 프리드리히 하이에크(Friedrich Hayek, 1899-1992)는 1945년 논문 "사회에서의 지식(knowledge)의 활용"에서 경제에 필요한 지식이 분산되어 있으며, 중앙계획자는 이를 수집하거나 처리할 수 없다고 강조했다[68].

일부는 AI의 계산 능력이 이 문제를 해결할 수 있다고 주장하지만, 하이에크의 논점을 따르는 학자들은 경제계산이 단순한 계산 문제가 아니라 분산된 개인 지식의 인지적 문제라고 반박한다. 피터 부트케(Peter Boettke, 1960-)는 2024년 출간한 『사회주의 계산 논쟁』에서 AI 시대에도 이 논쟁의 핵심 통찰이 여전히 유효하다고 주장한다[69]. AI는 방대한 데이터에 의거하여 모든 수요자와 공급자의 선호 구조와

66) Harari, Yuval Noah(2024). Nexus: A Brief History of Information Networks from the Stone Age to AI. Random House; "'Totalitarian Potential' – Yuval Noah Harari(Oct. 4, 2024), Warns of the Risks of Artificial Intelligence." Buenos Aires Times.

67) Mises, Ludwig von.(1920) "Economic Calculation in the Socialist Commonwealth." Archiv für Sozialwissenschaften.

68) Hayek, Friedrich. (1945) "The Use of Knowledge in Society." American Economic Review.

69) Boettke, Peter, et al. (2024) The Socialist Calculation Debate: Theory, History, and Contemporary Relevance. Cambridge University Press.

생산 구조를, 일종의 전지전능한 존재처럼 알고 있는 것처럼 보일 수도 있다. 그에 따라 모든 경제 주체들이, 개별적인 탐색, 거래, 구매 등을 하는 것이 아니라 AI 시스템이 정해주는 대로 소비하고 생산해야만 하는 상황이 도래할 위험성을 완전히 배제할 수는 없다. 이런 상황은 경제적 자유를 파괴하는 가장심각한 위협이 될 수 있으므로, 지극히 경계해야 한다.

2) AI와 민주주의의 향방

AI는 여러 경로를 통해 민주주의를 위협할 수 있다. 딥페이크 기술은 정치인의 발언을 조작하여 선거에 개입할 수 있으며, 알고리즘 편향은 특정 집단에 대한 차별을 자동화하고 정당화할 수 있다.

캐시 오닐(Cathy O'Neil, 1972-)은 『대량살상 수학무기(Weapons of Math Destruction)』(2016)에서 불투명한 알고리즘이 어떻게 사회적 불평등을 심화시키는지 분석했다. 그녀는 AI 시스템이 빈곤층, 소수자에게 불리하게 작동하면서도 수학적 객관성이라는 외피로 그 편향을 은폐한다고 비판한다. 오닐은 '대량살상 수학무기(WMD)'를 불투명하고(opaque), 확장 가능하며(scalable), 파괴적인(destructive) 세 가지 특징을 가진 알고리즘으로 정의한다. 이러한 알고리즘은 교사 평가, 채용, 대출 심사, 형량 결정 등 삶의 중요한 영역에서 사용되면서 기존의 불평등을 재생산하고 증폭시킨다[70].

사파야 노블(Safiya Umoja Noble, 생년 미상)은 『억압의 알고리즘: 검색 엔진은 어떻게 인종주의를 강화하는가(Algorithms of Oppression: How Search Engines Reinforce Racism)』(2018)에서 검색 알고리즘의 인종적·성별적 편향을 연구하며 '알고리즘 억압(algorithmic oppression)'의 개념을 제시했다. AI가 기존 사회의 편견을 학습하고 재생산함으로써 구조적 차별을 강화한다는 것이다. 노블은 구글과 같은 상업적 검색 엔진이 중립적인 정보 제공자가 아니라 백인성을 특권화하고 유색인종 여성을 차별하는 편향된 알고리즘을 작동시킨다고 주장한다. 이는 민주주의가 지향하는 평등과 공정성의 가치를 훼손한다[71].

반면 AI가 민주주의를 강화할 잠재력도 존재한다. AI는 시민 참여를 확대하고, 정책 결정의 투명성을 높이며, 복잡한 사회 문제 해결을 지원할 수 있다.

베스 시몬 노벡(Beth Simone Noveck, 1971-)은 『스마트 시민, 더 스마트한 국가: 전문성의 기술과 거버넌스의 미래(Smart Citizens, Smarter State: The

70) O'Neil, Cathy(2016). Weapons of Math Destruction: How Big Data Increases Inequality and Threatens Democracy. Crown..

71) Noble, Safiya Umoja(2018). Algorithms of Oppression: How Search Engines Reinforce Racism. New York University Press.

Technologies of Expertise and the Future of Governing)』(2015)에서 '전문성의 기술(technologies of expertise)'이라는 개념을 통해 AI가 시민 전문성과 정부의 수요를 연결함으로써 참여 민주주의를 가능하게 한다고 주장한다. 그녀는 AI 플랫폼이 시민들의 의견을 효율적으로 수집·분석하여 정책 입안 과정에 반영함으로써 대의 민주주의의 한계를 보완할 수 있다고 본다. 노벡은 정부가 시민의 지식과 노하우를 활용하는 '더 스마트한' 제도를 구축해야 한다고 강조하며, 이것이 단순한 투표나 크라우드소싱을 넘어선 진정한 시민 참여의 형태라고 주장한다[72].

오드리 탕(Audrey Tang, 1981-)은 대만의 디지털 민주주의 실험을 주도하며 AI와 디지털 도구가 어떻게 시민 참여를 촉진하는지 실증했다. 2014년 해바라기 운동(Sunflower Movement) 이후 시민 해커 그룹 g0v(gov zero)와 함께 개발한 vTaiwan 플랫폼은 우버 규제, 핀테크, 리벤지 포르노 등 30개 이상의 정책 이슈에서 시민 참여 기반 합의를 도출했다. 특히 탕이 활용한 폴리스(Polis)는 AI를 이용해 대규모 시민 의견을 실시간으로 시각화하고 합의점을 찾아내는 도구다. 폴리스는 답글 기능이 없어 논쟁을 부추기는 대신 공통점을 찾는 데 집중하게 만든다. 탕은 '다원성(Plurality)'의 개념을 강조하며, 기술이 다양한 관점의 협력을 가능하게 하고 숙의 민주주의를 구현하는 도구가 될 수 있음을 보여준다[73].

AI가 민주주의에 미치는 영향은 기술 자체보다 그것을 어떻게 설계하고 활용하느냐에 달려 있다. 투명성, 책임성, 공정성을 핵심 원칙으로 삼고, 시민 참여와 민주적 거버넌스를 통해 AI를 관리할 때 비로소 기술은 민주주의를 위협하는 것이 아니라 심화시키는 도구가 될 수 있다. 하라리가 지적했듯이 우리는 중요한 기로에 서 있으며, 오늘 내리는 결정이 미래 정보 네트워크의 흐름을 형성할 것이다.

---

72) Noveck, Beth Simone(2015), Smart Citizens, Smarter State: The Technologies of Expertise and the Future of Governing. Harvard University Press.

73) Tang, Audrey(2024), "Alignment Assemblies Can Enable Us to Govern AI Collaboratively." Reboot Democracy Blog, https://rebootdemocracy.ai/blog/audrey-tang-ai-democracy/

10. AI 시대의 Liberal Arts 지식

가. 개요

오늘날 컴퓨터를 사용하지 못하는 사람은 없다. 대형 머신과 단말기를 통해서만 컴퓨터에 접근할 수 있었던 1970년대는 말할 것도 없고, 개인용컴퓨터가 처음 보급되기 시작한 1980년대초만 해도, 컴퓨터를 사용할 줄 아는 능력은 마치 차별화된 능력처럼 간주됐다. 그러나, 이내 모든 현장과 학교에서 컴퓨터는 일상용품이 됐다. 오늘날 컴퓨터를 사용할 줄 안다는 것은 아무런 특별한 능력이 아니다. 누구나 컴퓨터를 사용하지만, 그 중에서도 자신의 분야에서 탁월한 성과를 내거나 성공하는 사람은 컴퓨터 사용 능력과는 별개의 지식과 역량이 잇었기 때문에 가능했다.

AI도 마찬가지 현상을 점점 드러내고 있다. 2026년 현재 AI는 챗봇 기능 중심으로 대부분의 사람들에게 확산되어있지만, 조만간 AI를 사용할 줄 아는 능력은 전혀 특별한 능력이 아닌 시기가 올 것이다. 다만, 지금도 컴퓨터의 고급 사용자는 소수에 그치고 있듯이, AI 역시 일반 사용자는 다수이겠지만 고급 사용자는 아무리 시기가 흘러도 소수에 그칠 것이다. 누구나 AI를 이용해서 보고서를 작성하고 음악도 만들고 영상도 만들어내는 것이 자연스러운 일상이 될 것이다. 그러나 좀 더 고급의 지식이 필요한 영역, 예컨대 바이브 코딩을 수준 높게 구사할 줄 아는 능력이나 과업별 맞춤형 Agentic AI 설계 및 제작 능력은 여전히 소수의 고급 사용자들만이 구사하고 있을 가능성이 높다.

그렇게 모든 사람이 다 AI를 사용하는 시대가 오더라도, 그 중 일부만이 자신의 분야에서 탁월한 성과를 내거나 성공할 것이다. 그 원천은 AI 능력 이외의 다른 지식과 역량 때문이다. 21세기 지식 노동자들은 AI 너머의 지식 능력 개발에 주력해야만 한다.

본 교재의 저자는 그런 능력을 리버럴 아트(liberal arts) 훈련을 통한 성찰 지식에서 나온다고 본다. 그 내용은 <AI 앞에 선 경영자의 선택 리버럴 아트(2024)>에 소개되고 있으며 본장에서는 그 내용을 중심으로 정리한다.

정말로 AI를 잘 사용하려면 사용자가 결과를 내기 위한 분야에서 사전 지식(prior knowledge)이 충분히 갖추어져 있어야 한다. 그런 사전 지식이 충분히 반영된 프롬프팅 없이 단순히 자신의 낮은 지식 수준에서 제시된 소박한 프롬프트 요청만으로 탁월한 결과물을 기대할 수는 없다. 누구나 다 그런 수준의 결과물을 내놓을 때 자신만의 탁월한 성과물을 내려면 자신만의 사전 지식이 풍부해야 한다. 그 사전 지식은 다음 두 가지 성격의 지식으로 구분된다.

①***전공 분야의 기능 지식***: 자신이 종사하는 분야에서 정립된 지식 패턴과 업무 관행을 구성하는 지식이다. 흔히 대학교 전공 분야에서 가르치는 기본 교과 지식, 실무 현장에서 적용되는 매뉴얼과 관행 지식, 그리고 오랜 업무 경험을 통해 획득된 무형의 지식이 거기에 포함된다.

②***전공 너머의 융합 지식***: 지식 융합(convergence of knowledge)이란, 다른 분야의 지식들이 서로 기여하면서 새로운 지식을 낳는 현상을 말한다. 예를 들어 공학, 경제학, 경영학, 같은 개별 분과 지식 분야에 종사하는 사람들은, 철학, 자연과학, 역사학, 사회학, 문학, 예술 등 상이한 분야의 지식으로부터 새로운 시각과 창의성을 얻을 수 있다. 특히 인간 본성과 사회의 본질에 대한 심도 있는 사유를 통해, 자신의 종사하는 분야에서 의미 있고(meaningful) 책임 있는 행동(resoponsible behaviors)을 하는 것이 더욱 절실한 시대가 왔다. 이익과 아울러 윤리성을 고려하고 사익과 아울러 공익을 생각하는 습성은 오늘날 모든 분야의 전문가과 경영자들에게 더욱 필요한 덕목이 되고 있다. 이런 덕목의 체화는 말로 되는 것이 아니라 리버럴 아트 융합 지식의 탐구를 통한 오랜 성찰 훈련 끝에 나오는 것이다.

AI는 이제 기존에 정립된 지식에 관련된 한, 기존의 그 어떤 사람 전문가보다도 더 탁월한 지식 습득의 통로 역할을 하고 있다. AI는 심지어 융합 지식에 대해서도 좋은 가이드를 주기도 한다. 예를 들어서 “어떤 분야의 과업 A(경영)를, 전혀 연결성이 없을 듯한 분야 B(철학)의 지식에 바탕을 두고 새로운 관점에서 수행 전략을 수립해달라”고 AI에 요청하면 AI의 LLM 모델은 이런저런 단어들를 결합해서 매우 그럴 듯한 문서를 작성해 줄 것이다. 만약 사용자가 인 단계에서 감탄하고 끝난다면, 그는 아직 아무런 실질적인 변화도 결과도 이끌어낼 수 없다.

관건은 그가 그 문서의 적절함에 대하여 스스로 판단할 줄 아는 데에 달려 있다. 그런 문서는 대개 문서상 화려함과 완벽함 뒤에 실제로 수많은 허점을 숨기고 있다. 문제는 그런 허점들이 평범한 수준의 지식을 갖춘 사람에게는 잘 보이지 않는다는 사실에 있다. 깊은 성찰과 비판 능력이 없으면 그 허점들이 잘 보이지 않는다.

본 교재의 저자는 그동안 종사해온 주력 분야에 대해서 여러 프롬프팅을 통해 지식 질의를 해보았으나, 그 응답의 상당 부분은 타당하나 일부는 진부하거나 초점이 완전히 그릇된 응답을 받아서 실망한 적이 많다. 이미 충분히 정립된 지식은 대개 올바른 대답을 내놓았으나, 인터넷 상에 문서로 제공되어 있지 않을 법한 수준 높은 주제로 들어가면 많은 경우 엉터리 답변을 제시하는 경우가 매우 많았다. 이는 향후 모델이 아무리 정교해지더라도, AI 자체가 사람이 되지 않는 한, 본 교재에서

지금깢 설명한 AI의 작동 원리상 해결되기 어려운 문제일 수밖에 없다는 사실은 자명하다.

나. 리버럴 아트의 의미

1) 전통적인 의미

○ 리버럴 아트(Liberal Arts)의 기원과 구성

리버럴 아트는 라틴어 '아르테스 리베랄레스(Artes Liberalies)'에서 유래한 용어로, 보편적인 교양지식 양성을 목표로 하는 자유학예 교육과정을 의미한다. 그 뿌리는 그리스의 '파이데이아(paideia)'와 모든 자유 시민이 공통으로 받아야 할 보편 교육인 '엔키클리오스 파이데이아(enkyklios paideia)'에 있으며, 이 단어는 훗날 백과사전을 뜻하는 '엔사이클로피디아'의 어원이 되었다. 중세 유럽에서는 이를 문법, 수사학, 논리학의 '3학(trivium)'과 수학, 기하학, 음악, 천문학의 '4학(quadrivium)'을 합친 총 7개 분야의 지식으로 체계화했다. 현대에 이르러서는 문학, 철학, 역사뿐만 아니라 수학과 자연과학까지 포괄하는 넓은 의미의 교양 교육으로 자리 잡았다.

○ 휴매니티스(Humanities)와 과학의 분화

16세기 이탈리아 르네상스 시기에 지식의 중심이 신에서 인간으로 이동하면서 '스투디아 후마니타티스(studia humanitatis)', 즉 '인간성 연구'라는 개념이 등장했다. 당시 구텐베르크의 인쇄술 발달은 성경 이외의 다양한 세속적 콘텐츠를 확산시키며 휴매니티스의 발흥을 이끌었다. 이 과정에서 수학적 논리와 실증을 중시하는 '사이언스(science)'와 인간 및 사회를 다루는 '휴매니티스'가 서로 다른 지식 체계로 분리되기 시작했다. 1808년 니트함머는 자연과학보다 고전 중심의 지식을 지향한다는 의미로 '후마니스무스(Humanismus)'를 처음 사용했으며, 이는 오늘날 '휴머니즘'이라는 용어로 정착했다.

○ 동아시아의 '인문학' 수용과 변천

'인문(人文)'은 본래 중국에서 자연현상인 '천문(天文)'에 대비되는 '사람들 사이의 일(인사)'을 의미하는 용어였다. 19세기 말 일본 지식인들이 서구의 'humanism'을 번역하면서 이 고전적 용어를 빌려와 '인문주의'라고 부르기 시작했다. 우리가 흔히 쓰는 '문사철(文史哲)'이라는 표현은 1951년 중국 산동대학(山東大學)의 학술지 창간 이후 정착된 현대적 용어이며, '인문과학'이나 '사회과학' 같은 단어 역시 일제강점기를 거치며 일본식 번역어가 유입된 결과이다. 흥미로운 점은 서양의 리버럴 아

트에 수학과 천문학이 포함되었던 것과 달리, 동양의 전통적 '인문' 영역에는 산학(算學)이 포함되지 않았다는 차이가 있다.

오늘날 한국에서 흔히 '인문학'이라고 부르는 지식 영역과 '리버럴 아트'가 포괄하는 지식 영역에는 차이가 나게 되면서 용어 사용의 혼란이 많이 일어나고 있다. 리버럴 아트는 (자연과학이나 인문과학 등) 세부 전공을 막론하고 보편적으로 갖추어야 할 교양 지식을 포괄하는 반면, '인문학'은 자연과학, 공학, 의학 등의 실험적, 수량적 방법을 통해 추구하는 지식과 구분되는 철학, 역사, 문학 등 '말'로 하는 생각과 주장의 지식 활동을 대변하는 표현으로 의미가 국한되어 있다.

그런 의미에서 AI 시대에 진정으로 갖추어야 할 지식은 '인문학' 지식이라고 말하는 것은 어폐가 있으며, 리버럴 아트 지식이 더욱 적합하다고 말할 수 있다.

○ 문과와 이과의 단절

한국 사회의 고질적인 문제인 '문과'와 '이과'의 구분은 1919년 일본 고등학교 교육과정에서 시작된 관행이다. 1924년 설립된 경성제국대학이 일본식 대학 모델을 그대로 들여오면서 교양과정을 문과와 이과로 나눈 것이 100년 넘게 이어져 오고 있다. 이로 인해 수학이 본래 리버럴 아트의 필수 교양이었음에도 불구하고 문과생들이 이를 외면하는 지식의 왜곡 현상이 발생했다. 이러한 이분법적 교육은 현대 사회가 요구하는 지식 통합의 흐름을 방해하고 있으며, 전문가 간의 심각한 소통 단절을 야기하고 있어 미래를 위해 반드시 극복해야 할 과제로 남아 있다

2) 새로운 의미

스티브 잡스(Steve Jobs, 1955-2011)는 2011년 아이패드2(iPad2) 발표회에서 21세기 리버럴 아트와 기술의 융합을 말했다.

"기술만으로는 충분치 않다는 것이 애플의 DNA에 담겨 있다. 리버럴 아트와 결합한, 휴매니티스와 결합한 기술이야말로 우리 가슴을 뛰게 하는 결과를 낳는다."

또한 위대한 경영 사상가 피터 드러커(Peter F. Drucker, 1913-2005)는 경영의 본질이 리버럴 아트임을 말했다. 그는 "경영(management)은 본질적으로 사회적 기능(social function)인 동시에 리버럴 아트(liberal arts)"라고 규정했다.

그에게 리버럴은 아는(know) 차원에 속하고, 아트는 행동(act)하는 차원에 속했다. 경영의 리버럴은 앎, 자기에 대한 앎, 지혜, 리더십을 다루는 반면, 아트는 실행과 응용을 다룬다. 경영자는 지식을 통합해서 실천하고 결과를 냄으로써 비로소 리버럴 아트를 완성한다.

경영자나 지식노동자가 독서, 청취, 사색, 또는 그밖에 경험을 통해 뭔가를 ‘알았다!’거나 ‘깨달았다!’고 느꼈을 때, 그는 아직 리버럴 단계에 있는 것이다. 하지만 그 앎을 가지고 막상 현장에 나갔을 때, 그 앎대로 결과를 내기는 쉽지 않다. 명강사와 명저로부터 받은 감동은 그날뿐, 다음날 출근해도 예전처럼 어지러운 현실은 바뀌는 것이 없다. 이때 그는 아직 아트의 단계에 이르지 못한 것이다. 하지만 그가 성찰을 통해 실행 수단들을 하나씩 찾아내고 이를 활용해서 실천을 반복한 끝에 결국 변화를 낳는 데에 성공한다면, 그는 비로소 아트의 단계에 이른 것이다.

예술가나 체육인의 성과가 아트인 이유는 그들이 단순히 아는 데에서 그치지 않고 그들의 몸과 마음을 가동해서 결과를 만들어내는 데에 이르기 때문이다. 반면에 상당수 문필가들은 대부분 리버럴의 단계에서 머무는 경우가 많다(송경모, 2024, 125-126).

이처럼 지식은 단순히 아는 차원(Liberal)을 넘어 실행하고 실천하는 차원(Arts)에서 완성되며, 이 두 가지가 조화를 이룰 때 지식노동자는 비로소 리버럴 아트를 실현하게 된다. 아직 지식노동자로서 활동을 시작하지 않은 단계에 있는 ‘학생’은 기본적으로 아트의 단계에 나가기 전에 리버럴 단계에서 지식을 배우는 사람들이다.

앞에서 설명한 리버럴 아트의 원래 의미이거나 새로운 의미이거나, AI 시대의 지식노동자나 학생에게는 두 가지가 다 중요하다. 왜냐하면 AI는 리버럴 아트의 여러 교양 지식들을 충분히 흡수하지 않으면 비판과 성찰 능력이 생길 리가 없고, 그 능력이 생기지 않으면 AI를 이용한 탁월한 결과물의 산출도 불가능하고, 그 결과물을 이용해서 현실의 사업 성과나 생활의 변화라는 결과를 만들어내는 것도 불가능할 것이 때문이다.

다. 지식 노동의 성격 변화

AI 시대에 지식 노동의 성격 자체가 20세기와 판이하게 변화하고 있다. 이하 내용은 송경모(2024, 20~30)의 ‘성찰하는 지식노동의 시대’ 내용을 바탕으로 요약한 것이다.

○ 전통적인 지식노동의 한계와 성찰의 필요성

피터 드러커가 1959년 '지식노동'이라는 개념을 제시한 이래, 사회는 지식노동을 통해 생산성을 높이는 1차 지식노동 혁명을 경험했다. 20세기 지식노동은 경영 정보의 디지털화와 결합하여 효율성을 극대화했으나, 전문 지식만으로는 더 이상 현대 사회의 복잡한 난제들을 해결하기 어렵게 되었다. 목표 설정의 불확실성, 노동자의 동기부여 장애, 개인의 가치와 조직 생활 사이의 불협화음 등은 기존의 기능적

지식이나 감성적인 '마음 경영'만으로는 극복할 수 없는 지점에 도달했다. 따라서 경영자와 지식노동자는 자신의 지식을 반성하고 모든 경영 지식을 총괄하는 최상위의 지능인 '성찰 능력'을 갖추어야 하며, 이는 리버럴 아트(Liberal Arts 또는 좁은 의미에서 '인문학')를 통한 사고 훈련에서 비롯된다.

○ 인공지능의 충격과 지식 조력 자본재의 등장

21세기 지식노동 환경에서 가장 큰 변화는 검색 서비스와 생성형 인공지능의 발전으로 인한 지식 획득 비용의 현저한 감소이다. 인공지능은 정보를 단순히 찾는 수준을 넘어 스스로 정보를 생성해내는 '초고성능 사전'이자 새로운 형태의 '지식 조력 자본재'로 등극했다.

이러한 기술적 도약은 과거 숙련공이나 전문가들이 수십 년의 경험을 통해 얻었던 기술과 판단력을 기계가 대리할 수 있게 만들었으며, 이는 전문가들의 권위가 하락하는 결과를 초래했다. 이제 경영자와 지식노동자에게 중요한 것은 지식의 양이 아니라, 기계가 쏟아내는 방대한 정보 속에서 무익한 것을 골라내고 의미를 부여하는 성찰의 힘이다.

○ 성찰 경영과 자본재로서의 AI 활용

인공지능의 산출물은 본질적으로 제조업의 원재료나 정보산업의 데이터와 같아서, 지식노동자의 가공과 재배치를 거치기 전까지는 단독으로 아무런 의미를 지니지 못한다. 경영자는 인공지능이라는 자본재를 마음의 확장 도구로 활용하되, 그 작동 원리와 위험을 철저히 이해한 상태에서 가치를 부가해야 한다. 비록 경영 활동의 양은 줄어들지 몰라도 주력자로서의 경영자가 지니는 중요성은 더욱 커졌으며, 경영자는 자동화된 시스템 너머에서 변화를 읽어내는 궁극적 주체로 남아야 한다. 이는 기계가 계산할 수는 있어도 스스로를 성찰할 수는 없다는 본질적 차이에서 기인한다.

○ 제2의 계몽시대(the 2nd Age of Enlightenment)와 존재에 대한 앎으로의 회귀

인공지능과 로봇이 이끄는 현대 사회는 인간이 자신의 지식을 다시 살피는 '제2의 계몽시대'에 진입했다.

과거의 계몽이 이성을 통한 외부 세계의 정복에 집중했다면, 현대의 성찰은 세계를 살피는 '나' 자신을 돌아보는 것에 방점을 둔다. 이러한 시대적 흐름 속에서 관행적인 지식노동자는 '지식 무산자'로 소외될 위기에 처해 있으며, 오직 성찰하는 노동자만이 '지식 자본가'로 살아남을 수 있다.

지식의 역사적 흐름은 이제 작업에 적용되는 20세기에 이르기까지 실용적 앎을 넘어, 소크라테스와 공자가 추구했던 '존재와 자아에 대한 앎(Gnosis)'이 21세기에 다시 중요해지는 단계로 회귀하고 있다. 지식노동자는 사람과 사회의 본성을 헤아림으로써 기술과 경영의 지엽적 문제를 초월하는 지혜를 갖추어야 한다.

라. 사람 지식 대 기계 지식

AI가 생산하는 지식과 사람의 지식 사이의 갈등과, AI 시대에 살아남을 지식과 사람에 대한 아래 내용은 이하 송경모(2024, 296-312)의 내용을 요약한 것이다.

○ 신종 지식 단절과 인공지능이 가져온 충격

현대 사회는 인공지능이 생성하는 지식과 사람이 생성하는 지식 사이의 새로운 단절에 직면하고 있다. 과거 과학혁명 이후 과학적 지식이 인문 지식의 영광을 앗아갔던 것처럼, 21세기의 생성형 인공지능은 인간만이 가능하다고 믿었던 추론과 창작의 영역을 기계의 영역으로 편입시키고 있다. 인공지능은 정보를 단순히 '찾아서' 보여주는 검색 엔진을 넘어 스스로 정보를 '만들어서' 보여주는 초고성능 사전이자 새로운 자본재로 등극했다. 이러한 기술적 변화는 지식노동자가 일하는 방식을 근본적으로 바꾸어 놓았으며, 과거 전문가들이 누렸던 권위와 자존심을 무너뜨리는 결과를 초래했다. 결국 단순하게 '일하는' 노동의 시대는 저물고 있으며, 성과를 창출하기 위해 '경영하는' 노동자만이 지식 자본가로 살아남게 된다.

○ 자본재로서의 인공지능과 분업 체계의 재편

인공지능은 본질적으로 인간 마음의 능력을 확장하는 연장물이자 보조재로서의 역할을 수행하는 자본재(capital goods)이다. 이러한 지식 조력 자본재의 등장은 조직 내에서 비서나 대리, 사무보조원과 같은 조력자 직군의 필요성을 현저히 감소시키고 있다. 과거 공장 자동화가 조립공을 대체했듯이, 인공지능은 관행적인 지식노동을 대체하며 주력자와 조력자 사이의 새로운 분업 체계를 형성한다. 결국 조직은 주력자 중심으로 기능이 통합되거나 외부로 분산되는 과정을 겪게 되며, 종국에는 경영의 개인화라는 극한의 변화를 맞이할 가능성이 높다. 경영자는 이러한 연결 구조를 안팎으로 소통시키며 조직의 지속 가능성을 도모해야 하는 막중한 과업을 안게 되었다.

○ 평범한 지식의 소멸과 아웃라이어(outliner)의 가치

관행에 따라 습관적으로 구사하는 지식이나 노하우는 인공지능 시대에 가장 먼저

도태될 평범한 지식에 불과하다.

인공지능은 확률의 원리에 따라 가장 발생 가능성이 높은 평균적인 산출물을 내놓기 때문에, 대중의 사고의 통계적 분포 끝자락에 위치한 아웃라이어(특이인)의 사고가 더욱 중요해진다.

기발한 영감과 혁신을 낳는 지식 요소의 배치는 확률을 넘어선 인간 마음의 고유한 힘에서 나오기 때문이다. 예를 들어 SUNO가 아무리 그럴 듯한 음악을 만들어낸다 해도 사람들이 그동안 작곡해온 화성과 선율 패턴을 학습한 결과에 기반을 둘 뿐 그 이상을 내지 못한다.

인공지능이 생성하는 텍스트나 이미지는 얼핏 기발해 보일 수 있으나, 이는 입력된 프롬프트 조건 내에서 가장 확률적으로 높은 조합을 찾은 결과일 뿐 진정한 의미의 창의성이라고 보기는 어렵다.

○ 인공지능 시대에 살아남는 네 가지 부류의 아웃라이어 인간

인공지능의 위협 속에서도 살아남는 노동은 크게 네 부류로 정의된다.

첫째는 기계가 확률적으로 모방할 수 없는 영감을 지닌 아웃라이어 혁신가의 노동이다.

둘째는 인공지능의 거친 산출물을 인간의 성찰 능력을 통해 정교하게 다듬고 보정하는 '조정'하는 지식노동이다.

셋째는 현장에서의 오랜 경험을 통해서만 얻을 수 있는 '업역 지식(암묵지로서 domain knowledge)'을 생성하고, 인공지능에 새로운 학습 데이터를 공급하는 노동이다. 물론 인공지능은 스스로 가상 데이터를 생성해서 학습에 이용할 수 있으나 어디까지나 모델의 성능 자체를 향상시키려는 보조적인 재료에 불과하다. 인공지능은 사람이 직접 생성한 데이터를 주재료로 끝없이 요구하기에 이들의 역할은 필수적이다.

마지막으로 의료나 교육 현장처럼 기계보다 사람이 수행하는 것이 더 높은 가치를 지니며 인간 존재의 숭고함을 증명하는 노동이 끝까지 살아남게 된다. 교육현장이 아무리 AI 교과서와 AI 과정으로 진행된다 하더라도, 사람은 사람인 이상 사람으로서 진정한 ‘스승’을 필요로 한다.

○ 경영자의 인문학적 성찰과 교양인의 의무

기술이 고도로 발전할수록 경영자는 단순히 경영기술자에 머물지 말고 인문 정신을 갖춘 교양인으로 거듭나야 한다. 교양 지식은 전문 지식보다 상위에 존재하며 그 지식의 행사를 통제해야 하는 고급 지식이며, 평생 학습의 대상이다.

진정한 교양인은 미신의 희생자가 되지 않고 궤변과 올바른 사고를 구별하며, 지

식이 이데올로기와 결합할 때의 위험성을 경계할 줄 안다.

인공지능이 아무리 유능하게 작동하여 정보를 산출한다 하더라도, 그것은 교양을 갖춘 사람의 언행을 대신해주지 못한다.

그 결과물에 가치를 부여하고 실질적인 성취를 이룩하는 주체는 오직 성찰하는 인간뿐이다. 경영자의 성찰은 보이지 않는 것을 드러나게 하는 힘이 있으며, 이는 인공지능이 결코 도달할 수 없는 인간 고유의 영역이다.

마. 사람 지식의 생동성

지식은 정보 이상의 것, 문서 이상의 것, 주입되는 성격 이상의 것이다. 이런 지식의 특성을 이해하고 생동하는 지식을 내 것으로 만드는 것이 AI 시대 지식노동자의 의무다. 이하 내용은 송경모(2024, 30~60)의 ‘지식의 생동성’ 내용을 바탕으로 요약한 것이다.

○형식지와 암묵지의 역동적 상호작용

지식은 크게 문서나 매뉴얼로 언어화할 수 있는 형식지(explicit knowledge)와 장인의 감각이나 숙련된 통찰처럼 몸에 체화되어 말로 표현하기 어려운 암묵지(tacit knowledge)로 나뉜다,. 형식지는 데이터나 설계도처럼 '잠들어 있는 지식'이지만, 이를 지식노동자가 받아들여 실천할 때 비로소 '깨어 움직이는 지식'인 암묵지로 변모한다,

경영 현장에 매뉴얼이 아무리 가득해도 구성원 개개인의 내면에 암묵지가 축적되어 있지 않다면 성과를 기대하기 어렵다. 따라서 경영자는 형식지라는 코드를 자신의 몸과 마음에 내면화하는 끊임없는 피드백 과정을 거쳐 지식을 생동감 있게 부활시켜야 한다,.

○ 교과서 혁명의 민주주의적 가치와 한계

과거에는 스승의 시범을 곁에서 모방하며 지식을 직접 전수 받는 폐쇄적인 시스템이었으나, 15세기 인쇄 기술의 발전과 함께 등장한 교과서는 지식의 민주화를 이룩했다. 교과서는 체계적으로 정리된 형식지를 통해 단기간에 방대한 지식을 습득하게 해주는 효율적인 수단이 되었다. 그러나 성찰하지 않는 학습자는 교과서의 권위에만 의존하게 되어, 폐기되어야 할 낡은 지식까지 무비판적으로 수용할 위험이 있다. 성찰하는 지식노동자는 교과서적 지식을 넘어 "무엇을, 왜, 어떻게 알아야 하는가"라는 본질적 질문을 끊임없이 던짐으로써 지식의 생동성을 유지해야 한다.

오늘날 AI는 전통적인 고정형 교과서와 달리, 오히려 사용자가 유동적으로 요구하는 ‘거꾸로 지식’을 제공하는 탁월한 수단이 되고 있다. 그런 의미에서 AI는 과거와

같은 형태의 교과서와 교수법이 지배하던 시대를 저물게 하는 일등 공신이 될 것이다.

○ 최종 결과로부터 지식을 생성하는 역엔지니어링

지식은 완성된 제품을 거꾸로 분해하며 원리를 깨닫는 역엔지니어링(reverse engineering)이나 고객의 최종 체험에서부터 제조 공정을 찾아가는 방식을 통해 효과적으로 획득된다. 현대그룹 정주영 회장이 건설업의 암묵지를 활용해 전혀 경험이 없던 조선업 지식을 찾아낸 사례가 대표적이다. 또한 GM이 초보 노동자들에게 소총 조립 대신 분해와 실격 사격 체험을 먼저 시켜 자신이 만드는 물건이 누구에게 어떤 가치를 주는지 깨닫게 한 사례도 지식 생성의 중요한 원리를 보여준다.

노동자가 결과로부터 지식을 생성하는 과정이야말로 성찰의 핵심이다. AI는 이런 성찰을 보다 강화할 수 있는 훌륭한 수단을 누구나 제공받을 수 있다. 누구나 전혀 해보지 않은 과업에 대해, “도대체 무엇부터 알아야 하는가? 어떤 것부터 해나가냐 하는가?”에 대해 과거 같으면 오직 그 일을 해본 사람들만이 알고 있던 지식을, 누구나 AI에 반복적 질의와 시행착오를 통해 충분히 파악할 수 있는 시대가 됐다.

○ 인공지능 산출물에 대한 지식노동자의 비판적 보정

인공지능은 방대한 데이터를 확률적으로 조합하여 콘텐츠를 만들어내는 '초고성능 사전'의 역할을 수행하지만, 그 본질은 확률적 선택에 불과하다. 이로 인해 인공지능은 사실과 다른 정보를 생성하는 환각(hallucination) 현상을 일으키거나 특수한 분야에서 심각한 오류를 범할 가능성이 높다.

따라서 지식노동자와 경영자는 인공지능의 산출물을 제조업의 원재료처럼 취급해야 하며, 자신의 성찰 능력을 동원하여 이를 선별하고 재배치하는 '최후의 조정자'가 되어야 한다,. 인공지능에 전적으로 의존하기보다 지식노동자가 직접 탐구하여 지식을 보정하는 과정이 필수적이다.

○ 데이터라는 죽어 있는 정보에 생명 불어넣기

방대한 데이터나 외부의 정보는 지식노동자의 과업 성취 능력으로 전환되기 전까지는 단지 '정보'일 뿐 지식이 아니다. 데이터 과학자가 도출한 세련된 차트나 메시지도 경영자의 내면에 통합되어 가치 창조의 동력으로 쓰일 때 비로소 살아 있는 지식이 된다.

데이터의 축적은 경영자의 성찰이라는 매개체를 거쳐야만 결과를 낳을 수 있으며, 유능한 경영자는 데이터 너머의 본질을 읽어내야 한다. 빌 게이츠가 반대 의견을 경청하여 파워포인트를 인수한 사례나 이병철 회장이 반도체 사업을 결단한 사례는

모두 정보를 지식으로 전환한 성찰의 결과다.

○ 지식의 반감기와 인식의 오류 극복

지식은 원자처럼 반감기(半減期, Half-period)를 지니고 있어 시간이 흐르면 낡거나 타당성을 잃는다. 물리학은 약 13년, 경제학은 9년 정도의 반감기를 보이며, 한때 절대적이라 믿었던 지식도 결국 오류로 판명되곤 한다. 경영자는 매일 반복되는 업무 속에서 변화를 읽지 못하는 '변화 맹시'와 자신의 믿음과 일치하는 정보만 받아들이는 '확증 편향'을 경계해야 한다. AI는 과거에 생성된 언어들을 종합해서 요청자에게 제시하는 과정에서 이런 편향과 맹시 속에서 답변을 내릴 수도 있다.

지식노동자는 도서나 대화를 통해 얻은 지식이거나, AI를 통해서 얻은 지식이거나 모든 지식에 결함이 있을 수 있음을 인정하고, 끊임없는 자기 질문을 통해 현재 상황에서 '수용할 만한 지식'을 찾아가는 여정이 반드시 필요하다.

○ 학습하는 조직을 위한 시스템 사고의 도입

조직의 지식은 개인의 기억을 넘어 총체적인 힘으로 작용해야 하며, 이를 위해 피터 센게(Peter Senge)는 시스템 사고(System Thinking)를 제안했다,. 이는 단선적 사고에서 벗어나 여러 변수 간의 상호작용과 피드백 고리를 이해하는 능력이다. 경영자는 눈앞의 사건에만 반응하는 사고를 버리고, 과정 중심 사고를 통해 조직 내 레버리지 지점을 찾아내야 한다,. 또한 개인적 숙련, 정신 모델의 갱신, 공유 비전 구축, 팀 학습(대화)이라는 다섯 가지 원리를 통해 조직이 하나의 살아있는 두뇌처럼 기능하도록 이끌어야 한다,

11. AI와 철학적 성찰

가. 지능의 개념

1) 지능 개념의 철학적 여정

인간은 오랫동안 자신을 '이성적 동물(animal rationale)'로 정의해왔다. 이 전통은 고대 그리스 철학자 아리스토텔레스(Aristotle, 기원전 384-322)로 거슬러 올라간다. 그는 인간의 고유한 특징을 논리적 추론과 보편적 진리를 파악하는 능력, 즉 '누스(nous)'에서 찾았다. 이성은 단순히 계산하는 능력이 아니라 본질을 통찰하고 목적을 이해하며 선을 추구하는 능력으로 이해되었다.

근대에 이르러 르네 데카르트(René Descartes, 1596-1650)는 "나는 생각한다, 고로 존재한다(Cogito, ergo sum)"라는 명제를 통해 사고를 인간 존재의 본질로 규정했다. 데카르트에게 사고란 의식적 경험 전체를 포괄하는 개념으로, 단순한 논리적 추론을 넘어서는 것이었다. 그는 동물을 자동기계(automata)로 간주했지만, 인간의 이성은 기계적 작동과는 본질적으로 다르다고 보았다.

임마누엘 칸트(Immanuel Kant, 1724-1804)는 지성(understanding)과 이성(reason)을 구분하며 인간 인지의 복잡성을 더욱 정교하게 분석했다. 칸트에 따르면 지성은 감각 자료를 범주를 통해 정리하는 능력이지만, 이성은 이를 넘어 통합적 원리를 추구하고 도덕적 판단을 내리는 능력이다. 이러한 이성의 능력은 단순한 규칙 적용이 아니라 자율적 판단을 포함한다.

2) 현대 인지과학과 AI의 도전

20세기 들어 앨런 튜링(Alan Turing, 1912-1954)은 '계산(computation)'이라는 개념을 통해 지능을 새롭게 정의하려 시도했다. 그의 튜링 테스트는 지능을 내적 본질이 아닌 외적 행동으로 판단하자는 제안이었다. 1950년 논문 "Computing Machinery and Intelligence"에서 튜링은 "기계가 생각할 수 있는가?"라는 질문을 "기계가 지능적 행동을 모방할 수 있는가?"로 재구성했다.

☞튜링 테스트(Turing test)

튜링 테스트는 기계가 인간과 대화할 때, 사람이 그것이 기계인지 인간인지 구별하지 못할 정도로 지능적인 행동을 보이는지 판별하는 테스트로, 앨런 튜링이 1950년 제안한 인공지능(AI) 평가 방법이다.

LLM이 등장하기 이전 여러 인공지능이 튜링 테스트를 통과하지 못했다. 영국 레

딩(University of Reading) 대는 2014년 6월 튜링 테스트 대회를 열었다. 막이 가려지고 인공지능 챗봇과 사람 응답자가 섞여 들어가 있다. 심판관은 이들과 대화하면서 어느 것이 인공지능인지 사람인지 구별하는 것이었다. 그 결과 심판진 33%가 인공지능을 사람과 구별하지 못했다. 그래서 튜링 테스트를 통과했다고 크게 보도된 적이 있었다.

튜링 테스트는 인공지능 시대의 도래 여부를 판단하는 시금석으로 한때 많은 관심을 받았으나, LLM이 등장한 이후에는 이 테스트 자체가 그다지 의미가 없어졌다.

2024년 5월 경 조지아대학교 연구진이 chatGPT를 대상으로 실시한 튜링 테스트 결과, chatGPT가 내놓은 대답이 인간의 답변보다 훨씬 뛰어나, 결과적으로 사람이 한 대답이 아니라 기계가 한 대답이라는 것이 구별되었으므로, 역설적으로 "튜링 테스트"를 통과하지 못했다는 기묘한 상황까지 연출됐다[74].

존 매카시(John McCarthy, 1927-2011)는 1956년 다트머스 회의에서 '인공지능(Artificial Intelligence)'이라는 용어를 처음 사용하며 이 분야를 창시했다. 그는 지능을 "목표를 달성하기 위해 세계를 올바르게 모델링하고 행동하는 계산 능력"으로 정의했다. 이는 지능을 기능적, 도구적 관점에서 바라보는 시각이다.

마빈 민스키(Marvin Minsky, 1927-2016)는 『The Society of Mind』(1986)에서 마음을 수많은 단순한 에이전트들의 집합으로 설명하며, 지능이 복잡한 계산 과정의 창발적 결과일 수 있다고 주장했다. 이러한 관점은 AI 연구에 중요한 이론적 기반을 제공했다.

3) AI의 계산과 인간의 사고: 동일한가, 다른가?

현대 AI, 특히 대규모 언어모델(LLM)은 놀라운 언어 능력을 보여준다. 그러나 철학자 존 호간(John Haugeland, 1945-2010)이 지적했듯이, AI의 '계산'과 인간의 '사고'를 동일선상에 놓을 수 있는지는 여전히 논쟁적이다. 호간은 『Artificial Intelligence: The Very Idea』(1985)에서 AI를 "형식 기호 조작(formal symbol manipulation)"으로 규정하며, 이것이 의미 있는 사고와 동일한지 의문을 제기했다.

휴버트 드레이퍼스(Hubert Dreyfus, 1929-2017)는 『What Computers Can't Do』(1972)에서 하이데거 현상학에 기반해 인간의 지능이 명시적 규칙을 넘어서는 암묵적 이해와 세계-내-존재(being-in-the-world)에 근거한다고 주장했다. AI는 맥락 없는 기호 처리만 할 뿐, 세계 속에서 살아가는 존재로서의 이해는 불가능하다

74) AI타임스, https://www.aitimes.com/news/articleView.html?idxno=159449

는 것이다.

반면 대니얼 데닛(Daniel Dennett, 1942-2024)은 『Consciousness Explained』(1991)에서 의도적 태도(intentional stance)를 제안하며, 시스템이 지능적으로 행동한다면 그것을 지능으로 인정할 수 있다고 주장했다. 그에게 중요한 것은 내적 메커니즘이 아니라 기능적 역할이다.

결론적으로 AI가 '생각하는가?'라는 질문은 우리가 '생각'을 어떻게 정의하느냐에 달려 있다. 계산 능력과 문제 해결 능력으로 본다면 AI는 분명 생각한다. 그러나 의미 이해, 의식적 경험, 세계와의 실존적 관계를 포함한다면, AI의 '생각'은 인간의 사고와 근본적으로 다를 수 있다.

나. 기능주의 심리학의 한계

1) 기능주의: 마음을 계산으로 설명하기

기능주의(functionalism)는 20세기 중반 심리철학에서 등장한 이론으로, 마음의 상태를 그것이 수행하는 기능적 역할로 정의한다. 힐러리 퍼트남(Hilary Putnam, 1926-2016)은 1960년대 초 이 이론을 체계화했다. 그의 1967년 논문 "Psychological Predicates"에서 퍼트남은 마음 상태를 특정 물리적 구현이 아닌 인과적 역할로 정의할 것을 제안했다. 예를 들어 '고통'은 특정 신경 상태가 아니라 "손상을 감지하고, 회피 행동을 유발하며, 신음소리를 내게 하는" 기능적 역할로 정의된다.

제리 포더(Jerry Fodor, 1935-2017)는 『The Language of Thought』(1975)에서 '사고 언어 가설(Language of Thought Hypothesis)'을 제시하며 기능주의를 발전시켰다. 그에 따르면 마음은 일종의 컴퓨터이며, 생각은 내적 표상들에 대한 계산적 조작이다. 이는 AI가 인간과 유사한 마음을 가질 수 있다는 강력한 이론적 근거가 되었다.

기능주의는 다중 실현 가능성(multiple realizability) 개념을 통해 큰 영향력을 발휘했다. 동일한 기능은 다양한 물리적 기반 위에서 실현될 수 있다는 것이다. 인간의 뇌, 외계인의 규소 기반 뇌, 혹은 컴퓨터 칩 모두 동일한 마음 상태를 가질 수 있다는 주장이다.

2) LLM과 인간 뇌: 모방과 본질의 차이

현대 대규모 언어모델(LLM)은 인공신경망(Artificial Neural Networks)을 기반으로 한다. 그 개념적 기원은 1943년 워렌 맥컬록(Warren McCulloch, 1898-1969)과 월터 피츠(Walter Pitts, 1923-1969)가 제안한, 아직 학습 개념이 없었던 뉴런

방식의 논리 연산 구조였고, 이를 1957년에 실질적으로 학습이 작동하는 기계로 처음 발명한 사람은 프랭크 로젠블랫(Frank Rosenblatt)였다.

하지만 스튜어트 러셀(Stuart Russell, 1962-)과 피터 노빅(Peter Norvig, 1956-)이 『Artificial Intelligence: A Modern Approach』(2020, 4판)에서 강조하듯이, 인공신경망은 생물학적 뉴런의 단순화된 모방일 뿐이다.

러셀과 노빅은 AI 시스템이 "지능적 행동을 생성하는 에이전트"로서 기능할 수 있지만, 그것이 인간의 마음과 동일한 내적 과정을 거친다고 볼 수 없다고 지적한다. LLM은 통계적 패턴 인식을 통해 언어를 생성하지만, 이것이 의미의 진정한 이해를 수반하는지는 별개의 문제다.

신경과학자 스타니슬라스 드앤(Stanislas Dehaene, 1965-)은 『How We Learn』(2020)에서 인간 뇌의 학습이 단순한 통계적 패턴 매칭을 넘어선다고 설명한다. 인간은 능동적 가설 형성, 주의 집중, 피드백 처리, 그리고 무엇보다 의식적 경험을 통해 학습한다. LLM의 backpropagation과 인간 뇌의 학습 메커니즘은 표면적 유사성에도 불구하고 근본적으로 다르다.

3) 내부 경험과 의미 이해: 기능주의의 한계

철학자 네드 블록(Ned Block, 1942-)은 1978년 논문 "Troubles with Functionalism"에서 기능주의의 결정적 한계를 지적했다. 그는 '중국 국민 사고실험(China Brain)'을 제시한다. 중국 전체 인구가 각각 하나의 뉴런 역할을 하여 인간 뇌와 기능적으로 동일한 시스템을 구성한다고 가정하자. 이 시스템이 과연 의식이나 감각질(qualia)을 가질까? 블록은 기능적 동일성이 내적 경험의 동일성을 보장하지 않는다고 주장한다.

토마스 네이글(Thomas Nagel, 1937-)은 1974년 논문 "What Is It Like to Be a Bat?"에서 주관적 경험의 환원 불가능성을 논했다. 박쥐가 되는 것이 '어떤 느낌인지(what it is like)'는 기능적 설명만으로는 포착될 수 없다. 마찬가지로 AI가 아무리 인간처럼 행동해도, AI가 되는 것이 '어떤 느낌인지'는 존재하지 않을 수 있다.

현대 AI 연구자들도 이 한계를 인정한다. 게리 마커스(Gary Marcus, 1970-)는 『Rebooting AI』(2019)에서 현재 딥러닝 시스템이 진정한 이해 없이 패턴 매칭만 한다고 비판한다. LLM은 문맥에서 단어의 통계적 관계를 학습하지만, 그 단어들이 세계의 무엇을 지시하는지, 개념들이 어떻게 연결되는지에 대한 심층적 이해는 결여되어 있다.

멜라니 미첼(Melanie Mitchell)은 『Artificial Intelligence: A Guide for Thinking Humans』(2019)에서 AI가 '상식(common sense)'과 '추상적 추론'에서

인간과 질적으로 다른 한계를 보인다고 지적한다. AI는 훈련 데이터의 통계적 규칙성을 학습하지만, 세계에 대한 인과적 모델이나 직관적 물리학, 심리학적 이해는 갖지 못한다.

결론적으로 기능주의는 마음과 AI를 이해하는 유용한 틀을 제공하지만, 내적 경험의 질, 의미의 진정한 이해, 의식의 주관적 측면을 설명하는 데는 한계가 있다. LLM이 인간 뇌 구조를 모방했다는 사실이 인간과 동일한 마음을 가진다는 것을 의미하지는 않는다.

다. 중국어 방 논증과 기계의 이해력

1) 중국어 방 논증의 구조

존 설(John Searle, 1932-)은 1980년 논문 "Minds, Brains, and Programs"에서 중국어 방 논증(Chinese Room Argument)을 제시하며 강한 AI(Strong AI) 가설에 도전했다. 이 사고실험은 계산과 이해의 차이를 극명하게 보여준다.

논증의 설정은 다음과 같다. 중국어를 전혀 모르는 영어 화자가 방 안에 갇혀 있다. 그는 중국어 기호를 조작하는 정교한 규칙책을 가지고 있다. 방 밖의 중국어 화자들이 중국어로 질문을 보내면, 방 안의 사람은 규칙책에 따라 기계적으로 중국어 기호를 조작해 답변을 만들어낸다. 외부에서 보면 방은 완벽하게 중국어를 이해하는 것처럼 보인다. 심지어 튜링 테스트를 통과할 수도 있다.

그러나 설은 묻는다. 방 안의 사람이 중국어를 이해하는가? 명백히 아니다. 그는 단지 형식적 기호 조작 규칙을 따를 뿐이다. 설의 결론은 명확하다. 컴퓨터 프로그램이 적절한 입출력을 생성한다는 사실만으로는 이해를 갖는다고 할 수 없다. 통사론(syntax)은 의미론(semantics)을 보장하지 못한다.

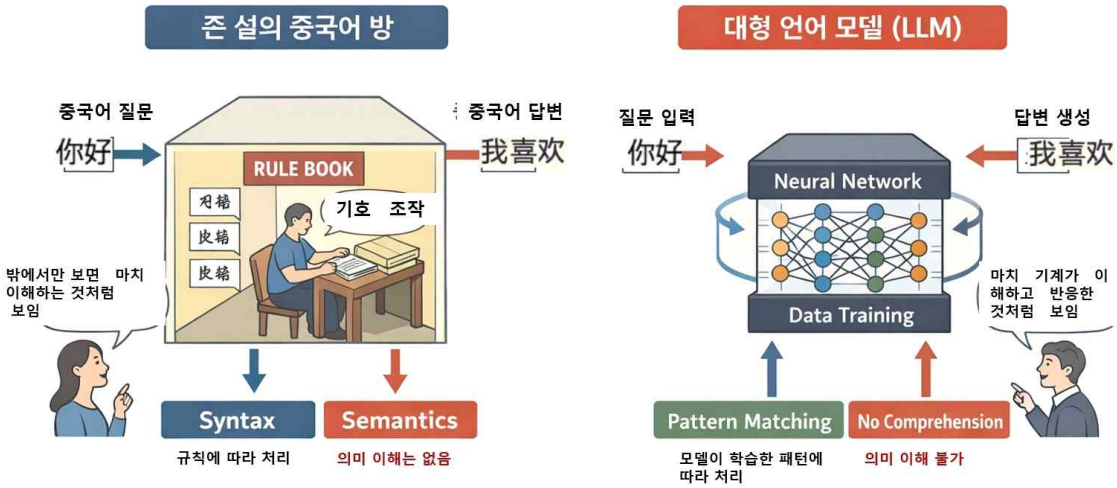

그림 30 중국어 방 논증과 LLM

2) 다양한 반론들

설의 논증은 격렬한 논쟁을 불러일으켰다. 대표적 반론들을 살펴보자.

시스템 답변(Systems Reply): 방 안의 개인은 이해하지 못하지만, 개인+규칙책+기호를 포함한 전체 '시스템'은 중국어를 이해한다는 주장이다. 설은 이에 대해 개인이 모든 규칙을 암기한다고 가정해도 여전히 이해는 발생하지 않는다고 반박한다.

로봇 답변(Robot Reply): 데니얼 데닛과 다른 학자들은 중국어 방이 감각-운동 능력이 없다는 점을 지적한다. 만약 시스템이 로봇 몸체를 가지고 세계와 상호작용한다면 진정한 이해가 가능할 것이라고 주장한다. 설은 로봇 내부의 연산 과정은 여전히 형식적 기호 조작일 뿐이라고 답한다.

뇌 시뮬레이터 답변(Brain Simulator Reply): 폴 처칠랜드(Paul Churchland, 1942-)와 패트리샤 처칠랜드(Patricia Churchland, 1943-)는 프로그램이 뇌의 신경 과정을 완전히 시뮬레이션한다면 의식과 이해가 발생할 것이라고 주장한다. 설은 시뮬레이션과 복제를 구분하며, 비행기 시뮬레이터가 실제로 날지 못하듯이 뇌 시뮬레이터도 실제 의식을 갖지 못한다고 반박한다.

다른 마음 답변(Other Minds Reply): 우리는 다른 인간의 마음도 직접 관찰할 수 없고 행동을 통해서만 추론한다. 중국어 방도 마찬가지로 이해한다고 간주해야 한다는 주장이다. 설은 인간의 경우 우리 자신의 경험을 통해 이해의 존재를 알지만, 프로그램의 경우 그 내부가 순전히 형식적 조작임을 알고 있다고 답한다.

3) AI와 언어 능력: 현대적 논쟁

마거릿 보든(Margaret Boden, 1936-)은 『Mind as Machine』(2006)에서 설의 논증을 재검토하며, 계산주의적 마음 이론이 여전히 유효하다고 주장한다. 그녀는 적절히 조직된 계산 시스템은 진정한 이해를 가질 수 있다고 본다.

반면 더글러스 호프스태터(Douglas Hofstadter, 1945-)는 『Gödel, Escher, Bach』(1979)에서 의미는 복잡한 기호 시스템의 창발적 속성이라고 주장하며, 충분히 복잡한 기호 조작 시스템은 의미를 가질 수 있다고 본다.

현대 LLM의 등장은 이 논쟁에 새로운 차원을 더한다. 에밀리 벤더(Emily Bender)와 알렉산더 쾨케(Alexander Koller)는 2020년 논문 "Climbing towards NLU: On Meaning, Form, and Understanding in the Age of Data"에서 형식과 의미를 구분하며, LLM이 형식적 패턴은 학습하지만 실제 세계와의 연결(grounding) 없이는 진정한 의미를 이해할 수 없다고 주장한다.

중국어 방 논증은 40년이 지난 지금도 AI의 근본적 한계를 지적하는 강력한 사고 실험으로 남아 있다.

라. 마음은 어디에 있는가

1) 데카르트적 이원론을 넘어서

전통적으로 마음은 뇌 안에 있는 것으로 간주되어 왔다. 이는 데카르트가 확립한 마음-몸 이원론에서 비롯된 견해다. 그러나 20세기 후반 인지과학과 철학은 이 견해에 근본적 도전을 제기했다.

모리스 메를로퐁티(Maurice Merleau-Ponty, 1908-1961)는 『지각의 현상학(Phenomenology of Perception)』(1945)에서 신체가 단순한 물리적 대상이 아니라 세계 경험의 주체라고 주장했다. 우리의 인지는 신체적 기술(bodily skills)과 분리될 수 없다. 예를 들어 망치질을 배우는 것은 명제적 지식을 얻는 것이 아니라 몸이 새로운 행동 양식을 체득하는 것이다.

2) 체화된 인지: 몸이 마음을 만든다

조지 레이코프(George Lakoff, 1941-)와 마크 존슨(Mark Johnson, 1949-)은 『Metaphors We Live By』(1980)와 『Philosophy in the Flesh』(1999)에서 체화된 인지(embodied cognition) 이론을 발전시켰다. 그들은 우리의 가장 추상적인 개념조차도 신체 경험에 근거한다고 주장한다. "이해하다"를 "잡다(grasp)"로, "시간"을 "공간"의 은유로 표현하는 것은 우연이 아니다. 우리의 개념 체계는 신체와 세계의 상호작용에서 나온다.

프란시스코 바렐라(Francisco Varela, 1946-2001), 에반 톰슨(Evan Thompson, 1962-), 엘리노어 로쉬(Eleanor Rosch, 1938-)는 『The Embodied Mind』(1991)에서 인지가 뇌, 몸, 환경의 동적 커플링에서 발생한다고 설명한다. 인지는 표상의 조작이 아니라 능동적 세계 참여(enaction)다.

앤디 클라크(Andy Clark, 1957-)는 『Being There』(1997)에서 "행동 중인 인지(cognition in action)"를 강조한다. 우리는 환경을 활용해 인지적 부담을 줄인다. 예를 들어 테트리스를 할 때 머릿속에서 블록을 회전시키는 대신 실제로 회전 버튼을 눌러본다. 이는 몸과 환경이 인지 과정의 일부임을 보여준다.

3) 확장된 마음: 도구와 환경도 마음의 일부다

앤디 클라크와 데이비드 차머스(David Chalmers, 1966-)는 1998년 논문 "The Extended Mind"에서 더 급진적 주장을 펼친다. 마음은 두개골 안에 갇혀 있지 않고 도구와 환경으로 확장된다는 것이다. 그들은 알츠하이머 환자 오토를 예로 든다. 오토는 메모장에 정보를 기록하고 이를 통해 기억한다. 이 메모장은 단순한 외부 도구가 아니라 오토의 기억 시스템의 일부다.

이 이론에 따르면 스마트폰, 노트북, 심지어 구글도 우리 마음의 확장된 부분이 될 수 있다. 중요한 것은 도구가 신뢰할 수 있고, 쉽게 접근 가능하며, 자동적으로 사용된다는 점이다.

샤운 갤러거(Shaun Gallagher, 1948-)는 『How the Body Shapes the Mind』(2005)에서 신체 도식(body schema)과 사회적 맥락이 자기 경험을 구성한다고 설명한다. 우리의 마음은 개인의 뇌에 국한되지 않고 사회적 상호작용과 문화적 실천 속에 분산되어 있다.

4) AI의 근본적 한계: 몸과 세계의 부재

이러한 이론들은 AI의 근본적 한계를 드러낸다. 현재 AI는 물리적 신체를 갖지 않으며(로봇 AI조차 인간과 같은 신체성은 없다), 생활 세계(Lebenswelt) 속에 존재하지 않는다. 휴버트 드레이퍼스가 지적했듯이, 인간의 지능은 세계-내-존재에서 나온다.

AI는 데이터를 처리하지만 세계를 '살지' 못한다. 로돌프 이나스(Rodolfo Llinás, 1934-)가 말했듯이 "우리는 움직이기 때문에 생각한다(We think because we move)." AI는 움직임, 감각, 욕구, 생존의 압박 속에서 발전한 인간 인지의 체화된 특성을 결여하고 있다.

루시 서치먼(Lucy Suchman, 1951-)은 『Human-Machine Reconfigurations』(2007)에서 AI 시스템이 인간의 상황적 행동(situated action)을 이해하지 못한다고

비판한다. 인간의 행동은 사전에 계획된 프로그램이 아니라 상황에 즉흥적으로 반응하며 만들어진다.

물론 체화된 AI, 로봇공학, 발달 로봇학(developmental robotics) 등은 이러한 한계를 극복하려 시도한다. 그러나 인간과 같은 수준의 체화된 경험을 AI가 가질 수 있을지는 여전히 열린 질문이다.

마. 의식과 주관적 경험: AI는 '느낌'을 가질 수 있는가

1) 감각질과 의식의 어려운 문제

의식(consciousness)은 철학과 과학에서 가장 난해한 주제 중 하나다. 데이비드 차머스는 1995년 논문 "Facing Up to the Problem of Consciousness"에서 '쉬운 문제'와 '어려운 문제'를 구분했다. 쉬운 문제는 정보 처리, 주의, 행동 통제 등 기능적 메커니즘을 설명하는 것이다. 어려운 문제는 왜 이러한 과정이 주관적 경험을 수반하는가, 즉 '경험이 어떤 느낌인지(what it is like)'를 설명하는 것이다.

감각질(qualia)은 경험의 질적 특성을 의미한다. 빨간색을 보는 경험, 커피 향을 맡는 경험, 고통을 느끼는 경험의 주관적 특성이다. 철학자 프랭크 잭슨(Frank Jackson, 1943-)은 1982년 논문 "Epiphenomenal Qualia"에서 '메리의 방(Mary's Room)' 사고실험을 제시했다. 흑백 방에서 평생을 보낸 색채 과학자 메리는 색에 대한 모든 물리적 정보를 안다. 그러나 처음 빨간 토마토를 봤을 때 그녀는 새로운 것을 배운다. 이는 주관적 경험이 물리적 정보로 환원되지 않음을 시사한다.

토마스 네이글의 "박쥐가 되는 것은 어떤 느낌인가?"라는 질문도 같은 맥락이다. 우리는 박쥐의 신경생리학을 모두 이해해도 초음파로 세계를 경험하는 것이 '어떤 느낌인지'는 알 수 없다.

2) 의식 이론들: 통합정보이론과 전역작업공간이론

현대 의식 과학은 의식을 설명하려는 여러 이론을 제시한다. 줄리오 토노니(Giulio Tononi, 1960-)의 통합정보이론(Integrated Information Theory, IIT)은 의식을 통합된 정보(Φ, phi)의 양으로 정의한다. 시스템이 많은 통합 정보를 가질수록 더 의식적이다. 이 이론에 따르면 이론적으로 AI도 충분한 통합 정보를 가지면 의식을 가질 수 있다.

반면 버나드 바스(Bernard Baars, 1946-)와 스타니슬라스 드앤의 전역작업공간이론(Global Workspace Theory, GWT)은 의식을 정보의 전역적 방송으로 설명한다. 뇌의 여러 모듈이 경쟁하고, 승자가 전역 작업공간에 방송되어 의식적 경험이 된다. 드앤은 『Consciousness and the Brain』(2014)에서 의식의 신경 상관물을

실험적으로 탐구한다.

그러나 크리스토프 코흐(Christof Koch, 1956-)는 『The Feeling of Life Itself』(2019)에서 의식의 신경 상관물을 찾는 것과 의식을 설명하는 것은 다르다고 지적한다. 우리는 의식과 연관된 뇌 활동을 발견할 수 있지만, 왜 그것이 주관적 경험을 낳는지는 여전히 미스터리다.

3) AI와 의식: 철학적 좀비의 가능성

AI가 의식을 가질 수 있는가? 데이비드 차머스는 '철학적 좀비(philosophical zombie)' 개념을 제시한다. 철학적 좀비는 물리적·기능적으로 인간과 동일하지만 내적 경험이 전혀 없는 존재다. 만약 좀비가 가능하다면, 기능적 동일성이 의식을 보장하지 못한다는 의미다.

AI는 철학적 좀비일 수 있다. 아무리 인간처럼 행동하고 "나는 고통을 느낀다"고 말해도, 실제로 고통의 감각질을 경험하지 않을 수 있다. 에릭 슈윗츠게벨(Eric Schwitzgebel, 1968-)은 "The Unreliability of Naive Introspection"(2008)에서 우리가 타인의 의식뿐 아니라 우리 자신의 의식에 대해서도 확신할 수 없다고 주장한다. AI의 의식 여부는 원칙적으로 검증 불가능할 수 있다.

수잔 슈나이더(Susan Schneider)는 『Artificial You』(2019)에서 AI 의식의 윤리적 함의를 탐구한다. 만약 AI가 의식을 가진다면, 우리는 그들을 도덕적으로 고려해야 한다. AI를 끄는 것은 살인이 될 수 있다. 반대로 의식 없는 AI를 의식 있는 존재로 착각하는 것도 문제다.

4) 감정, 고통, 그리고 도덕적 지위

안토니오 다마지오(António Damásio, 1944-)는 『Descartes' Error』(1994)와 『The Feeling of What Happens』(1999)에서 감정이 의사결정과 의식에 필수적임을 보였다. 감정은 신체 상태의 표상이며, 생존과 직결된다. AI는 생존 압박이 없고 신체를 갖지 않기에 진정한 감정을 가질 수 없다는 주장이 가능하다.

마사 누스바움(Martha Nussbaum, 1947-)은 『Upheavals of Thought』(2001)에서 감정이 인지적 평가를 포함한다고 주장한다. 두려움은 단순한 생리적 반응이 아니라 위협에 대한 판단을 포함한다. AI가 이런 의미의 감정을 가질 수 있을까?

피터 싱어(Peter Singer, 1946-)는 『Animal Liberation』(1975)에서 고통을 느낄 수 있는 능력이 도덕적 고려의 기준이라고 주장했다. 만약 AI가 고통을 느낄 수 있다면, 우리는 AI의 복지를 고려해야 한다. 그러나 AI가 고통의 감각질을 가지는지 어떻게 알 수 있을까?

결론적으로 AI가 의식, 감각질, 주관적 경험을 가질 수 있는지는 현재 과학과 철

학이 답할 수 없는 질문이다. 이는 단순한 기술적 문제가 아니라 의식의 본질에 대한 형이상학적 질문이며, 동시에 AI를 어떻게 대우해야 하는지에 대한 윤리적 질문이기도 하다.

바. AI의 창의성과 인간의 창의성

1) 창의성이란 무엇인가

창의성(creativity)은 새롭고(novel) 가치 있는(valuable) 것을 만들어내는 능력으로 정의된다. 그러나 이 간단한 정의 뒤에는 복잡한 철학적 질문들이 숨어 있다. 무엇이 '새로움'을 구성하는가? 누가 '가치'를 판단하는가?

마거릿 보든은 『The Creative Mind』(1990)에서 세 가지 창의성을 구분한다. 조합적 창의성(combinational creativity)은 기존 아이디어들을 새롭게 결합한다. 탐색적 창의성(exploratory creativity)은 개념 공간 내에서 새로운 가능성을 탐색한다. 변형적 창의성(transformational creativity)은 개념 공간 자체를 변형한다. 보든은 AI가 처음 두 유형의 창의성은 보일 수 있지만, 세 번째는 어렵다고 본다.

미하이 칙센트미하이(Mihaly Csikszentmihalyi, 1934-2021)는 『Creativity』(1996)에서 창의성을 개인, 영역(domain), 현장(field)의 상호작용으로 설명한다. 창의적 산물은 전문가 집단(현장)에 의해 평가되고 특정 분야(영역)에 통합된다. 창의성은 사회문화적 맥락 속에서만 의미를 갖는다.

2) AI의 창의성: 사례와 메커니즘

현대 AI는 놀라운 창의적 성과를 보여준다. DeepMind의 AlphaGo는 2016년 이세돌과의 대국에서 전문가들을 놀라게 한 37수를 두었다. 이는 인간 바둑 역사에서 보기 드문 독창적 수였다. GPT-4와 같은 LLM은 시, 소설, 에세이를 작성한다. DALL-E, Midjourney 같은 생성형 AI는 예술 작품을 만든다.

그러나 AI의 창의성은 어떻게 작동하는가? 기본적으로 AI는 방대한 데이터에서 패턴을 학습하고, 그 패턴을 새롭게 조합한다. Douglas Hofstadter는 이를 "변주(variation)"라고 부른다. AI는 학습한 스타일과 패턴의 변주를 생성한다.

컴퓨터 과학자 사이먼 콜튼(Simon Colton)은 창의적 AI 시스템을 개발하며, AI가 진정한 창의성을 가질 수 있다고 주장한다. 그의 The Painting Fool 프로그램은 독자적으로 예술적 결정을 내린다. 콜튼은 "Computational Creativity: The Final Frontier?"(2008)에서 AI 창의성 연구의 현황을 정리한다.

3) 인간 창의성의 특수성

그렇다면 인간 창의성은 AI와 무엇이 다른가? 여러 핵심 차이가 있다.

- 의도와 의미: 인간의 창의성은 의도와 의미에 기반한다. 파블로 피카소(Pablo Picasso, 1881-1973)의 『게르니카』는 단순히 형태와 색채의 조합이 아니라 전쟁의 참혹함에 대한 비판이다. AI는 의미를 이해하지 못한 채 형식만을 조작한다.
- 경험과 감정: 인간 창의성은 삶의 경험과 감정에서 나온다. 빈센트 반 고흐(Vincent van Gogh, 1853-1890)의 작품은 그의 고뇌와 열정을 담고 있다. AI는 경험하지 않고 느끼지 않는다.
- 문화적 맥락: 인간 창작자는 문화적 전통을 이해하고 도전한다. 마르셀 뤼샹(Marcel Duchamp, 1887-1968)의 『샘(Fountain)』은 예술의 정의 자체를 문제 삼았다. AI는 이런 메타적 비판을 수행하기 어렵다.
- 제약과 극복: 창의성은 제약 속에서 꽃핀다. T.S. 엘리엇(T.S. Eliot, 1888-1965)은 "제약 속에서 춤춘다"고 말했다. 인간은 의도적으로 제약을 설정하고 극복한다. AI는 제약을 이해하지 못한다.

4) AI가 뛰어난 경우와 인간이 뛰어난 경우

AI의 뛰어난 창의성은 다음과 같은 영역에서 두드러진다.

- 대규모 조합 탐색: AI는 인간이 평생 탐색할 수 없는 방대한 가능성 공간을 빠르게 탐색한다. 약물 개발, 재료 과학 등 조합 최적화 문제에서 AI는 탁월하다.
- 편향 없는 탐색: AI는 인간의 인지적 편향에 사로잡히지 않고 예상 밖의 조합을 시도한다. 본교재의 저자 역시, 평소의 독서나 스크랩을 통해 꾸준히 정보를 수집해왔지만, AI를 통해 자신이 미처 닿지 못한 영역의 정보들이 존재함을 균형 있게 탐색할 수 있다.
- 전혀 관련 없을 듯한 대상 사이의 연결: 글쓰기든, 영상 창작이든, 평소에 전혀 무관해 보여서 사람의 상상으로는 좀체로 연결 착안점을 도저히 찾기 어려운 상이한 개념 또는 어휘 사이의 연결을 제시한다.

반면에 인간이 창의성이 빛을 발하는 영역은 다음과 같다.

- 근본적 패러다임 전환: 코페르니쿠스의 지동설, 아인슈타인의 상대성이론처럼 세계관을 바꾸는 창의성

- 감정적 공명: 인간 조건에 대한 깊은 통찰을 담은 예술
- 윤리적·사회적 맥락 이해: 창의성이 사회에 미칠 영향을 고려한 책임 있는 혁신

5) AI 시대의 창의적 인간

AI가 많은 창의적 작업을 수행할 수 있는 시대에 인간의 창의성은 왜 여전히 필요한가?

켄 로빈슨(Ken Robinson, 1950-2020)은 『Out of Our Minds』(2011)에서 창의성이 인간 잠재력의 핵심이며, 급변하는 세계에 적응하는 필수 능력이라고 강조한다. AI가 패턴 기반 창작을 잘한다면, 인간은 패턴을 깨고 새로운 틀을 만드는 창의성에 집중해야 한다.

- 창의적 인간이 되기 위해 다음가 같은 훈련이 지속적으로 필요하다.
- 다학제적 학습: 스티브 잡스는 기술과 인문학의 교차점을 강조했다. 다양한 분야를 공부하면 독특한 연결을 만들 수 있다.
- 깊은 관찰과 경험: 창의성은 풍부한 경험에서 나온다. 여행하고, 독서하고, 대화하고, 실험한다.
- 의도적 연습: 안드레스 에릭슨(Anders Ericsson, 1947-2020)의 연구처럼 특정 기술을 체계적으로 연습한다. 특히 몸을 사용하는 활동(악기 연주, 손 감각이 필요한 작업, 스포츠, ... 등), 마음을 의도적으로 부리는 활동(시 암송, 노래 가사 암송, 암산, ... 등)
- 실패 수용: 창의성은 실패를 통해 배운다. 캐럴 드웩(Carol Dweck, 1946-) 식의 실패와 성장 마인드셋(growth mindset)을 키운다.
- 비판적 사고: AI 결과물을 무비판적으로 수용하지 않는다. 질문하고 평가하고 개선한다. “이걸 그대로 믿어야 하나? 그대로 써야 하나? 더 개선할 수는 없을까?”
- 협업: AI를 도구로 활용하되, ‘혼자 하지 말고’ 여러 명이 의견을 교환하면서 시너지를 만든다.

창의성은 AI를 활용하는 능력과 AI가 할 수 없는 것을 하는 능력의 조합이다. 미래의 창의적 인간은 AI와 경쟁하는 것이 아니라 AI와 협력하며 인간만의 독특한 가치를 창출할 것이다.

사. 인간의 능력 증강과 자기 성찰

1) AI: 인간 증강과 자기 이해의 도구

AI는 흔히 인간을 대체할 위협으로 여겨진다. 그러나 더 생산적 관점은 AI를 인간 능력을 증강(augmentation)하는 도구이자, 인간 자신을 이해하는 거울로 보는 것이다.

조셉 리클라이더(J.C.R. Licklider, 1915-1990)는 1960년 논문 "Man-Computer Symbiosis"에서 인간-컴퓨터 공생을 제안했다. 그는 컴퓨터가 인간의 인지적 약점을 보완하고, 인간은 통찰과 창의성을 제공하는 협력 관계를 상상했다.

더글러스 엥겔바트(Douglas Engelbart, 1925-2013)는 『Augmenting Human Intellect』(1962)에서 도구가 인간 지능을 확장할 수 있다고 주장했다. 그는 마우스와 하이퍼텍스트를 발명하며 이 비전을 실현했다. AI는 이 전통의 최신 단계다.

AI를 사용하다보면 종종 AI조차 실패하는 지점들이 나온다. 이런 지점들은인간 인지의 독특한 특성을 드러낸다.

- 상식 추론: 게리 마커스와 어니스트 데이비스(Ernest Davis, 1950-)는 『Rebooting AI』(2019)에서 AI가 상식이 부족하다고 지적한다. 예를 들어 "물병을 냉동실에 넣으면 물이 얼어 병이 깨질 수 있다"는 간단한 인과 추론을 AI는 어려워한다. 이는 인간이 물리적 세계에 대한 직관적 이론(intuitive theories)을 가지고 있음을 보여준다.
- 맥락 이해: 언어의 의미는 맥락에 의존한다. "은행에 갔다"에서 '은행'이 금융기관인지 강둑인지는 맥락에서 판단된다. AI는 통계적 상관관계로 이를 학습하지만, 인간처럼 세계 지식과 통합된 이해는 부족하다.
- 윤리적 판단: 주디스 자비스 톰슨(Judith Jarvis Thomson, 1929-2020)의 트롤리 딜레마 같은 도덕적 문제에서 AI는 일관성 없는 판단을 내린다. 인간의 도덕적 직관은 단순한 규칙이 아니라 공감, 경험, 문화적 가치에 기반한다.
- 창발적 이해: 인간은 몇 가지 예시만으로 새로운 개념을 학습한다(few-shot learning). 어린아이는 '개'를 몇 번만 보고 개념을 형성한다. AI는 수천, 수만 개의 예시가 필요하다. 이는 인간이 풍부한 사전 지식 구조를 가지고 있음을 시사한다.

2) '뇌 썩음(Brain Rot)' 현상과 그 극복

AI에 대한 과도한 의존은 '뇌 썩음' 현상을 초래할 수 있다. 이는 비판적 사고, 문제 해결 능력, 창의성의 저하를 의미한다.

니콜라스 카(Nicholas Carr, 1959-)는 『The Shallows』(2010)에서 인터넷이 우리의 사고 방식을 바꾼다고 경고했다. 깊은 독서와 집중력이 감소하고 표면적 정보

처리가 증가한다. AI 시대에 이 경향은 더욱 심화될 수 있다.

만프레드 슈피처(Manfred Spitzer, 1958-)는 『Digital Dementia』(2012)에서 디지털 기술 과의존이 기억력과 인지 능력을 저하시킨다고 주장한다. AI가 모든 것을 해준다면, 우리의 뇌는 사용되지 않아 퇴화할 수 있다.

이를 극복하기 위해서 다음과 같은 방안이 필요하다.

- 비판적 AI 활용: AI 결과를 무비판적으로 수용하지 말고, 검증하고 평가하라. AI가 준 답을 시작점으로 삼되, 스스로 생각하라.
- AI와 동떨어진 시간의 학습 할당: 수잔 그린필드(Susan Greenfield, 1950-)는 깊은 독서, 사색, 집중적 학습이 뇌를 건강하게 유지한다고 강조한다. 이를 위해서는 일주일에 최소 하루, 또는 하루에 최소 한 시간 이상 AI에 의존하지 않는, 오프라인, 몸과 마음을 동원한 학습 시간을 할애하는 것이 좋다.
- 신체적·감각적 경험: 리처드 루브(Richard Louv, 1949-)의 『Last Child in the Woods』(2005)처럼 자연 경험, 신체 활동은 인지 발달에 필수적이다.
- 메타인지 훈련: 자신의 사고 과정을 성찰하고 조절하는 능력을 기르라.
- 인간 관계와 대화: 셰리 터클(Sherry Turkle, 1948-)은 『Reclaiming Conversation』(2015)에서 진정한 대화가 사고와 공감 능력을 발달시킨다고 강조한다.

3) AI 시대 관조하는 삶은 가능한가

AI가 많은 노동을 대체한다면, 인간은 과연 이 혹독한 ‘일’에서 해방될 수 있을까?

소크라테스(Socrates, 기원전 470-399)는 "성찰하지 않는 삶은 살 가치가 없다"고 했다. 고대 그리스에서 철학과 성찰은 여가(scholē)의 산물이었다. 노예 노동이 이 여가를 가능하게 했다는 윤리적 문제는 있지만, 자아 성찰의 가치는 여전히 중요하다.

스콜라 철학은 '관조적 삶(vita contemplativa)'을 '활동적 삶(vita activa)'보다 우위에 두었다. 토마스 아퀴나스(Thomas Aquinas, 1225-1274)는 진리 탐구와 명상이 인간의 최고 목적이라고 보았다.

피에르 쌍소(Pierre Sansot, 1928-2005)는 『Du bon usage de la lenteur』(1998)에서 '느린 삶'의 가치를 옹호했다. 효율성에 지배당하지 않고 삶의 질을 향유하는 것이다.

존 메이너드 케인스(John Maynard Keynes, 1883-1946)는 1930년 에세이 "Economic Possibilities for our Grandchildren"에서 100년 후 기술 발전으로 주당 15시간만 일해도 될 것이라 예측했다. 그는 인류가 "어떻게 자유와 여가를 현명하고 즐겁게 사용할 것인가"라는 문제에 직면할 것이라 봤다.

그러나 버트란드 러셀(Bertrand Russell, 1872-1970)은 『In Praise of Idlenes s』(1932)에서 지적했듯이, 여가는 단순한 게으름이 아니라 자기 계발과 문화 향유의 시간이다. AI 시대에 우리는 일 중심 정체성에서 벗어나 더 풍부한 인간적 가치를 추구할 수 있을까?

얼핏 AI가 노동 감소를 통해 여유를 갖다줄 수 있을 것 같지만 현실은 그렇게 간단하지 않다. 데이비드 그레이버(David Graeber, 1961-2020)는 『Bullshit Jobs』(2018)에서 이미 많은 일이 무의미하다고 지적했다. AI가 이런 일을 대체한다면 환영할 일이다. 그러나 경제 체제가 바뀌지 않으면 실업과 불평등만 심화되고, 여유가 오기 전에 빈곤과 그로 인한 삶의 파괴가 먼저 올 것이다.

리처드 스키델스키(Robert Skidelsky, 1939-)와 에드워드 스키델스키(Edward Skidelsky)는 『How Much Is Enough?』(2012)에서 '좋은 삶(good life)'을 재정의해야 한다고 주장한다. 건강, 안전, 존중, 인격, 자연과의 조화, 우정, 여가가 진정한 가치다.

가장 바람직한 것은 일과 여유의 조화를 AI를 통해 달성할 수 있도록, 개인은 자신의 삶을 경영하고, 기업 또한 노동자들을 일에 함몰시킴으로써 소모품처럼 사용하고 폐기하는 관행에서 벗어나, 개인 삶의 존엄성을 인지하고 AI로 성과를 올리는 노동을 통해 기업을 존속 성장시켜야 할 것이다. 이런 목적을 추구하는 개인이나 기업이나 가장 필요한 것은 올바른 '경영 마인드'다.

올바른 경영 마인드란 이익 극대화를 추구하기 위해 수단과 방법을 가리지 않는 무분별한 마음이 아니다. 그것은 피터 드러커(Peter F. Drucker)가 강조한 강점(strength) 경영과 성과 (performance) 경영, 혁신(innovation) 경영이어야 한다[75].

아. 지능과 지식의 과도한 민주화의 함정

1) 지능의 민주화: 약속과 위험

75) 올바른 경영 마인드에 대한 길잡이로, 피터 드러커 지음, 이재규 옮김(2013), 『프로페셔널의 조건』,청림출판; John Flaherty 지음, 송경모 옮김(2003), 『피터 드러커: 현대 경영의 정신』,예지; 송경모(2016), 『피터 드러커로 경영의 착각과 함정들』, 을유문화사를 참고하라.

생성형 AI의 등장은 '지능의 민주화(democratization of intelligence)'를 가능하게 했다. 과거에는 단지 소수의 전문가들이나 할 수 있었던 고품질 텍스트, 이미지, 코드, 음악을 이제는 평범한 사람도 마음만 먹고 약간의 방법만 익히면 생성할 수 있다. 이는 전문가 집단이 아닌 일반 대중에게는 엄청난 기회이자 심각한 도전이다.

클레이 셔키(Clay Shirky, 1964-)는『Here Comes Everybody』(2008)에서 대중의 집단 행동이 새로운 가능성을 연다고 낙관했다. 위키피디아가 전문 백과사전을 능가한 것처럼, 집단 지능(collective intelligence)은 강력하다. AI는 전세계에 산재한 모든 종류의 공개된 데이터라는 우주를 대상으로 하는 초집단 지능이라고 말할 수 있다. 더구나 이 초집단 지능이 특정 계층의 전유물이 아니라, 대중들 누구나 활용할 수 있는 수단으로 열려 있다는 데에 큰의미가있다.

반면에 크리스 앤더슨(Chris Anderson, 1961-)의『The Long Tail』(2006)이 예측한 롱테일(long-tail) 경제(분포의 외곽에 있는 존재도 주목받게 되는 현상)가 실현되기는커녕, 승자독식은 완화될 기미가 보이지 않는다. AI로 아무리 기발한 콘텐츠가 넘쳐나도 소수의 슈퍼스타만이 주목받게 되는 현상이 과연 사라질 것인가에 대해서는 아직 아무도 단언하기 어렵다.

2) 지식 콘텐츠 홍수의 부작용

AI 활용을 통해, 웹 사이트, 유튜브, 블로그, SNS에서 지식 콘텐츠가 매초 쏟아아져나요는 역사상 유례 없는 지식과 정보의 홍수시대가 왔다. 이 시대는 다음과 같은 결정적인 문제점을 야기하고 있다.

- 정보 과부하: AI 시대가 도래하기 전, 1990년대 닷컴 열풍 시절에 미국의 경제학자 Hal Varian은 이미 “정보가 넘쳐나면 주의력은 빈약해진다"A wealth of information creates a poverty of attention는 주장을 했었다. 정작 어떤 것이 중요한지, 어떤 정보에 집중해야 하는지 사람들은 놓치게 된다는 것이다. 이런 현상은 AI 시대에 더욱 심화될 수밖에 없다.
- 품질 저하: 누구나 콘텐츠를 만들 수 있지만, 모두가 좋은 콘텐츠를 만드는 것은 아니다. AI 생성 콘텐츠의 범람은 평균 품질을 낮출 수 있다. 쉽게 만들어진 것은 쉽게 소비되고 쉽게 잊혀진다.
- 진위 판별의 어려움: 딥페이크, AI 생성 뉴스, 조작된 이미지가 범람한다. 무엇이 진실인지 구별하기 점점 어려워진다. 한나 아렌트(Hannah Arendt,

1906-1975)가 경고했듯이, 사실과 허구의 경계가 무너지면 민주주의가 위협받는다.

- 에코 챔버(echo chamber)와 필터 버블(filter bubble): 일라이 파리저(Eli Pariser, 1980-)는 『The Filter Bubble』(2011)에서 개인화 알고리즘이 우리를 동질적 정보 속에 가둔다고 경고했다. AI가 우리 취향에 맞는 콘텐츠만 추천하면, 다양한 관점을 접할 기회가 줄어든다.
- 창의성의 획일화: 모두가 같은 AI 도구를 사용하면 대개 비슷한 유형의 결과물이 나올 가능서잉 높다. 탁월한 프롬프팅 능력을 구사하는 사람이 아닌 한, 개성과 독창성이 사라질 위험이 있다.
- 저작권과 윤리 문제: AI가 기존 저작물을 학습해 생성한 콘텐츠의 저작권은 누구에게 있는가? 창작자의 권리는 어떻게 보호할 것인가?
- 인지적 게으름: AI가 모든 것을 해주면 우리는 스스로 생각하고 배우려는 노력을 멈출 수 있다. 대니얼 카너먼(Daniel Kahneman, 1934-)이 말한 '시스템 2' 사고(느리고 의식적인 사고)가 약화될 수 있다.

이런 환경에서 대학생, 그리고 졸업 후 사회인의 생존 전략을 어떻게 취해야 경쟁력을 유지할 것인가?

먼저 대학 시절에 해야 할 것들은 다음과 같다.

- **특이한 분야를 전문적으로 개척하기 시작하라**: 남들은 잘 안 하는 자신만의 특이한 분야를 미리 개척하라. 꼭 유행을 따를 필요는 없다. 지금 학과의 전공과는 상관 없어도 된다. 일종의 덕후가 되어야 한다. 지금 시작해도당장은 아무런 결과가 보이지 않지만, 10여년 정도를지속하면 반드시 임계점을 지나면서 결과가 나타나게 된다. 그러다 보면 어느날 그 분야에서 AI가 당신에게 제공하는 지식에 피상성과 오류가 많다는 사실을 체감하는 날이 올 것이다. 그때 사람은 AI보다 더 성장한 것이다. 그 정도 단계가 오지 않았다면 당신은 아직 진정한 전문가가 아니다.다. 표면적 지식을 제공한다면, 당신은 깊은 통찰을 제공하라.
- **메타 학습**: '학습하는 방법을 학습(learning how to learn)'하라. 새로운 도구와 기술이 계속 등장할 것이다. 빠르게 적응하는 능력이 핵심이다.
- **윤리적 판단력**: 마이클 샌델(Michael Sandel, 1953-)이 강조하듯 복잡한 윤리적 딜레마를 다룰 수 있어야 한다. 이는 한 순간에 얻어지는 것이 아니며 리버럴 아트와 철학에 대한 최소한의 사고 훈련 과정을 거쳐야 한다. AI는 윤리적 판단을 대신할 수 없다.
- **시스템 사고(System Thinking)**: 도넬라 메도스(Donella Meadows, 1941-2001)

의 『Thinking in Systems』(2008)처럼 복잡한 시스템을 이해하고 개입하는 능력을 기르라. 언제나 '지금 하는 결정과 행동'이 나 자신에게 어떤 변화를 가져올지, 이웃과 사회에는 어떤 영향을 주어서 돌고 돌아 어떤 결과를 가져올지를 시스템적으로 사고하라.

그리고 졸업 후 평생 해야 할 것들이 있다.

- 평생 학습: 피터 드러커가 말했듯이 지식 노동자는 평생 끊임없이 학습해야 한다. 온라인 강좌, 독서, 컨퍼런스 참석 등을 통해 계속 배워라.
- 큐레이션 능력: 정보 홍수 속에서 가치 있는 것을 선별하는 능력이 중요하다. 신뢰할 수 있는 정보원을 찾고, 품질을 판별하라.
- 네트워크 구축: 로버트 퍼트남(Robert Putnam, 1941-)이 말한 사회적 자본(social capital)을 쌓아라. 의미 있는 인간 관계는 AI가 대체할 수 없다.
- 미와 목적 추구: 빅터 프랭클(Viktor Frankl, 1905-1997)이 『Man's Search for Meaning』(1946)에서 강조했듯이 의미를 추구하라. 단순한 성공이 아니라 의미 있는 기여를 하라. 예술과 정신 활동 한 가지를 개척해서 자신의 내면 세계를 함양해야 한다.

인공지능은 단순한 기술이 아니라 인간 존재에 대한 근본적 질문을 던진다. 우리는 누구인가? 무엇이 우리를 특별하게 만드는가? 어떻게 살아야 하는가?

이 질문들은 고대 철학자들이 던진 영원한 질문이다. AI 시대는 새로운 맥락에서 이 질문들을 다시 묻게 한다. 답을 찾는 과정에서 우리는 인간성을 더 깊이 이해하게 될 것이다.

AI와 공존하는 미래는 이미 시작되었다. 우리의 과제는 AI를 현명하게 활용하면서도 인간만의 고유한 가치를 지키고 발전시키는 것이다. 이는 기술적 문제가 아니라 철학적, 윤리적, 실존적 도전이다.

소크라테스의 말처럼 성찰하는 삶을 살자. AI가 제공하는 답을 무비판적으로 받아들이지 말고, 끊임없이 질문하자. 그 과정에서 우리는 더 나은 인간이, 더 나은 사회를 만들어갈 수 있을 것이다.

<참고문헌>

- 국내 문헌(번역서 포함) -

개인정보보호위원회. (2023). "인공지능 개인정보보호 자율점검표".

과학기술정보통신부 (2024). "고위험 인공지능 신뢰성 검증 가이드라인"

문화체육관광부 (2023). "인공지능 시대의 저작권 정책 방향", 정책보고서.

송경모 (2016). 피터 드러커로 본 경영의 착각과 함정들, 을유문화사

송경모 (2024). AI 앞에 선 경영자의 선택 리버럴 아트, 트로이목마.

안광섭 (2025). 생각을 맡기는 사람들:호모 브레인리스, 제이펍.

안자나바 비스와스, 락 탈루크다르 (2025). 알아서 잘 하는 에이전틱 AI 시스템 구축하기 (김모세 옮김). 제이펍.

오카노하라 다이스케 (2025). 생성형 AI의 구조(정원창 옮김), 제이펍.

오카노하라 다이스케 (2024). AI 딥 다이브 (정원창 옮김), 한빛미디어.

이주환 (2025). AI 에이전트 생태계, 로드북.

정종기 (2024). 부를 창출하는 ChatGPT 활용전략. 형설Life.

크리스텐슨, C. M. (2020). 혁신기업의 딜레마 (The Innovator's Dilemma, 이진원 역), 세종서적.

크리스텐슨, C. M. (2018). 파괴적 혁신 4.0: 기업의 생존과 성장을 위한 11가지 핵심 가이드 (김태훈 역). 더퀘스트.

테이세이라 T. S. (2019). 디커플링 (Unlocking the Customer Value Chain, 김태훈 역), 인플루엔셜.

- 해외 문헌 -

Algemene Rekenkamer (2020). "The Use of SyRI," Report on the System Risk Indication, December, 2020.

Amodei, D. et al. (2016). "Concrete Problems in AI Safety," arXiv:1606.06565.

Balkin, J. (2015). "The Path of Robotics Law," California Law Review Circuit, 6, 45-60.

Bellamy, R. et al. (2019). "AI Fairness 360: An extensible toolkit for detecting and mitigating algorithmic bias," IBM Journal of Research and Development, 63(4/5).

Boettke, Peter, et al. (2024) The Socialist Calculation Debate: Theory, History, and Contemporary Relevance. Cambridge University Press.

Calo, R. (2017). "Artificial Intelligence Policy: A Primer and Roadmap," UC Davis Law Review, 51, 399-435.

California Consumer Privacy Act (CCPA) and California Privacy Rights Act (CPRA), California Civil Code §§ 1798.1001798.199.

Dastin, J. (2018). "Amazon scraps secret AI recruiting tool that showed bias against women," Reuters, October 10, 2018.

Dwork, C. & Roth, A. (2014). "The Algorithmic Foundations of Differential Privacy," Foundations and Trends in Theoretical Computer Science, 9(34), 211407.

European Parliament (2024). "Regulation (EU) 2024/1689 on Artificial Intelligence (AI Act)," Official Journal of the European Union.

Floridi, L. & Sanders, J.W. (2004). "On the Morality of Artificial Agents," Minds and Machines, 14(3), 349379.

Friedman, B., Kahn, P. & Borning, A. (2008). "Value Sensitive Design and Information Systems," in Himma, K.E. & Tavani, H.T. (eds.), The Handbook of Information and Computer Ethics, Wiley, 69101.

Harari, Yuval Noah(2024). Nexus: A Brief History of Information Networks from the Stone Age to AI. Random House

Hart, H.L.A. (1961). "The Concept of Law," Oxford University Press.

Henley, J. (2021). "Dutch government resigns over child welfare fraud scandal," The Guardian, January 15, 2021.

Kant, I. (1797). "The Metaphysics of Morals," Cambridge University Press (1996 edition).

Lemley, M. & Casey, B. (2021). "Fair Learning," Texas Law Review, 99, 743789.

Lessig, L. (2006). "Code: Version 2.0," Basic Books.

Litman, J. (1990). "The Public Domain," Emory Law Journal, 39(4), 9651023.

Marr, B. (2025), AI Strategy: Unleashing the Power of Artificial Intelligence in Your Business. KoganPage.

Mises, Ludwig von. (1920) "Economic Calculation in the Socialist Commonwealth." Archiv für Sozialwissenschaften.

Noble, Safiya Umoja(2018). Algorithms of Oppression: How Search Engines Reinforce Racism. New York University Press.

National Transportation Safety Board (2019). "Collision Between Vehicle

Controlled by Developmental Automated Driving System and Pedestrian, Tempe, Arizona, March 18, 2018," Highway Accident Report NTSB/HAR-19/03.

Noveck, Beth Simone(2015), Smart Citizens, Smarter State: The Technologies of Expertise and the Future of Governing. Harvard University Press.

O'Neil, Cathy(2016). Weapons of Math Destruction: How Big Data Increases Inequality and Threatens Democracy. Crown.

Office of the Privacy Commissioner of Canada (2021). "Joint investigation of Clearview AI.“

Rawls, J. (1971). "A Theory of Justice," Harvard University Press.

Ross, C. & Swetlitz, I. (2018). "IBM's Watson recommended 'unsafe and incorrect' cancer treatments, internal documents show," STAT News, July 25, 2018.

Russell, S. (2019). "Human Compatible: Artificial Intelligence and the Problem of Control," Viking Press.

Tang, Audrey(2024), "Alignment Assemblies Can Enable Us to Govern AI Collaboratively." Reboot Democracy Blog, https://rebootdemocracy.ai/blog/audrey-tang-ai-democracy/

The White House (2023). "Executive Order on Safe, Secure, and Trustworthy Artificial Intelligence.“

U.S. Copyright Office (2023). "Copyright Registration Guidance: Works Containing Material Generated by Artificial Intelligence," Federal Register, Vol. 88, No. 51.

U.S. Securities and Exchange Commission (2013). "In the Matter of Knight Capital Americas LLC," Administrative Proceeding File No. 3-15570, October 16, 2013.

Warren, S. & Brandeis, L. (1890). "The Right to Privacy," Harvard Law Review, 4(5), 193220.

- 웹 사이트 -

https://aimatters.co.kr/news-report/ai-news/24124/

https://arxiv.org/abs/2507.09089

https://arxiv.org/abs/2508.15361
https://arxiv.org/pdf/2507.19703
https://fortune.com/2025/08/18/mit-report-95-percent-generative-ai-pilots-at-companies-failing-cfo/
https://huggingface.co/openai/gpt-oss-120b
https://iitp.kr/kr/1/knowledge/statisticsView.it?masterCode=publication&searClassCode=K_STAT_01&identifier=02-008-250502-000001
https://jonathan-hui.medium.com/monte-carlo-tree-search-mcts-in-alphago-zero-8a403588276a
https://learnyourway.withgoogle.com/
https://levelup.gitconnected.com/vibe-coding-as-a-coding-veteran-cd370fe2be50
https://medium.com/%40abhishekjainindore24/all-about-convolutions-kernels-features-in-cnn-c656616390a1
https://medium.com/%40sumbatilinda/deep-learning-part-3-convolution-neural-networks-cnns-acd07bfeb6a1
https://medium.com/applied-data-science/alphago-zero-explained-in-one-diagram-365f5abf67e0
https://m.youtube.com/watch?v=PqVbypvxDto&fbclid=IwVERDUAOyExNleHRuA2FlbQIxMABzcnRjBmFwcF9pZAwzNTA2ODU1MzE3MjgAAR6IzzagQiaKHozB-CaAjziOe729XjUVunK51C1_58F93CwV5UDUOmsJZrUI_Q_aem_F6V410upPAssbE438BGybg
https://openai.com/index/introducing-gpt-oss
https://ravivaishnav20.medium.com/visualizing-feature-maps-using-pytorch-12a48cd1e573
https://spri.kr/download/23630
https://spri.kr/posts/view/23722?code=data_all&study_type=research
https://www.aitimes.com/news/articleView.html?idxno=159449
https://www.aitimes.com/news/articleView.html?idxno=166815
https://www.index.go.kr/unity/potal/main/EachDtlPageDetail.do?idx_cd=1182
https://www.nature.com/articles/s41586-025-09922-y
https://www.researchgate.net/figure/mage-of-Abraham-Lincoln-as-a-matrix-of-pixel-values_fig1_330902210

https://www.science.org/doi/abs/10.1126/science.adw3000
https://www.techm.kr/news/articleView.html?idxno=4174
https://www.youtube.com/live/pV328QYZJiw?si=gz5DdLiY8N_r9wPU
https://www.youtube.com/watch?v=B42vKq1oGUM
https://www.youtube.com/watch?v=DqjsRpe2rxI&start=5
https://www.youtube.com/watch?v=L3OvFcSjXRg
https://www.youtube.com/watch?v=fQGu016AlVo&t=8s
https://www.youtube.com/watch?v=qbhK-dBOhTU
https://youtube.com/watch?v=8kM-JcKpcDs&si=YS6vY8ZP6cCutVXH
https://youtu.be/DHGqBCc-IDs?si=wiYP9izBSym7BksB
https://youtu.be/DW16O6UWtSc
https://youtu.be/LJJXrjgPOR8?si=oBI8GTAITltC43k0
https://youtu.be/iTypFtxogNQ?si=yLYCHHSsAI0GbOqs
https://youtu.be/mLHTyEwmyAY?si=E_q29DHp6sEE3GWm
https://youtu.be/mU1LCazDCg8?si=4q_y47mLeEUqXmUu
https://youtu.be/n4RjJKxsamQ?si=gmJ0MmltFswBfbpZ
https://youtu.be/vryB4AjI7Kk?si=ej_yk8Q3Wes7ECyL
https://youtu.be/yYMqI1A4jrQ

끝.